

기본연구 25-09

AI 시대 데이터센터 증가의 국내 에너지 소비 시사점

김철현·김성균



에너지경제연구원
Korea Energy Economics Institute

AI시대 데이터센터 증가의 국내 에너지 소비 시사점

Implications for Korea's Energy Consumption
from the Increase in Data Centers in the AI Era

김철현 · 김성균

저 자 김철현, 김성균

연구진

연구책임자 김철현(에너지경제연구원 선임연구위원)
김성균(에너지경제연구원 연구위원)

연구참여자 이성재(에너지경제연구원 부연구위원)

목 차

요약	xi
제1장 서론	1
1. 연구 배경	1
2. 연구 필요성 및 목적	2
3. 보고서의 구성	2
제2장 데이터센터와 에너지 소비	7
1. 데이터센터(DC)의 구조와 에너지 소비	7
1.1. DC의 정의 및 인프라 구조	7
1.1.1. 정의	7
1.1.2. 인프라 구조	8
1.2. DC의 분류 및 유형	12
1.2.1. 규모에 따른 분류	12
1.2.2. 티어 분류	13
1.2.3. 소유 형태 및 서비스 제공 방식에 따른 분류	14
1.2.4. 엣지 데이터센터	16
1.2.5. 모듈러 데이터센터	17
1.2.6. AI 데이터센터	17
1.3. DC 유형별 에너지 소비	18
1.4. DC의 부하패턴	21
2. 글로벌 데이터센터의 전기 소비	23
2.1. DC 에너지 소비 추정 방법론	23
2.2. 데이터센터 에너지 소비 추정의 품질 평가	26
2.3. 글로벌 DC 에너지 소비 동향 및 전망	27
2.3.1. 글로벌	27
2.3.2. 미국	31
2.3.3. 중국	33

2.3.4. 유럽	34
3. 인공지능(AI)과 에너지 소비	37
3.1. AI의 종류 및 발전 단계	37
3.1.1. 기술기반 AI 분류	37
3.1.2. AI의 발전단계	38
3.2. 인공지능 연산방식과 에너지 소비	40
3.2.1. 학습과 추론	41
3.2.2. 학습과 추론의 전기 소비 특성 차이	44
3.2.3. 학습과 추론의 GPU 이용률 및 에너지효율	47
3.2.4. AI 시대 DC 에너지 소비 영향 요인	48
3.2.5. 추론 작업 유형별 전기 소비	54
4. 데이터센터(DC)의 에너지 성과	56
4.1. 에너지 성과 지표	56
4.1.1. 전력효율지수(PUE)	56
4.1.2. PUE 외 주요 성과 지표	58
4.2. 글로벌 PUE 및 냉방용 에너지 소비	61
4.2.1. 글로벌 PUE 추이 및 전망	61
4.2.2. PUE와 냉방용 에너지 소비	62
4.2.3. DC 규모별, 유형별 PUE	63
4.3. DC 에너지효율 영향 요인	65
4.3.1. IT 장비	65
4.3.2. DC 인프라	68
4.3.3. DC 설계, 운영, 관리	69
4.4. DC 에너지효율 개선 정책 효과	70
5. 소결	72
5.1. 데이터센터 전기 소비 증감 요인	72
5.2. 에너지 소비 외 생각해볼 점	76

제3장 국내 데이터센터 전력 소비 실증 분석 81

1. 국내 데이터센터 현황	81
1.1. 데이터센터의 정의	81
1.2. 주요 현황	84

2. 국내 데이터센터 전력 수요 분석	89
2.1. 국내 DC 전력 소비 월간 패턴(계절성) 분석	90
2.1.1. DC 샘플 자료	90
2.1.2. 샘플 DC의 전력 소비 추이, 분포, 계절성	91
2.1.3. STL 분해를 통한 계절성 분석(분산 측면 및 절대적 변동 폭 측면)	97
2.2. 국내 AI 데이터센터의 에너지 소비 추정 사례(울산 AIDC)	101
2.3. 국내 데이터센터 전기 소비 및 전망	108
2.3.1. 모형 설정 및 기준 전망	108
2.3.2. 시나리오 전망 및 국제 비교	116
2.3.3. PUE 개선에 따른 절감 잠재량 분석	120
3. 데이터센터 증가에 따른 국내 에너지 소비 시사점	123
3.1. 국가 전력 통계 및 전기 소비 추세	123
3.1.1. 국가 전력 통계	123
3.1.2. 국내 전력 소비 추세	125
3.2. 국내 전력 소비에의 시사점	126
3.3. 국내 데이터센터의 전력공급 방안	129
3.3.1. 발전원별 장단점	130
3.3.2. 건설 기간, 전력계통, 온실가스 배출 측면	136
3.3.3. 종합	140
3.4. 국가 전체 에너지 소비에의 시사점	140

제4장 데이터센터 관련 정책 및 제언 145

1. 에너지 소비 관련 글로벌 DC 정책	145
1.1. 유럽연합(EU)	146
1.2. 독일	149
1.3. 프랑스	152
1.4. 미국	152
1.4.1. 인증제도	153
1.4.2. 인프라 확장 정책	155
1.5. 중국	156
1.6. 일본	159
1.7. 싱가포르	161
2. 국내 데이터센터 관련 정책 현황	164

2.1. DC 에너지 소비 관련 정책	164
2.1.1. 에너지이용합리화법	165
2.1.2. 전기사업법	165
2.1.3. 분산에너지법	166
2.1.4. 녹색건축물 조성 지원법	168
2.2. 국내 데이터센터 정책 방향 및 인증제도	170
3. 국내 데이터센터 관련 정책 제안	171
3.1. 분류 기준 및 체계 마련	171
3.2. 정보 수집 및 보고 체계 마련	174
3.3. 에너지효율 개선 정책 마련	175
3.4. 에너지 성과 달성 지원	177
3.5. 적극적인 전력망 참여 지원	177
3.6. 균형있고 안정적인 분산	179

제5장 결론 181

1. 주요 결과 요약	181
1.1. 제2장: 데이터센터의 에너지 소비와 불확실성	181
1.2. 제3장: 국내 DC 전력 소비 전망 및 에너지 소비 영향	184
1.3. 제4장: 주요국 DC 관련 정책 현황 및 국내 정책 제안	189
2. 맺음말	193

참고문헌 197

부록 219

1. AI 기술 발전과 에너지 수요의 관계	226
1.1. AI 시스템의 에너지 수요	226
1.2. AI 매개변수와 학습 데이터 규모의 기하급수적 증가 원인	232
2. AI 전환의 현재와 미래	234
2.1. 과학 분야: 과학 연구 방법의 전환	234
2.2. 의료 분야: 인간 생명과 건강의 재정의	237
2.3. 산업 분야: 경쟁력의 근본적인 재편	239

표 목차

〈표 2-1〉	글로벌 데이터센터의 백업 발전기 타입	11
〈표 2-2〉	데이터센터 티어(Tier) 분류	13
〈표 2-3〉	클라우드 vs. 코로케이션 vs. 호스팅 DC	15
〈표 2-4〉	데이터센터 유형별 용도별 전기 소비 비중	20
〈표 2-5〉	데이터센터 에너지 소비 추정 방법론 비교	25
〈표 2-6〉	IEA의 지역별 데이터센터 전력 소비량 추정과 전망	36
〈표 2-7〉	AI 발전 단계	39
〈표 2-8〉	AI 핵심 역량 및 현 수준	39
〈표 2-9〉	AI 학습(훈련) vs. 추론	42
〈표 2-10〉	AI 학습(훈련) vs. 추론 전력 소비 특성	48
〈표 2-11〉	학습 관련 에너지 요소의 증가세 비교	49
〈표 2-12〉	추론 작업 유형별 전기 소비	55
〈표 2-13〉	국제표준(ISO/IEC)에서 정의된 데이터센터의 주요성과지표(KPI)	59
〈표 2-14〉	글로벌 데이터센터 유형별 PUE	63
〈표 2-15〉	데이터센터의 냉각 기술 및 에너지 절감	68
〈표 2-16〉	정책 시나리오별 유럽 데이터센터 에너지 절감 효과	71
〈표 2-17〉	전체 데이터센터 에너지 소비에서의 AI 비중	74
〈표 3-1〉	국내 데이터센터 면적 기준 규모별 비중	87
〈표 3-2〉	국내 데이터센터 업력별 수전용량별 비중	87
〈표 3-3〉	국내 데이터센터 상면 가동률 현황	89
〈표 3-4〉	클러스터별 월 평균 전기 소비량(GWh)	96
〈표 3-5〉	계절성에 따른 전력 수요 변동 폭(GWh)	100
〈표 3-6〉	시나리오별 울산 AIDC 에너지 소비	107
〈표 3-7〉	기준 전망의 주요 전제	114
〈표 3-8〉	기준 전망 결과	115
〈표 3-9〉	고성장(AI 가속) 시나리오 전망	117
〈표 3-10〉	데이터센터의 전력 수요 전망 비교(글로벌 vs. 국내)	120

〈표 3-11〉 절감 잠재량(TWh) 및 절감률(%)	123
〈표 3-12〉 부문별 전력 소비(간이 밸런스 vs. 확장 밸런스)	124
〈표 3-13〉 산업용과 상업·공공용 전력 소비 차이 추정	127
〈표 3-14〉 석탄 발전 방식 전력공급의 SWOT 분석	130
〈표 3-15〉 가스 발전 방식 전력공급의 SWOT 분석	131
〈표 3-16〉 SMR발전 방식 전력공급의 SWOT 분석	133
〈표 3-17〉 재생에너지 발전 방식 전력공급의 SWOT 분석	134
〈표 3-18〉 연료전지 발전 방식 전력공급의 SWOT 분석	135
〈표 3-19〉 전력 공급원별 건설 기간, LCOE, 출력조절 가능성	136
〈표 4-1〉 데이터센터 정책 카테고리별 채택 국가	146
〈표 4-2〉 EU 규정에 따라 보고해야 하는 핵심 성능 지표	148
〈표 4-3〉 EU 규정에 따라 보고해야 하는 데이터센터 정보	149
〈표 4-4〉 독일, 보고 의무 데이터센터 정보	151
〈표 4-5〉 일본 ‘DC업 정기 보고서’ 보고 항목	161
〈표 4-6〉 전력계통영향 평가 항목 및 배점	167
〈표 4-7〉 제로에너지건축물(ZEB) 인증 등급	169
〈표 4-8〉 국내 데이터센터 에너지 관련 법	169
〈표 5-1〉 국내 DC 전력 소비 전망 및 절감 잠재량	187
〈표 5-2〉 주요국 데이터센터 PUE 규제	190
〈표 5-3〉 주요국 정보 보고 대상 데이터센터	191
〈표 부록-1〉 주요 AI 모델 전력 소비 및 특성 비교	219
〈표 부록-2〉 LEED BD+C 기준 크레딧 항목 및 점수	220
〈표 부록-3〉 미국 주별 데이터센터 투자 인센티브	222
〈표 부록-4〉 트랜스포머 주요 연산별 계산 복잡도 및 에너지 소비 기여도	230
〈표 부록-5〉 AI 기반 주요 과학 기술 혁신 사례	236
〈표 부록-6〉 주요 산업별 AI 전환(AX) 현황 및 핵심 응용 사례	241

그림 목차

[그림 1-1]	제2장 구조	3
[그림 1-2]	제3장 구조	4
[그림 1-3]	제4장 구조	6
[그림 2-1]	데이터센터 인프라 구조	9
[그림 2-2]	랙 전력 부하에 따른 냉각 시스템 변화	12
[그림 2-3]	용도별 글로벌 데이터센터 보급 추이	16
[그림 2-4]	데이터센터 유형에 따른 용도별 전기 소비 비중	19
[그림 2-5]	데이터센터 유형에 따른 전기 소비 추이	20
[그림 2-6]	전세계 데이터센터 유형별 용량과 장비별 전력 소비 추이	21
[그림 2-7]	미국 데이터센터의 일일 평균 전력 부하 패턴(Flat vs. Mixed-use)	22
[그림 2-8]	Non-AI vs. AI 부하 패턴 비교	23
[그림 2-9]	시대별 데이터센터 에너지 소비 증가세	28
[그림 2-10]	주요 연구의 2022년 글로벌 데이터센터 전력 소비 추정 결과 비교	29
[그림 2-11]	2023년 전세계 데이터센터 전력 소비 추정 결과 비교	30
[그림 2-12]	IEA의 시나리오별 전세계 데이터센터 전력 수요 전망	31
[그림 2-13]	미국 데이터 센터의 총 전력 사용량(2014~2028)	32
[그림 2-14]	중국 데이터 센터의 전력 사용량 추정 결과 비교(2015~2030)	34
[그림 2-15]	EU의 데이터센터 전력 수요 추정과 전망 결과 비교(2010~2030)	35
[그림 2-16]	기술기반 AI 분류	38
[그림 2-17]	머신 러닝 개발 단계별 에너지 비중(%)	43
[그림 2-18]	AI 연산의 GPU와 CPU 전력 소비 특징	44
[그림 2-19]	훈련 부하 패턴	45
[그림 2-20]	다양한 추론 모델 별 GPU 전기 소비 패턴	46
[그림 2-21]	주요 AI 모델의 학습 파라미터 수, 데이터 사이즈, 시간 추이	50
[그림 2-22]	주요 AI 모델 학습의 전기 소비 추이	51
[그림 2-23]	글로벌 평균 PUE	62
[그림 2-24]	PUE와 데이터센터 총 전기에서의 냉방용 비중 관계	63

[그림 2-25] EU 데이터센터 규모별, 유형별 평균 PUE	64
[그림 2-26] 최신 슈퍼컴퓨터의 와트(Watt)당 연산량(Gigaflop)	66
[그림 2-27] 주요 AI 칩 서버의 최대 전력 요구량과 계산 속도	66
[그림 2-28] 데이터센터 에너지효율 영향 요인	70
[그림 2-29] 정책 시나리오별 글로벌 데이터센터 에너지 절감 효과	72
[그림 2-30] 데이터센터의 전기 소비 증감 요인	73
[그림 2-31] 데이터센터의 에너지 소비 증감 요인 정리	78
[그림 3-1] 국내 데이터센터 증감 추이(2000~2024)	84
[그림 3-2] 국내 지역별 데이터센터 분포 현황(2024년)	88
[그림 3-3] 국내 주요 데이터센터별 전력 소비 추이	92
[그림 3-4] 주요 데이터센터별 연간(2023.10~2024.9) 전력 소비 분포	93
[그림 3-5] 데이터센터별 월평균 전력 소비 패턴	94
[그림 3-6] 계절성 강도별 군집(클러스터) 분석 결과	95
[그림 3-7] 클러스터별 월평균 전기 소비 분포	96
[그림 3-8] DC1의 STL 분해 분석	97
[그림 3-9] DC4의 STL 분해 분석	98
[그림 3-10] 데이터센터별 계절성 분산 비중	99
[그림 3-11] 데이터센터별 계절성에 따른 전력 수요 변동 폭	100
[그림 3-12] 클러스터별 계절성에 따른 전력 수요 변동 폭	100
[그림 3-13] 주요 AI 반도체의 TDP(Thermal Design Power)	103
[그림 3-14] 주목할 만한 글로벌 AI 모델의 하드웨어 이용률	105
[그림 3-15] 울산 AIDC의 연간 전력 소비(GWh) 시나리오	106
[그림 3-16] 데이터센터 수 전제	109
[그림 3-17] 규모별 비중 전제	110
[그림 3-18] 수전용량(규모별 평균 및 총용량) 전제	111
[그림 3-19] 이용률(수전용량 기준) 전제	112
[그림 3-20] PUE 전제	113
[그림 3-21] 국내 데이터센터의 전기 소비 전망(BAU)	116
[그림 3-22] 기준 전망 vs. 가속 시나리오(데이터센터 수, 수전용량, 전기소비)	118
[그림 3-23] PUE 정책 목표 설정	121
[그림 3-24] PUE 개선 절감 잠재량	122

[그림 3-25] 데이터센터 규모별 절감률(%)	123
[그림 3-26] 국내 전기 소비 추이 및 기간별 연평균 증가율	126
[그림 3-27] 국내 데이터센터 냉방용 전기 소비 및 비중	128
[그림 3-28] 원자력+신재생기타, 석탄 발전량 및 석탄 발전 설비 이용률	137
[그림 3-29] 2038년 지역별 잉여 무탄소 용량	139
[그림 3-30] 산업용 도시가스와 LNG 민간 직수입	142
[그림 4-1] 중국 8대 국가 데이터센터 허브(거점)	158
[그림 4-2] 싱가포르 그린 마크 인증(GMDC)의 최소 PUE 기준	163
[그림 4-3] 계약종별 전기 요금 추이	173
[그림 5-1] 카테고리별 주요 정책 제안	193
[그림 부록-1] 트랜스포머 모델의 아키텍처	227
[그림 부록-2] 주요 거대언어모델의 매개변수 수 변화 추이	233

요약

1. 연구의 필요성 및 목적

- 전세계적으로 AI 시대 데이터센터(DC)의 에너지 소비가 주요 정책 이슈 중 하나이나, 국내 DC의 에너지 소비에 관한 연구와 관련 정책은 미흡한 상황임
 - 주요국을 중심으로 AI 시대 데이터센터의 에너지 소비 연구가 활발하게 이뤄지고 있으나, 국내 데이터센터의 에너지 소비 관련 연구는 없음
 - 정부는 AI 3대 강국으로의 도약을 국가 최상위 목표로 설정하고 다양한 정책들을 추진하고 있으나, DC 에너지 소비 관련 정책은 미흡함
 - 데이터센터가 국가 에너지 소비에 중요한 요소로 부상하고 있는 시기에, 국내 DC의 에너지 소비에 대한 연구와 정책에 대한 검토가 필요함
- 본 연구의 목적은 기존 연구 정리, 실증분석, 정책 시사점의 세 부분으로 구성됨
 - 첫째, DC 에너지 소비 관련 글로벌 연구에 대한 체계적 종합 정리 및 정확한 정보를 제공(2장)
 - 둘째, AI 시대 국내 DC 증가의 국내 에너지 소비에 대한 영향 분석(3장)
 - 셋째, 주요국의 DC 에너지 관련 정책 정리 및 국내 정책 수립 시 고려 사항에 대한 제언(4장)

2. 데이터센터와 에너지 소비

■ 데이터센터의 구조와 에너지 소비

- 데이터센터의 인프라 구조는 IT 부문과 비 IT 부문으로 구분할 수 있는데, IT와 비IT 부문의 에너지 소비 비율은 글로벌 평균 약 7:3 정도로 추정됨
 - IT 부문은 서버, 스토리지, 네트워크로 구성되며, 서버가 IT 부문 에너지 소비의 대부분(약 86%)을 차지함
 - 비IT 부문은 전력 시스템(무정전 전원 공급 장치, 배터리, 백업 발전기 등)과 냉각 시스템으로 구성되며, 냉각 시스템이 비IT 부문 에너지 소비의 64% 정도를 차지함
 - 글로벌 평균 DC 총 에너지 소비에서의 비중은 서버(61%), 냉각(18.5%)으로, 서버와 냉각이 전체 에너지의 약 80%를 점유함
- 데이터센터의 유형은 다양한 기준에 따라 나눌 수 있는데, 규모가 커질수록 에너지 소비가 증가하고 에너지효율은 상승함
 - DC는 규모, 티어(Tier), 소유 형태, 서비스 제공 방식 등에 따라 하이퍼스케일(Hyperscale), 자사용(Enterprise), 클라우드(Cloud), 코로케이션(Colocation), 엣지(Edge), 모듈러(Modular), AI데이터센터 등으로 분류됨
 - 최근 데이터센터의 에너지 소비는 대규모 하이퍼스케일 DC를 중심으로 증가하고 있는데, 일반적으로 규모가 커질수록 냉방용 에너지 소비 비중은 작아지며, 서버용의 비중은 커짐
- DC의 일간 부하패턴은 상주 인원의 여부에 따라 차이가 나며, AI 연산 여부에 따라 DC의 부하 변동성도 차이가 발생함
 - 사무실 등의 부대시설에 상주 인원이 많은 DC의 경우 근무시간에 부하가 상승하는 패턴을 보이며, 부대시설이 없는 경우는 하루 24시간 내내

부하가 일정하게 유지하는 패턴을 보임

- AI 데이터센터(AIDC)의 경우는 전력 소비 변동성 측면에서 기존 DC 대비 변동 폭이 큼

■ 글로벌 DC의 에너지 소비량 추정 및 전망

- DC의 에너지 소비량 추정 및 전망의 질은 이용 자료의 수준과 추정 방식에 따라 차이가 큼
 - 추정 방식은 크게 상향식, 총량 합산, 대리변수 외삽법, 혼합형으로 구분할 수 있는데, 상향식은 상대적으로 정확하나 자료 수집이 어렵고 대리변수 외삽법은 자료 수집이 상대적으로 용이하나 에너지 소비가 과대 평가되는 경향이 있음
 - 데이터센터의 에너지 소비 추정의 정확도를 높이기 위해서는 이용 자료의 데이터 품질이 가장 중요하며, 데이터의 투명성, 시나리오 또는 민감도 분석, 경제·기술·사회적 제약 고려 등도 중요한 요소임
- DC의 에너지 소비량에 대한 추정은 불확실성이 매우 큰데, IEA는 2024년 415TWh, 2030년 945TWh로 추정 및 전망함
 - 글로벌 DC의 에너지 소비량에 대한 기존 연구들을 종합하면, 2022년 추정치는 200~1,300TWh, 2023년 추정치는 200~2,000TWh로 연구에 따라 차이가 매우 큼
 - IEA는 2024년 기준 글로벌 DC의 에너지 소비량을 약 415TWh로 추정했으며, 이는 전세계 총 전력 소비의 약 1.5%에 달함
 - IEA는 DC의 전력 소비가 2024~2030년 기간 연평균 약 15%씩 증가해 2030년에는 945TWh에 도달할 것으로 전망했는데, 높은 불확실성을 반영해 시나리오에 따른 범위는 700~1,300TWh로 넓음

■ 인공지능의 에너지 소비

- AI 연산은 학습(훈련)과 추론으로 나눌 수 있는데, 학습은 한 번에 많은 에너지가 소비되나 일회성인데 반해, 추론은 건당 에너지 소비량은 작으나 반복적으로 수행되어 전체적으로는 추론에서의 에너지 소비가 학습보다 많음
 - 학습은 데이터를 통해 패턴을 학습하고 모델의 파라미터를 최적화하는 단계로, 에너지 소비가 크며 1회 수행 시 수주에서 수개월이 소요됨
 - 반면, 추론은 학습된 모델을 이용해 사용자의 요청을 수행하는 단계로, 단일 요청당 밀리초 수준의 짧은 시간이 걸림
 - 추론은 이용자 요청에 따라 수억~수조 번 반복되므로, 누적 에너지 소비 측면에서는 요청량에 따라 학습 대비 에너지 소비량이 훨씬 큼
- 단일 작업당 학습과 추론의 부하패턴을 비교하면, 평균적으로 학습은 추론 대비 에너지 소비와 변동성이 크며 에너지 효율적임
 - 학습은 부하가 GPU 최대 전력(TPU)의 최대치에 근접하며, 연산 집약적인 단계를 여러 GPU에서 번갈아 가며 수행하므로 전력 변동이 큼
 - 추론은 초기 시작 단계에서 전력이 급등하나 이후 안정적이고 낮은 부하 패턴을 보이며, 평균적으로 전력 소비는 TPU의 60~80% 수준임
 - GPU 이용률 측면에서 학습은 30~50% 수준, 추론은 10% 내외 수준이며, 이는 학습이 추론 대비 에너지 효율이 높음을 의미함. 달리 말하면, 추론은 에너지 효율 개선 여지가 큼
- 학습의 에너지 소비는 딥 러닝 시대(2010년 이후)에 들어서 연산량이 급속히 증가하며 빠르게 증가해 왔는데, 에너지 효율 증가로 연산량 증가세보다는 에너지 소비 증가세가 빠르지는 않았음
 - 학습 모델의 파라미터 수, 데이터 셋 사이즈, 훈련 시간이 2010년 이후 매년 각각 2.0배, 3.6배, 1.2배 증가하고 있으며, 이에 따라 학습의 연산량도 매년 4.6배씩 증가함

- 연산량 폭증으로 훈련에 소비된 전력 소비도 매년 1.7배씩 증가하였지만, 연산량 증가 대비 전력 소비 증가세는 크게 낮았음
- 학습과 추론의 에너지 소비는 배치 크기, 유틸 전력, AI 알고리즘에도 크게 영향을 받음
 - 배치 크기가 클수록 병렬 처리와 GPU 활용도(이용률)가 상승해 에너지 효율이 상승함
 - 학습의 경우 유틸 전력의 비중은 30% 이상인데, 유틸 전력을 줄이는 다양한 방법(가상화 기술, 하드웨어 및 소프트웨어 향상, AI 기반 최적화)이 연구되고 있음
 - 가지치기, 지식 증류, 양자화 같은 AI 알고리즘도 학습과 추론의 에너지 소비를 획기적으로 줄일 수 있는 것으로 조사됨
- 추론의 에너지 소비는 이용자의 요청(AI 수요)이 얼마가 될지에 달려 있어 전망의 불확실성이 더욱 큰데, 작업 유형별로도 에너지 소비에 차이가 커 불확실성이 가중됨
 - 가장 일반적인 텍스트 검색과 같은 추론 작업은 에너지 소비가 상대적으로 작음. 이미지 생성은 텍스트 생성보다 에너지 소비가 62배나 많음
 - “AI 검색당 전기 소비, 기존 구글 검색 대비 10배”라는 주장의 근거로 여러 연구에서 제시된 “구글 검색 0.3Wh 대 ChatGPT 2.9Wh”는 최신 정보와 보다 합리적인 가정 적용 시 과장된 것으로 조사됨
 - 최신 GPU와 일반적인 검색 수준의 입력과 출력량을 가정했을 때, ChatGPT 검색당 전력 소비는 0.3Wh로 추정됨
 - 전통적인 구글 검색의 전력 소비도 최신 정보 적용 시 기존 추정치보다 크게 낮아질 가능성이 있지만, 절대적 에너지 소비 측면에서 AI 검색의 에너지 소비량은 과장된 측면이 큼

■ 데이터센터의 에너지 성과

- PUE는 대표적인 데이터센터의 에너지 효율 지표이나, 여러 한계로 다른 보조 성과 지표와 함께 이용해야 함
 - PUE는 IT 장비의 전기 소비가 DC 총 전력 대비 얼마나 큰지를 나타내는 지표로서, 인프라 측면에서의 효율을 측정함
 - 단, PUE는 IT 장비의 효율, 폐열 활용, 재생에너지 사용 등을 반영하지 못한다는 단점이 있음
 - 정확한 DC의 에너지 성과 측정을 위해서는 PUE뿐만 아니라 다양한 성과 지표들을 함께 이용해야 함
- 특히, PUE는 DC의 설계, 기후 조건, 지리적 위치, 냉각 방식, DC 규모 등 여러 요소에 영향을 받기 때문에 DC 간 직접 비교 시에도 주의해야 함
 - PUE는 DC의 규모가 커질수록 작아(개선)지는데, IEA의 자료를 이용해 계산하면, 소형(자사용)은 1.92, 중형(코로케이션)은 1.53, 대형(하이퍼스케일)은 1.14 수준으로 추정됨
 - 2024년 기준 글로벌 평균 PUE는 1.4~1.5 수준으로 보고되고 있으며, 이에 따른 평균 냉방 부하의 비중은 19~24%로 계산됨
- 한편, 본 연구에서는 2023년 국내 전국 평균 PUE는 1.58, DC 총 전력 소비에서의 냉방용 전력의 비중은 약 17% 수준으로 추정함
- DC의 에너지 효율에 미치는 요인들은 다양한데, 본 연구에서는 이를 IT 장비 측면, DC 인프라 측면, 설계·운영·관리 측면으로 정리함
 - IT 장비의 효율은 하드웨어 혁신을 통해 지속해서 향상되어 오고 있으며, 이에 따라 서버의 전력 소비당 연산량도 급속하게 증가함. 또한, 서버통합, 컨테이너화, 서버리스 컴퓨팅 등의 기술로 IT 장비의 이용률을 높이는 것도 IT 장비의 에너지 효율을 크게 향상시킴

- 인프라 측면의 효율 요인은 주로 PUE 개선과 관련됨. 특히, 냉방용 에너지 소비 감소를 위한 기술들이 개발되고 있음. 공랭식+수냉식 냉각 방식은 기존 공랭식 대비 에너지 소비를 절반 정도 줄이는 것으로 보고되고 있음
 - 전력 관리 설계, 데이터센터의 티어 등급, 폐열 재활용 및 재생에너지 활용, 에너지 관리 시스템 설치, 워크로드 및 자원 관리 최적화 등을 통해서도 DC의 에너지 효율을 크게 향상시킬 수 있음
- 주요 연구에 따르면 DC의 에너지 효율 개선을 위한 정책 중 가장 효과가 큰 정책은 PUE로 조사됨
- DC의 에너지 효율 개선을 위해 주요국들은 여러 정책들을 시행 중인데, 여기에는 PUE 개선, 클라우드로의 전환, 장비 이용률 상승, 서버 효율 향상, 서버 사용률이 낮은 시간대에 장비 가동 중지 등이 있음
 - 유럽과 글로벌 DC 효율 정책 효과를 분석한 연구들에 따르면, 이러한 정책 중 PUE 개선(하락) 정책에 의한 에너지 절감량이 전체 절감의 50% 이상을 차지하여 효과가 가장 큰 것으로 나타남

3. 국내 데이터센터 전력 소비 실증 분석

■ 국내 데이터센터 현황

- 국내 데이터센터의 수는 2024년 기준 165개소로 조사되었으며, 전체 DC의 약 60.4%가 수도권(서울, 경기, 인천 등)에 위치함
- 한국데이터센터연합회(KDCC)에 따르면, 국내 DC 수는 2000~2020년 연평균 5.6%로 증가했으나, 2020~2024년 기간에는 증가세가 1.0% 수준으로 둔화됨
 - 이러한 최근의 추세 둔화는 과거 명확한 분류 기준에 따라 분류되지 못

- 하고 500m² 이하 소규모 DC 등이 포함되면서 발생한 것으로 추측됨
- DC의 수도권 집중화는 민간 DC에서 더 심하게 나타남. 2024년 기준 민간 DC의 약 75.3%가 수도권에 집중됨

■ 국내 DC의 월간 부하 패턴(계절성) 분석

- 국내 데이터센터 중 주요 25개 DC에 대한 월간 전력 소비량 자료를 분석한 결과, 국내 DC의 연간 전력 소비량은 대부분 30GWh 이하일 것으로 판단됨
 - 국토부의 건물에너지 정보에서 25개의 DC가 속한 건물의 월간 전력 소비량(2016.3~2024.9)을 추출해 분석함
 - 국내 주요 통신사 및 인터넷 사업자가 운영하는 DC를 중심으로 개별적으로 수집한 주소를 매칭하여 DC를 식별하였으나, 수집한 주소에 해당하는 모든 DC가 국토부 자료에 존재하지는 않았음
 - 선정된 DC는 대부분 국제 기준상 대형 이상의 DC로 판단되며, 국토부 자료의 성격상 건물 전체가 DC가 아니라면 전력 소비량이 과대 추정되는 한계가 존재함
 - 샘플 DC 중 연간 전력 소비량이 100GWh 이상인 곳은 8개였으며, 나머지는 모두 연간 50GWh 미만으로 나타남. 샘플의 성격과 자료의 한계를 고려하면, 샘플에 포함되지 않은 대부분 국내 DC의 전력 소비량은 연간 30GWh 이하일 것으로 판단됨
- 대부분의 DC에서 계절성이 부하 변동의 주요 요인으로 분석되었으나, 계절에 따른 전력 소비 변동 폭은 몇몇 대규모 DC를 제외하곤 크지 않았음
 - 대부분의 샘플에서 여름에 전력 부하가 상승하는 계절성을 보임
 - STL 분석을 이용해 소비량을 추세와 계절성 부분으로 분해하고 여기에 클러스터 분석을 적용해 계절성을 절대적 부하 변동 폭 측면과 변동성(분산) 측면으로 나누어 분석함

- 변동성 측면에서는 상당수의 DC에서 부하 변동은 주로 계절성에 기인하는 것으로 나타남. 과반수 이상의 샘플 DC에서 연중 부하 변동의 20% 이상이 계절성 때문이었으며, 70% 이상도 4곳으로 나타남
- 절대적 부하 측면에서 계절에 따른 부하 변동 폭은 연간 140GWh 이상의 초대형 DC를 제외한 대부분의 DC에서는 변동 폭이 작았음. 초대형 DC는 여름에 최대 0.75GWh까지 전력이 상승하는 것으로 나타남

■ 울산 AIDC 에너지 소비 추정


- 울산 AIDC 가동 시 가장 현실적인 가정에서 연간 전력 소비는 213GWh로 추정되며, 전력 소비 전량을 자가발전으로 충당한다면 울산의 상업용 천연가스 민간 직수입이 연간 3만톤 가량 증가할 것으로 추정됨
 - 총 6만 개의 칩이 설치된다는 가정하에, 칩의 TDP(최대전력), GPU 이용률, PUE 등에 대한 범위를 설정하여 울산 AIDC 건설 시 전력 소비의 최소와 최대 수준을 추정함
 - 연간 전력 소비는 최소 32.5GWh, 최대 718.2GWh로 추정되었으며, 가장 현실적인 전제하의 소비량은 213GWh 수준으로 분석됨
 - 한편, AIDC의 전력은 SK 멀티 유틸리티가 건설하는 LNG 열병합 상용 자가발전소로 충당되며, 발전 연료인 LNG는 민간 직수입 물량임
 - 열병합발전소의 발전 효율이 45%라는 가정하에, LNG 소비량 범위는 0.5~11만 톤 수준이며, 현실적인 전제하에서는 약 3만 톤으로 추정됨

■ 국내 DC 전력 소비 추정 및 전망

- 2023~2060년 국내 DC의 전력 수요는 기준 전망과 시나리오 전망에서 각각 연평균 7.2%, 9.3% 증가해 2060년 65TWh, 135TWh에 도달할 것으로 전망됨
 - 국내 DC를 규모별로 소형, 중형, 대형으로 나누고, DC 수, 수전용량, 이용률(수전용량 기준), PUE 전제를 이용해 2060년까지 국내 DC의 전

력 소비량을 전망함

- 2023년 전력 소비량은 제11차 전기본의 수치(5TWh)를 준용하여 설정되었으며, 이는 국내 총 전력 소비의 0.9%에 달하는 수준임
- 기준 전망 결과 국내 DC의 총 전력 수요는 2023년 5TWh에서 전망 기간 연평균 7.2%로 증가해 2060년에는 약 65TWh 정도로 전망됨
- DC의 수가 기준 전망 대비 2배 증가하는 AI 가속 시나리오에서 국내 DC 총 전력 수요는 전망 기간 중 연평균 9.3%로 증가해 2060년에는 135TWh에 달할 것으로 전망됨
- DC 규모별로는 AI 시대가 도래하는 2030년대 중반까지는 상대적으로 규모가 큰 데이터센터를 중심으로, AI 시대가 정착한 2040년 이후에는 소형 데이터센터를 중심으로 전기 소비가 증가할 것으로 예상됨
- 이러한 전망 결과는 글로벌 DC의 전력 수요 전망과 비교했을 때 합리적인 범위인 것으로 판단됨



- PUE 개선 정책에 따른 잠재 전력 절감량을 추정했을 때, PUE 개선 정책 효과는 정책이 최대한 빨리 실시될수록, 대형보다는 소형 DC를 중심으로, 신규보다는 기존 DC를 중심으로 실시될수록 큰 것으로 분석됨
 - 주요국 수준의 PUE 절감 정책이 실시될 경우, 기준 전망과 가속 시나리오에서의 최대 잠재 절감량을 분석함

- PUE 개선 정책으로 2023년 1.6 수준의 국내 평균 PUE가 향후 10년 내 빠르게 개선되어, 2030년에는 1.2 수준, 2030년대 중반 이후에는 1.1 이하로 하락한다고 가정함
- 이 경우 2030년 중반 이후 기준 전망에서는 DC 전력 수요가 약 18% 내외, 가속 시나리오에서는 약 16~17% 수준으로 절감될 수 있는 것으로 추정됨
- 가속 시나리오에서의 절감률이 기준 전망보다 낮은 것은, AI 가속화로 전기 소비가 예상보다 빠르게 증가할 경우 PUE 개선 정책 외에 추가적인 에너지 절감 정책이 필요함을 의미함
- 2040년 이후 PUE 개선 여지는 거의 없어지나 절감량은 누적효과로 지속해서 증가하며, 이는 PUE 규제 정책을 빨리 추진할수록 효과가 큼을 의미함
- DC 규모별로는 규모가 작은 DC일수록 절감률이 큰 것으로 나타났는데, 이는 PUE 규제 정책에서 소형 DC의 PUE 개선이 중요함을 시사함
- 또한, 절감률 상승 효과를 높이기 위해서는 신규 DC뿐만 아니라, 기존 DC의 PUE 개선이 매우 중요한 것으로 나타남

■ 데이터센터 증가에 따른 국내 시사점

- DC 증가에 따른 전력 소비 증가는 산업용과 상업·공공용 전력 소비 격차를 지속해서 축소시키고, 건물용 전력 소비가 산업용을 지속 추월하는 주요 원인 중 하나로 작용할 것으로 예상됨
 - DC 전력 소비 증가로 2040년 이후에는 상업·공공 전력 소비가 산업용을 추월할 가능성이 있음
 - 2024년에 들어 처음으로 건물용(가정+상업·공공) 전력 소비가 산업용을 추월했는데, DC 전력 소비 증가 등으로 이러한 추세는 향후에도 지속될 것으로 보임

- 하지만, DC 증가로 인한 전력 소비 증가는 국내 전력 수요 추세, 산업 구조 변화 등을 고려할 때 단기적으로는 크게 우려할 만한 수준은 아닌 것으로 분석됨
 - 국내 전력 수요 증가 추세는 경제 및 인구 구조 변화, 상용자가발전 증가, 수출 구조 변화 등으로 2011년경에 크게 둔화했으며, 최근에는 구조적 불황 등에 따른 전력 다소비 업종의 전력 소비 둔화가 심해짐
 - 기준 전망과 가속 시나리오의 전망을 고려할 때 DC 증가로 국내 전력 소비 추세가 다시 빨라질 것으로는 보이지 않음
 - 2023년 기준 국내 DC의 전력 소비는 국가 전체 전력 소비의 약 0.9%를 차지하며, 2038년 기준에서는 전기본 기준과 목표 수요 상 각각 4.1%, 4.8%를 차지함
- 단, DC 냉방 부하는 빠르게 증가할 것으로 예상되어, 이에 따른 전력 수급 안정에는 주의해야 함
 - 2023년 DC 냉방용 전력 소비는 DC 총 전력 소비의 17%(0.8GWh)로 추정됨
 - DC의 냉방용 전력 소비 비중은 PUE 개선에 따라 2060년에는 13% 수준으로 점차 낮아질 것으로 보이나, 냉방용 전력 소비량 자체는 급격하게 증가할 것으로 예상됨
 - 기준 전망에서 냉방용 전력 소비는 2023년 대비 2030년에는 약 2배, 2040년 5배, 2050년 8배, 2060년 10배로 증가할 것으로 전망됨
 - 특히, 냉방용 전력 소비 절감을 위해서는 개선의 여지가 상대적으로 높은 소형 DC에 집중해야 하며, 수요반응(DR) 자원으로서의 역할도 소형 DC에서 중요함을 시사함
- 국내 DC 전력공급원으로는 재생에너지와 원자력 발전이 모든 기간에 걸쳐 중요하나, 중단기적으로는 가스 발전이 가장 현실적으로 분석됨

- 석탄 발전은 중단기적으로는 송전선로 부족으로 발전 제한된 동해안의 발전소를 이용하는 선택지가 있지만, 탄소배출 측면에서는 매력이 낮음
 - 원자력 발전은 송전제약 문제가 심각한 동해안 지역에 DC가 입지한다면 중단기적으로 활용도가 높으며, 장기적으로도 계속 운전으로 DC 전력공급에 중요한 역할을 할 수 있음
 - SMR은 여러 장점이 있지만, 아직까지 상용화되지 못한 기술로서 건설 기간 및 비용, 관련 제도 등에서 불확실성이 매우 크며, 주민 수용성이 큰 걸림돌임. 장기적으로 기술이 상용화되고 기존 원자력 부지나 폐석탄 발전소 부지를 활용한다면 DC 전력공급원으로 큰 역할이 가능할 것으로 보임
 - 가스 발전은 타발전원 대비 상대적으로 주민 수용성 문제가 크지 않고, 발전소 건설 기간, 온실가스 배출 측면에서도 상대적으로 강점이 있음. 특히, 배터리를 제외하면 DC의 빠른 응답력 요구에 대응할 수 있는 유일한 전력공급원임. 단, 온실가스 배출로 장기적으로는 매력적인 선택지는 아님
 - 재생에너지 발전은 간헐성과 불확실성으로 DC의 전력을 전담하기는 불가능함. 재생에너지를 DC에 이용하기 위해서는 전통적인 발전원(기존 전력망)에 재생발전+에너지저장장치(BESS)와 같은 혼합형이 되어야 함
 - 연료전지 발전은 여러 장점이 있지만, 높은 초기 투자 비용과 수소 충전 인프라 부족이 가장 큰 제약임. 기술 발달로 비용이 하락한다면 중장기적으로 석유화학 단지가 위치한 지역을 중심으로 DC 전력공급의 주요 선택지가 될 수 있을 것으로 보임
- 국내 DC 입지는 송전선로 제약과 잉여 무탄소 발전 용량을 고려할 때 수도권과 충청권을 제외한 나머지 지역이 현실적임
- 수도권은 이미 많은 DC가 집중되어 있고, 수도권 송전선로 부족 등을 고려할 때 향후 DC 입지로서 비용이 큼. 중단기적으로 잉여 무탄소 용

량을 고려할 때 수도권과 충청권은 타 지역 대비 불리함. 단, 충청권은 대산 석유화학 단지를 활용한 연료전지가 선택지가 될 수 있음

- 호남 지역은 전통 발전원+재생발전+에너지저장장치가 강점이며, 중장기적으로는 여수 석유화학 단지의 부생수소를 이용한 연료전지도 가능
- 영남 지역은 재생에너지 발전뿐만 아니라 원자력 발전이 DC의 전력 공급원으로 주요하며, 중장기적으로는 원자력 계속운전과 SMR이 큰 역할을 할 수 있음. 울산 석유화학단지를 활용한 연료전지도 중장기적으로 가능함
- 강원 지역은 원자력 발전이 주요한 옵션이며 풍력 및 태양광을 활용한 재생에너지 발전도 가능함. 중장기적으로 원전 계속운전과 SMR이 중요한 역할을 할 것으로 보임

○ DC 증가로 전기 소비(한전의 전력 판매량)의 변동성 확대와 천연가스 민간 직수입 증가가 예상되어 이에 대한 정부의 대책 마련이 필요함

- 중단기적으로 LNG 상용자가발전이 국내 DC의 주요 전력 공급원으로 역할을 할 것으로 보임
- 특히, DC가 산업단지에 입지하는 경우 DC의 LNG 자가발전이 인근 수요지에 판매되며 연쇄효과로 실제 DC에 소비되는 전력 소비보다 훨씬 많은 LNG 자가발전이 이뤄질 가능성이 존재함
- 자가발전을 하는 사업체는 전력 시장 환경에 따라 자가발전량과 한전으로부터의 수전량을 자유롭게 조정할 수 있으므로 DC 증가로 한전의 판매량인 전력 소비 변동성이 확대될 수 있음
- 또한, DC 증가로 기존에는 거의 존재하지 않았던 상업용 천연가스 민간 직수입이 증가하여, 최근에 빠르게 증가해 온 천연가스 민간 직수입이 정부의 예상보다 더 빠르게 증가할 수 있음

4. 데이터센터 관련 정책 및 제안

■ 에너지 소비 관련 글로벌 DC 정책

- 유럽연합(EU)은 에너지효율 관리지침(EED)을 통해 DC 규제 체계를 구축했으며, 이에 따라 EU 회원국들은 지침의 내용을 국내법에 포함해야 함
 - 지침에 따르면 IT 전력 수요 500kW 이상의 DC 운영자는 DC의 에너지 소비 정보를 의무적으로 정기 보고해야 함
 - 보고 항목은 DC 정보, 에너지 및 지속가능성 지표, ICT 용량 지표, 데이터 트래픽 지표로 구성되며, 카테고리별로 상세한 정보가 포함됨
- 독일은 에너지효율법(EnEfG)을 통해, 프랑스는 DDADUE 법을 통해 EU의 EED를 국내법에 반영함
 - 기존 및 신규 DC에 대해 달성해야 하는 PUE가 규정되었으며, DC의 폐열을 다시 포집하여 사용하는 재사용 에너지 비율을 규정함
 - 또한, EED에서 규정하지 않은 DC의 재생에너지 비중도 규정함. 규정에 따르면 DC 운영자는 2027년부터는 100% 재생에너지로 생산된 전력을 이용해야 함
 - EnEfG에서는 에너지 또는 환경 관리 시스템 구축을 의무화하고 있으며, 이 시스템을 외부 전문 기관을 통해 검증 또는 인증해야 함
 - 독일의 정기 보고 의무 대상 DC는 EED보다 강화된 200kW 이상의 DC에 대해 단계적으로 적용됨
 - 프랑스 DDADUE 법에서는 DC의 에너지 성과 향상을 위한 전용 프레임워크 구축, 에너지 성능 정보 공개 의무, 폐열 활용 의무 및 불이행 시 제재, 경제성 분석 의무 등을 포함함
- 미국은 트럼프 2기 들어 DC의 환경 규제를 크게 완화하고 AI 인프라 구축 및 확장에 집중하고 있음

- 유럽연합과 같은 DC 에너지 정보 보고 체계는 일부 주를 제외하고 아직 미비함. 캘리포니아 주에는 DC에 대한 PUE 보고와 개선 의무 규정이 존재하며, 뉴욕 주의 경우 보고 의무 규정 마련을 추진중임
 - 미국 정부는 주요국과는 달리 DC가 환경에 미치는 영향이 미미하다고 여기며, 이에 따라 DC 건설에 관련한 환경 규제는 대폭 축소하고 스타게이트 프로젝트를 통해 대규모 인프라 확장에 집중하고 있음
 - 단, 미국에는 정부 주도의 에너지효율 인증제도인 에너지스타와 민간 주도의 LEED 제도가 존재함
 - 에너지스타 인증제의 경우, 단순히 현재의 PUE가 아닌 DC별 요인들을 고려해 평균적으로 달성 가능한 수준 대비 실제 PUE가 얼마나 개선되었는지를 평가함
- 중국은 ‘동수서산’ 프로젝트를 통해 네트워크 요구가 높은 DC는 동부에, 실시간 요구사항이 높지 않은 DC는 대규모 풍력 및 태양광이 위치한 서부에 집중하고 있음
- 에너지효율 측면에서는 PUE 기준, 기존 DC 개조, 에너지 절약 기술 및 장비 보급에 대해 규정함. 또한, 전국 DC의 평균 재생에너지 이용률을 매년 10% 높이는 것을 정부 목표로 설정함
 - 중국 정부는 ‘녹색 데이터센터’ 표준을 통해 DC의 장비에 대해 규제하고 있으며, ‘국가 데이터센터 구축을 위한 가이드라인’ 제시를 통해 인프라 확장에 대한 계획을 발표함
- 일본은 에너지 합리화법과 벤치마크 제도 및 추가적인 신규 제도를 통해 DC의 정보 공개 및 에너지 효율 개선을 규정함
- 에너지 합리화법에 따라 연간 에너지 소비량에서 기준을 초과하는 DC는 에너지 소비량 정기 보고, 에너지원단위 개선, 증장기 계획서 제출 의무를 부과함

- 벤치마크 제도에 따라 DC 운영자는 매년 PUE를 정부에 보고하고 PUE 1.4 목표 달성을 위해 노력해야 함
 - 또한, 신설 DC의 PUE 목표 값, 2030년 평균 PUE 목표 값, 에너지원 단위 증장기 개선을 목표 값을 포함하는 계획서와 DC별 에너지 사용 현황을 담은 보고서도 정부에 제출해야 함. 보고서의 일부 항목은 웹사이트 등을 통해 대중에 공개해야 함
- 싱가포르는 정부 주도의 DC 신청제, 데이터센터 인증제(GMDC), 그린 데이터센터 로드맵 등을 통해 DC의 에너지 효율과 그린 에너지 사용을 규제함
- GMDC에서는 신규 DC에 대해 IT 부하에 따라 PUE 기준을 차별 적용하고 있는데, 냉각 시스템 효율 측정과 검증을 위한 장치 설치, PUE 계산과 관련된 모든 에너지의 측정 및 추이 분석, 실시간 PUE 제공 의무를 규정함
 - 싱가포르는 DC 관련 제도를 포괄하는 그린 데이터센터 로드맵에서 향후 컴퓨팅/IT 장비 에너지 효율 및 액체 냉각 표준을 도입하고, DC 운영체와 그린 에너지 공급업체 간의 파트너십을 장려함. 또한, 물 효율 관리 모범 사례 지침 제공 등으로 DC의 물 효율성도 중요하게 다룸

■ 국내 DC 정책 현황

- 국내의 경우 DC에 특정된 정책은 상대적으로 미비한데, 에너지 측면에서는 에너지이용합리화법, 전기사업법, 분산에너지 활성화 특별법, 녹색건축물 조성 지원법이 관련됨
- 에너지이용합리화법에 따라 DC를 건설하고자 하는 사업자는 에너지사용 계획서를 제출해야 함. 공공 DC는 연간 10GWh 이상, 민간 DC는 20GWh 이상이 대상이며, 제출된 계획서는 한국에너지공단이 평가 및 검토하고 필요시 계획의 수정 및 보완을 요청/권고할 수 있음

- 전기사업법에 따라 5MW 이상 DC를 가동할 때 DC 사업자는 한전에 전력 수전 예정통지를 해야 하며, 한전은 해당 부지에 전력 여유분이 없을 경우 전기 공급을 거부할 수 있음
 - 분산에너지법에서는 연간 200GWh 이상 전력을 소비하는 수도권 DC에 대해 분산에너지 설치 의무를 규정함. 또한 계약전력 10MW 이상의 DC는 정부에 전력계통 영향 평가서를 제출하고 평가 점수가 70점 이상이 되어야 하는데, 자가발전기 설치 없이는 점수 달성이 쉽지 않음
 - 녹색건축물조성지원법에서는 연면적 1천 ㎡ 이상 신축 시 공공 DC는 제로에너지건축물(ZEB) 인증제의 4등급 이상을 달성해야 하며, 민간 DC는 인증 취득 의무는 없으나 건축 인허가 관련 설계 기준에 ZEB 5등급 기준을 반영해야 함
 - 요컨대, 국내 DC 관련 규제는 주로 신축 시 일회성으로 발생하며, 민간 보다는 공공부문이 주요 대상이고, 규제 강도도 국제 기준에 비추어 크게 완화된 수준임
- 국내 데이터센터에 관한 정책 방향은 주로 현재 수도권에 집중되어 있는 DC를 지방으로 분산시키는데 집중하고 있으며, 해외와 같은 정부 주도의 데이터센터 인증제는 미비함
- 정부는 DC의 지역 분산 유도를 위해 투자 유치 제도를 통한 규제 특례 및 보조금 지급, 주변 발전소와 DC 간 직접 PPA 활성화, 전력시설부담금 할인 등의 인센티브 정책을 실시하고 있음
 - 민간 인증제도로써 KDCC가 운영하는 그린데이터센터 인증제가 존재하나, 의무 사항은 아니며 인증 인센티브 역시 크지 않음

■ 국내 데이터센터 관련 정책 제언

- 데이터센터의 전기 소비는 높은 전력 밀도, 연속 운영, 대규모 단일 부하 및 변동성, 수요 예측의 불확실성 등의 특징으로 국가 전력 수급 안정을 위해 적극적인 정책 개입이 필요함
 - 데이터센터는 단위 면적당 전력 소비(전력 밀도)가 크며, 하루 24시간, 1년 365일 연속적으로 운영됨
 - 특히, AIDC의 경우 훈련과 추론의 부하는 상당부분 GPU 최대 전력 근처에서 발생하며, 변동성이 큼
 - 게다가 AI 연산량은 추론의 발생 빈도 및 시간, 추론 유형을 포함한 많은 요인들에 의해 결정되므로, 계획된 생산량을 통해 예측 가능한 제조업의 전기 수요에 비해 예측의 불확실성이 매우 높음
- 국내 DC에 대한 정확한 현황 파악을 위해서는 먼저 DC 분류 기준을 명확히 할 필요가 있음
 - 기존 전산실 면적 기준을 IT 용량 기준 또는 연간 전력 소비량 기준으로 변경할 것을 고려해야 할 것임
 - 건축법상 DC는 방송통신시설로 분류되나, DC의 에너지 소비 용도는 불명확함. DC의 에너지 소비가 건물용으로 분류되도록 용도 구분을 명확히 정리할 필요가 있음
 - 특히, 전기의 경우 한전이 DC에 공급한 전기 소비를 별도로 분류하여 집계할 필요가 있음. 또한 전기 소비 효율, 유연성, 수요 대응 기능 장려, 수요 불확실성에 따른 위험 대비 등을 위해 DC용 요금제를 도입하는 것도 적극적으로 검토할 필요가 있음
- 데이터센터의 정확한 에너지 성과를 평가하기 위해서는 용도를 세분화하여 파악하는 것이 중요하므로, 이를 위한 정보 수집 및 보고 체계를 구축해야 함

- 데이터센터의 에너지 소비는 단순히 총 전력이 아니라 IT용, 냉각용, 자가발전용 등으로 용도를 세분화하는 것이 중요함
 - DC 운영자가 세부 항목별 에너지 소비 정보를 직접 계측하여 이를 보고하는 체계를 마련할 필요가 있음
 - 주요 해외 사례처럼 이러한 정보 중 DC운영자와 정부의 협의를 통해 공개 가능하다고 판단되는 정보는 투명하고 지속 가능한 DC 운영을 위해 대중에게 공개하는 방안도 고려할 필요가 있음
 - DC의 에너지 관리 및 에너지 소비 정보 수집을 위해 건축물에너지 관리 시스템의 설치 의무 확대도 필요함
 - 보고해야 할 정보는 PUE와 같은 에너지 성과 지표를 계산할 수 있을 정도로 세분화되어야 하며, 특히, 배터리, 백업 발전기, 자가발전기와 관련해서는 총 발전량, 에너지원별 발전 투입 에너지, 자가 소비량뿐만 아니라, 인근 지역으로의 업종별 전력 및 열 판매량도 포함해야 함
- 보고된 에너지 정보를 바탕으로 계산된 에너지 성과 지표를 통해 DC의 지속적인 에너지 효율 개선을 위한 정책이 필요함
- 데이터센터의 에너지 성과 지표를 바탕으로 기존 및 신규 DC가 달성해야 할 에너지 효율 규제 기준을 마련해야 할 것임
 - 지속적인 DC의 에너지 효율 개선을 목표를 설정하고, 이에 대한 가이드라인 또는 지침을 마련하는 것도 필요함
 - 집단에너지 사업자와 협력해 폐열을 활용하는 DC에는 인센티브를 주고, 일정 수준 이상의 폐열을 배출하는 DC에 대해서는 효율적 폐열 활용 방안을 제시하도록 하는 것도 필요함
 - 정부 주도 데이터센터 인증제 도입을 통해 높은 수준의 효율 개선을 달성한 DC에 대한 인센티브를 제공하는 방안도 검토할 필요가 있음
- 데이터센터의 에너지 효율 개선 지원을 위한 정책 마련이 필요함

- 에너지 효율 성과 달성 지원을 위해 국내 상황에 부합하는 데이터센터의 설계 및 운영 모범 사례 마련을 고려할 필요가 있음
 - AI 모델 개발사에게 훈련과 추론 과정에서의 에너지 소비량에 대한 정보 제공을 유도하고, 이를 바탕으로 서로 다른 AI 모델 간 에너지 소비 비교 및 평가를 위한 지표 개발도 고려해야 함
- DC의 적극적인 전력망 참여를 지원하기 위해 PPA 활성화 및 DR 참여를 위한 연구와 제도 확장이 필요함
- 현재 시행 중인 송전제약 PPA의 실질적인 운영을 위해서 세부 고시 제정을 서둘러야 하며, 현재 분산에너지 특구 내 PPA 가능 열병합발전소의 기준 완화도 검토할 필요가 있음
 - 유연성 자원으로의 역할 확대를 위해, 모든 DC의 스마트 배전 시스템 확보에 노력해야 하며, IEEE 표준에 등록된 서버 간 최적 부하 분배 기술, DC의 주파수 조절 시장 참여 프레임워크 등과 같은 기술을 적극적으로 도입, 검토하는 것이 요구됨
 - 또한, 현재 검토 중인 오토 DR 제도에 DC를 포함시키는 방안을 검토하고, VPP에 DC의 비상발전기와 자가발전기를 참여시키는 방안도 검토할 필요가 있음
- 균형있고 안정적인 DC 분산을 위해 DC의 성격에 따른 분산과 정부 주도형 훈련중심 AIDC 건설을 고려할 필요가 있음
- 데이터센터의 지방 분산과 관련해, 훈련형과 추론형 DC에 대한 이분법적 접근이 필요함
 - 정부 주도의 훈련형 AIDC를 송전제약 및 전력계통 부하 등을 고려해 지방 분산을 추진하고, AI 모델 개발의 테스트베드로 활용하는 방안도 검토하기를 권고함

제1장

서론

1. 연구 배경

AI에 대한 관심이 폭발하는 시대이다. 전세계가 AI 혁명에서 앞서 나가기 위해 경쟁하고 있다. 우리나라도 AI 3대 강국 도약을 국가 최상위 목표로 설정하고, 이를 위해 전방위적인 정책을 추진하고 있다. 특히, 소버린(Sovereign) AI 구축을 통해 외국 기술에 대한 의존도를 줄이고 독자적인 AI 기술 주권 확보를 핵심 전략으로 삼고 있다. 이와 관련하여 “인공지능 발전과 신뢰 기반 조성 등에 관한 기본법(인공지능 기본법)”이 2025년 1월에 공포되었으며, 2025년 9월에는 대통령 직속 국가인공지능전략위원회가 출범했다. 위원회의 제1차 회의에서 의결된 “AI 액션플랜”에서는 “AI 혁신 생태계 조성”, “범국가 AI 기반 대전환”, “국제 AI 기본사회 기여”의 3대 축을 기반으로 구체적인 실행 계획을 제시하고 있다.

전세계적으로도 AI에 대한 연구와 정책은 AI 기술 혁신, 인프라 구축, 안보 등 여러 분야로 급속히 확산되고 있는데, 본 연구는 데이터센터의 에너지 소비 분석에 중점을 둔다. 에너지 소비에 대한 연구도 AI 열풍과 함께 최근 몇 년 사이에 전 세계적으로 쏟아지고 있으며, 각종 미디어에서도 데이터센터로 인한 전기 소비 폭

증이라는 헤드라인을 쉽게 찾을 수 있다. 미디어에 자주 등장하는 내용으로는 “구글 검색 대비 AI 검색의 전기 소비는 10배”, “데이터센터의 전기 소비에서 냉각용이 40~50%를 차지”, “전력 부족이 국내 데이터센터 확장의 걸림돌” 등이다. 본 연구는 이러한 정보들에 대한 구체적인 사실 관계 확인과 이에 대한 적절한 대응 방안이 무엇인가 하는 질문에서 시작되었다.

2. 연구 필요성 및 목적

국내 AI 정책 목표와 수많은 미디어의 보도에도 불구하고, 국내 데이터센터의 에너지 소비에 대한 연구나 정보는 거의 없다. 데이터센터의 에너지 소비에 대한 연구나 보도들은 미국을 중심으로 한 글로벌 사례가 대부분이다. 데이터센터가 국내 에너지 정책에 중요한 요소로 부상하고 있는 시기에, 올바른 정책 수립을 위해서는 데이터센터의 에너지 소비에 관한 체계적인 연구가 시급하다.

본 연구의 목적은 다음의 세 가지이다. 첫째, 데이터센터 에너지 소비에 대한 글로벌 연구들을 종합하여 체계적으로 정리함으로써 정확하고 균형 잡힌 정보를 전달한다. 데이터센터에 대한 해외 연구들은 다양한 방면에서 광범위하게 행해지고 있는데, 에너지 소비에 대한 체계적인 정리는 관련 연구와 정책 수립에 중요한 기초 자료가 될 것이다. 둘째, 데이터센터의 에너지 소비 분석 및 전망은 국가 에너지 계획 수립에 필수적임에도 불구하고 국내에서 이와 관련된 연구는 거의 없다. 본 연구에서는 데이터센터의 증가로 국내 에너지 소비가 얼마나 그리고 어떻게 변할 것인지에 대해 알아본다. 마지막으로 글로벌 주요국의 데이터센터 에너지 소비 관련 제도와 정책들을 정리하고, 이를 통해 국내 정책 수립 시 고려해야 할 항목과 정책 시사점을 제시한다. 현재 데이터센터의 에너지 소비에 대한 국내 정책에 대한 계획은 상대적으로 미흡한데, 데이터센터 에너지 소비의 영향력을 생각하면 에너지 및 효율 관련 정책 마련에도 힘써야 한다.

3. 보고서의 구성

본 연구의 주요 내용은 연구 목적에 따라 세 부분으로 구성되어 있다. 먼저 데


이터센터의 에너지 소비에 관한 해외 기존 연구들을 종합 정리(제2장)한다. 다음으로 국내 데이터센터 전기 소비를 실증 분석(제3장)한다. 마지막은 국내외 데이터센터 관련 정책들을 정리하고 정책 제안점을 도출(제4장)한다.

[그림 1-1] 제2장 구조



해외 기존 연구를 정리한 제2장은 5개의 절로 구성된다. 첫 번째 절에서는 데이터센터(DC)의 인프라 구조, 유형, 유형별 에너지 소비, 부하패턴에 대해 정리한다. 두 번째 절에서는 데이터센터의 전력 소비에 대한 해외 연구들을 정리한다. 세 번째 절에서는 인공지능 연산인 학습(훈련)과 추론의 전기 소비 및 특성, AI 에너지 소비 영향 요인, 추론 작업 유형별 전기 소비 등을 다룬다. 네 번째 절에서는 DC의 주요 에너지 성과 지표, 글로벌 PUE 추이 및 전망, 에너지 효율 요인 및 효율 개선 정책 효과에 대해 살펴본다. 마지막 절은 소결로, DC 전기 소비 증감 요인을 다시 한번 종합하여 정리하고, 에너지 이외에 DC의 증가에 대해 생각해볼 점을 논의한다.

[그림 1-2] 제3장 구조




제3장은 먼저 국내 데이터센터 현황을 정리하고 이어서 실증 분석과 국내 에너지 소비에 대한 시사점을 도출한다. 실증 분석은 국내 주요 데이터센터의 월간 전기 소비량 자료를 이용한 계절성 분석, 울산 AI 데이터센터의 에너지 소비량 추정,

국내 데이터센터 총 전력 수요 추정 및 전망의 3개의 부분으로 구성된다. 국가 총 DC 에너지 수요 전망에서는 시나리오 분석과 PUE 개선에 따른 전력 소비 절감 잠재량 분석도 포함한다. 제3장의 마지막은 데이터센터 증가로 인한 국내 총 전기 소비 증가 추세에 대한 시사점, 국내 데이터센터에 대한 전력 공급 방안 및 입지, 국가 전체 최종 에너지 소비에 대한 시사점 등을 논의한다.

정책 제언 부분인 제4장에서는 먼저 해외 주요국과 우리나라의 데이터센터 에너지 관련 정책들을 정리하고 이를 통해 추가적인 국내 정책을 제시한다. 주요국 사례로는 EU, 독일, 프랑스, 미국, 중국, 일본, 싱가포르의 데이터센터 에너지 관련 정책을 정리한다. 정책 제언은 6가지 카테고리(분류 기준 및 체계, 정보 수집 및 보고 체계, 에너지 효율 개선 정책, 에너지 성과 달성 지원, 적극적인 전력망 참여 지원, 균형있고 안정적인 분산)로 구성된다. 마지막 제5장 결론에서는 주요 결과들을 요약하고 시사점을 정리한다.

[그림 1-3] 제4장 구조



제2장



데이터센터와 에너지 소비

본 장에서는 글로벌 DC 관련 연구들을 바탕으로 데이터센터의 에너지 소비에 대한 전반적인 정보들을 정리한다. 본 장은 5개 절로 구성되며, 데이터센터의 에너지 소비, 글로벌 DC 전기 소비 전망, 인공지능 관련 에너지 소비, DC 에너지효율을 다룬다. 마지막 소절에서는 DC 에너지 소비 증감 요인과 추가적으로 생각해 볼 점들을 정리한다.

1. 데이터센터(DC)의 구조와 에너지 소비

1.1. DC의 정의 및 인프라 구조

1.1.1. 정의

데이터센터는 디지털 데이터를 저장, 처리, 전송하기 위한 물리적인 시설 또는 인프라의 집합체를 의미한다. 데이터센터는 다수의 서버, 저장 시스템, 네트워크 장비 전력 배분 및 제어 시설 등이 특정 장소에 집중되어 설치 및 운영되는 공간으로 에너지를 많이 소비한다. 우리나라의 지능정보화 기본법에서는 데이터센터를

“지능정보서비스의 제공을 위하여 다수의 초연결지능정보통신기반을 일정한 공간에 집적시켜 통합 운영·관리하는 시설”로 정의한다.¹

데이터센터의 정의는 전세계적으로 어느 정도 일관성이 있지만, 정보 수집, 연구 및 정책 대상으로의 데이터센터를 구체적으로 어느 범위까지 포함해야 하는지에 대해서는 조사기관이나 정책 결정자마다 다르다. 정의에 따라서는 기업의 소형 전산실 정도의 규모도 데이터센터에 포함될 수 있지만, 일반적으로 이용 가능한 데이터센터의 정보는 일정 규모 이상의 데이터센터를 대상으로 한다. 데이터센터와 관련한 제도가 만들어지고 있는 초기 시점이어서, DC의 범위 및 경계에 대한 세계적으로 통용되는 기준은 없다. 이 때문에 데이터센터에 관한 논의를 할 때는 반드시 어느 범위의 데이터센터를 의미하는지를 명확히 할 필요가 있다.

데이터센터의 모호한 경계는 에너지 소비 추정 및 연구에서 특히 주의해야 할 점이다. 지역의 전산 서비스에 공급된 에너지를 데이터센터의 에너지 소비라고 보는 경우도 있고, 데이터센터를 운영한다고 신고한 사업자들의 에너지 소비만을 DC 소비로 보는 경우도 있다. 후자의 경우 암호화폐 채굴 시설이 데이터센터로 분류되기도 한다. 조사에 따라 하이퍼스케일(Hyperscale)과 같이 상당 규모 이상만을 데이터센터로 보는 경우도 있고, 기업의 소형 규모까지 포함하는 경우도 있다. 이러한 문제들로 데이터센터 관련 연구나 자료를 비교할 때는 주의해야 한다.

1.1.2. 인프라 구조

데이터센터의 구성은 크게 IT 하드웨어 시스템과 그 외 비IT 시스템으로 나눌 수 있다([그림 2-1] 참조).


(1) IT 부문

IT 시스템은 서버(Server), 스토리지(Storage), 네트워크(Network) 및 이와 관련된 보조 장비(모니터링 및 제어 장치 등)로 구성된다. 이러한 장치들은 랙(rack)이라고 불리는 캐비닛에 설치되는데, 데이터센터의 표준 랙은 약 1.87미터 크기로 설계된다. 데이터센터당 랙 수는 DC의 크기와 용도에 따라 매우 다양한데, 소

¹ 지능정보화기본법(시행 2025. 3. 27.) [법률 제20410호, 2024. 3. 26., 일부개정]

형 DC에는 50개 미만, 중형에는 50~100개, 대형에는 수천~수만 개의 랙이 설치된다. 하나의 랙에는 최대 42개의 서버가 장착될 수 있다. 서버에는 CPU 중심의 범용 서버와 GPU 같은 AI 가속기가 설치된 고성능 서버가 있다. 일반적으로 범용 서버에는 랙당 20개 내외의 서버가 장착되며, AI 서버의 경우는 냉각 및 전력 한계로 랙당 4~10개의 서버가 장착된다. 범용 서버에는 보통 서버당 1~2개의 CPU가 설치되며, AI 고성능 서버의 경우는 서버당 4~8개의 GPU가 표준 구성이다. 랙에는 서버뿐만 아니라 스토리지 및 네트워크 장비도 장착되어 있다. 스토리지는 데이터 저장 장비로서 HDD(Hard Disk Drives), SSD(Solid State Drives) 등이 장착된다. 네트워크 장비는 서버가 통신망에 연결되도록 도와주는 통신 장비로서 LAN(Local Area Network) 스위치, SAN(Storage Area Network) 스위치, WAN(Wide Area Network) 라우터, 방화벽(Firewalls) 등으로 구성된다.

[그림 2-1] 데이터센터 인프라 구조



(2) 비 IT 부문

비IT 시스템은 전력 시스템, 냉난방공조(HVAC) 시스템, 기타 보조 시스템으로 구성된다. 전력 시스템은 데이터센터의 안정적인 전력 공급과 분배를 위한 장비들로 구성되는데, 여기에는 전력 분배 장치(PDU, Power Distribution Unit), 무정전 전원 공급 장치(UPS, Uninterruptible Power Supply) 및 배터리, 변압기(Transformer), 에너지 관리 및 제어 시스템(EMCS, Energy Management and Control System), 백업 발전기 등이 포함된다. 전력 분배 장치(PDU)는 랙 내부 또는 외부에 설치되어 전력을 서버, 스토리지, 네트워크 등에 효율적으로 분배하는 장비다. 무정전 전원 공급 장치 (UPS)는 전력 공급이 중단될 때 즉시 배터리 등으로 전환해 데이터센터의 장비가 정상적으로 운영되도록 돕는 장치다. 에너지 관리 및 제어 시스템(EMCS)은 스위치기어(Switch Gear)², ATS(Automatic Transfer Switch)³, 배전반, 발전기 등 다양한 장비의 상태를 모니터링하며 전체 전력 시스템을 제어 및 운전하는 시스템이다.

데이터센터는 순간 전압 강하(Voltage Sags), 과전압(Over-voltage), 고조파(Harmonics)⁴, 주파수 변동(Frequency Variation)⁵, 계통 정전 및 고장(Grid Outage Faults) 등에 취약하다. 이러한 문제들을 해결하기 위해 일반적으로 데이터센터는 배터리와 백업 발전기를 설치한다. 특히, AI 데이터센터와 같은 경우는 작업 내용에 따라 급격한 전력 변동이 발생할 수 있는데, 일반적인 발전기는 이러한 급격한 부하 변동에 빠르게 대응하기 힘들다. 배터리는 이러한 부하 변동에 가장 빠르게 응답할 수 있어 데이터센터의 중요한 구성 요소이다.

백업 발전기는 비상시 전력 공급을 위한 자가발전기로 연속 운영이 필수적인 데이터센터에서 핵심적인 역할을 한다. 데이터센터의 백업 발전기로는 주로 디젤 발전기가 쓰인다(〈표 2-1〉 참조). 출처에 따라 다르지만, 2024년 기준 글로벌 데이터센터 백업 자가발전기의 70~80% 정도가 디젤 발전기이다. 디젤 발전기 다음으

² 전력 제어 장치로서 과부하, 단락 사고 발생 시 회로를 자동으로 차단해 시스템과 장비를 보호함. 스위치기어는 회로 차단기, 분리기, 퓨즈, 보호 계전기 등으로 구성됨

³ 주 전원과 예비 전원 사이에 전력을 자동으로 전환해 주는 장치

⁴ 기초 주파수의 경우 배 주파수를 가진 전기 신호로, 고조파가 심하면 전력 품질 저하, 변압기 및 기타 장비 과열, 통신 장애, 계통 진동 등을 일으킬 수 있다.

⁵ 발전과 전력 소비의 불균형으로 주파수가 기준 값에서 벗어나는 현상

로는 가스 발전기가 많이 사용되며, 최근에는 바이오연료(Biofuel) 및 식물성 오일(HVO) 발전기, 연료전지와 같은 수소 발전기가 성장하고 있는 추세이다. 디젤 발전기는 신뢰성이 높고 시동 시스템이 간단해 응답 능력이 높다는 것이 장점이다. 선택적 촉매 환원(SCR) 및 미립자 필터 제어기능을 갖춘 최신 디젤 발전기의 경우 탄소 배출이 거의 없지만, 탄소 배출 규제 및 ESG 등으로 디젤 발전기의 성장세는 제한되고 있다. 가스 발전기는 탄소 배출 제한 정책 등으로 증가하는 추세이다. 디젤 발전기는 매연저감장치를 설치해야 하지만, 가스 발전기는 이러한 장치가 불필요해 디젤보다 환경친화적이다. 그러나, 디젤 발전기 대비 상대적으로 시동이 느리며, 전용 천연가스 연결망 등의 인프라 설비가 요구될 수 있다는 점이 단점이다. 수소 및 HVO 발전기는 가장 친환경적인 발전기로 향후 가장 빠른 속도로 증가할 것으로 예상된다. 대표적인 수소 발전기인 연료전지는 비용 및 수소 공급 인프라 문제로 아직까지는 초기 단계에 있다. 국내 데이터센터에서도 디젤 발전기가 대부분을 차지하고 있으나, 최신 데이터센터를 중심으로는 가스 터빈 발전기 설치가 증가하고 있으며, 연료전지도 고양 소재 데이터센터에 첫 적용되는 등 적용 사례가 등장하고 있다.

〈표 2-1〉 글로벌 데이터센터의 백업 발전기 타입


구분	비중	비고
디젤	73~75%	대부분을 차지하고 있으나, ESG 및 규제 압력이 존재
천연가스	15~17%	북아메리카와 아시아를 중심으로 증가
HVO/Biofuels	5~7%	유럽을 중심으로 가장 빠르게 증가
수소	1% 미만	초기 단계

자료: Mordor Intelligence Research & Advisory(2025)

데이터센터 비IT 부문의 두 번째는 냉방 시스템으로 대표되는 냉난방공조 (HVAC, Heating, Ventilation, and Air Conditioning) 시스템이다. HVAC는 데이터센터의 IT 장비가 안정적으로 작동할 수 있도록 온도, 습도, 공기 흐름 등을 조절하는 시설이다. 여기에는 항온항습기(CRAC, Computer Room Air Conditioner), 수냉식 시스템, 냉각수를 공급하기 위한 펌프, 냉각수 냉각을 위한 냉각탑 등이 포함된

다. 데이터센터의 냉각 방식에는 공랭식(Air Cooling)과 수냉식(Liquid Cooling)이 있다. 최근의 초대형 AI 데이터센터의 경우 랙당 전력밀도가 높아지며 액체 냉각이 요구되고 있다([그림 2-2] 참조). 마지막으로 비IT 부문에는 조명, 데이터센터 운영 및 관리를 위한 자동화 장치, 건물 보안 및 방재 장비 등도 포함된다.

[그림 2-2] 랙 전력 부하에 따른 냉각 시스템 변화



자료: CompuDynamics(2024.6.25.), Vertiv (IT Power Trends) 재인용

1.2. DC의 분류 및 유형

데이터센터의 종류는 규모, 등급(Tier), 소유 형태, 서비스 제공 방식 등 여러 기준에 따라 분류된다.

1.2.1. 규모에 따른 분류

먼저 규모에 따른 분류는 다시 센터의 물리적 크기(상면 면적: 데이터센터에서 서버나 랙 등을 설치할 수 있는 공간), 설치된 서버 및 네트워크 장비 규모(용량), 데이터 저장 및 처리 능력, 전기 소비량 등의 항목에 따라 분류된다. 이러한 항목들은 고정된 값이 아니라 기술 발전에 따라 변화하기 때문에, 규모에 따른 분류는 경계의 불확실성 문제가 있는 분류이다. 예를 들어, 최신 AI 반도체의 최대 전력 소비량은 지속해서 증가해 오고 있는데, 분류 기준을 유지한다면 초소형으로 분류

된 데이터센터가 나중에는 소형, 중형이 될 수도 있다. 데이터센터 규모에 대해서는 세계적으로 표준화된 분류 기준은 없지만, EU의 에너지효율관리지침에서는 설치된 IT 전력 소비 용량에 따라 데이터센터를 초소형(100~500kW), 소형(500~1,000kW), 중형(1~2MW), 대형(2~10MW), 초대형(10MW 이상)으로 분류한다. 일반적으로 소형 데이터센터는 조직이나 기업(Enterprise)이 특정 서비스 제공을 목적으로 자체적으로 운영하는 경우가 많으며, 상대적으로 관리가 쉽고 맞춤형 서비스를 제공하지만 확장성은 제한된다. 중형 데이터센터는 클라우드 컴퓨팅을 포함한 보다 다양한 서비스를 지원하는 것이 가능하며, 이에 따라 서버의 안정성 및 에너지 소비 관리, 네트워크 설계 등의 효율화 전략이 중요하게 된다. 일반적으로 하이퍼스케일(Hyperscale) DC라고 부르는 초대형 데이터센터는 거대한 데이터 처리 용량 및 저장시설을 갖추고 수천~수만 대의 서버를 운영하며 글로벌 인터넷 서비스나 클라우드 인프라를 제공한다.

1.2.2. 티어 분류

다음으로 데이터센터의 등급에 따른 분류는 데이터센터의 안정성과 신뢰성에 따른 분류로, 주로 Uptime Institute의 기준에⁶ 따라 Tier 1~ Tier 4로 분류된다. 이러한 티어(Tier) 분류는 데이터센터의 기술적 신뢰성만을 고려한 분류로서, 에너지효율성을 포함한 다른 요소들은 고려되지 않는다. 티어 분류는 아래의 <표 2-2>와 같이 전력 및 냉각 시스템의 이중화 정도 등에 따라 분류된다. 티어가 높을수록 전력 및 냉각 시스템의 이중화가 강화되어 가동 중단 위험이 줄어드나, 그만큼 에너지 소비는 증가할 수 있다.

〈표 2-2〉 데이터센터 티어(Tier) 분류

구분	주요 특징	업타임 / 연간 허용 다운타임	서비스 중단 가능성
Tier I	전원 공급이나 냉각 시스템에 대한 백업이 없음	99.671%/28.8시간	유지보수시 서비스 전체 중단 필요, 장애 대응 제한적

⁶ Uptime Institute

Tier II	기본 백업 시스템 존재 전원 공급과 냉각 시스템에 대한 일부 이중화	99.741%/22시간	장비 유지보수시 일부 서비스 중단 가능
Tier III	전원 공급 및 냉각 시스템에 대한 완전 이중화	99.982%/1.6시간	장비 유지보수시 서비스 중단은 없으나, 장애시에는 일부 중단 가능
Tier IV	모든 시스템 및 구성요소 완전 이중화	99.995%/26.3분	어떤 문제가 발생해도 IT 장비가 중단되지 않음

자료: Uptime Institute

1.2.3. 소유 형태 및 서비스 제공 방식에 따른 분류

데이터센터는 소유 형태 및 서비스 제공 방식에 따라 자사용(Enterprise 또는 Corporate), 클라우드(Cloud), 코로케이션(Colocation), 호스팅(Hosting) 등으로 구분하기도 한다. 먼저 자사용은 기업, 공공기관 등이 자체적으로 구축, 소유 및 운영하는 데이터센터로 규모면에서는 주로 소형이다. 나머지 클라우드, 코로케이션, 호스팅은 사업자가 인프라를 소유하고 고객에 임대하는 상업용 데이터센터이다. 규모면에서 클라우드와 코로케이션은 주로 중형 이상이며, 서버 및 IT 장비를 임대 및 관리하는 서비스인 호스팅은 일반적으로 클라우드나 코로케이션 보다는 규모가 작다.

클라우드형은 데이터센터의 소유자가 하드웨어를 소유하고, 인터넷을 통해 이 용자에게 가상의 IT 자원(서버, 스토리지, 네트워크, 각종 애플리케이션, 소프트웨어, 애플리케이션 개발 및 배포에 필요한 플랫폼 등)을 서비스로 제공하는 형태이다. 하드웨어(IT 자원)의 소유자인 클라우드 사업자가 인프라 관리, 유지 및 보수 등을 담당하기 때문에 고객(기업)은 인프라 설치 및 관리 부담 없이 빠르고 유연하게 IT 환경을 구축할 수 있다. 대표적인 클라우드 서비스의 유형은 IaaS(인프라 기반 서비스), PaaS(플랫폼 기반 서비스), SaaS(소프트웨어 기반 서비스)가 있다(삼성SDS 클라우드 용어집). 클라우드 데이터센터는 주로 인프라가 가상화 되어 있어 수요에 따라 클릭 몇 번만으로 서버를 즉시 늘리거나 줄일 수 있다. 이러한 특징 등으로 클라우드형은 중앙집중식 서버에 대한 수요 증가의 주요 원인으로 작용하고 있다.

〈표 2-3〉 클라우드 vs. 코로케이션 vs. 호스팅 DC


유형	규모	IT 장비 소유권	서버 확장성
클라우드	중형 이상	클라우드 사업자	가상화된 인프라로 서버 유연성이 큼
코로케이션	중형 이상	고객	물리적 서버로 유연성이 제한적
호스팅	중형 이하	호스팅 사업자	물리적 서버로 유연성이 제한적

코로케이션 서비스는 전문 데이터센터(IDC)가 고객(기업)에게 서버와 네트워크 장비 등을 설치할 수 있는 공간(랙 등)과 인프라(전력, 냉방, 네트워크, 보안 등)를 임대하는 서비스이다. 클라우드형과는 달리 코로케이션에서는 IT 장비의 소유권이 고객에게 있기 때문에 장비의 추가 및 설치, 운영, 유지 보수 및 관리의 책임도 고객이 진다. 클라우드 서비스에서는 고객이 데이터센터에 방문할 필요가 별로 없지만, 코로케이션 서비스에서는 IT 장비에 접근하기 위해 고객이 직접 데이터센터에 방문해야 한다.

호스팅형 DC는 클라우드형과 유사하게 호스팅 서비스 제공자가 하드웨어(서버 등)를 소유하고 운영하며 고객에게는 애플리케이션이나 데이터의 관리만을 맡기는 형태이다. 클라우드형의 인프라가 가상화 되어 있어 유연성이 큰 반면, 호스팅형은 코로케이션처럼 서버 자원이 주로 물리적 단위로 구성되어 유연성이나 확장성이 상대적으로 낮다. 이 밖에 비용 구조도 클라우드형과 차이가 있다.

Uptime Intelligence가 글로벌 데이터센터의 운영자를 대상으로 해마다 실시하는 설문조사(Donnellan et al., 2024)에 따르면 자사용(Corporate) 데이터센터의 비중은 감소하고 클라우드용(민간 및 공공용 cloud)과 코로케이션의 비중이 증가하는 모습을 보인다. 2026년에 대해 예측한 결과를 보면 글로벌 데이터센터의 비중은 자사용(42%), 코로케이션(17%), 공공 클라우드(13%), 호스팅(11%) 순으로 나타난다.

[그림 2-3] 용도별 글로벌 데이터센터 보급 추이



자료: Donnellan et al.(2024), p22, Figure 13

1.2.4. 엣지 데이터센터

위의 [그림 2-3]에서 엣지(edge) 데이터센터는 현재 전세계적으로 약 4% 수준을 차지하고 있지만, 향후 AI 시대가 발전함에 따라 보급이 크게 증가할 가능성이 크다. 엣지 DC는 지리적으로 데이터가 생성되거나 소비되는 근처에 위치한 데이터센터로 규모면에서는 보통 소형이다. 엣지 DC가 요구되는 분야는 이용자와 DC 간 매우 빠른 반응, 즉, 저지연(low-latency)이 요구되는 애플리케이션이다. 저지연이 중요한 애플리케이션으로는 자율주행, 스마트 교통 등 사람의 생명과 직결되는 업무가 포함된다. 사물인터넷(IoT), 5G, 가상현실, 증강현실 등도 엣지 DC가 요구되는 애플리케이션에 포함된다. 이러한 애플리케이션에 대한 수요는 제조, 소매, 게임, 원격 의료, 원격 학습, 블록체인 등으로 AI 시대가 활성화될수록 크게 증가할 것으로 보인다. 글로벌 시장 조사 기관들은 전 세계 엣지 데이터센터 시장이 2030년까지 연평균 22.1%로 빠르게 증가할 것으로 전망하고 있다(EPRI, 2024). Savills Korea(2024)는 2028년에는 엣지 DC가 전세계 데이터센터의 약 24%를 차지할 것이라고 예상한다.

1.2.5. 모듈러 데이터센터

최근에는 미국과 중국을 중심으로 모듈러 데이터센터(Modular Data Center)가 빠르게 성장하고 있다. 모듈러 DC는 컨테이너 또는 모듈 형식으로 사전제작(Prefabricated)된 독립적인 구성 요소를 현장에서 조립하여 완성하는 형태의 데이터센터이다. 모듈러 DC는 기존 데이터센터 대비 건축 시간을 40~50%가량 단축시킬 수 있고, 사전 공장 제작으로 현장 노동력을 줄임으로써 비용도 큰 폭으로 절감할 수 있다(Dgtl Infra, 2023). 모듈러 DC는 수요가 발생한 현장에 직접 설치할 수 있을 뿐만 아니라, 기존 데이터센터의 건설이 어려운 지역에서도 설치할 수 있어 유연성이 크다. 또한, 데이터센터 수요 크기에 따라 표준화된 모듈을 추가할 수 있어 확장성이 높다는 점도 장점이다. 모듈러 DC의 단점은 제작 공장에서 현장으로 운송하는 과정에서 발생할 수 있는 위험이다. 현장의 도로 여건에 따라 운송이 어려운 경우도 있고, 운송 중 모듈이 손상될 위험도 있다. 또한, 우리나라에서는 이와 관련된 법 체계가 미비해 인허가 문제도 있다. 이 밖에, 상대적으로 물리적 보완이 취약하고, 내구성이 기존 DC에 비해 낮다는 점 등도 모듈러 DC의 단점으로 지목된다.

1.2.6. AI 데이터센터

마지막으로 AI 데이터센터(AIDC)를 정의할 필요가 있다. 앞에서 살펴본 하이퍼스케일, 클라우드, 엣지, 모듈형 DC 등은 서로 다른 기준에 따른 분류로 이들이 AIDC일 수도, 아닐 수도 있다. AIDC는 인공지능(AI) 관련 작업을 할 수 있는 인프라를 갖춘 DC를 의미한다. 즉, 엄청난 연산량을 빠른 속도로 처리해 훈련 및 추론 작업을 수행할 수 있는 AI 가속기(GPU, TPU, ASIC 등)가 구비된 데이터센터를 의미한다. 앞서 설명한 데이터센터 구조에서 서버에 CPU 대신 AI 가속기가 설치된 경우이다. 이러한 AI 가속기들은 발열량이 기존 반도체에 비해 높기 때문에 보다 고성능의 냉각장치가 필요하며, 전기 소비량이 많아 배전방식 등의 전력 인프라도 전통적인 DC와 다를 수 있다. AIDC를 말할 때 주의해야 할 점은 반드시 “AIDC=전력 소비 폭증”은 아니라는 것이다. 본 보고서에서 앞으로 다루겠지만, 에너지효율 기술들이 빠르게 발전하고 있으며, 무엇보다 AIDC가 건설된다고 해

도 AI 서비스 수요가 적으면 AIDC의 에너지 수요는 크게 증가하지 않는다. 비유하자면 AIDC는 엄청난 그래픽이 요구되는 최신 게임을 구동할 수 있는 고사양 PC라고 할 수 있다. 고사양 PC에도 문서 작업 등의 기초적인 작업이 가능하다. PC 사용 시간의 대부분을 최신 게임이 아닌 영화 감상이나 문서작업 또는 저사양 게임 구동에 쓴다면 고사양 PC를 쓴다고 해도 전기 소비는 기존 PC 대비 예상보다 크게 증가하지 않을 수 있다.

1.3. DC 유형별 에너지 소비

데이터센터의 에너지 소비는 대부분 IT 장비(서버, 스토리지, 네트워크)에서 발생한다. IT 장비의 에너지 소비에 영향을 미치는 요소는 칩의 종류, 서버 수, 연산량, IT 장비 이용률 등이다. 비IT 쪽에서의 에너지 소비는 과반수 이상이 냉각 시스템에서 발생한다. 냉각 시스템에 소비되는 에너지는 냉각 기술뿐만 아니라 데이터센터가 위치한 장소의 기후에도 크게 영향을 받는다. 예를 들어, 유럽에서 가장 낮은 냉방도일 등의 요인으로 데이터센터의 설치가 집중되고 있는 아일랜드의 경우, 전체 DC 에너지 소비에서의 냉방용의 비중은 약 14%로 글로벌 평균보다 낮은 수준인 것으로 보고되고 있다⁷. 한편, 우리나라 데이터센터의 평균 냉방용의 비중은 약 17%로 추정된다(자세한 추정은 3장을 참조). 이렇듯 규모, 기후, 냉각기술 등 여러가지 요인 때문에 데이터센터의 전체 에너지 소비에서 IT 장비와 냉각용이 차지하는 비중은 조사 기관마다 차이가 있다.

일반적으로 데이터센터의 에너지 소비는 DC의 규모가 커질수록 많게 된다. 그러나 에너지효율 측면에서는 규모가 큰 DC일수록 효율이 높다. 이는 규모의 경제(economy of scale) 등으로 냉각, 전력공급, IT 장비 배치, 고효율 냉각 시스템, 에너지 절감형 인프라 투자 등이 대형 데이터센터에서 경제적으로 더 유리하기 때문이다. IEA(2025b)는 데이터센터를 규모를 기준으로 세 가지(자사용, 코로케이션 및 클라우드 서비스 제공용, 하이퍼스케일)로 나누고 있다.⁸ 먼저, 가장 소규모


⁷ Walsh(2024)

⁸ IEA의 분류는 정확히는 규모별 분류는 아니다. 앞에서 살펴보았듯이 자사용과 코로케이션 같은 분류는 소유 형태 및 서비스 제공 방식에 따른 분류이다. 하지만 일반적으로 자사용은 상대적으로 소규모이고, 코로케이션은 초대형 하이퍼스케일과 자사용의 중간 정도의 규모이므로 이처럼 분류한 것으로 보인다.

인 자사용(Enterprise)의 용량은 25MW 정도로, 일반적으로 효율이 낮은 편이며 냉각 시스템이 총 전기 소비의 30% 이상을 차지할 수도 있다. 자사용의 평균 이용률은 20% 미만이며 전력효율지수(PUE)는 약 2 정도이다(PUE는 DC 에너지 성과(효율) 지표 중 하나이다. PUE에 관해서는 추후 자세히 다룬다). 중간 규모의 코로케이션 및 클라우드 서비스 제공 데이터센터는 여러 기업이 공간과 인프라를 공유하는 형태로, 냉각에 사용되는 전기 비중이 자사용 보다는 작지만 하이퍼스케일 보다는 크다. Chauhan(2024)에 따르면 클라우드 데이터센터는 평균적으로 기존 데이터센터보다 에너지 소비가 약 30% 더 많다.

하이퍼스케일 데이터센터는 아마존, Google, Meta, Microsoft와 같은 대형 클라우드 기업이 운영하는 대규모 센터이다. 일반적인 용량은 100MW 이상이며 이는 기존 데이터센터 대비 4배나 더 큰 규모이다. 전체 전력 소비에서 냉각용의 비중은 7% 정도로 대부분의 전력이 서버 및 IT 장비에 사용된다. 효율이 상대적으로 높은 편이며 평균 이용률은 약 50%, PUE는 1.15 미만으로 낮은 편이다 IEA(2025b).

[그림 2-4] 데이터센터 유형에 따른 용도별 전기 소비 비중



자료: IEA(2025b), p53, Figure 2.2

IEA에서는 유형별, 용도별 전기 소비 비중에 관한 구체적인 수치를 제공하고 있지 않지만, 위의 [그림 2-4]를 바탕으로 데이터센터 유형별, 용도별 전기 소비 비중을 계산하면 다음의 <표 2-4>와 같다. 글로벌 데이터센터 전체로는 IT, 냉각용,


기타의 에너지 소비 비중은 약 71%, 19%, 10% 정도이다. IT 에너지 소비의 대부분(약 86%)은 서버에서 발생한다. 비IT 에너지 소비에서 냉각용의 비중은 약 64%를 차지하는 것으로 나타난다. 전체 데이터센터의 에너지 소비에서 냉각용이 차지하는 비중은 규모가 커질수록 작아지는 것을 알 수 있는데, 자사용 DC의 경우는 약 33%이며, 하이퍼스케일의 경우는 7% 수준이다. 반면, 서버의 에너지 소비 비중은 DC 규모와 양의 상관관계를 가진다.

〈표 2-4〉 데이터센터 유형별 용도별 전기 소비 비중

비중, %	IT				Non-IT		
	서버	스토리지	네트워크	계	냉각	기타	계
전체	61.0	5.5	4.5	71.0	18.5	10.5	29.0
자사용(Enterprise)	44.0	4.5	3.5	52.0	33.0	15.0	48.0
코로케이션 및 서비스 공급자	56.0	5.0	4.4	65.4	21.5	13.1	34.6
하이퍼스케일	76.0	6.6	4.9	87.5	7.0	5.5	12.5

자료: IEA(2025b), p53, Figure 2.2를 바탕으로 저자 계산

[그림 2-5] 데이터센터 유형에 따른 전기 소비 추이




자료: IEA, Global data centre energy demand by data centre type.

한편, AI의 확대에 데이터센터의 에너지 소비는 대규모 하이퍼스케일 DC를 중심으로 증가해 오고 있다([그림 2-5] 참조). 반대로 전통적인 DC의 에너지 비중은

빠르게 하락하고 있으며, 상대적으로 중형 클라우드 DC의 에너지 소비 비중은 일정하게 유지되고 있다. 이러한 추세는 최소한 단기적으로는 하이퍼스케일 DC를 중심으로 전기 소비가 증가할 것을 의미한다.

특히, 아래 [그림 2-6]을 보면 2017년경부터 하이퍼스케일 DC의 에너지 소비가 빠르게 증가하고, 구성 요소별로는 서버의 에너지 소비 증가가 전체 에너지 소비를 견인하고 있음을 알 수 있다. 이는 인공지능 연산에 높은 비용의 고효율 냉각 시스템과 대규모 전력 시스템이 요구되기 때문에 규모의 경제를 극대화시키기 위해 DC가 대형화되고 GPU와 같은 가속기의 사용으로 서버의 에너지 소비가 급증했기 때문이다.

[그림 2-6] 전세계 데이터센터 유형별 용량과 장비별 전력 소비 추이




자료: IEA(2025b), p.55, Figure 2.3

1.4. DC의 부하패턴

데이터센터의 일일 부하 패턴은 DC의 성격에 따라 차이가 크게 발생할 수 있다. [그림 2-7]은 미국의 대표적인 두가지 유형의 DC의 일일 평균 부하 프로파일을 보여준다. 왼쪽 그림(a)의 DC는 하루 24시간 내내 일정한(Flat) 부하를 가지며, 부하율이 높은 편이다. 이는 사무실과 같은 보조 부하의 비중이 작은 DC의 경우이며, 따라서 날씨나 시간에 따라 부하가 크게 영향을 받지 않는 경우이다. 반면,

그림(b)는 사무실 등 복합 용도 DC의 사례로 근무시간 동안의 부하가 높으며, 날씨에 따라 전기 소비가 상대적으로 크게 영향을 받는 경우이다. 이러한 유형의 DC는 부하율이 전자 대비 상대적으로 낮다. 이러한 부하 패턴이 데이터센터의 규모, 위치, 제공 서비스 형태 등의 특징과 어떤 관계가 있는지에 관한 연구는 아직 없는 것으로 보인다. 계절성 측면에서 DC의 전력 소비는 여름철 냉방 수요 증가와 함께 상승할 것임은 자명하다. 상승 폭은 DC의 규모뿐만 아니라, 복합 용도의 여부에도 영향을 크게 받을 것으로 판단된다. 일정한 일일 부하를 가진 DC는 계절성이 상대적으로 작은 반면, 복합 용도의 DC는 여름철에 전력 소비가 상대적으로 크게 증가할 것으로 보인다.

[그림 2-7] 미국 데이터센터의 일일 평균 전력 부하 패턴(Flat vs. Mixed-use)




자료: Nøland et al. (2024), p.2, Fig.3

한편, AI 데이터센터(AIDC)의 경우, AI 연산의 특성상 전력 소비의 변동성이 기존의 전통적인 DC보다 크다. [그림2-8]은 비AI 연산과 AI 연산의 부하 패턴을 보여준다. 그림에서 확인되는 바와 같이 AI 작업은 비AI 작업에 비해 변동 폭이 10배가량 클 수 있다. 이러한 AI 작업 부하 패턴의 특성상 전통적인 DC와 AIDC의 부하 패턴 역시 크게 다를 것으로 보인다. 한가지 주의해야 할 점은 [그림2-8]은 특정 AI 연산에 대한 부하 패턴이며 AIDC의 부하 패턴은 아니라는 점이다. AIDC의 부하 변동 폭이 기존의 전통적인 DC 대비 훨씬 클 것임은 자명하지만, AIDC가 24시간 항상 AI 연산만 수행하는 것은 아니다. AIDC의 부하 패턴은 결국 AI

연산이 얼마나 자주 발생하고, 어떤 성격의 AI 작업인가에 따라 크게 차이가 난다. 보다 자세한 AI 연산의 부하 특징은 다음에 다루기로 하고, 이어지는 절에서는 데이터센터의 글로벌 전기 소비량 추정 및 전망에 대해 알아본다.

[그림 2-8] Non-AI vs. AI 부하 패턴 비교



자료: Ontiveros. et. al.(2025.6.25.) Google at OCP EMEA Summit 2025 재인용

2. 글로벌 데이터센터의 전기 소비

2.1. DC 에너지 소비 추정 방법론⁹

데이터센터의 에너지 소비는 실적 자료가 없기 때문에 과거 소비량도 추정할 수 밖에 없다. 최근 들어 데이터센터의 에너지 소비를 추정하는 연구가 활발히 발표되고 있다. IEA 산하 EDNA(Efficient, Demand Flexible Networked Appliances)에서 2025년 3월에 발간한 조사(Survey) 연구(Kamiya & Coroama, 2025)는 2014년 이후 발표된 100편 이상의 논문, 보고서, 통계 자료들을 조사하고 평가하였는데, 연구에서 사용한 방법을 4가지(상향식, 총량 합산, 외삽법, 혼합형)로 구분하였다.¹⁰

⁹ 이 절은 Kamiya & Coroama(2025)의 보고서 내용을 요약, 정리한 내용이다.

¹⁰ Kamiya와 Coroama의 2025년 조사 연구는 현재로서 데이터센터의 에너지 소비량을 추정하는 데 있어 가장 중요한 자료이다. 데이터센터의 에너지 소비 관련한 저급한 분석이 많이 발표되면서 정책 결정에 혼선을 주고 있다는 문제점에서 연구를 시작하였는데, “언론인, 정책입안자와 기타 비전문가는 데이터센터 에너지 추정치의 품질을 비판적으로 평가해야 한다”고 강조하였다. 특히, 극단적인 시나리오를 배척할 것을 권하였다. 이들의 연구에서 데이터센터의 범위는 엔터프라이즈, 코로케이션, 하이퍼스케일 유형이고, 암호화폐 채굴은 제외하였다. 데이터센터의 구성은 서버, 스토리지, 네트워크 장비, 건물 설비(공조설비, 조명)으로 정하였다. 이런 데이터센터의 운영에 필요한 에너지 소비에 초점을 두었다.

주요 방법론과 그 특징은 다음과 같다(〈표 2-5〉)). 첫째, 상향식(Bottom-up)은 데이터센터 설비의 기초 데이터를 수집하여 전력 소비량을 추정하는 방식이다. 서버 용량, 효율 등 하드웨어의 정보를 이용률 등과 결합하여 총 전력 소비량을 추정한다. 상향식 접근법의 장점은 서버 하드웨어와 보급에 관한 정보가 가용하다면 상대적으로 좀더 정확한 에너지 소비량 추정이 가능하다는 점이다. 그러나, 데이터센터의 설비 정보, 하드웨어 관련 정보 등 기초 정보를 수집하기 어렵다는 것이 단점이다. 컴퓨팅 관련 기술의 발전이 빠르고 설비 교체가 빈번하다는 점도 추정의 신뢰도를 떨어뜨리는 요인이다. 상향식 접근법을 사용한 대표적인 사례로는 Science지의 전세계 데이터센터 에너지 소비량 재추정 연구(Masanet et al., 2020), Lawrence Berkeley National Laboratory(LBNL)의 미국 데이터 센터 에너지 사용량 분석(Shehabi et al., 2018, 2024) 등이 있으며, 국제에너지기구(IEA) 역시 서버 출하량을 소비량 추정에 사용하였다(IEA, 2025b).

둘째, 총량 합산(Aggregated Totals) 접근법은 기업 또는 국가의 데이터센터 에너지 소비량 실적 자료를 수집하여 합산하는 방식이다. 이 방법은 설문 조사 또는 기존 통계를 활용하여 지역, 국가 수준의 에너지 소비 총량을 추정한다. 총량 합산 방식은 수행이 비교적 쉽고 비용이 적게 드는 장점이 있지만, 데이터센터의 에너지 소비량을 다른 부문, 예를 들어 건물의 공조, 조명 등에 의한 에너지 소비와 분리하기가 어렵고, 에너지효율에 관한 동향을 파악하기 어렵다는 단점이 있다. 제11차 전력수급기본계획(제11차 전기본)에서의 2023년 데이터센터 전력 소비량 추정이 여기에 해당한다.

셋째, 대리변수 외삽법(Temporal Proxy Extrapolation)은 데이터센터 에너지 소비량을 추정하기 위해 대리변수를 사용하는 방법이다. 예를 들어, 데이터센터의 IP 트래픽, 거시경제 지표(예, 경제 성장, 소비)를 데이터센터 에너지 소비량의 대리변수로 사용하여 이들 변수가 증가할 때 에너지 소비량도 증가하는 것으로 추정할 수 있다. 일반적으로 가용한 자료를 활용할 수 있다는 점이 가장 큰 장점이다. 자료 확보에 투입되는 노력을 절약할 수 있다. 이 방법의 단점은 에너지 소비를 과대평가할 가능성이 높다는 것이다. 과거 1990년대 데이터센터의 에너지 소비 흐름에서 알 수 있듯, 대리변수와 데이터센터의 에너지 소비의 상관관계가 일부 존재한다 하더라도 기술 발전에 따라 효율이 개선되면서 디커플링(Decoupling)이 발생

할 수 있기 때문이다.

넷째, 혼합형(Hybrid) 접근법은 앞서 설명한 세가지 방법을 조합하는 방식이다. 상향식과 총량 합산 방식의 강점을 활용하고, 각각 방식의 추정 결과를 교차 검증하는 데 활용할 수 있다. 그러나 각 방법의 단점을 결합할 위험 역시 존재한다. 대표적으로 IEA는 상향식 추정 결과를 대규모 데이터센터가 보고한 에너지 소비 데이터로 보완하는 혼합형 방식의 추정치를 제시했다(IEA, 2025b).

마지막으로, 앞서 살펴본 4가지 방법이 아닌 기타 방법을 사용하는 사례도 있다. 정량적 시스템 역학 모델링(Quantitative System Dynamics)을 사용한 연구가 있고, 투입-산출 분석을 사용한 연구도 있으나 그 수가 많지는 않다.

〈표 2-5〉 데이터센터 에너지 소비 추정 방법론 비교

방법론	특징/정의	장점	단점
상향식 (Bottom-up)	데이터센터의 기초 데이터를 수집하여 전력 소비량을 추정(서버 용량, 효율 등의 하드웨어 정보를 이용률, PUE 등과 결합)	서버 하드웨어와 보급 등에 관한 정보가 가용하다면 상대적으로 더 정확한 에너지 소비량 추정이 가능	기초정보 수집이 어려움 컴퓨팅 기술 발전이 빠르고, 설비 교체가 빈번하여 추정 신뢰도가 떨어질 수 있음
총량 합산 (Aggregated Totals)	기업 또는 국가의 데이터센터 에너지 소비량 실적자료를 수집하여 합산(설문 조사 또는 기존 통계를 활용)	상향식 방법 대비 수행이 비교적 쉽고 비용이 적게 듭	데이터센터의 에너지 소비량을 건물의 공조, 조명 등 다른 부문의 소비와 분리하기가 어려움. 에너지효율에 관한 동향 파악이 어려움
대리변수 외삽법 (Temporal Proxy Extrapolation)	데이터센터 에너지 소비의 대리변수를 사용하여 소비량을 추정(IP트래픽, 경제성장, 소비 등 거시경제 지표)	일반적으로 가용한 자료를 활용할 수 있어서 비용과 노력이 적게 듭	대리변수와 에너지 소비 간의 상관관계가 디커플링 될 소 있음(설비의 효율 개선이 빠르기 때문에 에너지 소비량을 과대 평가할 가능성이 높음)
혼합형 (Hybrid)	위의 세 가지 방법을 조합	각 방식의 추정 결과를 교차 검증하는 데 활용 가능	각 방법의 단점을 결합할 가능성

자료: Kamiya & Coroama(2025)의 내용을 바탕으로 저자 정리

2.2. 데이터센터 에너지 소비 추정의 품질 평가¹¹

데이터센터 에너지 사용량 추정은 방법론과 투명성에 따라 그 품질이 크게 달라진다. Kamiya & Coroama(2025)는 (1) 사용한 방법의 품질, (2) 사용한 데이터의 품질, (3) 자료를 추정하는 과정에서 채택한 가정의 적절성과 같은 세가지 기준을 설정하여 기존 연구의 품질을 평가하였다¹². 보고서에서 구체적인 평가 기준을 제시하지는 않았으나 평가 결과를 살펴보면, 방법에 있어서는 상향식 방법을 가장 높게 평가하고 다음으로 총량 합계 방식, 그리고 대리변수 외삽 방식을 가장 낮게 평가하였다. 하이브리드 방식은 중간 정도로 평가했다. 방법론을 가장 큰 기준으로 놓고, 다음으로 데이터 품질에 있어서 최신의 자세한 측정 통계를 가장 높게 평가했고, 가정을 바탕으로 추정한 통계를 낮게 평가하였다. 마지막으로 자료를 추정하는데 가정을 사용했다면 그 가정이 데이터센터 업계의 추세를 적절하게 반영했는지 여부를 따져 품질을 평가하였다.

데이터의 품질과 가정의 적절성은 추정 통계의 품질을 평가하는데 있어서 직관적으로 동의할 수 있는 기준이다. 사용한 방법의 품질에 관해 상향식의 접근이 가장 우수하다고 보았는데, 이와 관련해서 저자들은 상향식 방법으로 도출한 백캐스팅의 결과가 다른 방법과 비교하여 실적치에 더 근접했기 때문에 방법적으로 우수하다고 밝혔다. 상향식 방법이 총량 합계나 대리변수 외삽 방식에 비해 더 신뢰할 만하다는 점은 다른 문헌들도 대체로 동의하고 있다(Masanet et al., 2024).

방법론, 데이터, 가정의 적절성과 함께, 에너지 소비량 추정의 품질을 평가할 때 추가로 고려해야 하는 점은 결과 보고의 투명성, 불확실성 검토를 위한 민감도 분석의 여부, 그리고 데이터센터와 IT 업계 전문가의 의견 반영 여부 등이다.

Kamiya & Coroama(2025)는 이러한 문헌 조사와 평가를 통해 추후 데이터센터 에너지 소비량 추정을 위한 제언을 하였는데, 다음과 같이 정리할 수 있다. 첫째, 추정 방법과 사용 데이터의 품질이 가장 중요하다. 측정된 고품질 데이터를 가지고 상향식 방법을 사용하는 것이 바람직하다. 오래된 데이터와 가정에 기반한 데이터의 사용은 당연히 피해야 한다. 상향식 방법은 좀 더 정확한 추정치를 제공

¹¹ 이 절은 Kamiya & Coroama(2025)의 보고서 내용을 요약, 정리한 내용이다.

¹² 이때 두 저자는 객관적인 기준과 척도를 적용한 것은 아니고 두 연구자가 각각 주관적으로 6점 척도로 평가 점수를 부여한 뒤에 두 결과를 맞혀보면서 최종 평가를 도출하였다.

할 뿐만 아니라, 데이터센터의 하드웨어 요소와 에너지 사용량에 대한 통찰을 제공하여 미래 하드웨어 기술 발전에 따른 전망을 가능하게 해주는 장점이 있다. 반면에 총량 합산이나 대리변수 외삽과 같은 방법은 적은 데이터를 가지고도 수행이 가능하지만, 과거 인터넷 보급기에 전기 소비량이 둔화되었던 것처럼 데이터 서비스 수요와 전력 사용량 간의 연관성이 약해지면서 과대 추정의 가능성이 존재한다. AI 데이터센터의 핵심인 GPU 반도체를 포함하여 IT 부문의 기술이 매우 빠르게 발전하고 있기 때문이다. 둘째, 사용 방법과 데이터 출처, 그리고 세부사항을 투명하게 공개해야 한다. 특히 분석 대상이 되는 데이터센터의 시스템 경계를 명확하게 정의해서 제시해야 한다. 데이터센터의 시스템 경계 범위에 따라 에너지 소비량은 크게 달라질 수 있다. 어떠한 유형의 데이터센터를 포함 또는 제외했는지, 그리고 암호 화폐 채굴이 포함되었는지 여부를 밝혀야 한다. 셋째, 불확실성을 평가할 수 있는 시나리오 분석 또는 민감도 분석이 이루어져야 한다. 데이터센터의 에너지 소비는 추정에 의존할 수밖에 없고, 따라서 불확실성이 크다. 적용 방법에서 불확실성의 요소를 식별하고 그에 따른 시나리오와 민감도 분석을 제공하여 불확실성의 정도를 보여줘야 한다. 넷째, 경제적, 기술적, 사회적 제약을 고려하고 이를 반영해야 한다. 예상 비용, 전력망 가용성, 사회적 수용성 등 다양한 제약 조건을 고려함으로써 추정치의 설명력을 제고할 수 있다. 우리나라의 경우 전력 공급원의 지역 편중 분포도 에너지 소비 추정의 주요한 고려사항이 될 수 있다. 다섯째, 현업 전문가의 자문과 검토를 반영해야 한다. IT 업계는 매우 빠르게 변하고 있기 때문에 현업 종사자의 의견을 반드시 청취하여 현재의 상황을 반영할 필요가 있다.

2.3. 글로벌 DC 에너지 소비 동향 및 전망


2.3.1. 글로벌

글로벌 데이터센터의 에너지 소비가 처음으로 급격하게 증가하기 시작한 것은 1990년대 인터넷 혁명 시기부터다. 개인용 컴퓨터와 인터넷 통신망이 빠르게 보급되고, 인터넷 사용자가 급증하면서 데이터의 처리와 저장 수요가 폭발적으로 늘어났다. 하지만, 2007~2008년경을 기점으로는 데이터센터 전력 소비 양상에 중

요한 변화가 나타났는데, 전산 서비스 수요는 계속 급증했지만 데이터센터의 전력 소비 증가세는 크게 둔화된 것이다. 2010~2018년 기간 동안 글로벌 데이터센터의 컴퓨터 용량이 550% 증가했음에도 불구하고, 글로벌 데이터센터의 전기 소비량은 6% 증가에 그쳤다(Masanet et al., 2020). 이러한 탈동조화(decoupling) 현상의 주요 원인은 데이터센터의 대형화와 컴퓨터 하드웨어의 효율 개선이었다. 전산 처리 용량 증가에 따라 기업 단위의 소규모 데이터센터(enterprise data center)에서 효율이 높은 대형 전문 데이터센터로의 이전이 가속화하면서 단위 데이터당 전력 소모가 크게 감소하였다.

한편, 2015년경부터는 클라우드 컴퓨팅이 빠르게 성장하고, 유튜브와 넷플릭스로 대표되는 온라인 미디어 소비와 SNS의 광범위한 확산으로 인해 데이터 서비스 수요가 증가하기 시작했다. 특히, 최근에는 생성형 인공지능의 부상과 함께 GPU를 탑재한 서버의 용량이 빠르게 증가하며 전력 소비 증가세가 가속되고 있다. 이를 반영하듯 2018년부터 2023년 사이에는 대형 데이터센터들의 전력 소비가 3배 이상 증가하였다(Kamiya & Coroama, 2025).

[그림 2-9] 시대별 데이터센터 에너지 소비 증가세




Kamiya & Coroama(2025)에 따르면 고품질 글로벌, 지역 및 기업 수준의 데이터를 종합하였을 때 2023년 기준 전세계 데이터센터의 전력 소비량은 암호화

페 채굴 투입을 제외하고 300~380TWh로 추정된다. 지역별로는 북미의 소비가 125~200TWh로 가장 큰 비중을 차지했고, 아시아태평양 지역이 105~180TWh, 유럽이 55~80TWh, 기타지역은 5~10TWh를 소비한 것으로 조사되었다.

다만 이러한 글로벌 데이터센터 에너지 소비량 추정에서 불확실성은 매우 큰 것으로 나타났다. 데이터센터의 전력 소비량을 직접 집계하는 통계가 아직 없기 때문에 모두 추정에 의존할 수밖에 없는데, 앞서 살펴본 추정 방법, 기초 자료 등에 따라 큰 차이를 보인다. 특히, 국가 수준의 추정에서도 불확실성이 큰데 글로벌 수준의 데이터센터 전력 소비량 추정의 불확실성은 더 클 수밖에 없다. 2022년 글로벌 데이터센터의 전력 소비를 추정한 주요 연구의 결과를 보면 최소 200TWh에서 최대 약 1,300TWh까지 그 차이가 매우 크다([그림 2-10]). 다수의 추정 결과는 대체로 200~400TWh 범위에 분포하고 있다. 데이터센터의 전력 소비량은 추정에 의존할 수밖에 없는 만큼 그 결과를 사용할 때 불확실성에 유의할 필요가 있다.


[그림 2-10] 주요 연구의 2022년 글로벌 데이터센터 전력 소비 추정 결과 비교



자료: Kamiya & Coroama(2025), p.19, Figure 3.2

IEA(2025b)도 DC 전력 수요 전망의 불확실성을 보여주는 그래프를 제시하고 있다. 수집할 수 있는 추정 결과를 나열해 보면, 범위가 약 200TWh에서 2,000 TWh까지 넓게 분포하고 있다([그림 2-11]). 주로 상향식 방법을 채택한 고품질의 연구결과만 보면 범위가 약 200~500TWh 수준으로 축소되고, 다시 주요 빅테크 기업들의 데이터센터 자료를 활용하여 추정하면 그 범위가 더 축소된다. 이 때문에 IEA는 상향식 방법을 사용하여 1차로 추정하고 기업 수준의 자료를 활용하여 범위를 조정하는 하이브리드 방식으로 글로벌 데이터센터 전력 소비량을 추정하였다. IEA가 추정한 2023년과 2024년의 글로벌 데이터센터 전력 소비량은 각각 361TW, 415TWh로 전세계 총 전력 소비량의 약 1.5%에 해당한다.

[그림 2-11] 2023년 전세계 데이터센터 전력 소비 추정 결과 비교




자료: IEA(2025b), p.61, Figure 2.9

IEA(2025b)는 데이터센터의 전력이 2024~2030년 기간 연평균 약 15%씩 증가하여 2030년에는 945TWh에 도달할 것으로 전망하였다. 기준(Base) 전망에 따르면 현재 전체 전력 소비량의 약 1.5%를 차지하는 데이터센터의 전력 소비량 비중은 2030년에는 약 3%로 2배 정도 상승한다. 기준 전망은 전세계 데이터센터의 가중평균 PUE가 1.41에서 1.29로 개선되고, IT 전력 사용 단위당 냉각 요구량은 약 30% 절감될 것이라는 전제하에서 작성되었다. 또한, 인공지능의 보급 확

대를 감안하여 2025년부터 2030년까지 데이터센터 전기 수요 증가분의 약 70%가 GPU를 탑재한 서버에서 발생한다고 전제하였다. IEA는 기준 전망안에 더해 민감도 분석 차원에서 Lift-off case(인공지능이 더 빠르게 보급되는 시나리오), High efficiency case(기준안과 수요는 동일하나 효율만 개선되는 시나리오), Head-wind case(인공지능 수요가 둔화되고 투자가 위축되는 시나리오)를 함께 제시하였다. 아래 [그림 2-12]에서 확인할 수 있듯이 각 시나리오에 따른 전망의 범위(2030년에 약 700~1,300TWh)는 상당히 크며 2030년 이후로는 전망의 불확실성이 증폭되는 것으로 나타났다.

[그림 2-12] IEA의 시나리오별 전세계 데이터센터 전력 수요 전망




자료: IEA(2025b), p.67, Figure 2.14

2.3.2. 미국

데이터센터에 관해 논의하면서 소위 빅테크 기업들이 모여 있는 미국을 빠뜨릴 수 없다. 사실상 미국이 인터넷 혁명을 주도하였고, 현재의 AI 전환도 미국이 주도하고 있다. 미국에서는 에너지부 산하 로렌스 버클리 국립연구소(Lawrence Berkeley National Laboratory, LBNL)가 주도적으로 데이터센터의 전력 소비 추정에 관한 연구를 수행해 왔고, 이미 2016년에 “미국 데이터센터의 에너지 사용량”이란 보고서를 발표하였다. LBNL은 매년 출하되는 GPU 출하량 정보를 활용하

여 상향식으로 데이터센터 전력 사용량을 추정하였다. 2024년 12월에 발표한 최신 보고서(Shehabi et al., 2024)에 따르면 2018년 미국 데이터센터의 소비량은 약 70TWh로 미국 전체 전력 사용량의 1.9% 비중을 차지하였다. 다른 나라들의 평균적인 비중이 약 1.5% 수준임을 고려할 때 비중이 훨씬 큼을 알 수 있다. 2023년에는 약 176TWh(암호화폐 채굴 사용량 제외)로 전체 소비량의 4.4% 정도를 소비한 것으로 추정하였고, 현재의 추세를 고려할 때 2028년에는 325~580TWh까지 증가할 것으로 전망하였다(미국 전체 전력 사용량 전망에서 차지하는 비중은 6.7~12.0% 수준).

[그림 2-13] 미국 데이터 센터의 총 전력 사용량(2014~2028)



자료: Shehabi et al. (2024), p.5, Figure ES-1

2023년의 데이터센터 전력 사용량 중 약 40TWh가 AI 전용 서버에서 소비될 것으로 예상하였고, 2028년에는 AI 전용 서버의 소비량이 약 165~325TWh 수준일 것으로 전망하였다. 데이터센터의 전력 소비량 증가 속도를 살펴보면 2014년부터 2018년까지는 연평균 약 7%씩 증가했고, 2018년부터 2023년까지는 약

18%, 그리고 2023년부터 2028년까지는 13~27%로 점점 빠르게 증가할 것으로 전망하고 있다. 이러한 결과는 LBNL 분석을 전 세계로 확장한 Masanet et al. (2020)에도 반영되어 있다.

2.3.3. 중국


중국은 AI를 국가 전략 산업으로 정하고 이를 육성하기 위해 국가 주도하에 데이터센터 인프라를 확충하고 있다. 중국의 데이터센터는 2023년 말 기준으로 총 449개가 있으며 대부분 동부 연안 지역에 위치한 것으로 알려졌다(Carbon Brief, 2025). 중국의 데이터센터 전력 소비량에 관해서는 여러 연구 결과가 나와 있는데 불확실성이 매우 크다. 특히 네트워크 소비량을 포함했는지 여부가 불확실하여 편차가 크게 나타난다. 2025년 2월 발간된 IEA의 보고서(IEA, 2025a)는 중국 데이터센터의 전기 소비량을 2023년 70~130TWh로 추정하고, 2027년 180~340TWh, 2030년 260~470TWh로 전망했다. IEA는 글로벌 데이터센터 전력 소비량 추정과 마찬가지로 GPU 등 데이터센터 하드웨어의 정보를 사용하여 상향식으로 추정하였다. 2025년 4월 발간된 IEA 보고서(IEA, 2025b)는 2023년과 2024년의 전기 소비량을 각각 84TWh, 102TWh로 추정하였고, 2030년은 약 277TWh 수준으로 전망하였다.

중국 국무원의 2024년 발표에 의하면 2022년 중국 데이터센터의 전기 소비량을 약 77TWh로 집계(중국 총 전기 소비의 0.9%)하고, 2025년에는 150~200TWh(총 전기 소비의 약 1.5~2.0%)로, 2030년까지는 연평균 10% 증가해 400TWh(총 전기 소비의 약 3.7%)에 도달할 것으로 전망하고 있다(韩雪, 2024.5.20.; Carbon Brief, 2025; IEA, 2025a).

IEA와 중국 국무원의 발표를 종합해 보면 2022~2023년경에 중국 데이터센터의 전력 소비량은 대략 70~80TWh 수준이었으나 최근 몇 년 사이에 빠르게 증가하고 있다. IEA가 조금 더 보수적으로 보았고, 국무원은 더 많이 증가한 것으로 보았다. 2030년까지의 전망 관련해서 중국 국무원은 400TWh로 보았으나, IEA는 300TWh 이하로, 400TWh가 넘을 가능성은 낮게 보았다. 추정치도 불확실성이 크지만, 전망의 불확실성은 더 크게 나타나고 있다.

그린피스, 산업정보화부, 국가 기후변화 전략연구 국제협력센터가 공동으로 발표한 2021년 보고서(Greenpeace, 2021)는 2035년까지 중국 데이터센터의 전력 소비량이 451~486TWh에 달할 것으로 전망하고 있다. 골드만삭스는 2030년에 중국 데이터센터의 전력 수요가 600TWh 정도가 될 것으로 굉장히 높게 잡았다(Carbon Brief, 2025). 여기서도 네트워크 소비량, 그리고 기타 통신 관련 소비를 포함했는지 여부가 불확실성의 핵심으로 보인다.

[그림 2-14] 중국 데이터 센터의 전력 사용량 추정 결과 비교(2015~2030)



주: 몇몇 연구는 분명하게 텔레커뮤니케이션의 네트워크 전력 소비를 포함한 것으로 보인다(점선으로 표시). 개별 연구의 출처 정보는 IEA(2025a)에서 확인 가능하다.


자료: IEA(2025a), p.27

2.3.4. 유럽

EU 국가들의 DC 에너지 소비에 관한 기존 연구들을 정리한 최근 연구로는 Kamiya & Bertoldi(2024)를 들 수 있다. 이 연구에서는 2018년 이후 행해진 EU-27 국가들의 DC 에너지 소비량 추정 연구들을 종합하여, 2022년 기준 EU 전체 전기 소비량의 1.8~2.6%에 해당하는 45~65TWh의 전기가 데이터센터에서

소비되었다고 추정했다. 데이터센터 전기 소비가 가장 많은 EU 국가는 독일(15TWh)이었고, 다음으로 프랑스(10TWh), 네덜란드(6TWh), 아일랜드(5TWh) 순으로 나타났다¹³. 이들 네 나라가 EU 전체 데이터센터 전기 소비의 2/3가량을 차지하는 것으로 조사되었다(Kamiya & Bertoldi, 2024).

[그림 2-15] EU의 데이터센터 전력 수요 추정과 전망 결과 비교(2010~2030)



자료: Kamiya & Coroama(2025), p.25, Figure 3.4

주: 진한 원은 과거 추정치, 밝은 원과 점선은 전망치임. 오차 막대는 시나리오에 포함된 범위이다. 암호화폐 채굴은 제외하였다. 개별 연구의 출처는 Kamiya & Coroama(2025)에서 확인할 수 있다.

한편, 국가별 전체 전기 소비에서 데이터센터가 차지하는 비중은 2022년 기준 아일랜드(18%), 네덜란드(5.2%), 룩셈부르크(4.8%), 덴마크(4.5%), 독일(3%), 스웨덴(2.3%), 프랑스(2.2%) 순이었으며, EU 국가들의 평균 데이터센터 전기 소비 비중은 2.2%로 나타났다(Kamiya & Coroama, 2025).

데이터센터의 전력 소비량이 국가 전체 전력 소비량에서 차지하는 비중에 관한 정보는 대리변수 외삽 방식으로 데이터센터 전력 소비량을 추정하는 경우에 유용

¹³ 국가별 DC의 전기 소비량은 복수의 연구들에서 추정된 값들을 신뢰도 등을 고려하여 가장 평균한 것으로 판단된다. 네덜란드와 아일랜드의 전기 소비량 수치는 연구에서 제공되지 않았으며, 제시된 표와 그림을 바탕으로 저자가 삽입한 어림값이다.

할 수 있다. 미국의 빅테크 기업들이 대거 위치해 있는 아일랜드의 경우는 그 비중이 18%로 이는 매우 이례적이라 할 수 있고, 대체로 1.5%에서 5%의 비중 분포를 보인다. 글로벌 수준에서 데이터센터의 전력 소비량 비중은 1.5%였고, 우리나라는 2023년 기준 0.9% 정도이다(3장 참조).

〈표 2-6〉 IEA의 지역별 데이터센터 전력 소비량 추정과 전망

	2020	2023	2024	2030(전망)
총전력 소비량(TWh)				
전세계	269	361	416	946
북미	112	158	187	434
미국	108	154	183	426
중미와 남미	1.5	1.5	1.7	3.3
유럽	57	66	68	113
아프리카	1.1	1.3	1.4	2.9
중동	1.1	1.3	1.5	3
아시아	93	128	150	378
중국	62	84	102	277
IT 전력 소비량(TWh)				
전세계	176	252	295	733
북미	80	120	142	351
미국	78	117	139	345
중미와 남미	0.8	0.8	1	2.2
유럽	36	45	47	88
아프리카	0.6	0.7	0.8	1.8
중동	0.5	0.7	0.8	1.7
아시아	55	82	100	281
중국	37	54	68	205

주: 반올림으로 인해 합계의 차이가 발생할 수 있음

자료: IEA(2025b), p.260, Table A.4

3. 인공지능(AI)과 에너지 소비

3.1. AI의 종류 및 발전 단계


OECD는 인공지능(AI, Artificial Intelligence) 시스템을 “명시적 또는 암묵적 목적을 위해 입력된 입력을 정보를 바탕으로 예측, 콘텐츠, 추천, 물리적 또는 가상 환경에 영향을 미칠 수 있는 의사 결정과 같은 출력을 생성하는 방법을 추론하는 기계 기반 시스템”으로 정의한다.¹⁴ 인공지능 기술은 2017년 트랜스포머(Transformer)라는 새로운 아키텍처(Architecture)가 개발되면서 빠르게 발전했다. 그 결과 대규모 언어모델(LLM)을 기반으로 ChatGPT, Claude, Gemini, Grok, Perplexity, Copilot 등의 AI 서비스가 등장했다. 최근에는 단순히 사용자의 명령에 응답하는 수준이 아니라, 사용자가 과업과 목표를 설정하면 스스로 과제를 분석하여 워크플로어(Workflow)를 구성하고, 사용 가능한 도구들을 활용하여 작업을 자율적으로 수행할 수 있는 “AI 에이전트” 개발로 이동하고 있다. 구글은 음성과 영상을 통해 사용자와 상호 작용할 수 있는 AIE이전트 아스트라(Astra)를 공개하였고, 더 나아가 조사 수집, 제품 구매, 항공편 예약 등을 포함한 다양한 작업을 수행할 수 있는 AIE이전트 서비스를 개발 중이다.

3.1.1. 기술기반 AI 분류

AI는 여러 기준에 따라 분류할 수 있는데, 기술적 분류에 따른 대표적인 유형으로는 머신 러닝(Machine Learning), 딥 러닝(Deep Learning), 자연어 처리(Natural Language Processing)가 있다. 머신 러닝(ML)은 알고리즘을 통해 데이터의 패턴을 학습하고 매번 특정 프로그래밍 없이 결과를 예측하는 분야이다. 딥 러닝(DL)은 머신 러닝의 하위 분야로 인간 두뇌의 구조를 모방한 대규모 신경망을 활용해 복잡한 패턴을 인식하고 정교한 결정을 내리는 분야이다. 자연어 처리(NLP)는 인간의 언어를 이해하여 해석하고 결과를 생성하는 분야의 AI이다.

¹⁴ “An AI system is a machine-based system that, for explicit or implicit objectives, infers, from the input it receives, how to generate outputs such as predictions, content, recommendations, or decisions that can influence physical or virtual environments.” (OECD, 2024, p.4)

[그림 2-16] 기술기반 AI 분류



자료: Syracuse University School of Information Studies.

모델의 활용 분야, 구조, 학습 방식 등에 따라 AI 모델은 LLM, GAN, CNN, Transformer 등으로 분류되기도 한다. 대표적인 LLM(Large Language Model) 모델은 자연어 처리(NLP)에 특화된 모델이다. GAN(Generative Adversarial Network)은 두 개의 신경망이 경쟁하면서 학습하는 구조의 모델로서 이미지 생성 등에 특화되어 있다. CNN(Convolutional Neural Network)은 합성곱(Convolution) 계층으로 특징을 추출하는 모델로 이미지 및 영상 분석과 패턴 인식에 주로 활용된다. Transformer는 신경망 계열로 LLM 아키텍처의 기반이 되는 자연어 처리에 특화된 모델이다.

3.1.2. AI의 발전단계

한편, OECD(2025)는 9가지 핵심 역량을 기준으로 AI의 발전을 5 단계로 분류하고 있다. 핵심 역량은 언어, 사회적 상호작용, 문제해결, 창의성, 메타인지 및 비판적 사고, 지식·학습·기억, 시각, 조작, 로봇 지능이다. 발전 단계는 키워드 매칭과 같은 기초적이고 정형화된 기능의 레벨 1에서 인간과 완전히 동등하고 초인적인 잠재력을 가진 레벨 5까지로 분류된다. OECD에 따르면 현재 AI 시스템은 2~3

레벨(단계) 수준으로 평가된다.

〈표 2-7〉 AI 발전 단계

단계	주요 역량
1 단계	지식이나 추론 능력이 없이 키워드 매칭이나 기본적인 인식을 통해 작업을 수행하며, 환경에 대한 적응 능력이 제한적
2 단계	반정형화된 환경에서 잘 정의된 작업을 수행하며, 단순한 움직임을 결합하여 감정을 표현하거나, 정량적 분석과 함께 공간적/시간적 관계 같은 정성적 추론 가능
3 단계	고급 역량 및 현재 최첨단 단계. 상당한 가치, 참신함, 때로는 놀라움을 주는 출력을 생성
4 단계	인간 수준에 근접한 다재다능함. 복잡한 사회적 환경에서 상호작용을 해석하고 문제를 식별
5 단계	미묘한 언어 능력과 실시간 세계 지식, 비판적 사고를 통합하고 모든 형태의 인간 지능을 모방. 자율성, 진정성, 완전한 주체성을 가지며, 세계적 수준의 인간 창작자와 동등한 변혁적인 결과물을 창출

자료: OECD(2025)의 내용을 재구성

〈표 2-8〉 AI 핵심 역량 및 현 수준

능력 지표	정의	현단계
언어	인간의 언어를 이해하고, 해석하며, 생성하는 능력	3
사회적 상호작용	동적인 대인 관계 상황에서 사회적 신호를 인지하고, 해석하며, 적절하게 대응하는 능력	2
문제 해결	분석, 예측, 설명, 반사실적 사고를 포함하여 정성적, 정량적, 논리적 정보를 다단계 추론을 통해 통합하는 능력	2
창의성	문제 해결 및 예술적 표현과 관련하여 가치, 참신함, 변혁성(transformativity), 놀라움을 가진 결과물을 생성하는 능력	3
메타인지 및 비판적사고	자신의 추론 과정을 평가하고, 확신 수준을 조절하며, 복잡한 작업에서 관련 정보를 식별하는 능력	2
지식, 학습, 기억	다양한 출처로부터 정보를 획득하고, 목표 추구를 위해 학습하며, 경험을 통계적 또는 상징적 분석을 통해 일반화하는 능력	3
시각	광범위한 시각적 조건과 환경 속에서 시각적 장면을 해석하는 능력	3
조작	환경 내 객체와 상호작용하는 물리적 능력으로, 물리적 움직임, 촉각/시각 등 필요한 인지(perception) 피드백, 움직임을 계획하고 조정하는 인지 능력	2
로봇 지능	자연 환경에서 자율 에이전트(autonomous agent)로서 행동하는 능력	2

자료: OECD(2025)의 내용을 재구성

3.2. 인공지능 연산방식과 에너지 소비¹⁵

기존 컴퓨터의 연산방식은 데이터를 순차적으로 처리하는 방식인데 반해, AI는 수많은 데이터를 동시에 병렬로 처리하기 때문에 에너지 소비가 더 크다. AI 모델 운영은 크게 학습(Training)과 추론(Inference)으로 나눌 수 있다. 학습(또는 훈련)은 AI모델이 데이터를 통해 스스로 배우는 과정이며, 추론은 그 학습 결과를 바탕으로 실제 문제 해결에 활용하는 과정이라고 할 수 있다. 첫 번째 학습 단계에서 AI 모델은 대규모 데이터셋을 이용해 반복적인 계산(예, 역전파 알고리즘)을 통해 모델의 내부 파라미터(가중치와 편향 등)를 최적화한다. 두 번째 추론 단계에서는 이미 학습된 모델을 실제 서비스나 응용 프로그램에 적용하여 새로운 데이터에서 결과를 도출한다. 추론은 실제 AI 모델이 적용되어 사용되는 과정이라고 할 수 있다.

예를 들어, 학습은 ChatGPT의 경우 대규모 텍스트 데이터를 이용해 언어 모델이 문장의 패턴, 문법 등을 학습해 모델의 최적 내부 파라미터를 도출하는 과정이다. 이 과정은 엔비디아의 H100 GPU 같은 고성능 반도체 수천 개를 이용해 수 주에서 수 개월간 진행된다. 학습이 완료되면 AI 모델은 이용자의 질문에 대해 실시간으로 문장을 생성하여 답변을 제시하는 데 이 과정을 추론이라고 할 수 있다.

또 다른 예로 자율주행을 들 수 있다. 자율주행 인공지능의 경우 학습은 다양한 모델 측면에서 이뤄진다. 보행자 인식 모델의 학습에서는 수많은 도심 주행 영상을 통해 운전 중 보행자가 나타나는 모습을 수집해 모델이 실시간으로 보행자를 인식할 수 있도록 한다. 차선 인식 모델의 학습에서는 다양한 날씨나 조도 상태에서의 수많은 차선 정보를 수집하고 모델이 여러 형태의 차선을 정확히 구분할 수 있도록 한다. 신호등이나 교통 표지판 인식 모델의 학습에서는 전 세계 다양한 국가의 신호등 및 표지판 이미지를 통해 다양한 교통 규칙을 인식할 수 있도록 훈련한다. 주행 행동 모델 학습에서는 사람이 실제 운전한 데이터를 기반으로 특수한 상황(예를 들어 앞차와의 거리가 빠르게 좁혀질 때, 교차로나 커브에 진입할 때 등)에서 어떻게 행동했는지를 학습한다. 이러한 여러 자율주행 모델이 학습이 되면 이용자는 추론 과정을 통해 자율주행을 이용하게 된다. 자율주행의 AI의 추론은 차량 전방의 카메라나 센서로 보행자를 감지하거나 신호등의 색깔이나 교통 표지

¹⁵ 에너지 수요를 발생시키는 AI 기술의 전산학적 특성은 부록 1절을 참조하기 바란다.

판 인식을 통해 브레이크를 작동한다던 지, 차선 정보를 추론하여 차량의 현재 위치를 판단하고 차선 이탈 시 핸들 조정, 이 밖에 여러 위험 및 돌발 상황을 예측하고 이에 대응하는 작업 등이 모두 추론 과정에 포함된다고 할 수 있다.

3.2.1. 학습과 추론

학습(훈련)은 모델이 방대한 입력 데이터를 이용해 패턴과 특징을 스스로 파악하는 단계인데, 모델의 파라미터와 입력 토큰(token)¹⁶의 수가 많아 학습에 걸리는 시간을 줄이기 위해서 다수의 장치를 병렬로 실행하는 분산 훈련 방식을 사용한다. AI에 쓰이는 반도체는 기존 프로세서 대비 연산이 가속되었다고 하여 하드웨어 가속기(accelerators)라고 불리는데, 대표적인 가속기에는 GPU, TPU, ASIC 등이 있다. 학습은 추론 대비 단일 작업당 훨씬 많은 연산이 필요하고 이를 위해 고성능의 가속기를 오랜 시간 운용하기 때문에 에너지 소비가 상대적으로 크다(Masanet et al., 2020). 반면, 추론은 학습보다 단위 연산당 에너지 소비가 적지만, 사용자 요청에 따라 매우 빈번하게 이루어지기 때문에 전체 에너지 소비는 훨씬 클 수 있다(Castro, 2024). 다시 말해, 단일 연산 기준으로 보면 학습은 매우 에너지 집약적이지만, 전체 서비스 관점에서는 추론 연산의 빈도와 규모에 따라 전체 에너지 소비가 크게 달라질 수 있다.

일반적으로 학습이 일회성인데 반해 추론은 반복적으로 수행되므로, 많은 연구에서 AI 모델 이용에 들어가는 에너지 소비의 대부분이 추론 단계에서 발생한다고 보고하고 있다. 실제로 Amazon, NVIDIA 와 같은 기업들의 기술 보고서 등의 연구에서는 전체 AI 시스템의 머신 러닝 비용 중 추론 비용이 90%를 차지한다고 추정한다(Desislavov et al., 2023). Luccioni et al.(2024)는 다양한 범주의 ML 모델들을 이용해 학습과 추론에 따른 전기 소비를 추정했는데, 모델의 크기에 따라 차이가 있기는 하지만 약 2~5.9억 건의 추론이 수행되면 각 모델의 학습과 추론에 소비되는 전기 소비가 비슷해지는 것으로 추정했다. 이는 ChatGPT 월간 활성 사용자 수가 약 8억 명 이상으로 추정되는 것을 고려하면, 사용자당 쿼리(Query)가 한 번만 발생한다고 가정하더라도 ChatGPT의 경우 약 한 달이 지나

¹⁶ 토큰은 자연어 처리(NLP)에서 텍스트를 구성하는 최소 단위로 평균적으로 0.75 영어 단어와 대응된다.

면 추론에 소비되는 전기 소비량이 학습에 소비되는 전기를 초과한다는 의미이다. 그렇다면 AI의 발전과 보급 확장에 따른 에너지 소비는 어떻게 될까? 대부분의 연구를 보면 컴퓨터의 연산 능력 향상과 함께 에너지 효율성 또한 증가할 것이라는 것은 자명하다. 하지만 AI 이용 빈도가 기하급수적으로 증가할 경우 AI 연산에 따른 에너지 소비(특히, 추론)가 얼마나 증가할지는 예측하기 매우 힘들다.

〈표 2-9〉 AI 학습(훈련) vs. 추론

구분	학습 (Training)	추론 (Inference)
목적	모델이 데이터를 통해 패턴을 학습하고 파라미터를 최적화함	학습된 모델을 활용해 사용자의 요청에 대한 응답 생성
입력	대규모 학습용 데이터셋	새로운 사용자 입력 또는 테스트 데이터
출력	최적화된 모델(가중치, 구조 포함)	예측값, 분류 결과 등
연산량	매우 큼(수주~수개월의 GPU 연산 필요)	비교적 적음(단일 요청당 수 밀리초~초 단위 연산)
자원요구	고성능 GPU/TPU, 대규모 메모리 및 저장소	경량화된 하드웨어 또는 엣지 장치에서도 가능
빈도	1회 또는 주기적 재학습	실시간 다수 요청에 반복 수행
에너지 소비	단일 실행 기준 매우 높음	개별 소비는 적지만 누적 시 총량이 클 수 있음
예시	GPT-4 모델 학습, 이미지 분류기 학습	챗봇 응답 생성, 사진 속 인물 인식

자료: 저자 정리


에너지 소비 측면에서 학습은 대체로 추론 대비 유연성이 낮다고 할 수 있다. 학습은 일단 시작되면 일부 계산 강도를 조절하는 것은 가능하나, 원하는 시간에만 학습하거나 학습을 일시 중단하는 것이 쉽지 않기 때문이다.¹⁷ 이는 학습 시 가능한 최대(peak) 전력이 발생하는 시간을 피해야 한다는 것을 시사한다. 추론의 경우 유연성은 AI의 성격에 따라 달라질 수 있다. 대규모 언어 모델(LLM)이나 보편적인 목적으로 널리 사용되는 ChatGPT 등과 같은 AI는 사용자의 추론 요청을 사

¹⁷ AI 학습을 중간에 멈추는 것이 기술적으로 불가능하지는 않다. 예를 들어, 딥 러닝 모델이 오버피팅(overfitting)되는 것을 방지하기 위해 검증 손실(validation loss)이 더 이상 개선되지 않을 때 학습을 조기 종료(early stopping)하는 기법 등이 존재한다. 그러나 훈련에 소모되는 막대한 금전적, 시간적 비용을 고려하면 현실적으로 학습을 중간에 중단하는 것은 쉽지 않다.

용량이 적은 시간으로 조정하기 어려우므로 유연성이 떨어진다. 반면, 기업의 특정 AI나, 특수 목적의 AI는 상대적으로 유연성이 높다고 할 수 있다.

한편, Facebook(메타) AI팀의 연구(Wu et al., 2022)는 머신 러닝 모델 개발과 배포를 데이터 처리, 실험, 학습, 추론의 4단계로 나눈다. 데이터 처리는 데이터의 특징을 추출하고 모델의 최적화를 위해 개별 특징에 가중치를 적용하는 단계이다. 실험 단계에서는 AI 연구자들이 제안한 알고리즘, 모델 구조, 모델링 기법, 모델의 파라미터 결정을 위한 훈련 방법들을 평가한다. 이 단계는 여러 후보 모델들을 실험하는 단계로 계산 집약적(computationally-intensive)이며, 이에 따라 많은 리소스가 필요한 과정이다. 실험 단계에서 선정된 모델은 훈련(교육) 단계로 넘어간다. 교육 단계에서는 훨씬 광범위한 데이터를 이용해 파라미터를 최적화한다. 훈련은 1회에 그치는 것이 아니라 모델에 따라 다양한 빈도로 교육과 재교육을 반복하게 된다. 예를 들어 메타의 검색 모델은 매시간마다 훈련을 하며, 번역 서비스의 경우 주 단위로 훈련이 이뤄진다. 마지막 추론 단계에는 최고 성능의 모델이 이용자에게 배포되어 매일 수조 건의 작업을 수행한다. 보고서에 따르면, 메타의 경우 실험, 훈련, 추론에 이용되는 전력 설비 용량 비중은 각각 10:20:70이며, 머신 러닝의 전주기(end-to-end) 에너지 소비량 비중은 대략 31:29:40이다.

[그림 2-17] 머신 러닝 개발 단계별 에너지 비중(%)




자료: Wu et al.(2022) 자료를 이용해 저자 작성

3.2.2. 학습과 추론의 전기 소비 특성 차이

훈련(교육)과 추론 과정 모두 GPU, CPU, RAM이 사용된다. GPU가 대규모 병렬 연산 등의 핵심 연산을 담당하고, CPU와 RAM은 데이터 전처리, 시스템 운영, 전체 시스템의 작업 공간 제공 등의 역할을 한다. 전기 소비 측면에서 CPU와 RAM은 GPU 대비 에너지 소비량이 작고 훈련이나 추론 과정에 상관없이 소비량이 일정하게 유지된다([그림 2-18]). 따라서 사실상 훈련과 추론 단계의 에너지 소비는 GPU에 의해 좌우된다고 할 수 있다. 이러한 CPU 및 GPU의 서로 다른 전력 소비 특성은 AI 연산의 에너지 소비를 특징짓는 중요한 요소이다.

[그림 2-18] AI 연산의 GPU와 CPU 전력 소비 특징




자료: Li & Li(2025), p.2, Fig. 1

GPU의 에너지 소비는 훈련과 추론에 따라 패턴에 차이가 있는 것으로 조사되고 있다. Mavromatis et al.(2024)에 따르면 GPU의 전기 소비는 대부분의 훈련 모델에서 GPU의 최대전력(TDP¹⁸)에 근접하지만, 추론은 모델에 따라 TDP에 크게 못 미치는 경우도 나타난다. 다른 연구에서도 유사한 결과를 보여준다. Patel et al.(2024)에 따르면 LLM 훈련 시 GPU의 최대 전력 소비량은 평균적으로 TDP의 97%에 달하며, 계산 및 통신 집약적인 특성으로 대규모 전력 변동이 짧은 시간

¹⁸ TDP(Thermal Design Power, 열 설계 전력)은 열이 빠져나오는데 필요한 시스템 냉각의 최대 전력으로서, 통상 GPU의 최대 전력으로 간주된다.

(몇 초 간격) 내에 자주 발생하는 것으로 나타났다. 또한 많은 GPU에서 연산 집약적인 단계를 번갈아 가며 수행하기 때문에 훈련에서는 대규모 전력 변동이 일반적이다. Li & Li(2025)는 GPT-2의 훈련에 GPU 마더보드의 전력이 특정 이벤트와 관련해 14.5초 전후 시간에 피크 수준에서 거의 유향 상태로 급락하는 경우를 보고하고 있다([그림 2-19]).


[그림 2-19] 훈련 부하 패턴



자료: Li & Li(2025), p.5, Fig. 4-(a)

반면, 추론은 시작 단계에서 전력이 급등한 후 안정적이고 낮은 전력 소비 패턴을 보이는데, 훈련 대비 상대적으로 전력 변동이 작다. 초기 전력이 급등하는 단계는 추론 명령이 입력되는 단계이며, 안정적이고 낮은 전력의 단계는 결과가 산출되는 단계이다. 전자는 지속 기간이 짧으며 TDP를 초과하기도 하지만, 후자는 상대적으로 기간이 길지만 전력 소비는 상대적으로 작고 안정적인 특징을 가진다([그림 2-20]). 추론 단계 전체로는 평균적으로 최대전력의 60~80% 수준을 소비하는 것으로 조사되었고, 전기 소비가 일주기(Diurnal) 패턴을 가지는 것으로 나타난다.

[그림 2-20] 다양한 추론 모델 별 GPU 전기 소비 패턴



자료: Patel et al.(2024), Figure 6.

요컨대, 학습은 추론에 비해 피크 및 평균 전력 소비량이 더 크고, 추론은 학습에 비해 상대적으로 전력 사용량이 안정적으로 유지된다. 이는 학습이 추론에 비해 전력 공급 인프라에 훨씬 큰 부담을 줄 가능성이 있음을 의미한다. 단, 앞서서도 언급했지만 다시 한번 강조할 점은, 위의 학습과 추론의 부하 패턴이 반드시 AI 데이터센터(AIDC)의 전기 소비 패턴은 아니라는 점이다. 앞의 그림들은 단일 모델의 부하 패턴이다. 모델의 크기에 따라 하나의 서버에 여러 개의 모델이 구동되기도 하며, 하나의 모델이 여러 서버에 분산되어 구동되기도 한다. 앞의 데이터센터 인프라 구조에서 설명했듯이, 데이터센터는 많은 수의 랙으로 구성되고, 랙당 수십 개의 서버가 장착될 수 있다. 일반적인 경우는 수십~수백 개의 AI 모델의 전기 소비 패턴이 교차하므로 DC 수준에서의 부하 변동성은 상당 수준 완화될 것이다. 물론, 그럼에도 불구하고 AI 연산의 본질적인 부하 특성상 AIDC의 전력 변동성이 일반 DC 대비 클 것임은 자명하다.

3.2.3. 학습과 추론의 GPU 이용률 및 에너지효율

한편, GPU 이용률 상승은 전체 에너지 소비 증가로 이어지지만, 에너지효율 측면에서는 동일한 전력으로 더 많은 연산을 처리할 수 있어 효율 향상으로 이어질 수 있다. 이에 따라 훈련과 추론에서의 GPU 이용률을 높이기 위한 연구들이 진행되고 있다. 예를 들어, Delestrac et al.(2024)에 따르면 머신 러닝의 학습에 있어 전체 GPU 이용률은 100%에 가까울 수 있지만, 텐서코어(Tensor cores¹⁹)와 같은 특정 구성 요소의 이용률은 평균 5.2% 미만으로 상당히 낮아 아직도 많은 부분에서 이용률 개선의 여지가 있다고 밝히고 있다. 마이크로소프트의 연구(Gao et al., 2024)에서는 딥 러닝 작업의 평균 GPU 이용률이 50% 수준으로 나타났는데, 비효율적인 호스트-GPU 데이터 전송, 부적절한 배치(batch)²⁰ 크기 등이 이러한 낮은 이용률의 주 원인이며, 이를 해결하면 이용률이 크게 상승할 수 있음을 보이고 있다. 또한, Libon Council Research(2024)에 따르면 Meta의 머신 러닝 학습 모형은 GPU 이용률이 30~50%에 달하는 것으로 조사되었는데, 가상화나 워크로드 통합(workload consolidation) 기술을 통해 이용률을 높여 에너지효율을 개선시킬 여지가 많음을 지적하고 있다.

훈련과 추론에서의 GPU 이용률은 연구에 따라 차이가 있으나, 일반적으로 추론에서의 이용률이 훈련(학습) 대비 낮다고 여겨진다. 앞에서 훈련과 추론에서의 전기 소비 TDP 근접도 차이도 훈련의 GPU 이용률이 추론 대비 높다는 것을 시사한다. 이는 추론에서는 연산보다는 메모리를 읽고 쓰는 시간이 더 길어, GPU의 연산 자원을 충분히 활용하지 못하기 때문이다. 통상적으로 추론에서의 GPU 이용률은 10% 내외로 여겨진다(You, 2025.2.7.). 이는 에너지효율 측면에서는 일반적으로 훈련이 추론 대비 효율적이라는 의미이며, 향후 추론의 에너지 소비 효율 향상 여지가 상대적으로 더 크다는 의미이다.

¹⁹ 엔비디아에서 개발한 GPU 내장 하드웨어 가속기

²⁰ 학습 시 한 번에 모델이 입력되어 가중치가 업데이트되는 데이터 샘플 개수를 의미한다.

〈표 2-10〉 AI 학습(훈련) vs. 추론 전력 소비 특성

구분	학습/훈련 (Training)	추론 (Inference)
최대전력(TDP) 근접도	대부분의 모델에서 최대전력에 근접함. 평균적으로 GPU 최대전력의 97%	모델에 따라 TDP에 크게 못 미치는 경우도 나타남. 평균적으로 GPU 최대전력의 60~80%
전력 변동 패턴	연산 및 통신 집약적으로 대규모 전력 변동이 몇 초 간격으로 발생, 특정 이벤트에 따라서 피크 수준에서 거의 유휴 상태로 급락하는 경우도 발생	시작 단계에서 전력이 급등한 후, 결과가 산출되는 단계에서는 안정적이고 낮은 전력 소비 패턴을 보임. 학습 대비 상대적으로 전력 변동이 크지 않음
평균/피크 전력 소비량	추론에 비해 피크 및 평균 전력 소비량이 더 큼	학습에 비해 상대적으로 전력 사용량이 안정적임. 전력 소비가 일주기 패턴을 가짐
전력 공급 인프라 부담	추론에 비해 전력 공급 인프라에 훨씬 큰 부담	상대적으로 부담이 작음
GPU 이용률	추론 대비 높음. 연구에 따라 평균 이용률은 30~50% 수준	학습 대비 이용률이 낮음. 통상적으로 10% 내외로 여겨짐
에너지효율 측면	추론 대비 효율적	상대적으로 비효율적이나, 효율 향상 여지가 큼

자료: 저자 정리

3.2.4. AI 시대 DC 에너지 소비 영향 요인²¹

(1) 학습의 에너지 소비 변동 요인

IEA(2025b)는 오늘날 가장 큰 AI 모델의 학습에는 약 154MW의 전력이 필요하며, 대규모 프런티어 AI 모델의 총 누적 학습 전기 소비량은 약 1,700GWh로 추정하고 있다. 학습의 에너지 소비가 빠르게 증가한 것은 모델의 파라미터 수와 학습 데이터 세트 규모가 증가하고 이에 따라 훈련 시간 또한 증가했기 때문이다. 스탠포드 대학의 연구(Maslej et al., 2025)에 따르면 모델의 파라미터 수는 2020년대 초반부터 아키텍처의 복잡성 증가, 데이터 가용성 향상, 하드웨어 개선 등으로 급격하게 증가했다. 학습에 사용된 데이터 양도 2017년 LLM의 혁명을 촉발한 트랜스포머 모델을 시작으로 약 8개월마다 두 배로 증가하고 있다. 학습(훈련) 시

²¹ 주요 AI 모델의 전력 소비 및 특성 비교는 부록의 〈표 부록-1〉을 참조

간을 보면 2012년 GPU를 활용한 최초의 AI 모델 중 하나인 AlexNet의 경우 5~6일 걸렸는데, 최신 모델들은 보통 90일 정도 걸리고 있다. 프론티어 및 주요 AI 모델들의 학습 연산량(FLOP²²)은 2010년 이후 매년 4~5배씩 증가해 왔다(Sevilla & Roldán, 2024).

Epoch AI의 주요(notable) AI 모델 데이터에 따르면²³, AI 학습(훈련) 에너지 소비와 관련된 요소들은 딥 러닝 시대(2010년)에 들어서며 증가세가 과거에 비해 크게 빨라졌다(〈표 2-11〉). 학습에 이용된 파라미터 수, 데이터셋의 크기, 훈련 시간, 훈련 연산량은 2010년 이후 각각 매년 2배, 3.6배, 1.2배, 4.6배씩 증가해 오고 있다. 이러한 요소들이 빠르게 증가함에 따라 한 번 학습에 소비되는 전기 소비도 매년 1.7배씩 증가하고 있는 것으로 나타났다. 주목할 점은 훈련의 전기 소비는 각 요소들의 곱(즉, 파라미터 수 × 데이터셋 크기 × 훈련 시간)에 영향을 받는데 이러한 요소들의 증가 속도에 비해 훈련의 전기 소비 증가세는 상대적으로 빠르지 않다는 것을 알 수 있다. 달리 말해 이는 훈련의 에너지효율도 파라미터 수, 데이터 크기 등의 증가 요인과 함께 빠르게 상승했다는 것을 의미한다.

〈표 2-11〉 학습 관련 에너지 요소의 증가세 비교

훈련(학습)	딥 러닝(2010년) 이전	이후
파라미터 수	× 1.2/ year	× 2.0/ year
데이터셋 사이즈(words)	× 1.3/ year	× 3.6/ year
훈련 시간	× 1.1 / year	× 1.2/ year
연산량(FLOP)	× 1.5 / year	× 4.6/ year
전력 소비(power draw)		× 1.7/ year

자료: Epoch AI, Data on AI Model

²² 부동소수점 연산(Floating Point Operation)의 약자로, 컴퓨터가 실수(부동소수점 수)를 가지고 수행하는 한 번의 산술 연산을 의미함. AI 분야에서는 모델이 학습 또는 추론 과정에서 수행하는 전체 연산량을 FLOP 단위로 표시한다. 하나의 토큰(token)을 생성하기 위해서는 활성화된 파라미터 수의 두 배에 달하는 FLOP이 필요하다.


²³ Epoch AI, Data on AI Model

[그림 2-21] 주요 AI 모델의 학습 파라미터 수, 데이터 사이즈, 시간 차이



자료: Epoch AI. Data on AI Model

[그림 2-22] 주요 AI 모델 학습의 전기 소비 추이



자료: Epoch AI, Data on AI Model

(2) 학습과 추론의 에너지 소비 변동 요인

(가) 배치 크기

학습과 추론의 에너지 소비는 위에서 설명한 요인들 외에도 배치(batch) 크기에도 영향을 많이 받는다. 배치 크기가 클수록 여러 입력의 병렬 처리가 가능해져 GPU의 활용도가 향상되고, 샘플당 오버헤드(overhead²⁴)가 감소해 에너지효율이 높아진다. 예를 들어 Latif et al.(2024)은 배치 크기를 512에서 4,096로 늘렸을 때 학습에 드는 전기 소비가 4분의 1 수준까지 감소된 것으로 보고한다. 관련 연구들에 따르면 배치 크기 증가에 따른 에너지 소비 감소 및 효율 증가는 선형이 아니며, 일정 수준 이상으로 크기가 커지면 에너지 소비 감소 효과는 거의 사라지기 때문에 최적의 크기를 찾는 것이 중요하다.

(나) 유휴 전력

학습과 추론 과정의 에너지 소비에 관한 대부분의 연구들은 모델이 계산

²⁴ AI 시스템에서 실제 또는 본질적인 연산 및 작업 외에 추가적으로 소모되는 자원(계산, 메모리, 통신 등)을 의미한다. 효율적이고 빠른 AI 학습 및 추론을 위해 오버헤드를 최소화하는 것이 중요하다.

(computing)하는 과정에서 발생하는 동적 소비량을 추정하는 데 중점을 둔다. 하지만, 전원은 켜져 있지만 사용하지 않은 서버에서 소비되는 유허(idle) 전력도 있다. 이러한 유허 전기 소비의 존재는 실제 데이터센터의 전기 소비가 연구 결과보다 훨씬 클 수 있음을 의미한다. 예를 들어, Luccioni et al.(2022)에 따르면 1,760억 개의 매개변수를 가진 머신 러닝 모델(BLOOM)의 학습에 소요되는 전기 소비를 추정했는데, 전체 학습에 소요되는 전기 소비 중 동적 전기 소비가 54.5%를 점유하였으며, 인프라(DC 유지보수 및 냉각 시스템 등)와 유허 소비는 각각 13.5%와 32%를 차지한 것으로 나타났다. 이러한 결과는 유허 전기 소비가 경우에 따라 인프라 소비의 2배 이상, 동적 전기 소비의 50% 이상을 차지할 수도 있다는 것을 보여준다. 이러한 유허 전력을 줄이기 위한 연구들도 하드웨어와 소프트웨어 측면, 가상화 기술, AI 기반 최적화 등의 다양한 분야에서 진행되고 있다. 예를 들어, CEC(2024)는 서버가 유허 상태일 때는 딥 슬립(deep sleep) 상태로 진입하고, 요청을 처리해야 할 때는 코어를 깨울 시점과 실행할 주파수를 최적으로 결정하는 저 전력 관리 시스템을 개발해 최대 25%의 서버 에너지를 줄일 수 있음을 보고하고 있다.

(다) AI 알고리즘

배치 크기나 유허 전력 이외에도 AI 알고리즘에 따라서 데이터센터의 전기 소비는 크게 영향을 받는다. 최근 연구에서는 모델의 정확도를 조금 양보하고 전기 소비를 큰 폭으로 줄이는 알고리즘들이 개발되고 있다. 대표적인 기술들로는 가지치기(Pruning), 지식 증류(Knowledge Distillation), 양자화(Quantization) 등이 있다. 가지치기는 신경망에서 중요도가 낮거나 불필요한 요소 및 중복되는 부분을 제거하여 효율성을 높이는 기법이다. 여러 연구들에 따르면 가지치기를 통해 훈련과 추론 시간을 단축시킬 수 있는 것으로 나타났으며, 일부 연구(Widmann et al., 2023)에 따르면 사물 인터넷에서 가지치기를 통해 추론의 에너지 소비를 59%까지 감소시킨 사례도 보고되고 있다. 지식 증류는 복잡하고 큰 대형 모델(teacher)의 지식을 작고 효율적인 소형 모델(student)에 전달하여, 소형 모델이 대형 모델에 준하는 성능을 내도록 학습시키는 방법을 의미한다. 최근 중국의 AI 스타트업 딥시크(DeepSeek)

가 기존 빅테크 기업들이 지출한 비용의 10분의 1 수준에서 ChatGPT와 유사한 성능을 가진 AI 모델을 출시하며 큰 화제가 되었는데²⁵, 그 핵심 비결 중 하나로 지식 증류 기술이 주목받고 있다. 양자화는 모델의 파라미터 등의 수치 정밀도를 줄여서 계산 및 메모리 요구 사항을 낮추는 기술이다. Rajput & Sharma(2024)는 양자화로 추론하는 경우 GPU, CPU, RAM에서의 전기 소비가 모두 줄며 총 71~73% 수준의 전기가 절감되는 것으로 보고하기도 했다.

(라) 종합

앞서 언급한 방법들을 결합하는 연구들도 진행되고 있는데, 예를 들어, Tran et al. (2025)은 양자화와 가지치기를 결합할 경우 40% 이상의 에너지 소비를 절감할 수 있다고 주장하며, 엔비디아(NVIDIA Technical Blog, 2024.8.4.)는 가지치기와 지식 증류를 결합해 효율성을 높이는 사례를 제시하기도 한다. Liu & Zeng(2025)도 가지치기와 지식증류를 결합하여 정확도를 원래 수준과 비슷하게 유지하며, 모델의 크기와 파라미터 수를 28% 이상 경량화할 수 있음을 보고하기도 했다.

이러한 여러 요소들의 변화가 미래의 에너지 소비 증가세에 어떻게 작용할까? 직관적으로는 모델이 커지고 복잡해지면 파라미터의 수나, FLOP이 증가해 에너지 소비도 비례해서 증가할 것으로 생각된다. 하지만, 향후 하드웨어의 발전과 성능 향상으로 파라미터나 연산량 등의 증가 속도에 비해 에너지 소비 증가세가 느려질 가능성도 높다. 칩 수량 증가와 칩 성능 개선을 모두 고려한 연구(Pilz et al., 2025)에 따르면 주요 선도적인(leading) AI 슈퍼컴퓨터의 성능(초당 FLOP 처리 능력)은 2019년 이후 매년 2.5배씩 향상되어 온 것으로 조사되었으며, 에너지효율은 2019~2025년까지 매년 1.34배 개선된 것으로 나타났다. 상위 500대의 슈퍼컴퓨터를 이용한 연구(Benhari et al., 2024)에서도 이와 유사하게 에너지효율이 매년 1.31배 증가하는 것으로 나타났다. 이는 동일한 계산 능력에서 에너지 소비가 약 25% 감소한다는 의미이다. Desislavov et al.(2023)에 따르면 연산 컴퓨팅 수요가 증가함에 따라 하드웨어와 소프트웨어의 혁신으로 에너지효율이 개선되며, 추론의 전기 소비 증가세는 학습 대비 훨씬 느리게 증가하는 것으로 조사되고 있다.

²⁵ DeepSeek의 주장에 따르면 ChatGPT 대비 훈련 비용은 18배, 추론 비용은 36배 절감된다.

앞서 AI 이용이 얼마나 증가할지에 대한 불확실성으로, 추론의 에너지 소비 전망의 어려움을 지적했는데, 이러한 불확실성을 가증시키는 또 다른 요소는 작업 유형에 따른 에너지 소비의 차이이다. 추론의 전기 소비는 작업 유형에 따라 차이가 커, 만약 이미지나 동영상 생성 위주의 추론이 폭증한다면 추론의 전기 소비 증가세는 다시 빨라 질 수도 있다.

3.2.5. 추론 작업 유형별 전기 소비

가장 일반적인 추론 작업 유형은 텍스트 검색일 것이다. 여러 연구에 따르면 구글 한 번 검색에 0.3Wh의 전기가 소비되지만, ChatGPT는 2.9Wh가 소비된다. AI 검색당 전기 소비량이 기존 검색 대비 10배라는 이 추정치는 많은 언론과 연구 등에서 AI 시대 전기 수요 폭증의 근거로 인용되어 왔다. 구글의 검색당 0.3Wh 소비는 2009년에 구글이 발표한²⁶ 수치이며, ChatGPT의 2.9Wh는 de Vries(2023)가 SemiAnalysis의 ChatGPT 운영 비용 평가 결과를 근거로 추정한 것이다. 이후 IEA(2024)를 비롯해 최근까지 여러 공신력 있는 기관에서 이를 재인용하면서 사실로 인식되고 있다.

하지만, 최근 Epoch AI의 연구(You, 2025.2.7.)에 따르면 가장 최신 모델인 GPT-4o의 경우 검색당 에너지 소비는 0.3Wh로 전통적인 구글 검색의 전기 소비 추정치와 동일하다. 이 연구에서는 기존 ChatGPT 추정치(2.9Wh)가 비상식적으로 큰 입출력, 최신 GPU보다 덜 효율적인 GPU를 가정했기 때문에 실제보다 과도하게 추정되었다고 주장한다. 기존 추정치(2.9Wh)는 엔비디아 A100 GPU에 A4 8장(3,200 단어)에 달하는 입력과 A4 4장(1,600단어)에 달하는 출력이라는 과장된 가정하에서 도출된 수치인 반면, 신규 추정치(0.3Wh)는 A100보다 고성능의 최신 H100 칩에 일반적인 텍스트 기반 입력 질문 분량, A4 한 장 분량 출력이라는 가정에서 도출된 것이다.

물론 기존의 구글 검색당 전기 소비 추정치가 16년 전의 오래된 수치이고, 칩 성능 개선과 전력 집약도 개선을 생각하면 여전히 ChatGPT가 기존 검색 보다 검색당 에너지 소비가 수 배 높을 수 있다. 하지만, 절대적 소비량 측면에서

²⁶ Google Official Blog(2009.1.11.)

ChatGPT 에너지 소비에 대한 신규 추정치는 기존 대비 약 1/10로 축소되었기 때문에, 이를 적용하여 추정한 AI에 따른 전기 소비량 전망도 훨씬 낮아질 수 있다. 신규 추정치에 따르면 전세계 ChatGPT의 사용자가 하루 10억 개의 질문을 했을 때, 약 12.5MW의 전력이 소비된다.

〈표 2-12〉 추론 작업 유형별 전기 소비

작업 유형	평균 kWh/백만 킬리	표준편차	배수
텍스트 분류	0.2	0.001	1
추출형 질의응답*	0.3	0.001	1.5
이미지 분류	0.7	0.001	3.5
객체 탐지**	3.8	0.02	19.0
텍스트 생성	4.7	0.03	23.5
요약	4.9	0.01	24.5
이미지 캡셔닝***	6.3	0.02	31.5
이미지 생성	290.7	3.31	1,453.5

주: * 추출형 질의응답은 주어진 문서(문맥, context)에서 질문의 정답에 해당하는 부분을 "추출"하는 질의응답 방식, **객체 탐지는 주어진 시각 데이터 내에서 "어디에", "무엇이" 있는지를 인공지능이 자동으로 식별하는 작업, ***이미지 캡셔닝(Image Captioning)은 인공지능이 이미지를 입력 받아, 해당 이미지를 설명하는 자연어 문장(캡션)을 자동으로 생성하는 기술임

자료: Luccioni et al.(2024)

단, 이러한 추정치는 텍스트 출력일 때의 추정치이다. 추론에 소비되는 전기 소비는 작업의 내용에 따라 크게 차이가 난다. 텍스트 기반보다는 이미지 기반 추론 작업에 드는 전기 소비가 훨씬 크다. Luccioni et al.(2024)에 따르면 텍스트 분류 작업의 전기 소비가 가장 적다. 텍스트 생성은 텍스트 분류 작업의 약 24배의 전기가 소비되며, 이미지 생성은 텍스트 생성의 62배에 달하는 전기가 소비된다. 최근에는 비디오 생성과 관련된 AI 서비스(OpenAI의 Sora, Runway 등)도 빠르게 확장되고 있는데, 현재는 주로 2차원 기반 이미지 생성 모델을²⁷ 시간축으로 확장하여 이용하는 방식을 채택하여 동영상상을 생성한다. 최근에는 3차원 데이터 처리를 위한 모델들이 개발되고 있는데, 대표적으로 3차원 컨볼루션 신경망(3D ConvNet,

²⁷ 이미지 생성 분야의 대표적 딥 러닝 모델로는 GAN, VAE, Diffusion, Autoregressive, Transformer 기반 모델 등이 있다.

3D CNN) 같은 모델은 시간적, 공간적 정보를 동시에 학습할 수 있도록 설계된 딥러닝 모델로, 특히 비디오, 의료 영상(CT, MRI 등) 분석, 행동 인식, 엔터테인먼트 등 다양한 분야에서 활용되고 있다. 이러한 동영상 생성이 단순 이미지 인식 및 생성 작업보다 훨씬 더 많은 연산 자원을 필요로 할 것임은 자명하다.

4. 데이터센터(DC)의 에너지 성과

4.1. 에너지 성과 지표

4.1.1. 전력효율지수(PUE)

데이터센터의 에너지효율 등과 같이 성과를 측정하기 위한 지표들은 수 십 개가 넘으며, 현재도 다양한 새로운 지표들이 개발 및 제안되고 있다. 전세계적으로 통용되는 가장 대표적인 DC 성과 지표는 전력효율지수(PUE, Power Usage Effectiveness)이다. PUE는 데이터센터에서 사용한 전체 전기 소비를 IT 장비에서 소비된 전기 소비로 나눈 값으로, 1에 가까울수록 전력 효율이 높다고 간주된다. 가장 이상적인 PUE=1의 경우 데이터센터의 전력 소비는 오롯이 IT 장비에서만 비롯된다.

$$PUE = \frac{\text{데이터센터 총 전기 소비}}{\text{IT 장비 전기 소비}}$$

앞서 데이터센터 인프라 구조에서 보았듯이, IT 장비의 전기 소비에는 서버, 스토리지 및 네트워크와 이와 관련된 보조 장비에서 소비되는 전기가 포함된다. IT 장비 외 데이터센터의 전기 소비는 전력 공급 관련 구성 요소(UPS 시스템, 배전장치(PDU), 발전기 및 배터리 등), 냉각 시스템 구성 요소, 기타 구성 요소(조명 등)에서 발생한다. 데이터센터의 유형에 따라 용도별 전기 소비 비중이 다르지만, 앞에서의 <표 2-4>에서 확인할 수 있듯이 평균적으로 IT 관련이 약 70%, 냉방 관련이 약 20%, 나머지 기타 인프라 관련이 약 10%를 차지한다.

PUE는 에너지 소비 측정 위치에 따라 PUE1, PUE2, PUE3으로²⁸ 나누기도 하며, 측정 기간에 따라 1년 미만의 기간 동안 측정된 iPUE(Interim PUE), 데이터센터의 설계 목표 및 예상되는 전력 부하 범위에 따라 데이터센터 운영 전에 예측된 dPUE(Designed PUE)도 있다. 데이터센터 전체가 아니라 특정 서버 시스템의 전력사용효율성을 평가하기 위해 pPUE(Partial PUE)를 사용하기도 한다. 국내 ‘그린데이터센터 인증’의 평가 지표 중 pPUEcooling(데이터센터 냉각 부문 PUE), pPUEpower(데이터센터 전력 시스템 부문 PUE)가 pPUE의 예이다.

PUE는 전세계적으로 널리 사용되고 있는 데이터센터의 에너지효율 지표이지만, 엄밀히 말하면 효율의 개념은 아니다. PUE는 데이터센터의 본래 목적 달성을 위한 필수적인 전기 외에 부차적인 전기 소비가 얼마나 더 소요되는지를 측정하는 지표이다. 즉, PUE가 1에 가깝다는 것은 IT 장비 외의 요소에 소비되는 전기가 거의 없다는 의미로, 이는 일반적인 에너지효율의 개념과는 차이가 있다. 다시 말해, PUE는 전기 외의 다른 에너지원의 소비 효율성 등을 제대로 반영하지 못한다. 예를 들어, 물의 증발을 이용해 냉각을 하거나, 열병합발전소에서 공급받은 열을 냉각용으로 사용하는 흡수식 냉각기 등 전기 외에 다른 에너지원으로 냉각을 하는 경우에도 PUE는 낮아진다. 이렇듯 PUE는 IT 장비의 효율성, 폐열 활용, 재생에너지 소비 등을 제대로 반영하지 못하기 때문에 데이터센터의 에너지 성과를 포괄적으로 대표하기는 힘든 지표이다.

이러한 에너지효율 지표로의 한계에도 불구하고, PUE가 널리 쓰이는 이유는 계산이 쉽고 실용적이기 때문이다. 데이터센터의 효율을 측정하기 위해서는 작업당 전기 소비를 측정해야 하나, 데이터센터마다 수행하는 작업이 다르기 때문에 통일되고 일관성 있는 기준을 설정하는 것이 쉽지 않다. PUE는 작업당 전기 소비 대신, 작업 전체에 들어가는 전기와 인프라 측면에서 작업과 직접적인 관계없이 발생하는 전기의 비율을 표시한다. 이런 면에서 PUE는 어느 정도 인프라 측면의 효율성을 평가한다고 할 수 있다.

²⁸ PUE1은 UPS(무정전 전원 공급 장치)에서, PUE2는 PDU(전력 분배 장치)에서, PUE3는 IT 장비에서 직접 측정되며, PUE3가 가장 측정 정확도가 높다.

4.1.2. PUE 외 주요 성과 지표

PUE의 한계를 보완하기 위해 다양한 데이터센터의 에너지 성과 지표들이 사용되고 있으며, 새로운 지표들도 개발되고 있다. Fieni et al.(2025)의 연구에서는 소프트웨어 측면을 고려하지 못하는 PUE의 한계를 개선해, 하드웨어 구성 요소부터 실행 중인 소프트웨어 요소까지의 전반적인 에너지효율을 평가하기 위한 다양한 형태의 xPUE를 제안하기도 한다. Patterson et al.(2013)은 IT 장비의 실제 연산에 사용되는 에너지효율을 평가하는 지표로 ITUE(IT Usage Effectiveness)와 $ITUE * PUE = TUE$ (Total Usage Effectiveness)를 제안하기도 한다. TUE는 데이터센터 전체 에너지 소비에서 IT 장비가 실제 연산에 사용한 에너지를 기준으로 작성되는 데이터센터의 총 에너지효율을 평가하는 지표이다.

한편, 국제 표준(ISO/IEC)에서는 데이터센터의 에너지 성과 지표로서 PUE뿐만 아니라 REF, ERF, CER, ITEEsv, ITEUsv, CUE, WUE 계산을 위한 표준을 제시한다. REF(Renewable Energy Factor)는 재생에너지 사용률로서 데이터센터 전체 에너지 소비에서 재생에너지가 차지하는 비중을 나타낸다. ERF(Energy Reuse Factor)는 에너지 재사용 지수로 데이터센터에서 발생한 폐열 등의 잉여 에너지 중 유용하게 재사용되는 에너지의 비율을 나타낸다. CER(Cooling Efficiency Ratio)은 냉각 시스템의 효율성을 평가하는 지표로서 DC에서 제거(냉각)된 총 열량을 냉각 시스템에서 소비된 전기 소비량으로 나눈 값이다. ITEEsv(IT Equipment Energy Efficiency for servers)는 데이터센터 내 서버 장비의 에너지효율성을 계측하기 위한 지표로서, kW당 최대 작업 수행 능력을 정량화한다. ITEUsv(IT Equipment Utilization for servers)는 서버의 평균 이용률과 전력 관리 측면을 다루는 지표이다. CUE(Carbon Usage Effectiveness)는 탄소사용효율지수로서 데이터센터 운영에 따른 CO2 배출량을 IT 장비가 소비한 에너지로 나눈 값이다. 직접 배출과 간접 배출을 모두 포함하는 CUE는 데이터센터의 탄소 배출 효율성을 평가할 수 있는 지표이며 작을수록 탄소 배출 효율성이 높음을 의미한다. 동일한 PUE를 가진 데이터센터라도 REF가 높다면 CUE는 작다. WUE(Water Usage Effectiveness)는 물 사용 효율성을 측정하는 지표로 데이터센터에서 냉각용 등으로 사용한 물의 양을 IT 장비가 소비한 전기 소비량으로 나눈 값이다.

〈표 2-13〉 국제표준(ISO/IEC)에서 정의된 데이터센터의 주요 성과 지표(KPI)

지표	표준	정의 및 설명
PUE (Power Usage Effectiveness)	ISO/IEC 30134-2	데이터 센터 에너지효율성을 정량화하는 KPI. 총 에너지 소비량 ÷ IT 장비 에너지 소비량. PUE는 항상 1보다 크며, 전력/냉각 아키텍처, 장비 배치, 운영 효율성을 파악하는 지표. 단, IT 부하의 효율성이나 생산성은 고려하지 않으며 데이터 센터 간 직접 비교 지표로는 부적합.
REF (Renewable Energy Factor)	ISO/IEC 30134-3	데이터 센터의 재생에너지 사용 비율. 데이터 센터가 소유/통제하는 재생에너지 양 ÷ 총 에너지 소비량. REF=1.0은 100% 재생에너지 사용을 의미. 탄소 감축 평가 및 에너지 조달 전략 분석에 활용.
ITEEsv (IT Equipment Energy Efficiency for servers)	ISO/IEC 30134-4	데이터 센터 내 서버(전체 또는 그룹)의 kW당 최대 성능을 정량화하는 KPI. 서버의 에너지효율성 역량(capability)을 반영하며, 실제 운영 효율성은 아님. 더 큰 값은 평균적으로 더 높은 에너지효율성을 가진 서버가 설치되었음을 의미. 데이터 센터 인프라(냉각 등)는 포함되지 않음. ITEUsv와 함께 서버 에너지 효과를 구성하는 세 가지 요소 중 작업량당 에너지 소비(capability)를 다룸.
ITEUsv (IT Equipment Utilization for servers)	ISO/IEC 30134-5	데이터 센터 또는 서버 그룹에서 서버의 평균 이용률을 정량화하는 KPI. 서버 에너지효율성은 높은 이용률 수준에서 최적화되는 경향이 있음. 가상화 및 서버 통합 등을 통해 서버 활용률을 높이거나 동일 작업량을 더 적은 서버로 수행하는 접근 효과를 정량화. 역량(capability), 이용률(utilization), 전력 관리(power management) 중 이용률과 전력 관리에 해당. 데이터 센터 인프라에는 관여하지 않음.
ERF (Energy Reuse Factor)	ISO/IEC 30134-6	데이터 센터에서 소비된 에너지 중 재활용되는 에너지의 비율. 재활용 에너지 ÷ 총 에너지 0은 재활용 없음, 1.0은 전량 재활용됨을 의미. 단, 재활용 과정의 효율성은 고려하지 않으며, 데이터 센터 외부에서 활용되는 에너지만 포함.
CER (Cooling Efficiency Ratio)	ISO/IEC 30134-7	냉각 효율성 지표 제거된 총 열량 ÷ 냉각에 사용된 전기 에너지 데이터 센터 관리자가 냉각 효율을 빠르게 파악·개선할 수 있도록 지원
CUE (Carbon Usage Effectiveness)	ISO/IEC 30134-8	데이터 센터 운영 단계에서 발생하는 CO ₂ 배출량을 정량화하는 KPI. 연간 CO ₂ 배출량 ÷ IT 장비 에너지 소비량 값이 낮을수록 탄소 집약도가 낮음
WUE (Water Usage Effectiveness)	ISO/IEC 30134-9	데이터 센터 운영에서 발생하는 물 소비량을 정량화하는 KPI 물 소비량 ÷ IT 장비 에너지 소비량 물 집약도를 나타내며 냉각 설비의 성능 평가 및 지속가능성 개선에 활용.

자료: (ISO/IEC 30134-2), (ISO/IEC 30134-3), (ISO/IEC 30134-4), (ISO/IEC 30134-5), (ISO/IEC 30134-6), (ISO/IEC 30134-7), (ISO/IEC 30134-8), (ISO/IEC 30134-9)를 이용해 저자 정리

이 밖에 PUE의 역수로 데이터센터의 총 에너지 소비에서 IT 장비가 사용하는 에너지의 비율을 나타내는 데이터센터 인프라 효율(DCiE, Data Center infrastructure Efficiency)도 있다. 에너지 재사용 효율지수(ERE, Energy Reuse Effectiveness)는 데이터센터 외부로 재사용되는 에너지를 제외한 PUE로 아래의 식과 같이 표현된다.

$$ERE = \left(\frac{\text{데이터센터 총 에너지 소비} - \text{재사용 에너지}}{\text{IT 장비 전기소비}} \right) \\ = \left(1 - \frac{\text{재사용 에너지}}{\text{데이터센터 총 에너지}} \right) * PUE$$

최근에는 데이터센터의 실질적인 작업 처리 효율을 평가하기 위한 지표들도 주목받고 있다. IEA 산하 EDNA의 연구(IEA 4E EDNA, 2022)에서는 데이터센터의 에너지효율성에 관한 기존의 여러 성과 지표들을 검토하고 장단점 등을 평가했다. 이러한 분석을 기초로 EDNA는 정책 입안자들을 위한 지표로 ITAEI(IT Equipment Average Efficiency Index)와 DCFE(Data Center Functional Efficiency)를 제안하였다. ITAEI는 IT 장비의 효율을 평가하는 지표로 서버, 스토리지, 네트워크 장비의 사용 용량을 총 IT 전기 사용량으로 나눈 값이다. DCFE는 데이터센터의 기능 측면을 고려한 지표로 서버가 제공한 작업량, 누적 스토리지 사용량, 누적 네트워크 사용량의 합을 데이터센터의 전체 에너지 소비량으로 나눈 값이다. ITAEI와 DCFE를 측정하기 위해서는 서버, 스토리지, 네트워크의 사용 용량 및 전력, 측정 기간 동안 서버가 제공한 작업, 누적 스토리지 및 네트워크 사용량 정보가 필요하다.

이상의 여러 에너지효율 지표에서 살펴본 바와 같이 데이터센터의 에너지효율을 어느 한 지표만으로 측정하기는 힘들다. 이는 에너지효율을 어떻게 정의할 것인가와 관련이 있기 때문이다. 데이터센터라는 인프라 측면에서의 효율은 PUE로 측정할 수 있으며, 데이터센터의 기능 측면의 효율은 EDNA가 제안한 ITAEI와 DCFE 같은 지표가 보다 적합하다. 온실가스 배출 측면에서는 CUE, 버려지지 않고 실제 소비된 에너지를 기준으로 한다면 ERE가 더 나은 효율 측정 방법일 것이다. 수많

은 데이터센터 관련 에너지 성과 지표들이 있지만, PUE를 제외하곤 공개된 수치들은 거의 없다. 아래에서는 글로벌 PUE가 어떻게 변해왔는지 살펴본다.

4.2. 글로벌 PUE 및 냉방용 에너지 소비

4.2.1. 글로벌 PUE 추이 및 전망

전세계 평균 PUE는 2014년까지 빠르게 개선되다가 이후에는 개선세가 둔화되고 있다. Uptime intelligence가 전세계 526개 데이터센터를 대상으로 조사(Donnellan et al., 2024)한 결과, PUE는 2007년 2.5에서 2014년 1.65로 빠르게 개선된 후, 개선세가 크게 둔화되어 최근 5년 기간에는 1.5 수준을 기록하고 있다. 최근의 신규 데이터센터 경우 대부분 1.3 수준을 보이고 있어, 향후에도 PUE는 지속 하락(개선)될 것으로 예상하고 있다. 보고서에 따르면 PUE의 개선은 데이터센터 설계 개선 등에 따른 인프라 효율 개선 보다는 블랭킹 패널(Blanking Panels)²⁹, 컨테인먼트 시스템(Containment Systems)³⁰, 가변 주파수 구동장치(VFD, Variable Frequency Drivers)³¹, 온도 설정값 완화 등과 같은 상대적으로 쉽고 경제적인 방법들을 통해 이루어졌다고 밝히고 있다.


한편, IEA(2025b)에서는 글로벌 평균 PUE 수치와 함께 2030년 전망치도 제공하고 있다. IEA는 2024년 기준 글로벌 평균 PUE를 Uptime intelligence보다 낮은 1.41로 추정하고 있으며, 이후 연평균 약 1.5%씩 개선되어 2030년에는 1.29까지 낮아질 것으로 전망하고 있다.

²⁹ 서버랙의 빈 공간에 설치하는 패널로, 서버 후면의 뜨거운 배기 공기가 전면의 차가운 공기와 섞이지 않도록 해 냉각 효율을 높이는 방법이다.

³⁰ 데이터센터 내 공급되는 차가운 공기와 배출되는 뜨거운 공기를 분리하여, 찬 공기의 공급은 극대화하고 뜨거운 공기는 별도로 처리하여 냉각 효율을 높이는 시스템이다.

³¹ 데이터센터의 부하에 따라 냉각 및 환기 시스템, 펌프, 압축기 등의 모터 속도를 제어하는 장치이다.

[그림 2-23] 글로벌 평균 PUE



자료: IEA(2025b), Donnellan et al.(2024)의 내용을 이용해 저자 작성

4.2.2. PUE와 냉방용 에너지 소비

정의상 PUE에 가장 큰 영향을 미치는 전력 소비 용도는 냉방용이다. 앞에서 언급했듯이 IT용 외 전력 소비의 과반수 이상은 냉방용이 차지한다. 데이터센터 총 전력 소비에서의 “냉방용 비중”과 비IT 전기 소비에서 냉방용이 차지하는 비중(τ)을 이용해 PUE 식을 다시 쓰면 아래와 같다.


$$PUE = 1 / (1 - \text{냉방용 비중} / \tau)$$

비IT(Non-IT) 전기 소비의 2/3가 냉방용에서 발생한다고($\tau = 2/3$) 가정하면, PUE와 전체 냉방용의 비중의 관계는 아래의 [그림 2-24]과 같다. 선형 비례적이지는 않지만 PUE가 낮아지면 그에 따라 데이터센터 총 전기소비에서 냉방용이 차지하는 비중도 낮아진다. 2024년 기준 글로벌 평균 PUE 수준(1.41~1.56)을 적용하면 평균적으로 냉방용의 비중은 19~24% 수준으로 계산되며, 최신 데이터센터의 경우(PUE 1.3) 냉방용의 비중은 15% 정도이다. 우리나라 네이버 데이터센터 각 춘천의 경우 2022년기준 PUE는 1.10로 보고되었는데³² 이에 따른 냉방용의 비중은

³² 네이버(2022)

4~6% 수준이며³³, 국내 데이터센터 전체 전기 소비에서의 냉방용의 비중은 2023년 기준 약 17%로 추정된다³⁴.

[그림 2-24] PUE와 데이터센터 총 전기에서의 냉방용 비중 관계



4.2.3. DC 규모별, 유형별 PUE

한편, 위의 식과 앞 절의 <표 2-4>의 데이터센터 유형별 용도별 전기 소비 비중을 이용하면 데이터센터 규모별 PUE를 아래 표와 같이 계산할 수 있다. 데이터센터의 규모가 자사용에서 하이퍼스케일로 커질수록 비IT 에너지 소비에서 냉방용이 차지하는 비중은 작아지며, 이에 따라 PUE도 하락하는 것을 확인할 수 있다. 단, 앞에서도 언급했듯이 IEA의 분류는 정확한 규모별 분류는 아니다. 자사용과 코로케이션 같은 분류는 소유 형태 및 서비스 제공 방식에 따른 분류이기 때문이다.

<표 2-14> 글로벌 데이터센터 유형별 PUE

구분	자사용	코로케이션	하이퍼스케일	전체
Non-IT에서의 냉방용 비중(τ)	68.8	62.1	56.0	63.8
PUE	1.92	1.53	1.14	1.41


자료: IEA(2025b), p53, Figure 2.2를 바탕으로 계산

³³ 네이버 데이터센터 각 층천의 냉방용과 기타 인프라 전기 소비가 동일하다고 가정하면 냉방용 비중은 4.5%로 추정된다.

³⁴ 자세한 추정은 제 3장을 참조하기 바란다.

한편 EU는 에너지효율지침과 EU 집행위원회의 새 위임규정에 근거해 보고한 681개의 DC의 정보를 바탕으로 첫 기술 보고서(Heatubun et al., 2025)를 발간했다. 이 보고서에는 보다 명확한 규모별 분류에 따른 PUE 조사 결과를 제시하고 있다. 아래 [그림 2-25]에 나타나듯이 규모의 경제 효과로 규모가 커질수록 PUE가 개선(하락)함을 재확인할 수 있다.

[그림 2-25] EU 데이터센터 규모별, 유형별 평균 PUE



주: n=681, 보고 의무가 있는 최소 규모는 500~1000 kW이며, 500 kW 미만의 DC는 자발적 보고임.
 자료: Heatubun et al.(2025), p34, Figure 7 및 p38, Figure 10

그림에 따르면 유형별로는 코호스팅(Cohosting) DC가 코로케이션이나 자사형 대비 PUE가 더 우수한 것으로 나타난다³⁵. 보고서는 이의 원인으로 코로케이션의 경우 DC 운영자가 IT 기기의 이용률을 통제할 수 없으며, 계약상의 이유로 과잉 용량을 유지하는 경우가 있기 때문으로 지적한다. 게다가 기존 코로케이션 DC는 고사양 고객을 위해 설계되어, 이러한 고사양이 필요 없는 저사양 고객에도 필요 이상의 낮은 온도나 높은 중복 요구사항을 적용하기 때문이라고 분석한다.

³⁵ 이러한 결과는 위의 IEA 보고서 정보를 바탕으로 계산한 PUE 결과 표와 모순되는 것으로 나타나는데, 이는 IEA의 분류가 정확한 유형별 분류가 아닌 규모를 바탕으로 한 유형별 분류이기 때문이다.

이러한 점은 다시 한번 PUE의 한계를 보여준다고 할 수 있다. 요컨대, PUE는 DC의 설계, 기후 조건 및 지리적 위치, IT 장비 활용도, 냉각 방식, 규모 등 많은 요소에 영향을 받기 때문에 데이터센터 간 비교를 위해서는 이러한 요소들을 종합적으로 고려하여 분석해야 한다. 아래에서는 PUE를 포함한 데이터센터의 에너지 효율에 영향을 미치는 요소들을 살펴보기로 한다.

4.3. DC 에너지효율 영향 요인

데이터센터의 에너지효율은 다양한 요인들에 의해 영향을 받는데 크게 IT 장비, 데이터센터 인프라, 설계/운영/관리로 구분하여 생각해볼 수 있다.


4.3.1. IT 장비

IT 장비의 에너지효율은 하드웨어 혁신과 장비 이용률에 크게 영향을 받는다. 무어의 법칙(Moore's Law)에 따라 집적 회로에 집적할 수 있는 구성 요소의 수는 해마다 2배씩 증가해 왔으며, 이는 트랜지스터의 소형화를 통해 컴퓨터 용량당 에너지 소비가 지속 감소한다는 쿠미의 법칙(Koomey's Law)으로 이어져 왔다. 최근에는 트랜지스터의 크기가 원자 단위에 도달함에 따라 추가적인 소형화가 물리적 한계에 부딪치며 하드웨어의 에너지효율 개선 속도가 둔화되고 있다. 하지만, GPU, TPU, ASIC, FPGA, DPU와³⁶ 같이 병렬처리가 가능한 AI 반도체(하드웨어 가속기)와 3D 패키징³⁷과 같은 반도체 집적 기술의 개발로 하드웨어의 에너지효율은 지속 개선되고 있다. Libon Council Research(2024)에 따르면 하드웨어 가속기를 사용하지 않는 슈퍼컴퓨터의 에너지효율은 와트당 4 GigaFlop인 반면 가속기를 사용하는 경우는 22 GigaFlop로 5배 이상 차이가 난다. 슈퍼컴퓨터의 성능은 지난 15년간 100배 이상 향상되었으며, 앞으로도 새로운 기술 개발로 상승세를 이어갈 것으로 보인다.

³⁶ GPU(Graphics Processing Unit)은 대규모 병렬처리에 특화, TPU(Tensor Processing Unit)는 구글이 설계한 AI 전용 가속기, ASIC(Application-Specific Integrated Circuit)은 특정 작업에 최적화된 주문형 칩, FPGA(Field-Programmable Gate Array)는 사용자가 목적에 맞게 회로를 재구성할 수 있는 가속기, DPU(Data Processing Unit)는 데이터센터 및 클라우드 환경에서 데이터를 효율적으로 처리하도록 특화 설계된 프로세서이다.

³⁷ 기존 반도체가 로직 및 구성요소를 옆으로 배열하는 방식이었다면, 3D 패키징은 이를 위로 쌓아 올리는 방식이다.


[그림 2-26] 최신 슈퍼컴퓨터의 와트(Watt)당 연산량(Gigaflop)



자료: Libon Council Research(2024), p.7, Figure 2

골드만삭스의 연구(Davenport et al., 2024)에서도 더 고성능 AI 칩(엔비디아 A100 → H100 → B200)이 설치된 서버일수록 전력 수요량 증가 대비 연산속도가 상대적으로 빠르게 증가하며 전력 원단위(연산량당 전력 소비, kW/pFLOPs)가 개선(1.3 → 0.3 → 0.2)되고 있는 것으로 나타난다.

[그림 2-27] 주요 AI 칩 서버의 최대 전력 요구량과 계산 속도



자료: Davenport et al.(2024), p.14, Exhibit 12.

앞 절에서 AI 연산에서의 GPU 이용률 상승을 통해 에너지효율을 향상시키기 위한 연구들을 소개한 바 있다. 동일한 논리로 IT 장비의 에너지효율은 장비 이용률에도 크게 좌우된다. IT 장비에서의 에너지 소비 대부분은 서버에서 발생하는데 유휴 전력 때문에 에너지 손실이 발생한다. 따라서 IT 장비 이용률을 높이면 유휴 전력을 줄일 수 있고, 이는 에너지효율 개선으로 이어진다. 서버 이용률이 20% 미만인 경우와 80%일 때의 서버의 에너지효율을 비교하면 이용률이 높을 때가 효율이 3~4배 높다(IEA 4E EDNA, 2023). 이러한 장비 이용률과 에너지효율의 강한 양의 상관관계는 클라우드로의 전환이나 서버 가상화 기술이 에너지효율 향상으로 이어지는 이유를 설명해 준다. 클라우드 서비스는 여러 클라우드 사용자 간의 리소스 공유를 통해 작업량 및 이용률 증가로 이어진다. 가상화는 단일 물리 서버에 여러 가상머신을 실행할 수 있게 함으로써 장비 이용률을 높인다.

IT 장비 이용률을 높이는 것은 에너지효율 관점에서 매우 중요한 문제이며 이에 대한 연구가 활발히 진행되고 있다. 대표적인 예로 서버 통합(Server Consolidation), 컨테이너화(Containerization), 서버리스 컴퓨팅(Serverless Computing) 기술을 들 수 있다. 서버 통합은 여러 대의 저활용 서버를 소수의 고성능 서버로 통합하는 방식으로, Song et al.(2009)에 따르면 물리적 서버 인프라를 기존 대비 50%, 전기 소비를 53%, CPU 이용률을 1.7배 상승시킬 수 있다고 한다. 컨테이너화는 가상머신 보다 훨씬 가볍고 고밀도 배치를 통해 더 많은 애플리케이션을 실행할 수 있다. 서버리스 컴퓨팅은 서버를 상시 가동하지 않고 요청이 있을 때만 실행하므로 유휴 전력 낭비가 거의 없는 기술이다. 일반적인 서버는 트래픽 변동에 대비해 서버를 과대하게 확보해야 하므로 평균 이용률이 23~30%에 불과하나, 컨테이너화와 서버리스 컴퓨팅을 도입하면 이용률이 72%까지 상승하는 사례(Vora, 2025)도 보고되고 있다. 한편, 서버의 에너지효율이 높아짐에 따라 서버 이용률이 50~60%에서 가장 에너지 효율적이고, 따라서 워크로드를 소수 서버로 통합하는 것보다 여러 서버에 부하를 분산하는 것이 더 효율적이라는 연구(CEC, 2024)도 있다. 이 경우 가장 효율적인 부하 분산을 위한 알고리즘 개발이 중요하다.

장비 이용률은 PUE에도 크게 영향을 미치는데, 이용률이 상승할수록 PUE도 향상된다. DC의 규모가 커질수록 이용률은 상승하며 이는 대규모 DC에서 PUE가 낮은 이유 중 하나다. 관련해 코로케이션과 같이 외부 사업자가 제공하는 시설을 임차해서 사용하는 경우는 임차 수요에 따라 DC 센터의 이용률과 PUE가 크게 변할 수 있다.

4.3.2. DC 인프라

데이터센터 인프라 측면에서의 효율은 주로 PUE와 관련된다. IT 장비(서버, 스토리지, 네트워크)를 제외하면 나머지 데이터센터 에너지 소비의 과반수 이상은 냉방용이 차지한다. 따라서 냉방용 에너지 소비를 줄이는 것이 PUE를 낮추는 가장 손쉬운 방법 중 하나이다. 데이터센터의 냉방 방식은 현재는 주로 차가운 공기를 이용하는 공랭식(Air cooling)이 상용된다. 앞서 언급한 블랭킹 패널, 컨테이너먼트 시스템은 모두 공랭식의 예이다. 최근에는 공기 대신 액체를 이용하는 수냉식(Liquid cooling) 기술들이 개발되고 있다. EPRI(2024)에서는 현재 적용 중이거나 고려 중인 데이터센터의 냉각 기술들을 기술 준비 수준별로 정리한 표를 제공하고 있다(〈표 2-15〉). 이에 따르면 현재 적용 가능한 공기 보조 액체 냉각(공랭식+수냉식)의 경우 기존 공랭식 대비 냉각용 에너지 소비를 50%까지 줄인다. 전자 부품을 비전도성의 특수 액체에 직접 담가서 냉각하는 침수 냉각의 경우 최대 95%까지 에너지 소비를 절감할 수 있다. 이 밖에 물 사용량이 거의 없는 미세 대류 액체 냉각이나 복사 냉각, 2상 침수 냉각과 같은 기술들도 개발되고 있다.

〈표 2-15〉 데이터센터의 냉각 기술 및 에너지 절감

기술	기술 준비 수준(TRL)	효율 개선 폭
공기 보조 액체 냉각	9	기존 공랭식 냉각에 비해 에너지 사용량을 최대 50%까지 절감할 수 있으며, 1.1미만의 PUE를 달성할 수 있는 잠재력을 가지고 있음
침수 냉각	8	기존 공랭식 냉각 방식에 비해 50~95%까지 에너지를 크게 절감할 수 있음
미세 대류 액체 냉각	6	다른 수냉식 시스템 대비 18%의 에너지 절감과 90%의 물 사용량 감소가 가능하게 해 PUE=1.02을 달성할 수 있는 잠재력이 있음
복사 냉각	6	50~70%의 에너지 절감 효과와 함께 물 사용량 제로, 유지보수 비용 절감이라는 이점이 있음
2상 침수 냉각	7	공기 냉각에 비해 41%의 에너지 절감이 가능하다고 주장되고 있으며, 물과 공간 절감이 장점임

자료: EPRI(2024), p.19, Table 4


4.3.3. DC 설계, 운영, 관리

마지막으로 설계, 운영 및 관리 측면에서 데이터센터의 효율에 영향을 미치는 요인들로는 전력 관리 설계, 데이터센터의 등급(Tier 등), 폐열 재활용 및 재생에너지 활용, 에너지 관리 시스템(EMS, Energy Management System), 워크로드 및 자원 관리 최적화 등을 들 수 있다. 전력 관리 설계는 IT 장비가 최대 출력으로 작동하지 않을 때 소비하는 에너지가 최소화되도록 회로 설계, 부품 통합 및 소프트웨어 개선을 하는 것이다. 또한, Tier 4 데이터센터의 경우 최소 2개의 UPS 시스템이 활성화되는데, 이 경우 에너지효율은 낮을 수 있다. 무정전 전원 공급 장치(UPS)는 일반적으로 최대 부하의 25% 이상에서 효율적인데(Moura et al., 2016), 실제 UPS 부하는 이보다 훨씬 낮은 경우가 많기 때문이다. 최신 UPS 시스템은 모듈형으로 구성되어 IT 부하에 따라 확장이 가능해 UPS 시스템의 부하를 25% 이상으로 유지할 수 있다(IEA 4E EDNA, 2023). EMS는 실시간 에너지 사용량, 온도, 장비 상태 등을 모니터링하고 에너지 소비를 최적화하는 시스템이다. 버려지는 폐열과 같은 에너지를 재활용하거나, 태양광 등 재생에너지 활용을 높이면 DC의 에너지 효율이 상승할 수 있다. 이 밖에 서버 및 장비의 전력 상태를 분석해 저부하 시 자동으로 전원을 차단하거나 절전 모드로 전환하는 기술 등을 통해 데이터센터의 에너지효율을 높일 수 있다.

특히, AI 자체가 에너지 소비를 절감하는데 큰 역할을 할 수도 있다. 예를 들어 구글은 DeepMind를 이용해 데이터센터의 냉각을 최적화시켜 냉각에 소비되는 에너지를 40% 절감하여 PUE를 15% 감소시킨 것으로 보고한다³⁸. Narasingu (2025) 등의 최근 연구들은 냉각 시스템의 최적화뿐만 아니라 작업 부하 예측, 동적 자원 할당 등에 AI를 활용함으로써 데이터센터의 에너지효율을 높이는 방법들을 연구하고 있다. 미 캘리포니아 에너지부(CEC, 2024)는 딥 러닝 기반의 서버 간 작업량(workload) 조절 알고리즘을 통해 모든 서버들이 가장 에너지효율적으로 작동하도록 유도해 약 25%의 전력 비용을 절감시킬 수 있음을 보이기도 했다.

³⁸ Quantum Zeitgeist(2025.2.27.)

[그림 2-28] 데이터센터 에너지효율 영향 요인



4.4. DC 에너지효율 개선 정책 효과

데이터센터의 에너지효율 개선을 위해 여러 나라들이 관련 정책들을 수립하고 있다(자세한 내용은 제4장을 참조). 이러한 정책들은 지표를 이용해 효율성을 평가하거나 기존 및 신규 데이터센터가 충족해야 하는 요건을 설정, 또는 특정 조치를 취하도록 규정하는 형식을 띤다. 보통 이러한 데이터센터 에너지효율 개선 정책들은 효율적인 IT 장비 및 소프트웨어 사용, 서버의 유휴 시간 감축(서버 이용률 상승), PUE 하락 등을 목표로 한다.

관련해서 Siderius et al.(2024)는 EDNA의 에너지 모델(TEM)을 이용해 2030년까지 유럽에서 연간 15TWh를 절감하기 위한 정책 시나리오별 데이터센터의

에너지 절감 효과를 측정했다(〈표 2-16〉). 분석에 따르면 2030년 기준 절감의 절반 정도는 PUE 하락으로 달성되며, 다음으로 서버 이용률 상승, 클라우드 컴퓨팅으로의 전환, 서버 사용률이 낮은 시간대에 장비 운전 중단(Shutdown) 순으로 정책 효과가 큰 것으로 분석되었다.

〈표 2-16〉 정책 시나리오별 유럽 데이터센터 에너지 절감 효과

시나리오	Savings (TWh/year)					
	2025	2026	2027	2028	2029	2030
시나리오1: Shift to cloud	1	1	2	3	3	3
시나리오2: Decrease PUE	3	6	9	9	9	8
시나리오3: Increase utilization	2	3	5	4	4	4
시나리오4: Increase server efficiency	9	2	0	0	0	0
시나리오5: Increase shutdown	2	2	2	2	2	2
시나리오6: Combine 1-5	16	14	17	16	16	15


자료: Siderius et al. (2024), Table2.

보고서에서 PUE 하락 정책은 신규 데이터센터를 제외한 모든 유형의 데이터센터에 대해 2027년까지 PUE 1.2를 달성한 후 유지되는 것으로 설정하고 있다. PUE 다음으로 정책 효과가 큰 서버 이용률 상승은 2027년까지 이용률 20%를 달성한 후 유지되는 설정이다. 클라우드 컴퓨팅으로의 전환 정책은 데이터가 자사용 데이터센터에서 클라우드형 데이터센터로 이동한다는 시나리오로서, 데이터 이동률이 2025년까지 25%로 상승한 후 유지되는 설정이다. 클라우드 DC는 PUE가 낮고 서버 이용률이 높아 다른 DC 대비 에너지효율이 일반적으로 높다. 흥미로운 점은 서버 효율 개선 정책의 효과가 2027년 이후로는 거의 없다는 점이다. 분석에서 서버 효율은 데이터 처리당 전기 소비인데, 이는 2027년까지 기존 서버의 효율이 최신 DC의 효율 수준으로 향상될 것으로 가정했기 때문으로 보인다.

동일한 모델(TEM)을 이용한 유사한 연구로는 IEA 4E EDNA(2024)가 있다. 이 연구는 주요국의 데이터센터 관련 정책들을 기초로 글로벌 데이터센터의 정책 시나리오별 에너지 절감 효과를 분석했다. 분석 결과는 앞에서의 연구와 유사하다(〔그림 2-29〕). PUE 규제 정책 효과가 가장 큰 것으로 나타났으며, 이러한 정책

들의 결합 효과로 2025년 이후 2030년까지 에너지 소비가 60TWh 이상 꾸준히 절감될 것으로 추정하고 있다.

[그림 2-29] 정책 시나리오별 글로벌 데이터센터 에너지 절감 효과



자료: IEA 4E EDNA(2024), p30, Figure 3 재구성

5. 소결


5.1. 데이터센터 전기 소비 증감 요인

향후 데이터센터의 전기 수요 폭증의 근본적인 원인으로는 AI 수요 폭증과 이에 따른 AI 데이터센터의 증가를 들 수 있다. 앞에서 데이터센터의 효율성 향상 요인들에 대해 살펴보았는데, 이러한 효율성 향상은 AI 비용을 하락시켜 AI 수요 상승으로 이어질 수도 있다(Jevons 역설). 특히, GPU, TPU 등과 같은 AI 연산을 위한 하드웨어 가속기는 기존 칩(CPU) 대비 에너지 효율적이지만 훨씬 에너지 집약적이어서, 이러한 가속기들이 설치된 AI 데이터센터가 얼마나 증가할지가 데이터센터의 전기 소비의 주요 증가 요인이다.

예를 들어, IEA는 상향식 모형을 이용해 글로벌 데이터센터의 전기 소비를 전망했는데, 주요 증가 요인으로 서버 수 증가와 IT 용량 증가에 따른 서버당 전기

수요 증가를 지목한다([그림 2-30]). IEA는 하드웨어 가속기가 설치된 가속 서버(Accelerated servers)가 향후 전기 소비 증가를 주도할 것으로 전망했다. 2030년까지 전체 서버 수는 2024년 대비 60% 이상 증가하는데, 가속 서버는 더 빠르게 증가할 것으로 예상된다. 단, 2030년에도 전체 서버에서의 가속 서버의 비중은 10% 이내로 유지될 것으로 가정하고 있다. 용량 측면에서 기존 데이터센터는 약 10~25MW 수준인 반면, 가속기로 구성된 AI 하이퍼스케일 데이터센터는 용량이 100MW 이상으로 증가할 수도 있어 기존 데이터센터 대비 4~10배 정도 규모가 크다. IEA는 전체 데이터센터의 IT 용량은 하드웨어 가속기의 설치가 늘어나면서 서버 수 증가보다 더 빠르게 증가해 2030년 기준 225GW로 2024년 100GW 대비 2배 이상 증가할 것으로 전망한다.

[그림 2-30] 데이터센터의 전기 소비 증감 요인



자료: IEA(2025b), p63, Figure 2.10

IEA에 따르면 2024년 기준 가속화된 서버는 전체 서버 전기 소비의 24%, 전체 데이터센터 전기 소비의 15%를 차지한다. De Roucy-Rochegonde & Buffard (2025)에 따르면 현재 AI는 데이터센터 에너지 소비의 10~15%에 불과하며 이는 전 세계 전력 소비의 0.2%에 못 미치는 수준이다. 인공지능으로 데이터센터의 에너지 소비가 증가할 것이라는 데에는 동의하지만, 인공지능 도입으로 데이터센터의 에너지 소비가 얼마나 추가적으로 증가할지에 대해 분석하는 것은 매우 어렵고

추정한다 하더라도 불확실성이 매우 크다³⁹.

〈표 2-17〉 전체 데이터센터 에너지 소비에서의 AI 비중

현재	전망(2028 년)
10~15% (De Roucy-Rochegonde & Buffard, 2025)	50% (보스턴 컨설팅 그룹, 2025)
15% (IEA, 2025b)	19% (골드만삭스)
50% (de Vries-Gao, 2025)	70% (용량기준) (맥킨지, 2024)

주: 출처의 정보를 이용해 저자 정리

IEA는 AI와 비AI의 워크로드를 명확히 구분하기 힘들고, 일부 AI 추론 작업이 온디바이스(On-device) 기기 등으로 이동할 가능성 등을 이유로 AI에 따른 데이터센터의 전기 소비 증가에 대해 구체적인 수치를 제공하지 않았다. 반면, de Vries-Gao(2025)는 AI 하드웨어 공급망 분석을 통해 AI 시스템의 전기 소비가 2024년에 비트코인 채굴의 전기 소비량을 초과하여 글로벌 데이터센터 전기 소비량의 절반에 육박할 것으로 예상했다. 보스턴 컨설팅 그룹(Lee et al., 2025.1.20.)은 AI 학습과 추론 작업량이 각각 연평균 30% 및 122%로 폭발적으로 증가하여 2028년 기준 생성형 AI가 전체 데이터센터 전기 소비에서 차지하는 비중이 35%에 달할 것으로 예상한다. 골드만삭스(Goldman Sachs, 2024.5.14.)는 2023~2030년 기간 AI로 인해 글로벌 데이터센터의 전기 소비가 연간 200TWh씩 증가하고 2028년에는 AI가 전체 데이터센터 전력 소비의 약 19%를 차지할 것으로 분석한다⁴⁰. 한편, 맥킨지(McKinsey & Company, 2024.10.29.)는 용량을 전망했는데, 데이터센터의 글로벌 용량은 2023~2030년 연평균 19~22%, AI 데이터센터 용량은 동기간 연평균 33%씩 증가할 것으로 전망한다. 이 경우 2030년에는 전체 데이터센터 용량에서 AI가 차지하는 비중은 약 70%에 달한다. IDC(2024)도 AI 데이터센터 용량이 2027년까지 연평균 40.5% 증가할 것으로 전망했다.

³⁹ AI의 정의가 확립되지 않았기 때문에 AI를 어떻게 정의 하느냐에 따라서 전통적인 데이터센터가 포함되기도 하고 누락되기도 하는 문제가 있다(IEA, 2025b).

⁴⁰ 골드만삭스의 전망은 ChatGPT가 기존 구글 검색 대비 전기 소비가 10배라는 정보를 기초로 이뤄진 것으로 보인다. 하지만, 앞에서 언급했듯이 최근 조사에 따르면 전기 소비는 거의 같다.

데이터센터 전기 소비의 감소 요인들은 앞 절의 에너지효율 부문에서 이미 다룬 바 있다. IEA는 유허 전력(Idle power) 감소에 따른 에너지 절감은 주로 기존 서버에서 발생할 것으로 전망하고 있다. 인프라 측면에서 전기 소비 감소는 자사용 데이터센터에서 코로케이션이나 하이퍼스케일 데이터센터의 이동⁴¹보다는 냉방 효율 상승 때문에 발생하는 것으로 전망했다. IEA도 언급했듯이 향후 AI 시대의 도래에 따른 전기 소비 증가에는 수많은 불확실성이 존재한다. 특히 전망 기간이 길어지면 이러한 불확실성은 더욱 커진다. 장기적인 관점에서 데이터센터의 에너지 소비 감소 요인으로 고려해야 할 점들을 추가적으로 언급한다면 다음과 같다.

먼저 양자 컴퓨터의 도입이다. 양자 컴퓨터는 이진수 비트가 아닌 양자 중첩(여러 상태로 동시에 존재할 수 있는) 큐비트를 이용하기 때문에 복잡한 연산을 기존 컴퓨터에서는 상상하기 힘든 속도로 빠르게 수행할 수 있다. 이러한 양자 컴퓨터가 실현될 경우 AI 학습과 추론에 필요한 시간과 전기 소비는 혁신적으로 감소할 것이다. 양자 컴퓨터의 실용화는 아주 먼 미래가 아니다. 현재 IBM이나 구글에서 개발된 양자 프로세서는 특정 작업으로 한정되지만, 기존 컴퓨터로는 수천 년이 걸리는 작업을 단 몇 초 만에 수행할 수 있다. 대부분의 양자 컴퓨터 전문가들은 실질적인 양자 컴퓨터의 등장은 시기의 문제이지, 등장 자체에 대해 의심하지 않는다. 양자 컴퓨터 전문가를 대상으로 한 2024년 설문조사(Mosca & Piani, 2024)에 따르면, 현재의 암호화 시스템을 무력화시킬 만큼의 유의미한 양자 컴퓨터(CRQC, Cryptographically Relevant Quantum Computer⁴²)가 향후 15년 이내 실현될 것이라고 답한 응답자는 50% 이상이었으며, 향후 30년 이내 등장할 것이라는 데에는 대부분(88%)의 전문가들이 동의하고 있다. 단, 양자 컴퓨터는 냉각을 위해 극저온이 필요하기 때문에 CRQC가 실용화된다고 해도 대규모 중앙 집중식 데이터센터에만 적용될 가능성이 크다.

옛지 데이터센터의 확산도 장기적으로 데이터센터의 전기 소비 감소 요인이다. 기존의 AI 특화 데이터센터의 에너지 소비 증가의 근본적인 원인은 클라우드 컴

⁴¹ 자사용 데이터센터 용량 비중은 20% 이하로 지속 감소할 것으로 전망.

⁴² CRQC는 RSA-2048 암호체계를 24시간 이내에 해독할 수 있는 양자 컴퓨터를 말함. RSA-2048은 2048비트의 정수를 소인수 분해하는 문제로, 현재 이용가능한 슈퍼컴퓨터를 모두 동원해도 수십억 ~ 수조 년이 걸려 사실상 기존 컴퓨터로는 불가능에 가깝다.

퓨팅 등과 같은 서버의 중앙 집중화이다. 중앙 집중화된 서버는 더 큰 규모의 데이터센터를 필요로 하며, 이에 따른 냉각용 에너지 소비도 크게 증가한다. 하지만 연산 처리를 분산해 데이터 수요와 지리적으로 가까운 곳에서 데이터를 처리할 경우 장거리 데이터 전송의 필요성이 줄고 서버 집중화가 완화된 에너지 소비를 줄일 수 있다. 앞서 언급했듯이 시장 조사 기관들은 전 세계 엣지 데이터센터 시장이 연평균 20% 이상 빠르게 증가할 것으로 전망하고 있다.

AI가 내장된 스마트폰, 스마트 홈 기기, 자동차, IoT 등의 온디바이스(on-device)를 중심으로 AI 시대가 도래한다면 데이터센터의 전기 소비는 빠르게 증가하지 않을 수도 있다. 온디바이스 AI는 실시간 작업 처리와 프라이버시 보호, 경량화에 따른 에너지효율 등으로 기존 데이터센터의 한계를 보완하며 빠르게 증가할 수 있다. 현재도 이미지 및 음성 인식, 실시간 번역, 가상 비서 등의 다양한 온디바이스 AI 서비스가 제공되고 있으며, 주요 시장 보고서들은⁴³ 글로벌 온디바이스 AI 시장이 2025년 이후 향후 5~7년간 연평균 20~28%로 빠르게 성장할 것으로 전망하고 있다.

5.2. 에너지 소비 외 생각해볼 점

AI 시대 전기 소비의 증가에 대해 말할 때 간과하지 말아야 할 점은 AI에 따른 생산성 향상이다. 예를 들어, 하버드, 와튼 스쿨, MIT 등의 공동연구(Dell'Acqua et al., 2023)는 생성형 AI가 숙련된 근로자의 생산성을 40% 정도 향상시킬 수 있다고 보고하고 있다. AI의 등장으로 자동화의 잠재력이 크게 향상되었는데, 맥킨지의 연구(Chui et al., 2023)에 따르면 생성형 AI와 기존 다른 기술과 결합한 업무 자동화로 전반적인 경제의 노동 생산성 증가율이 매년 3.4%p까지 상승할 수 있다. 산업별로는 제조, 금융, IT, 고객센터, 물류 등에서 AI 도입 효과가 크게 나타나고 있으며, 이에 대한 여러 사례들이 보고되고 있다.⁴⁴ 이러한 AI에 따른 업무 자동화는 노동 시간을 줄이고 생산성을 향상시켜 국가 전체의 에너지원단위 개선으로 이어질 수 있다.

⁴³ Coherent Market Insights(2025), Grand View Research(2025) 등

⁴⁴ 과학, 의료, 산업 분야에서의 AI 적용 및 발전에 관해서는 부록 2절을 참조하기 바란다.

에너지원단위란 생산(또는 산출) 단위당 투입되는 에너지의 양을 의미하는데 원단위가 하락할수록 에너지 소비가 효율적이라고 할 수 있다. 국가 전체의 관점에서 에너지원단위는 앞에서의 반도체 효율이나 데이터센터의 에너지효율보다 훨씬 중요하다. 에너지 소비가 빠르게 증가한다고 해도 그에 따른 생산과 소득이 더 빠르게 증가한다면(즉, 에너지원단위가 하락한다면) 에너지 소비 증가를 우려하는 시각으로만 볼 필요는 없다. AI 시대에 따른 국가 에너지원단위 개선에 관한 연구는 아직 없지만, AI 도입에 의한 생산성 향상 잠재력을 생각한다면 AI로 인한 에너지원단위의 하락 가능성이 매우 높아 보인다.

한편, AI 시대에 따른 전기 소비의 증가에도 불구하고, 국가 전체의 경제·사회적 비용은 오히려 감소할 가능성도 있다. 이메일의 발명으로 우편량이 감소하고, 화상 회의가 보급되면서 대면 회의에 따른 시간 및 비용이 감소했듯이, AI 시대 전기 소비 증가가 반드시 국가 전체의 비용 상승으로 이어진다고 말하기는 힘들다.

마지막으로 언급해야 할 중요한 요소 중 하나는 경제적 요소이다. 결국 지금까지 언급한 AI 시대 데이터센터의 전기 소비에 영향을 미칠 수 있는 주요 요인들을 최종적으로 조정하는 것은 ‘보이지 않는 손’, 즉 경제적 요소이다. 예를 들어, SemiAnalysis(2023.2.9.)은 구글 검색을 모두 ChatGPT로 교체하기 위해서는 2023년 기준 4백만 개 이상의 엔비디아 A100 GPU가 필요하다고 추정했는데, 2025년 6월 기준 가격을⁴⁵ 적용하면 칩 가격만 38~56억 달러(한화, 약 51~75조 원)로 계산된다. 여기에 설비 투자 및 전기 요금도 천문학적으로 추가될 것이다. 구글이 이러한 천문학적 비용을 지불하는 것이 경제적으로 이득이 있을지는 따져보아야 할 것이다. AI 시대에는 수많은 AI 모델과 서비스가 경쟁할 것이다. 이에 따라 AI 서비스의 가격도 지속 상승하기는 힘들 것이며, 데이터센터의 전기 수요 또한 어느 지점을 지나면 제한되기 시작할 것이다. Kunkel(2025.1.29.)의 보고서에 의하면 현재 ChatGPT와 Claude의 개발사인 OpenAI와 엔트로픽은 여러 AI 모델과의 경쟁으로 수수료 인상이 쉽지 않으며, 이에 따라 상당한 적자를 내고 있을 가능성을 지적한다. 보이지 않는 손은 전기 소비 증가뿐만 아니라 감소 요인으로도 동일하게 작용한다. 최신 고효율 냉각기술이 소형 데이터센터를

⁴⁵ NVIDIA A100 GPU(80GB) 신품 가격은 2025년 기준 9,500~14,000달러(약 1,300만~1,900만 원)에 달함. NVIDIA에서 가장 강력한 H100 GPU의 가격(약 5,000만 원)을 적용하면 비용은 더욱 상승한다.

포함한 모든 데이터센터에 적용되는 것은 경제적으로 어려우며, 업무 자동화를 위한 AI 도입 비용은 산업별로 차이가 크기 때문에 AI 도입이 일률적으로 확산되기는 힘들다. 향후 양자 컴퓨터가 도입된다고 해도 모든 데이터센터에 양자 컴퓨터가 도입되기는 어렵다. 데이터센터의 에너지효율을 지속해서 상승시키는 가장 근본적인 힘도 경제적 요인이다.

[그림 2-31] 데이터센터의 에너지 소비 증감 요인 정리



이상에서 향후 데이터센터의 에너지 소비 증감에 관해 고려해야 할 요인들을 살펴해보았는데, 이를 통해 데이터센터의 전력 소비 예측에 불확실성이 얼마나 큰 지를 알 수 있었다. 다음 장에서는 국내 데이터센터의 실증 자료를 이용해 분석 및 전망을 시도하는데, 이와 관련해 먼저 생각해봐야 할 점은 다음과 같다.

우리나라의 AI 서비스 수요는 가파르게 증가하고 있다. 국내 ChatGPT의 가입자 수는 2025년 4월 기준 약 1,740만 명으로 미국에 이어 세계 2위 수준이다⁴⁶. AI 서비스 수요에 따른 에너지 소비는 해당 AI 모델의 서버가 위치한 국가에서 발생한다. ChatGPT 서버는 주로 미국에 위치하며, 유럽 및 아시아 주요 거점 국가

⁴⁶ The Korea Herald(2025.6.1.)

에서도 서버를 운영하고 있다. 하지만, 2025년 현재 아직까지 한국에 ChatGPT 서버는 없다. 다시 말해, 국내 AI 이용자 수가 급증하고 있음에도 불구하고, 이에 따른 에너지 소비는 아직까지 국내 에너지 소비에 거의 영향을 미치지 못하고 있다. 그렇다면 앞으로는 어떻게 될까?

스탠포드 대학의 AI index 보고서(Maslej et al., 2025)에 따르면, AI 연구 및 주목할 만한 AI 모델 개발은 중국과 미국을 중심으로 이뤄지고 있으며, 아직 우리나라의 주목할 만한 AI 모델 개발은 소수에 불과하다. 2025년 5월 기준 Epoch AI에서 조사한 글로벌 주요 AI 모델 955개 중 한국의 모델은 14개로 전체의 1.5% 수준이다. 물론 이러한 조사들은 주목할만한 모델들을 대상으로 하므로, 국내에 더 많은 AI 모델들이 존재할 것으로 추측된다. 하지만 에너지 소비에 실질적으로 영향을 미칠 수 있는 규모의 AI 모델은 아직 없다. 따라서 향후 국내에서 글로벌 규모의 AI 모델이 얼마나 개발될 지가 국내 데이터센터 에너지수요 전망에 중요한 요소 중 하나다. 만약 향후 국내 AI 모델 개발이 특정 작업과 일부 소비자에게 특화된 소규모 모델을 위주로 이뤄진다면 국내 전력 소비에 대한 영향은 작을 수도 있다.

또한, 이러한 대규모 AI 모델의 학습과 추론을 위한 데이터센터가 얼마나 국내에 위치할지도 변수이다. ChatGPT의 서버가 위치한 데이터센터는 수요지에 따라 전세계에 분산되어 있다. 네이버도 미국, 독일, 일본, 베트남 등 해외 주요 거점에 데이터센터를 구축하여 운영하고 있다⁴⁷. 국내에서 개발된 글로벌 AI 모델을 구동하기 위한 서버가 수요처가 집중된 국가의 데이터센터로 분산된다면, 국내 전기 소비에 대한 영향은 생각보다 크지 않을 수도 있다.

⁴⁷ NAVER CLOUD PLATFORM

제3장



국내 데이터센터 전력 소비 실증 분석

본 장에서는 국내 데이터센터 현황을 살펴보고, 에너지 소비에 대한 실증 분석을 실시한다. 실증 분석은 국내 DC 전력 소비의 계절성 분석, 울산 AIDC의 에너지 소비 전망, 국가 전체 데이터센터 전력 소비 전망으로 이뤄진다. 실증 분석을 바탕으로 데이터센터 증가에 따른 국가 에너지 소비에 대한 시사점도 도출한다. 시사점에는 국내 DC의 전력공급 방안도 포함된다.

1. 국내 데이터센터 현황

1.1. 데이터센터의 정의

우리나라 법령 가운데 데이터센터의 정의를 제시하는 법은 지능정보화 기본법과 정보통신망 기본법이다. 지능정보화 기본법은 데이터센터 설립과 운영을 지원하기 위해, 정보통신망법은 통신 중단과 같은 사고를 예방하기 위해 안전 규제 대상으로서 데이터센터를 정의한다. 먼저 지능정보화 기본법은 데이터센터를 “지능정보서비스의 제공을 위하여 다수의 초연결 지능정보통신 기반을 일정한 공간에

집적시켜 통합 운영·관리하는 시설”로 정의한다.⁴⁸ 정보통신망 기본법은 “(타인 또는 자신의) 정보통신서비스 제공을 위하여 집적된 정보통신시설”로 정의한다.⁴⁹

구체적으로 지능정보화 기본법의 시행규칙은 서버와 스토리지, 안전시설 등을 갖춘 전산실과 수배전설비, UPS, 공조시설, 비상 발전 시설 등을 데이터센터의 요소로 보고 있고, 전산실의 바닥 면적이 500㎡ 이상이어야 지원의 대상인 민간 데이터센터가 될 수 있음을 밝히고 있다.

정보통신망법은 데이터센터의 구체적인 설비 요건을 밝히고 있지는 않으나, 규제의 대상이 되는 데이터센터는 전산실의 바닥 면적이 500㎡ 이상이고, 자가 데이터센터의 경우에는 “정보통신서비스 부문 전년도(법인인 경우에는 전 사업연도를 말한다) 매출액이 100억 원 이상”이며, “전년도 말 기준 직전 3개월 간 하루 평균 국내 이용자 수가 100만 명 이상”이어야 함을 명시하고 있다.⁵⁰

지능정보화 기본법이나 정보통신망법 모두 데이터센터의 규모 요건으로 전산실의 바닥 면적을 제시하고 있고 수전용량이나 전산 설비 용량은 제시하지 않고 있다. 다만 예외적으로 방송통신발전 기본법 시행령에서 “주요” 방송통신설비로 분류되는 데이터센터를 정의하면서 “전산실 바닥면적이 2만 2,500㎡ 이상이거나 수전(受電)설비의 용량이 40MW 이상일 것” 그리고 “전년도 매출액이 100억 원 이상일 것”의 요건을 제시하고 있다.⁵¹

지원이나 규제의 대상인 데이터센터를 정의하는데 있어서 공통적으로 전산실 바닥면적이 500㎡ 이상 조건을 달고 있는데, 여기서 500㎡는 대략 초등학교 교실 8개를 합쳐 놓은 정도에 해당하는 넓이이고 우리나라 건축법에서 중소형과 대형을 나누는 기준이다. 대규모 사업자에게 엄격한 규제 적용을 위한 “합리적 최소 단위”로서 우리 법체계에서 통용되고 있다. 그런데 데이터센터의 규제와 지원에 있어서 설비 용량이 아닌 면적 기준을 적용하는 방법의 적절성 여부는 추가 논의가 필요하므로 국내 현황과 함께 좀 더 살펴본다.

⁴⁸ 지능정보화 기본법([시행 2025. 3. 27.] [법률 제20410호, 2024. 3. 26, 일부개정]), 제40조(데이터센터의 구축 및 운영 활성화)

⁴⁹ 정보통신망 이용촉진 및 정보보호 등에 관한 법률([시행 2025. 6. 4.] [법률 제20534호, 2024. 12. 3., 일부개정]), 제 46조(집적된 정보통신시설의 보호)

⁵⁰ 정보통신망 이용촉진 및 정보보호 등에 관한 법률 시행령([시행 2025. 5. 20.] [대통령령 제35533호, 2025. 5. 20., 일부개정]) 제37조(집적정보통신시설 사업자등의 보호조치)

⁵¹ 방송통신발전 기본법 시행령([시행 2025. 4. 23.] [대통령령 제35470호, 2025. 4. 22., 일부개정]), 제23조(주요방송통신사업자)

2019년부터 우리나라에서 데이터센터는 건축법 시행령에 방송통신시설로 분류⁵²된다. 이전에는 데이터센터의 용도에 관한 규정이 없어서 업무시설, 교육연구시설, 방송통신 시설로 제각각 등록되었다. 2019년 이전에 등록한 데이터센터들은 이 세가지 분류로 나뉘어져 있어서 국내 데이터센터의 통계를 분석할 때 주의가 필요하다.

지능정보화기본법 시행규칙([시행 2025. 1. 1.][과학기술정보통신부령 제141호, 2024. 12. 13., 일부개정]), 제3조(민간 데이터센터의 시설 및 규모)


- ① 시행령 제27조제1항제1호에서 “과학기술정보통신부령으로 정하는 시설”이란 다음 각 호의 시설을 말한다.
1. 다음 각 목의 기준을 충족하는 전산실
 - 가. 서버와 스토리지 등의 정보통신장비를 갖추는 것
 - 나. 소방설비와 폐쇄회로텔레비전(CCTV) 등 안전시설을 설치할 것
 - 다. 외부와 공간이 분리되어 외부인의 접근 통제가 가능할 것
 2. 순간적인 정전, 전압 변동 등의 상황에도 안정적인 전력을 공급할 수 있는 수전(受電)·배전(配電) 설비와 무정전 전원장치 등 전력공급시설
 3. 전산실 내부의 정보통신장비를 일정한 온도로 유지하기 위한 공기조화시설 또는 냉각시설
 4. 30분 이상 정전이 발생할 경우 「지능정보화 기본법」(이하 “법”이라 한다) 제40조제2항에 따른 민간 데이터센터(이하 “민간 데이터센터”라 한다)의 전체 부하를 감당할 수 있는 자체 전력공급 능력을 갖춘 비상발전시설
- ② 제1항제2호부터 제4호까지의 규정에 해당하는 시설은 해당 시설의 개별 기능을 수행하는 설비에 장애가 발생하는 경우를 대비하여 정상적인 기능 수행을 보조하기 위한 예비설비를 갖추어야 한다.
- ③ 시행령 제27조제1항제2호에서 “대통령령으로 정하는 규모”란 다음 각 호의 어느 하나에 해당하는 면적을 확보하는 경우를 말한다.
1. 제1항제1호에 따른 시설의 바닥면적이 500㎡인 경우
 2. 복층의 바닥면적 등을 고려하여 제1항제1호에 따른 시설의 바닥면적이 500㎡에 해당한다고 볼 수 있는 경우

⁵² 건축법 시행령[시행 2025. 10. 1.] [대통령령 제35811호, 2025. 10. 1., 타법개정] [별표 1]

1.2. 주요 현황

우리나라에서는 전산실 바닥 면적 500㎡ 이상의 데이터센터만 규제와 지원의 대상이 되기 때문에 대체로 이 기준에 따른 시설만 데이터센터로 고려된다. 2023년 3월 9일 산업통상자원부가 발표한 “데이터센터 수도권 집중 완화 방안”을 보면 2022년 12월 현재 국내 데이터센터의 숫자를 147개라 하였고 “전력수요는 1,762MW”라 하였다(산업통상자원부, 2023.3.9.). 2022년 6월 12일자 냉난방공조 신재생 녹색건축 전문저널 기사에 따르면 2021년 기준 전국에는 총 159개 데이터센터가 있고, 이 가운데 112개는 정부와 공공 시설이고, 47개는 상업용이다.⁵³ 데이터센터 산업 관련 업체들의 이익집단인 한국데이터센터연합회(Korea Data Center Council, KDCC)가 2024년 7월에 발표한 조사에 따르면 2023년 기준 국내 데이터센터는 총 153개로 집계되었다(KDCC, 2024). 2025년 8월에 발표한 조사에는 2024년 기준 국내 데이터센터는 총 165개로 1년 사이에 12개나 증가하였다(KDCC, 2025).

[그림 3-1] 국내 데이터센터 증감 추이(2000~2024)



자료: KDCC(2025), p.11

⁵³ 냉난방공조 신재생 녹색건축 전문저널(2022.6.12.)

2000년 이후 코로나19가 대유행을 시작한 2020년을 제외하고 지속적으로 증가해 온 데이터센터의 수는 2022년과 2023년 연속해서 소폭 감소하였다. 그런데 이는 국내 데이터센터의 수가 실제 감소한 것이 아니고 조사상의 문제에 기인한 결과다. 조사를 수행한 KDCC에 따르면 재조사를 통해 상면 500㎡를 넘지 않는 소형 데이터센터를 찾아내서 제외하였는데, 특히 공공 데이터센터 가운데 소형 데이터센터를 다수 식별하여 제거하면서 전체 데이터센터의 수가 감소하였다(KDCC, 2024, 2025). 그런데 2022년 이전 자료를 모두 수정하지 않았기 때문에 국내 DC의 과거 증가 추세를 판단하는 데 주의를 기울여야 한다. 국내 데이터센터의 수는 소규모 데이터센터의 폐쇄에도 중대형 데이터센터가 꾸준히 개소하면서 지속적으로 증가하고 있다.

한국전력이 2024년 3월 21일 공공데이터 포털(<https://www.data.go.kr>)에 등록한 “데이터센터 전기 공급 현황”자료(한국전력공사, 2024.3.21.)에 따르면, 2023년에 한국전력은 총 150개 데이터센터에 전력을 공급하였고, 데이터센터의 수전용량 합계는 1,986MW이다. 국내 데이터센터의 수를 약 150여 곳으로 밝힌 것을 볼 때 한국전력과 산업부, 한국데이터센터연합회가 데이터센터에 대해 비슷한 기준을 갖고 있음을 확인할 수 있다. 이러한 정보를 종합하여 볼 때 통계 작성이나 정책의 대상이 되는 우리나라 데이터센터는 약 150여개라 할 수 있고, 이들은 전산실 바닥 면적이 500㎡ 이상 되는 상당한 규모의 시설이다.

그런데 2025년 6월 26일 발표된 IDC 자료는 우리나라 데이터센터의 전력 용량을 3,656MW로 발표하여 앞서 살펴본 산업부, 한국전력 자료와는 큰 차이가 있다. 세빌스코리아가 2024년 발표한 자료(Savills Korea, 2024)는 2023년 수도권 데이터센터의 전력 용량을 1,300MW로 발표하였으므로, 이를 사용해 간략히 전국 데이터센터의 용량을 추정해 보아도 IDC 자료와 차이가 있다. 이러한 차이는 데이터센터의 범위 설정에서 오는 것으로 추정한다. IDC의 경우 500㎡ 이하의 중소형 기업 데이터센터도 모두 포함한 것으로 보인다.

이번 연구에서는 정부가 준용하고 있는 기준인 바닥 면적 500㎡ 이상의 데이터센터만을 연구의 대상으로 한다. 이 기준을 적용하면 중소형 기업 데이터센터는 분석 대상에서 제외되고 금융업과 같은 대형 기업 데이터센터와 코로케이션이나 하이퍼스케일 데이터센터만 포함된다. 그렇지만 기업내 중소형 데이터센터의 전

력 수요가 얼마나 될지는 별도의 추정이 필요하고, AI 전환기에 발생하는 추가 전력 수요에 기업 데이터센터의 기여가 어느 정도일지도 검토가 필요하다. 일단 바닥 면적 500㎡ 이하 중소형 데이터센터를 논외로 놓고 데이터센터의 전력 수요를 분석하기 위한 기초 자료로서 아래에서는 한국데이터센터연합회(KDCC)의 2024년의 조사 보고서를 위주로 검토한다⁵⁴.

KDCC(2024)에 따르면 2023년 기준 153개 데이터 센터 가운데 민간 데이터 센터는 85개(55.6%)로 전체의 절반 이상을 차지하며, 이 중 자사용이 37개, 상업용이 48개이다. 자사용 데이터센터에는 금융권의 데이터센터 19곳이 포함되어 있다. 상업용 데이터센터는 KT, LG유플러스, SK 통신3사와 삼성전자 등 테크 기업들이 운영하는 데이터센터다. 2025년 현재 KT가 13곳의 데이터센터를 운영하는 등 통신3사들은 경쟁적으로 데이터센터를 확장하고 있다. 공공 데이터센터는 68개(44.4%)인데, 이 중 54.4% 이상이 정부 산하 공공기관에 속하고, 나머지는 중앙 정부와 지자체에 속한다.

민간 데이터센터가 제공하는 주요 서비스는 코로케이션이 91.3%로 가장 비중이 크고, 백업 서비스 60.9%, 서버/웹 호스팅 53.3%, 매니지드 서비스 49.3% 순으로 나타났다(중복응답 허용). 코로케이션 서비스는 사무실 임대처럼 임차인이 서버를 놓고 운용할 공간을 제공하고 전문적인 관리를 제공한다.

바닥 면적을 기준으로 한 규모별 분류에서 2,000㎡ 초과 데이터센터가 전체의 54.8%를 차지하는데, 민간 데이터센터의 경우 2,000㎡ 초과 대규모 데이터센터의 비중이 75.9%로 가장 많은 반면, 공공 데이터센터는 2,000㎡ 이하 규모인 중소형 데이터센터의 비중이 73%로 대부분을 차지하여 대조를 이룬다. 여기서 데이터센터의 규모 기준은 KDCC가 “Strategic Directions의 ‘Datacenter Size and Density, 2014’ 분류기준⁵⁵”에 따라 설정한 기준이다. 방송통신발전 기본법 시행령이 주요 방송통신설비로 분류하는 “전산실 바닥면적 22,500㎡ 이상”의 “거대” 또는 “메가” 데이터센터는 몇 군데 없는 것으로 보인다.

⁵⁴ KDCC는 2025년에도 조사 보고서를 발표하였으나, 국내 데이터센터의 현황에 대해서는 자세하게 다루지 않았다. 따라서 2024년 KDCC 보고서가 데이터센터 현황에 관한 가장 최신 자료이다.

⁵⁵ 원 참고문헌을 확인할 수 없어서 그대로 인용하였다.

〈표 3-1〉 국내 데이터센터 면적 기준 규모별 비중

상면 기준	민간	공공	합계
중소형(~2,000㎡)	24.1%	73.0%	45.2%
대형(2,001~7,500㎡)	47.0%	20.6%	35.6%
거대(7,501~22,500㎡)	27.7%	6.3%	18.5%
메가(22,501㎡~)	1.2%	0%	0.7%

주: Statagic Directions의 'Datacenter Size and Density, 2014'의 분류 기준 활용. 조사 대상 153개 데이터센터

자료: KDCC(2024), p.17

민간 데이터센터의 평균 수전용량은 17.7MW로 공공 데이터센터의 6.0MW 보다 약 2배 이상 컸다(KDCC, 2024). 민간 데이터센터의 규모가 공공보다 2배 정도 크다고 볼 수 있다. 평균 수전용량을 사용하여 전체 수전용량을 계산하면 약 1,913MW로 한국전력이 공개한 2023년 수전용량과 소폭 차이가 있으나 유사한 것으로 나타난다. 한국데이터센터협회의는 운영 기간에 따른 수전용량을 조사했는데 운영 기간이 짧을수록 수전용량이 커지는 경향이 있다. 이는 클라우드 서비스의 확대, AI 보급 확대 등을 반영하여 신설 데이터센터의 설비 용량이 커지고 있음을 보여준다.

〈표 3-2〉 국내 데이터센터 업력별 수전용량별 비중

구분	5년 미만	5~10년	10~15년	15~20년	20년 이상
10MW 미만	25.0%	53.9%	38.1%	45.5%	68.0%
10~20MW 미만	33.3%	19.2%	38.1%	18.2%	8.0%
20~40MW 미만	25.0%	15.4%	14.3%	27.3%	24.0%
40MW 이상	16.7%	11.5%	9.5%	9.0%	0.0%


주: 조사 대상 153개 데이터센터 가운데 95개 데이터센터 응답

자료: KDCC(2024), p.25

2023년 기준 전체 데이터센터의 58.8%가 수도권에 위치하고 있으며, 특히 민간 데이터센터의 수도권 집중도가 72.9%로 매우 높게 나타난 반면에 공공 데이터센터는 41.2%만이 수도권에 위치하여 상대적으로 전국에 균등하게 분포되어 있다(KDCC, 2024). 2024년에는 수도권 집중이 더 강화되어, 전체 데이터센터의

60.4%가 서울과 경기 수도권에 위치한 것으로 조사되었다(KDCC, 2025). 민간 데이터센터의 경우는 75.3%가 수도권에 위치하고 있어 수도권 집중 현상이 더욱 두드러진다(KDCC, 2025). 데이터센터의 수도권 선호는 인프라, 고객 수요, 인력 수급 용이성, 네트워크 지연율 등의 요인에 기인한다. 수도권에 이어 영남과 호남 지역의 DC 비중 약 13% 내외이며, 강원은 단 6개의 DC만 존재한다.

[그림 3-2] 국내 지역별 데이터센터 분포 현황(2024년)



자료: KDCC(2025)의 자료를 이용해 재구성

데이터센터의 상면(상부 면적: 데이터센터에서 서버나 랙 등을 설치할 수 있는 공간) 가동률을 살펴보면 대략 62%의 데이터센터가 80% 이상의 가동률을 보고하였다(KDCC, 2024). 한국데이터센터연합회는 이 조사를 수도권과 비수도권으로 나눠 살펴봤는데, 상면 가동률이 80% 이상인 수도권 데이터 센터의 비중이 81.8%인 반면에 비수도권에 위치한 데이터센터의 비중은 40% 수준으로 나타났다. 비수도권에 위치한 데이터센터의 임대 영업이 어렵다는 것을 보여준다. 한가지 짚고 넘어갈 점은 상면 가동률은 앞 장에서의 IT 장비 또는 서버 가동률(이용률)이나 이번 연구의 전망 모형에서의 이용률과는 다른 개념이며 수치상으로도 큰 차이가 있다.

〈표 3-3〉 국내 데이터센터 상면 가동률 현황

상면 가동률	수도권	비수도권	총합
20% 이하	-	-	-
20~40%	-	10.0%	4.8%
40~60%	9.1%	45.0%	26.2%
60~80%	9.1%	5.0%	7.1%
80~100%	81.8%	40.0%	61.9%

주: 조사 대상 153개 데이터센터 중 42개소 응답

자료: KDCC(2024), p.25

2. 국내 데이터센터 전력 수요 분석

국내 데이터센터의 에너지 소비 추정과 전망에 대한 연구는 거의 없다. 가장 큰 원인은 이용할 수 있는 국내 데이터센터의 정보가 매우 제한적이기 때문으로 보인다. 국내 데이터센터의 정보가 포함됐을 만한 통계는 에너지총조사와 국토부의 건축물 통계이다. 산업통상자원부가 3년마다 발표하는 에너지총조사는 우리나라 전체 에너지 소비 실태와 구조를 파악하기 위해 산업, 수송, 가정, 상업, 공공 및 대형건물 등 여러 부문을 대상으로 한 표본조사이다. 2023년 조사에서는 약 5만 4천여개의 표본을 대상으로 실시되었다. 에너지총조사의 상업·공공 부문에서 데이터센터 관련 조사가 일부 이뤄지고 있는데, 공식 통계로 가공하여 발표하지는 않고 있다. 국토교통부가 매월 전국의 일정 규모 이상의 건물을 대상으로 전수 조사하는 건축물 통계에도 데이터센터의 에너지 소비가 포함되어 있다.

하지만, 두 통계 모두 애초에 DC의 에너지 소비를 조사하기 위한 목적으로 이뤄진 조사가 아니기 때문에, DC 에너지 소비량 분석에 활용하는 데는 큰 한계가 존재한다. 표본 조사인 에너지총조사에 포함된 방송통신시설, 업무시설, 교육연구시설이 모두 데이터센터는 아니며, 다른 업종으로 분류된 데이터센터도 존재할 수 있다. 건축물 통계는 건물을 대상으로 하기 때문에 데이터센터를 정확히 분리하는 것은 불가능하며, 건물 전체가 데이터센터라고 하더라도 데이터센터인 건물을 식별하는 코드는 따로 없다. 게다가 건축물 통계에서는 산업 등의 용도로 구분된 건물도 조사대상에서 제외되어, 모든 데이터센터 건물이 포함되었다고 할 수도 없다.

본 연구에서는 국내 주요 데이터센터의 월간 전기 소비 패턴 분석을 위해 국토교통부 자료에서 최대한 데이터센터를 식별하여 총 25개 데이터센터의 월간 전기 소비 자료를 이용했다.

2.1. 국내 DC 전력 소비 월간 패턴(계절성) 분석

2.1.1. DC 샘플 자료

국내 DC의 월간 전력 소비 패턴 분석에 사용한 자료는 녹색건축포털⁵⁶에서 제공하는 “지번별 에너지 사용량” 정보이다. 자료의 원출처는 국토교통부의 건축 HUB 건물에너지 정보이며, 건물에너지 관리 시스템을 통해 수집된 전기 사용량 정보이다. 에너지 사용량의 경우 단독주택과 200세대 미만 공동주택의 소비는 조사 대상에서 제외되고, 산업, 수송, 발전, 열병합, 충전용 등의 용도도 제외된다⁵⁷. 분석에 이용한 자료는 2016년 3월부터 2024년 9월까지의 월간 자료이며, 2024년 9월 기준 조사된 전체 건물 수는 143만 개 이상이다.

데이터센터의 전기 소비를 추출하기 위해 먼저 LG U+, KT Cloud 홈페이지 등을 포함한 복수의 출처들을 이용해 데이터센터의 주소를 식별했으며, 이를 “지번별 에너지 사용량” 정보에서 제공하는 주소와 매칭하여 월간 전기 소비량 자료를 추출했다. 데이터센터의 주소와 일치하는 모든 자료가 존재하지는 않았으며, 소비량 자료가 최근 1년 이상 존재하고, 추세 등에 이상치가 없는 데이터만을 분석에 이용했다. 최종적으로 선정된 샘플 수는 총 24개이며⁵⁸, 여기에는 KT 데이터센터 9개(용산, 목동, 강남, 송정, 대구, 대전, 백석, 충주, 천안), LG U+ 데이터센터 9개(상암, 서초1, 서초2, 논현, 부산, 대구, 광주, 대전, 안양), 네이버 각 춘천 등이 포함되었다.

2024년 9월 소비량 기준, 원자료에서 조사된 전국의 건물 중 소비량이 가장 많은 100대 건물 가운데 앞서 선정한 데이터센터 중 7개가 포함되어 있었으며, 나머지 100대 건물 중 데이터센터로 여겨지는 곳은 없었다. 서울특별시의 10대 전

⁵⁶ 녹색건축포털 그린투게더

⁵⁷ 공공데이터포털(국토교통부 건축HUB 건물에너지정보 서비스)

⁵⁸ 한 샘플의 경우 두개의 데이터센터가 합산되어 있음으로 데이터센터 수로는 25개이다.


기 다소비 건물 중에는 두 번째와 여섯 번째 순위가 포함되어 있었다. 이를 통해 추측할 수 있는 것은 위에서 선정한 샘플 데이터센터는 상당 규모 이상의 국내 주요 데이터센터라는 것이다. 아래 이어지는 실증 분석에서는 편의상 규모별로 대형, 중형, 소형으로 분리했지만, 사실상 본 연구에서 사용된 자료는 대부분 국제 기준상 상당 규모(대형) 이상의 데이터센터라고 할 수 있다. 마지막으로 국토부 자료의 한계는 “지번별” 자료의 특성상 지번에 속한 건물 전체의 전기 소비량을 조사하므로, 경우에 따라서는 데이터센터뿐만 아니라 동일 건물에 입주한 데이터센터 외 업종의 전기 소비량도 포함되어 있다는 점이다.

2.1.2. 샘플 DC의 전력 소비 추이, 분포, 계절성


[그림 3-3]은 선정된 데이터센터별 월간 전기 소비량을 나타낸 것이다. 그림을 통해 확인할 수 있듯이 공통된 추세는 발견되지 않았다. DC 1, 2, 9, 15, 17, 18, 20, 21, 23의 경우 전기 소비가 시간에 따라 상승하는 모습을 보인 반면, DC 13, 14와 같은 데이터센터는 전기 소비가 감소하는 추세를 보였다. 나머지 DC 3, 4, 5, 6, 7, 8, 10, 11, 12, 16, 19, 22 데이터센터는 특별한 추세를 보이지 않고 일정한 전기 소비를 보여주었다.

전기 소비량 측면에서는 대부분의 데이터센터의 연간 전기 소비량이 50GWh 미만이었다. [그림 3-4]은 최근 1년(2023.10~2024.9)의 전기 소비량을 기준으로 샘플 데이터센터의 분포를 보여준다. 연간 전기 소비량이 100GWh를 넘는 데이터센터는 총 3개(DC1, DC4, DC24)였으며, 50~100GWh 수준이 5개이었다. 나머지 16개 데이터센터의 전기 소비는 연간 50GWh 미만으로 나타나고 있다. 샘플 DC가 국내의 주요 DC라는 것과 자료의 한계상 소비량이 과대 추정되었을 가능성을 고려하면, 대부분 국내 DC의 실제 연간 전기 소비량은 30GWh 이하일 것으로 판단된다.

[그림 3-3] 국내 주요 데이터센터별 전력 소비 추이




[그림 3-4] 주요 데이터센터별 연간(2023.10~2024.9) 전력 소비 분포



계절성 측면에서는 대부분의 데이터센터가 여름철에 전기 소비량이 증가하고 겨울철에는 감소하는 양상을 보여주었다. 샘플별로 계절성이 아주 뚜렷하게 나타난 곳도 있었고, 몇몇은 계절성이 크게 나타나지 않았다. 계절성을 빠르고 쉽게 (rule of thumb) 확인하는 방법은 매월의 전기 소비량 평균을 살펴보는 것이다 ([그림 3-5] 참고). 몇몇 데이터센터(예를 들어 DC3, DC21)를 제외하곤 대부분 8월경에 전기 소비량이 평균적으로 제일 크게 나타나는 계절성을 보여주었다. 앞에서 데이터센터 부하 패턴이 사무실 등 복합 용도의 경우 높은 계절성을 보일 가능성에 대해 언급했는데 위의 결과는 이러한 사실을 확인해 준다. 아래에서는 국내 데이터센터의 전기 소비의 계절성 여부가 데이터센터의 특징과 관련이 있는지 살펴보기 위해 군집(Cluster) 분석을 했다.


[그림 3-5] 데이터센터별 월평균 전력 소비 패턴



군집(클러스터) 분석은 데이터간 유사성을 근거로 클러스터를 나누는 것으로, 분석에는 데이터센터별 매월 평균 전기 소비량 자료를 이용했다. 위의 월평균 전력 소비 패턴에서 대부분의 데이터센터의 전기 소비량이 계절성을 보인다는 것을 확인했으나, 그 크기는 센터별로 크게 다를 수 있다. 예를 들어 DC5나 DC6의 경우 여름철(8~9월)의 평균 소비량이 가장 크나, 연중 소비량이 가장 적은 월과의 전력 소비량 차이는 크지 않음을 알 수 있다. 다시 말해 여름철에 전기 소비량이 상대적으로 얼마나 더 증가하는(즉, 계절성이 얼마나 큰)지를 보기 위해서는 자료를 표준화(Scale)해야 한다. 스케일된 자료를 이용해 군집 수를 3개로 했을 때의


결과는 [그림 3-6]에 제시되어 있다. 결과에 따르면 계절성의 크기에 따라 클러스터를 3개로 나눌 수 있었다. Cluster-1에서 계절성이 가장 뚜렷하게 나타났으며, Cluster-3은 미약한 계절성을, Cluster-2는 계절성이 거의 없었다.

[그림 3-6] 계절성 강도별 군집(클러스터) 분석 결과



[그림 3-7]은 각 클러스터에 속한 데이터센터와 월평균 전력 소비량을 보여주는 박스(Box) 그래프이다. 앞의 그림과 비교하면 계절성이 상대적으로 뚜렷한 클러스터(Cluster)일수록 전기 소비량이 큰 데이터센터와 대응된다는 것을 알 수 있다. Cluster-1의 경우 연간 전력 수요가 140GWh 이상, Cluster-3은 40~90 GWh, Cluster-2는 30GWh 이하의 데이터센터들로 구성되어 있었다. 이는 한편으로 상식적인 결과일 수 있다. 대형 데이터센터일수록 IT 냉각 요구량 및 상주 인원 증가 등으로 여름 냉방용 전기 수요의 절대적인 변동 폭이 상대적으로 클 수 있기 때문이다.

[그림 3-7] 클러스터별 월평균 전기 소비 분포



<표 3-4> 클러스터별 월 평균 전기 소비량(GWh)

클러스터	최소	1 사분위(25%)	중간값	평균	3 사분위(75%)	최대
Cluster 1	12.2	13.7	15.2	14.4	15.5	15.9
Cluster 2	3.4	3.8	5	5.2	6.6	7.1
Cluster 3	0.1	0.3	0.5	0.8	1.2	2.3

그렇다면 우리나라에서 데이터센터의 규모가 커질수록 계절성에 더욱 영향을 받는다고 할 수 있을까? 이에 대한 답을 하기 전에 계절성의 영향력을 어떻게 측정할 수 있을지에 대해 생각해 보아야 한다. 예를 들어 어떤 데이터센터의 전기 소비량이 기온 변화가 없다면 소비가 연중 일정하게 유지되고, 기온 변화 시 소비량이 소폭 변한다고 가정해 보자. 즉, 이 DC의 전기 소비량 변화는 대부분 계절성(기온)에 기인하나, 이에 따른 변동 폭은 크지 않다. 이 경우 이 데이터센터의 에너지 소비는 계절성의 영향이 크다고 할 수 있을까? 전기 소비 변동(분산) 측면에서는 계절성의 영향력이 크다고 할 수 있을 것이나, 그 절대적인 변동 폭이 크지 않다면 국가 전체적으로는 계절성의 영향이 크지 않다고 할 수 있을 것이다. 다시 말해 계절성의 영향력을 평가하기 위해서는 소비량 변동성(분산) 측면과 절대적 변동 폭 두 가지 관점에서 살펴보아야 할 것이다. 위의 클러스터 분석 결과는 후자 측면에서의 계절성의 크기를 보여준다고 할 수 있다.


2.1.3. STL 분해를 통한 계절성 분석(분산 측면 및 절대적 변동 폭 측면)

본 연구에서는 계절성의 영향력을 보다 자세히 알아보기 위해 STL 분석을 실시한다. STL 분석은 시계열을 추세(Trend), 계절성(Seasonal), 잔차(Remainder)의 세 부문으로 분해하는 통계적 방법론이다⁵⁹.

$$Y_t = Trend_t + Seasonal_t + Remainder_t$$


STL 분석을 위해서는 월간 자료가 최소한 2년치는 있어야 한다. Cluster-1에 포함되는 DC24의 경우 이러한 조건을 충족하지 못해 STL 분석을 실시할 수 없었다. 따라서 DC24를 제외한 총 23개의 데이터센터에 대해 STL 분석을 실시했으며, [그림 3-8]과 [그림 3-9]는 각각 Cluster-1에 속한 DC1과 DC4의 STL 분해 분석 결과를 보여준다. DC1과 DC4의 STL 분석 결과의 가장 큰 차이점은 추세의 유무이다. DC1은 증가 추세가 뚜렷한 반면, DC4는 앞의 [그림 3-3]에서도 확인할 수 있었듯이 사실상 추세가 없이 소비량이 일정하게 유지된다고 할 수 있다.

[그림 3-8] DC1의 STL 분해 분석



⁵⁹ 자세한 방법론은 Cleveland et al.(1990)을 참조하기 바란다.

[그림 3-9] DC4의 STL 분해 분석




분산 측면에서의 계절성의 크기 측정을 위해 전체 전기 소비량의 분산과 계절성에 기인한 소비의 분산 비율을 아래와 같이 계산했다.

$$\text{분산비중} = \frac{\text{계절성 전기 소비 분산}}{\text{데이터센터 총 전기 소비 분산}}$$


이를 백분율로 나타낸 것이 [그림 3-10]이다. 분산 비중이 20%라면 전력 소비 변동의 20%가 계절적 요인에 기인한다는 의미이다. 계절성 분산 비중이 가장 큰 데이터센터는 DC14이었는데, 이 경우 전력 소비 변동의 80% 이상이 계절적 요인에 기인하는 것으로 나타났다. 반면, 분산 비중이 가장 작은 DC1은 전체 전기 소비 변동에서 계절적 요인에 기인하는 부분이 미미한 것으로 나타났다. DC1의 경우 강한 증가 추세로 소비 변동의 대부분이 계절적 요인보다는 추세적 요인에 기인했기 때문이다. 분산 비중은 클러스터별로 특별한 특징을 보이지는 않았다. DC1과 함께 가장 전기 소비가 많은 DC4의 경우 소비량 변동의 50% 가까이가 계절성에 기인하는 것으로 나타났으며, 규모가 가장 작은 군집인 Cluster-2에 속한 DC17과 DC10에서는 변동의 10% 미만이 계절성에 기인한 것으로 나타나기도 했다. 즉, 전력 소비의 변동(분산)에 계절성이 미치는 영향력은 데이터센터별로 매우 달랐으며, 데이터센터의 규모와는 큰 관계가 없는 것으로 판단된다.

[그림 3-10] 데이터센터별 계절성 분산 비중




다음으로는 계절성의 절대적 변동 크기를 비교한다. STL 분해 결과에 따른 계절성에 기인한 전기 소비 변동량 자체를 데이터센터별로 조사(이상치 제외)했으며, 이를 [그림 3-11]이 보여주고 있다. 그림은 클러스터 또는 데이터센터의 규모와 변동폭이 양의 상관관계가 있음을 보여준다. 이는 앞서 클러스터 분석의 결과로부터 추측되었던 결과이다. 클러스터별로 계절성에 따른 절대적 소비 변동은 [그림 3-12]에 표현되었다. DC24가 STL 분석에서 제외되어 Cluster-1의 샘플 수가 2개뿐이어서 한계가 있지만, 대규모(Cluster-1, 연간 140GWh 이상) 데이터센터에서는 여름철 고온으로 전기 소비가 평균적으로 약 0.13GWh, 최대 0.75GWh 상승한 것으로 나타났다. 중간 규모의 데이터센터(Cluster-3, 연간 40~90GWh)의 경우 평균적으로는 계절성에 따른 전기 수요 변동량이 거의 0에 가까웠지만 최대 0.49GWh 정도까지 증가하는 것으로 나타났다. 소형(Cluster-2, 연간 30GWh 이하) 데이터센터에서는 중간 규모와 유사하게 평균적으로는 계절에 따른 전기 수요 변동은 없었으나 최대 0.07GWh까지 증가하는 경우도 있었다.

[그림 3-11] 데이터센터별 계절성에 따른 전력 수요 변동 폭



[그림 3-12] 클러스터별 계절성에 따른 전력 수요 변동 폭



<표 3-5> 계절성에 따른 전력 수요 변동 폭(GWh)

클러스터	최소	1 사분위(25%)	중간값	평균	3 사분위(75%)	최대
Cluster 1	-0.667	-0.116	0.122	0.129	0.275	0.750
Cluster 2	-0.079	-0.019	-0.003	-0.005	0.011	0.070
Cluster 3	-0.471	-0.132	0.011	0.001	0.114	0.487

이상의 계절성 분석 결과를 요약하면 다음과 같다. 국내 DC 전기 소비는 대부분 여름철에 증가하는 계절성을 보이는데, 계절성의 크기를 절대적 측면과 분산 측면으로 나누어 보면 전자에서는 계절성의 영향력이 크지 않았으나 후자에서는 영향력이 큰 것으로 나타났다.

먼저, 절대적 변동 폭의 측면에서는 일부 대규모 DC를 제외하고는 데이터센터의 전기 소비는 기온과 계절에 큰 영향을 받지 않는 것으로 보인다. 계절에 따른 전기 소비 변동 폭은 규모와 양의 상관관계를 보였다. 연간 140GWh 이상의 전기를 쓰는 초대형 DC의 경우 여름철에 최대 약 0.75GWh까지 상승하는 것으로 나타났다으나, 국내 DC의 다수를 차지할 것으로 보이는 연간 30GWh 이하의 소형 DC는 평균적으로 계절에 따른 수요 변동이 거의 없었다. 이러한 결과는 향후 데이터센터가 초대형 중심으로 확산된다면, 국가 피크전력 수요에 부담을 줄 수 있다는 점을 시사한다. 다음으로 분산 측면에서는 상당수의 DC에 있어 전기 소비 변동의 주 원인이 기온으로 나타났다. 분석 샘플의 17%에 달하는 DC에서 전기 소비 변동의 70% 이상이 계절에 기인한 것으로 나타났다. 절대적 측면과는 달리 이러한 현상은 DC의 규모와 유의미한 관계가 없는 것으로 보인다.

이러한 결과는 전력 정책 측면에서 데이터센터가 DR에 상당한 잠재력을 가지고 있음을 시사한다. 데이터센터의 에너지 소비가 계절성을 가지는 이유는 IT 냉각용뿐만 아니라 관리 사무실과 상주 인원을 위한 냉방 부하 때문으로 판단되는데, 여름철 권장 설정 온도 상승과 같은 간단한 조치만으로도 국가 전체의 피크 수요 부담 경감에 도움이 될 것으로 보인다. 데이터센터는 고도로 자동화된 시설로 에너지효율 및 부하 관리 시스템을 통한 DR 참여를 생각하면 실시간 유연성 자원으로의 역할이 기대된다.

2.2. 국내 AI 데이터센터의 에너지 소비 추정 사례(울산 AIDC)

앞 장에서 살펴보았듯이 AI 데이터센터(AIDC)는 기존 DC 대비 에너지 소비가 크다. 상업적인 AI가 출현하고 이에 대한 관심이 증폭된 것은 비교적 최근으로, 2024년까지 국내에 실질적인 AIDC는 없었다. 국내 AIDC는 최근 들어 건설되기 시작하였는데, 대표적으로 울산 AIDC를 들 수 있다. 본 절에서는 AIDC 에너지

소비 추정의 예로 울산 AIDC가 준공되었을 경우 에너지 소비량을 추정해 본다.

최근 기사에 따르면⁶⁰ SK그룹과 글로벌 1위 클라우드 기업 아마존(Amazon)은 울산 미포 국가산업단지에 초대형 AIDC를 건설하기로 했다. 데이터센터 건설을 위해 약 7조 원이 투자되고, 약 6만 장의 AI 반도체가 설치될 예정이다. 2025년 9월에 착공해 2027년 11월 41MW 규모로 가동을 시작하고, 2029년 2월까지 103MW 규모로 완공될 예정이다.

AI 반도체 개수가 6만 개라고 가정할 경우, 데이터센터의 전기 수요를 결정하는 가장 중요한 요소는 서버를 구성하는 AI 반도체의 구성이다. AI 반도체는 크게 GPU, TPU(Tensor Processing Unit), ASIC(Application-Specific Integrated Circuit), NPU(Neural Processing Unit) 등으로 분류된다. 이 중 데이터센터용 AI 반도체는 NPU를 제외한 나머지라고 할 수 있다. NPU는 주로 엣지 및 모바일 환경에서 실시간 저지연 처리에 특화되어 있는 반도체이다.

GPU에는 대표적으로 엔비디아의 A100, H100, H200, B200 등이 있다. TPU는 구글이 개발한 전용 AI 칩으로 대규모 텐서(Tensor)⁶¹ 연산에 특화되어 있다. 대표적인 TPU로는 TPU v4, TPU v5e, TPU v5p 등이 있다. ASIC은 특정 AI 작업을 위해 맞춤형으로 설계된 칩으로 대표적으로 인텔의 Gaudi2, Gaudi3과 아마존의 자체 설계 칩인 학습용 AWS Trainium 1, Trainium 2, 추론용 AWS Inferentia 1, Inferentia 2 등이 있다. 이들 AI 반도체들의 최대전력 TDP(열 설계 전력)와 연산 효율은 천차만별이다. 일반적으로 고성능 최신 칩으로 갈수록 TDP와 연산 속도가 모두 상승하나, 연산 속도가 TDP 대비 빠르게 상승해 연산 효율이 높아진다.


AI 반도체의 전기 소비량은 칩의 종류와 연산량에 따라 변한다. 울산 AIDC의 전기 소비량을 정확히 추정하기 위해서는 설치된 칩의 종류와 연산량을 알아야 하지만 이를 예측하기란 매우 힘들다. 특히, 연산량은 울산 AIDC에 어떤 AI 서비스가 얼마나 발생할지를 예측해야 하므로, 실증 데이터가 없는 현재로서는 예측이 불가능에 가깝다. 앞 장에서 살펴보았듯이, AI 작업의 성격이나 형태에 따라 전력 소비량은 크게 차이가 난다. 극단적으로 AI 반도체가 설치되었다고 해도, 기존 데

⁶⁰ 울산저널(2025.7.19.)

⁶¹ 텐서 연산이란 다차원 배열 구조(텐서)의 데이터를 빠르고 효율적으로 다루기 위한 모든 수학적 연산을 포괄하는 개념이다.

이터센터와 유사한 작업들이 주로 수행된다면 에너지 소비는 기존 데이터센터 대비 크게 늘지 않을 수도 있다. 데이터센터에 설치될 반도체의 종류도 예측하기 매우 힘들다. 글로벌 국가들은 최신 AI 반도체 확보를 위해 총력을 기울이고 있으며, 우리나라가 최신 고성능 반도체를 얼마나 확보할지 불확실성이 크다.

[그림 3-13] 주요 AI 반도체의 TDP(Thermal Design Power)




자료: 개별 정보(Google Cloud, Intel, NVIDIA 사이트)를 종합해 저자 작성. AWS 칩의 경우 공개된 TDP 정보가 없음.

다음에서는 울산 AIDC의 연산량에 대한 전제는 생략하고 계획대로 6만 개의 AI 칩이 설치된다는 가정하에 전기 소비량을 계산한다. 먼저, 주요 AI 칩에 대한 정격 최대전력(TDP)은 위 그림과 같다. TDP는 칩의 종류에 따라 190~1,000W로 다양하다. 현재 개발 중인 최신 칩의 경우 TDP가 더욱 상승할 수 있다. 실제 GPU당 평균 전력 소비는 TDP 대비 낮다. Patel et al.(2024)에 따르면 추론 작업에서 GPU TDP의 약 60~80%의 전기 소비를 하는 것으로 조사된다. 울산 AIDC의 대부분의 작업이 추론이라고 가정해 GPU 최대전력의 약 70%가 AI 작업 시 평균적으로 소비된다고 가정한다. 울산 AIDC에 설치될 6만개의 칩의 종류와 평균 TDP를 특정해 전제하기는 어려우므로 TDP를 200~1,200W 범위로 가정한다.

AI 훈련과 추론 과정에서 AI 반도체의 실제 전력 소비량은 서버와 데이터센터의 오버헤드 비용으로 정격 최대전력(TDP)을 초과할 수 있다. 예를 들어 H100의 TDP는 700W이지만, H100 칩으로 구성된 서버는 GPU당 전기 소비가 최대 1,500W까지 증가할 수 있다(You, 2025.2.7.). 칩의 종류에 따라 오버헤드 비용으로 전기 소비가 TDP에 비하여 얼마나 증가할지는 알 수 없으나, 위의 사례를 근거로 GPU의 최대전력은 정격 용량인 TDP 대비 최대 2.1배까지 증가할 수 있는 것으로 가정한다.

다음으로 고려해야 할 요소는 GPU 이용률이다. GPU 이용률은 일반적으로 훈련의 경우 약 30~50% 수준이며, 추론의 경우 메모리 대역폭 병목현상으로 훈련 대비 이용률이 낮다고 알려져 있다. 이용률은 데이터센터의 규모가 클수록 높아지는 경향이 있는데, IEA(2025b)에 의하면 초대형 하이퍼스케일 데이터센터의 경우 약 50% 수준으로 추정하고 있다. 한편, Epoch AI에서는 주목할 만한(notable) 글로벌 AI 모델에 관한 정보를 제공한다. 2025년 5월 기준 Epoch AI 데이터셋에는 총 955개의 주요 AI 모델에 관한 정보가 포함되었는데, 이 중 41개 모델이 장비 이용률(Hardware Utilization) 정보를 제공하고 있다. 이를 히스토그램으로 나타내면 [그림 3-14]와 같다. 이에 따르면 주요 AI 모델의 장비 이용률은 17.1~ 56.5%로 다양했으며 평균은 36.5% 수준으로 나타난다. TDP와 마찬가지로 울산 AIDC의 장비 이용률을 특정한 값으로 전제하기는 어려우므로 범위로 가정한다.

[그림 3-14] 주목할 만한 글로벌 AI 모델의 하드웨어 이용률



자료: Epoch AI. AI model data 정보를 추출해 저자 작성


울산 AIDC의 전기 소비를 추정하기 위해 마지막으로 PUE 전제가 필요하다. 앞에서 살펴본 대로 2024년 기준 글로벌 평균 PUE는 1.4~1.5 수준이며, 최신 데이터센터의 경우 1.3 수준을 달성하고 있다. 국내 네이버 각 춘천 DC의 경우 PUE를 1.1로 보고하고 있다. 울산 AIDC의 PUE 전제도 TDP 및 이용률과 함께 범위로 가정했다. 이상의 전제들을 이용해 울산 AIDC의 연간 전력 소비량은 아래의 식과 같이 계산되었다.

$$\text{칩 수(6만개)} \times \text{TDP} \times 70\% \times 2.1 \times \text{GPU 이용률} \times \text{PUE} \times 8,760 \text{ 시간}$$

식에서 TDP는 200~1,100W, 이용률은 20~65%, PUE는 1.05~1.30 범위로 설정했으며, 이에 따른 울산 AIDC의 연간 전력 소비량은 [그림 3-15]와 같다. 전력 소비량은 TDP, 이용률, PUE가 높을수록 커진다. TDP 1,100W, 이용률 65%, PUE 1.3일 때 울산 AIDC의 연간 전력 소비량은 약 718GWh로 최대치를 기록하며, 최소 전력 소비량은 TDP 200W, 이용률 20%, PUE 1.05일 때 33GWh로 추정된다. 보다 현실적인 가정(TDP 600W, 이용률 40%, PUE 1.15)에서는 전력 소

비량이 연간 약 213GWh 수준으로 추정된다. 전체 시나리오 분석에서의 평균 및 중간 값은 각각 248GWh, 208GWh로 나타났다.

[그림 3-15] 울산 AIDC의 연간 전력 소비(GWh) 시나리오



한편, 울산 AIDC의 전력 공급은 SK케미컬의 자회사인 SK멀티 유틸리티 (SKMU)가 건설하는 LNG 열병합발전소(CHP)로 충당될 계획이며, 발전 투입연료인 LNG는 직수입될 것으로 보인다. 열병합발전은 전기와 열을 동시에 생산하며 버려지는 열을 최소화하기 때문에 효율이 높다. 일반적으로 열병합발전은 투입에너지의 약 75~80%를 유용한 에너지(전기+열)의 형태로 생산하며, 전기 보다는 열 생산 비중이 더 크다. 특히, 전기/열 비중은 건물용(0.7~0.8)보다는 산업용(0.9) CHP에서 더 크다(IEA, 2008). 전기와 열의 생산 비중은 CHP에 적용된 기술에 따라서도 달라진다. 가스터빈(GT)만을 사용하는 GT CHP에서는 투입에너지에서의 전기와 열의 생산 효율이 각각 30~36%, 44~50%이며, 가스터빈과 증기터빈을 모두 사용하는 복합사이클(CCGT) CHP에서는 각각 42~47%, 33~38%에 달

한다⁶². 즉, CCGT CHP에서는 열보다 전기의 생산 비중이 더 높을 수 있다. SKMU가 건설하는 CHP의 전기 생산 효율이 45%라는 가정하에 위에서 시나리오별 연간 전력 소비량 추정치를 바탕으로 총 발전 투입 천연가스 직수입 물량을 계산하면 연간 0.5~10.5만 톤이며, 보다 현실적인 가정하에서는 약 3만 톤으로 추정된다.

〈표 3-6〉 시나리오별 울산 AIDC 에너지 소비

시나리오	TDP(W)	GPU 이용률(%)	PUE	연간 전력 소비(GWh)	LNG 직수입 물량(만톤)
Low	200	20	1.05	32.5	0.5
현실적	600	40	1.15	213.2	3.1
High	1,100	65	1.30	718.2	10.5

주: CHP 발전 효율 45% 가정

이러한 결과가 울산의 에너지 소비 구조에 의미하는 바는 무엇일까? 국가 에너지 통계(간이 밸런스)에서 전기 소비는 한국전력의 판매 전력량이므로 자가발전에 의한 소비는 전기로 집계되지 않고 자가발전에 투입된 에너지원(울산 AIDC의 경우 LNG) 소비로 집계된다. 또한 부문별 분류에서도 데이터센터의 에너지 소비는 산업용이 아니라 건물용으로 분류된다. 간이 밸런스의 산업 부문은 제조업을 포함한 총 16개의⁶³ 업종으로 나뉘어 있다. SKMU는 석유화학업종인 SK케미컬의 자회사이지만, AIDC에서 제공하는 서비스의 수요는 석유화학업종에서만 발생한다고 할 수 없다. 방송통신시설인 데이터센터의 용도는 산업용보다는 건물용 내의 상업용으로 분류된다. 이상의 내용을 정리하면, AIDC 건설로 울산의 상업용 천연가스 소비가 연간 최대 약 11만 톤 증가할 수 있다는 의미이다.

이상에서 울산 AIDC의 에너지 소비를 추정해 보았으며, 다음 절에서는 우리나라 전체 데이터센터의 전기 소비를 추정한다. 현재까지 국내 데이터센터의 대부분은 AIDC가 아닌 전통적인 DC이다. 기존 데이터센터에 어떤 반도체가, 얼마나,

⁶² IEA-ETSAP(2010), Table 3

⁶³ 농림업, 어업, 광업, 건설업, 제조업(식품 및 담배, 섬유 및 가죽, 목재 및 나무제품, 제지 및 인쇄, 화학 및 석유화학, 비금속광물, 철강, 비철금속, 기계류, 수송장비, 기타제조, 기타에너지)

그리고 어느 정도의 이용률로 사용되고 있는지, DC별 IT 장비의 용량은 얼마인지 등에 관한 정보는 구하기 힘들다. 이용 가능한 정보는 2023년기준 국내 데이터센터의 수, 2017~2019년 전국 평균 PUE, 2023년 12월 31일 기준 한전에서 공급하는 전국 데이터센터의 전기공급 계약 전력량(MW) 등 정도이다. 이러한 제한된 정보 때문에 다음 절에서의 국내 데이터센터 에너지 수요 추정 및 전망은 본 절과는 다른 방법으로 수행된다.

2.3. 국내 데이터센터 전기 소비 및 전망

2.3.1. 모형 설정 및 기준 전망

앞 장에서 살펴보았듯이 데이터센터의 전기 소비량을 측정하는 방식은 다양한 방식이 있다. 다만, 데이터센터별 IT 용량, PUE, 수전량 등의 정보가 존재하지 않기 때문에 데이터센터의 전기 추정에는 많은 제약이 있다. 본 절에서는 최대한 이용 가능한 정보들을 기초로 국내 데이터센터의 전기 소비량을 추정했다.

먼저 데이터센터를 규모별로 3단계(소형, 중형, 대형)로 나누고, 규모별 소비량은 데이터센터 수(N), 수전용량(NW), 이용률(UTL), PUE의 곱으로 계산했다. 최종적으로 총 전기 소비량은 규모별 전기 소비의 합으로 도출했다. 규모는 상면 면적과 수전용량을 기준으로 소형은 2,000m² 및 10MW 이하, 중형은 2,001~ 7,500m² 및 11~20MW, 대형은 7,501m² 및 21MW 이상으로 설정했다. 이는 <표 3-1>에 나타난 한국데이터센터연합회(KDCC)의 규모 분류상 각각 중소형, 대형, 거대 및 메가에 해당한다. 이상의 모형을 수식으로 표현하면 다음과 같다.


$$E_t = \sum_i \left(\prod_t (N_{\{i,t\}} \cdot MW_{\{i,t\}} \cdot UTL_{\{i,t\}} \cdot PUE_{\{i,t\}}) \right), i = \text{소형, 중형, 대형}$$

(1) DC 수

한국데이터센터연합회(KDCC, 2024)에 따르면 2023년 기준 국내 데이터센터는 총 153개이다. 규모별 데이터센터 비중은 동일 자료에서 제공된 상면 기준에

따른 DC 비중을 이용해 각각 45.2%, 35.6%, 19.2%로 설정했다. 본 연구의 전망 기간은 2024~2060년이다. 전망을 위한 데이터센터 수(N)는 AI 시대의 진입으로 2040년경까지 상대적으로 빠르게 증가한 후 증가세가 둔화하는 것으로 가정했다. 2027년까지의 데이터센터 수 전망에는 KDCC에 제공된 민간 데이터센터 추진 단계 기준 데이터센터 정보를 일부 반영했다. KDCC 따르면 2024~2027년 기간 30개의 민간 데이터센터가 준공될 예정인데, IT용량이 제공된 24개 데이터센터를 기준으로 수전용량을 추정했을 때⁶⁴, 본 연구에서 설정한 규모 기준으로 소형은 1개, 중형은 2개, 나머지 21개는 모두 대형 데이터센터였다. 이는 대부분 규모가 큰 데이터센터를 중심으로 조사되었기 때문으로 추측되며, 따라서 본 연구에서는 KDCC의 자료에 추가적인 신규 소형 및 중형 데이터센터를 가정했다. 전체 데이터센터의 수는 전망 기간 연평균 약 3% 증가하며 증가세는 점차 둔화하는 것으로 전제했다. 2030년의 데이터센터 수는 2023년 대비 67% 증가한 230개, 2060년에는 2023년 대비 3배 수준인 440개에 달할 것으로 전망했다.

[그림 3-16] 데이터센터 수 전제




주: 실적 자료(실선) 출처는 KDCC(2025)

신규 데이터센터의 규모별 비중은 2035년까지는 AI 시대의 도래에 따른 대형 데이터센터 중심으로 보급이 확산될 것으로 가정하고 2040년 이후에는 AI 시대 안정화에 따른 중형 및 소형 데이터센터가 상대적으로 많이 보급될 것으로 가정했

⁶⁴ IT용량은 수전용량의 약 60%라고 가정하여 추정했다.

다. 이에 따라 대형 데이터센터의 비중은 2023년 19.2%에서 2030년 22% 수준까지 상승 후 다시 19% 수준으로 하락할 것으로 보이며, 소형 데이터센터는 2023년 45.2%에서 2030년까지 하락하다 이후 상승하며 2060년에는 50% 수준에 도달할 것으로 전제되었다.

[그림 3-17] 규모별 비중 전제




(2) 수전용량

수전용량은 한국전력의 2023년 데이터센터 총 수전 계약 용량(1,986MW) 자료를 기준으로, KDCC의 2023년 민간과 공공 데이터센터의 평균 수전용량(17.7MW와 6.0MW)과 업력별 수전용량 자료, 한전의 전기 사용 예정통지 자료에 따른 5MW 이상 DC 수⁶⁵ 등을 참조하여 규모별로 설정했다. 수전용량은 IT 용량 및 장비 이용률, PUE, 장비의 효율 및 기술 트렌드 등에 따라 달라진다. 동일한 IT 용량이라도 GPU 등의 장비 효율이 높다면 수전용량은 낮을 수 있다. 이런 측면에서 수전용량에는 어느정도 반도체 기술 발전에 따른 효율 개선이 반영되었다고 할 수 있다. 다른 조건이 동일하다면, 단위 연산당 반도체의 전기 소비가 작아진다면 (즉, 장비 효율이 상승하면) 수전용량은 AI 시대에도 크게 증가하지 않을 수 있다. 반면, 동일한 상황이라도 AI 시대에 연산량이 폭증한다면 효율 개선을 압도하며 수전용량이 빠르게 증가할 수도 있다. 이러한 측면에서 수전용량을

⁶⁵ 산업통상자원부(2023.3.9.)에 따르면 전기 사용 예정통지서(2022.12) 기준 총 147개 DC 중 5MW 미만은 46개소이다.

전제하기란 불확실성이 매우 크지만, 일반적으로 AI 데이터센터의 경우 기존 데이터센터와는 달리 GPU나 TPU와 같은 반도체의 비중이 훨씬 높으므로 전망 기간 수전용량은 모든 규모에서 증가할 것으로 가정했다. 또한, 앞에서 규정한 규모별 기준 수전용량은 전망 기간이 길어지며 증가할 수 있다고 가정했다. 신규 데이터센터는 가속 서버의 증가로 기존 데이터센터 대비 수전용량이 높고, 시간이 지남에 따라 기존 서버가 가속 서버로 대체되어 기존 데이터센터의 수전용량도 완만하게 증가하는 것으로 가정했다. 수전용량은 전망의 후반기로 갈수록 증가세가 둔화하며, 2023~2030년 기간은 연평균 10.5%, 2050~2060년 기간은 연평균 1.8% 증가할 것으로 예상했다. 2030년 총 수전용량은 2023년 대비 2배 이상 증가, 2060년은 2023년 대비 약 5.6배 증가한 수치이다. 전망 기간 전체(2023~2060년) 수전용량의 연평균 증가율은 4.8%이다. 한편, 데이터센터의 정의와 용량 기준 차이 등으로 정확한 비교가 될 수는 없지만, 최근 IDC(2025)는 국내 데이터센터의 전력 용량이 2023~2028년 기간 연평균 11.1% 증가할 것으로 전망하였다.

[그림 3-18] 수전용량(규모별 평균 및 총용량) 전제




(3) 이용률(수전용량 기준)

본 절에서 이용률은 수전용량에 대한 이용률이다. 따라서, 지금까지 앞에서 언급되어온 반도체 장비(GPU, 서버, IT 용량) 이용률과는 정확히 일치하지는 않는다. 하지만 IT 용량과 수전용량이 양의 관계가 있으므로, 반도체 장비 이용률과 본

모형의 이용률 역시 유사하게 변할 것으로 보인다. 단, IT 용량은 수전용량 보다 작으므로⁶⁶ 본 모형에서의 이용률은 일반적인 서버 또는 IT 장비 이용률 대비 낮다. 모형에서 설정한 2023년 국내 이용률은 제2장에서 다룬 일반적인 서버의 평균 이용률(23~30%), IEA 보고서의 규모별 IT 장비 이용률, Epoch AI의 글로벌 주목할 만한(notable) AI 모델 데이터셋의 글로벌 평균 장비 이용률(Hardware Utilization) 36.5%를 고려하여 소형, 중형, 대형에 대해 각각 10%대 초반, 10%대 후반, 30% 수준을 가정했다. 이 경우 국내 데이터센터의 수전용량 기준 평균 이용률은 약 18%이다. 앞장에서 설명했지만, 이용률 역시 에너지효율에 큰 영향을 받는다. 가상화, 리소스 통합, 워크로드 최적화 등을 통해 IT 장비의 이용률을 높이면 동일한 연산 작업을 더 적은 수의 장비로 수행하는 것이 가능하므로 전체 전기 소비가 감소하기 때문이다. 전망 기간 이용률은 이러한 효율 상승을 감안해 지속해서 증가하는 것으로 전제했다. 2060년 데이터센터당 평균 이용률은 2023년 대비 3배 가까이 상승할 것으로 가정했다.

[그림 3-19] 이용률(수전용량 기준) 전제




(4) PUE

마지막으로 PUE는 KDCC에서 제시한 2017~2019년 국내 평균 1.69와 제2장에서 언급한 Uptime intelligence의 2023년 글로벌 평균치 1.58을 감안하여

⁶⁶ 2025년 준공 예정인 KT Cloud 경북 AI 데이터센터(수전용량 10 MW, IT 용량 6MW, 자료: KT Cloud, 2025.6.2.)의 경우 IT 용량은 수전용량의 60% 수준이다.

2023년 기준 평균 1.58로 설정했다. 규모별로는 제2장의 <표 2-14> 글로벌 데이터센터 유형별 PUE 값 등을 참조해 소형, 중형, 대형 각각 2023년 1.8, 1.4 및 1.2 수준으로 전제했다. 전망 기간 PUE는 완만하게 하락해 2060년에는 평균 1.3 수준으로 하락할 것으로 가정했다. 수전용량과 유사하게 최신 데이터센터의 PUE는 기존 대비 낮다고 가정했으며, 기존 데이터센터의 PUE도 완만하게 개선되는 것으로 가정했다.

[그림 3-20] PUE 전제



위에서의 2023년 규모별 수전용량, 이용률, PUE는 2023년 전기 소비량 실적치를 달성하는 수준에서 미세 조정되었다. 2023년 데이터센터의 전기 소비량은 KDCC와 제11차 전력수급기본계획(전기본)에 따르면 각각 4,958GWh와 5,000GWh인데, 본 연구에서는 2023년 국내 데이터센터의 전력 소비를 약 5TWh로 설정했다. 이 수준은 국내 전기차 충전용 전기 소비의 2.6배 수준이나, 아직 국가 전체 전력 소비에서 차지하는 비중은 1%에 못 미친다. 데이터센터의 전기는 상업용이나 공공용으로 분류되는데, 2023년 기준 소비량은 상업+공공용 전기 소비의 약 2.8%, 총 전력 소비의 0.9%에 불과하다.⁶⁷

⁶⁷ 여기서의 전기 소비는 한국전력의 전력 판매량을 기준으로 하며 자가발전량은 포함하지 않는다.

〈표 3-7〉 기준 전망의 주요 전제

DC 전체	2023	2030	2040	2050	2060
데이터센터 수	153	230	326	396	440
수전용량(GW)	2.0	4.0	6.9	9.3	11.1
이용률(%)	17.5	25.4	35.3	43.0	48.4
PUE	1.58	1.46	1.38	1.35	1.32

(5) 기준 전망 결과

이상과 같은 각 변수에 대한 전제하에 추정된 국내 데이터센터 전기 수요 기준 전망(BAU) 결과는 아래 〈표 3-8〉 및 [그림 3-21]에 나타나 있다. 데이터센터 총 전기 소비는 전망 기간(2023~2060) 연평균 7.2% 증가할 것으로 전망되었다. 전망의 초기는 AI 시대 진입에 따른 데이터센터 수 증가, 클라우드 및 코로케이션, 하이퍼스케일 데이터센터 중심 증가에 따른 수전용량 증가로 전기 소비가 상대적으로 빠르게 증가할 것으로 전망되었다. 기간별 총 전기 수요는 2023~2030년 기간은 연평균 15.5% 증가하나 이후 증가세가 지속적으로 둔화되어 2050~2060년 기간에는 연평균 2.7% 증가할 것으로 예상된다.

규모별 총 전기 소비량은 대형, 중형, 소형 순이 유지되나, 대형의 비중은 2023년 48%에서 2030년 50%로 상승한 후 엡지 데이터센터나 온디바이스 AI 기기의 발달 등으로 완만하게 하락해 2060년에는 40% 수준으로 축소되는 것으로 전망되었다. 반면, 소형 데이터센터의 전체 전기 소비 비중은 2023년 16%에서 2030년 15%로 하락한 이후 지속 상승하며 2060년에는 25%에 도달할 것으로 보인다. 다시 말해, AI 시대가 정착하기까지는 상대적으로 규모가 큰 데이터센터를 중심으로, AI 시대가 정착한 후에는 소형 데이터센터를 중심으로 전기 소비가 증가할 것으로 예상된다.

한편, 기준 전망과 제11차 전기기본에서의 데이터센터의 전기 수요 전망치를 비교하면 2030년은 전기본 대비 낮으나 2040년은 유사한 수준으로⁶⁸ 나타났다. 전


⁶⁸ 전기본은 2038년까지의 수치만을 제공하므로 2040년 수치와의 직접 비교는 아니다.

기본의 DC 전력 수요 전망이 전기 사용 예정통지서를 보수적으로 고려하여 이뤄진 반면, 본 연구는 규모별 DC수, 수전용량, 이용률, PUE 등을 이용해 전망했다는 점에서 차이가 있다. 전기본 전망의 한계는 전기 사용 예정통지서가 DC 전력 수요를 대표하는 변수로 사용되기에 매우 부정확하다는 점이다. 예를 들어, 실제 데이터센터 운영이 아닌 부동산 매매 이익을 취하기 위해 전기 사용 예정통지 제도를 이용하여 데이터센터 건설 예상 부지에 전기 공급 승인을 미리 받는 사례가 다수 존재한다. 2024년 한전 감사실이 실시한 ‘데이터센터 전기공급 실태 특별감사’에 따르면 2020년 1월~2023년 2월기간 한전에 접수된 데이터센터 전기 사용 예정통지 총 1,001건 가운데 실수요 목적이 아닌 부동산 개발 목적의 허수 신청이 678건(전체 신고의 67.7%), 약 26GW에 달하는 것으로 밝혀졌다(한국전력공사 보도자료, 2025.3.11.). 감사 이후에 허수 신청을 막기 위한 조치가 취해짐에 따라 2024년에는 전기 사용 예정통지 신청 건수가 크게 감소하기도 하였다.

〈표 3-8〉 기준 전망 결과

전력 수요(TWh)	2023	2030	2040	2050	2060
총	5.0	13.8	31.6	49.9	65.4
소형	0.8	2.1	5.5	10.8	16.5
중형	1.8	4.8	11.2	17.5	22.6
대형	2.4	6.9	14.8	21.6	26.3
연평균 증가율(%)	2023~2030	2030~2040	2040~2050	2050~2060	전망 기간 전체 (2023~2060)
총	15.5	8.6	4.7	2.7	7.2
소형	14.4	10.2	6.9	4.3	8.5
중형	14.9	8.9	4.6	2.6	7.0
대형	16.4	7.9	3.8	2.0	6.7

[그림 3-21] 국내 데이터센터의 전기 소비 전망(BAU)



주: 그림에서 표시된 2040년 전기본(산업통상자원부, 2025.3.13.) 수치는 2038년 수치임.

2.3.2. 시나리오 전망 및 국제 비교

(1) AI 가속 시나리오

본 절에서는 AI 시대가 가속화되어 데이터센터의 수와 전력 소비가 크게 증가하는 경우의 시나리오를 고려한다. 앞 장의 말미에서 언급했듯이, AI 가속화 시나리오에서 국내 데이터센터 전기 소비 전망을 위한 변수 전제에는 많은 불확실성이 작용한다. 하지만, 본 보고서의 모형에서는 데이터센터의 효율 개선이나 AI 수요 폭증을 직접적으로 고려하지 않는다. 효율 개선은 수전용량, 이용률, PUE 모두에 영향을 미치며, AI 수요 역시 데이터센터의 수와 수전용량에 영향을 미친다. 이에 따라 모형의 모든 변수를 AI 가속화 시대에 따라 전제하는 것은 불가능하다고 판단하여, 데이터센터의 수와 수전용량만을⁶⁹ 시나리오에 따라 변화시켰다. 이는 데이터센터 수의 증가와 이에 따른 수전용량의 증가가 AI 가속화 시나리오에서 가장 직접적인 변화라고 판단했기 때문이다. 구체적으로 데이터센터의 수가 기준 전망 대비 2060년 기준 2배로 증가하는 것을 AI 시나리오로 설정했으며, 수전용량은 기준 전망에서의 2023년 대비 2060년 데이터센터의 수 증가 배수(2.9배)와 수전용량 증가 배수(5.6배)의 비율 관계(약 2배)가 유지된다고 설정했다. 참고로 앞장의 소결에

⁶⁹ 모형이 기존 데이터센터의 PUE가 신규 데이터센터 수준으로 일정 부분 개선됨을 고려하므로, 데이터센터 수와 수전용량을 변화시켜도 전체 평균 PUE는 기준 전망 대비 소폭 개선되는 것으로 나타났다.


서 언급한 바와 같이 IEA는 2030년 기준 데이터센터의 수는 2024년 대비 약 60% 증가하고, IT 용량은 동기간 2배(100%) 이상 증가할 것으로 전망한 바 있다.

아래 [그림 3-22]에서는 AI 가속화 시나리오하에서의 데이터센터 수, 수전용량 및 총 전력 수요 변화를 기준 전망과 비교하였다. 시나리오에서 2060년 데이터센터의 수는 2030년 대비 5.8배 증가하고 수전용량은 11.7배 증가하는 것으로 나타났다. 데이터센터의 총 전기 수요는 AI 가속화 시 전망 기간 연평균 9.3% 증가해 2060년에 135TWh 수준에 도달하는 것으로 전망되었다. 이는 2024년 우리나라 총 전력 소비의 25%, 상업·공공용 전기 소비의 74%에 달하는 수준이다.

〈표 3-9〉 고성장(AI 가속) 시나리오 전망

전력 수요(TWh)	2023	2030	2040	2050	2060
총	5.0	20.9	59.8	101.4	134.8
소형	0.8	3.2	11.1	23.2	35.3
중형	1.8	6.9	20.4	34.5	45.4
대형	2.4	10.8	28.3	43.7	54.1
기간별 연평균 증가율(%)	2023~2030	2030~2040	2040~2050	2050~2060	전망 기간 전체 (2023~2060)
총	22.5	11.1	5.4	2.9	9.3
소형	21.4	13.3	7.6	4.3	10.7
중형	20.9	11.5	5.4	2.8	9.1
대형	24.0	10.1	4.4	2.2	8.8

[그림 3-22] 기준 전망 vs. 가속 시나리오(데이터센터 수, 수전용량, 전기소비)



(2) 전망의 국제 비교

앞에서 전기본과 기준 전망이 유사함을 살펴보았다. 전기본 외 우리나라 데이터센터의 전기 수요에 대한 전망 연구는 없다. 이에 따라 본 연구의 전망 결과를 최신 글로벌 데이터센터의 전기 수요 전망 연구와 비교해 본다. 모형의 구조가 다르고 전망하는 대상도 다르기 때문에 비교 결과에 큰 의미를 부여하기는 어렵지만, 전망의 검증과 한계에 대한 어느 정도의 가늠자는 될 수 있다고 여겨진다.

신뢰할 만한 기관의 글로벌 데이터센터 전력 수요 전망에 관한 가장 최신 연구는 2025년 5월에 발간된 EDNA의 연구(Wu & Brocklehurst, 2025)이다. EDNA 보고서는 상향식 하이브리드 모델(TEM 4.0)을 이용해 전망을 했는데, AI 부문의 성장을 모델링함에 있어 현실적인 시장 제약을 고려하지 않아 전망치가 다른 기관에 비해 매우 높게 나타났음을 보고서에 적시하고 있다. 보고서는 결과를 2024년 골드만삭스(Davenport et al., 2024)와 SemiAnalysis⁷⁰ 등의 전망과 비교했는데, 골드만삭스는 AI 반도체 공급 제약을 주요 제약 요인으로 고려하고 SemiAnalysis도 GPU 공급 및 전력 공급 등의 제약을 고려한 전망이다. 아래 <표 3-10>에서는 이들 연구에 본 연구의 전망(KEEI)을 추가해 2023~2030년 기간에 대해 비교했다.

먼저 기준 전망에서는 골드만삭스의 글로벌 전망과 KEEI 전망이 유사했으며, SemiAnalysis 전망 대비보다는 증가세가 낮았다. EDNA는 시나리오 전망을 하지 않았기 때문에, 고성장 시나리오의 나머지 두 기관의 전망과만 비교했다. KEEI 시나리오 전망은 골드만삭스와 SemiAnalysis 전망의 중간 정도의 증가세를 보이는 것으로 나타났다. 이상의 비교에 비추어 볼 때 본 연구의 국내 DC 전력 수요 전망은 합리적인 범위에서 이뤄졌다고 판단된다. 데이터센터가 미국과 중국을 중심으로 증가하고 있음을 감안하면, 본 연구의 전망은 우리나라가 미국과 중국을 제외한 대부분의 국가보다 DC 에너지 수요 증가세가 빠를 것임을 나타낸다.

⁷⁰ SemiAnalysis, Datacenter Industry Model.

〈표 3-10〉 데이터센터의 전력 수요 전망 비교(글로벌 vs. 국내)

전망대상	전망기관	2023	2030	2030/2023	2023~2030 연평균 증가율
기준 전망					
글로벌	골드만삭스 (2024)	425TWh	1,150TWh	2.7배	15.3%
	SemiAnalysis	450TWh	1,500TWh	3.3배	18.8%
	EDNA (2025)	323TWh	2,510TWh	7.8배	34.0%
국내	KEEI	5.0TWh	13.8TWh	2.7배	15.5%
AI 가속(고성장) 시나리오					
글로벌	골드만삭스 (2024)	425TWh	1,400TWh	3.3배	18.6%
	SemiAnalysis	450TWh	2,250TWh	5.0배	25.8%
국내	KEEI	5.0TWh	20.9TWh	4.1배	22.5%

자료: 제시된 출처의 정보를 이용해 저자 작성


2.3.3. PUE 개선에 따른 절감 잠재량 분석

데이터센터의 전기 소비 절감은 중요한 정책 목표 중 하나이다. 앞 장에서 2030년까지 유럽과 글로벌 데이터센터 전력 소비를 절감하기 위한 정책 시나리오별 효과를 추정한 연구를 소개한 바 있다. 연구 결과 데이터센터의 PUE가 1.2를 달성한 후 유지된다는 것을 전제로, 절감 목표의 절반이 PUE 개선으로 이뤄지는 것으로 나타났다. PUE 규제는 EU 등 주요 국가에서 데이터센터의 에너지효율 관련 의무사항으로 일정 PUE 수준을 요구하는 등 가장 직관적이고 손쉬운 데이터센터의 전기 소비 절감 정책 수단이다.

본 절에서는 PUE 개선으로 국내 데이터센터의 전기 소비를 얼마나 절감할 수 있는지 알아본다. 가장 직관적이고 쉬운 PUE 절감 방법은 냉방용 에너지 소비를 줄이는 것이다. 하지만, IT 장비 외 에너지 소비가 냉방용에서만 발생하는 것은 아니므로 PUE 1.0을 달성하는 것은 사실상 불가능하다. 본 연구에서는 국내 데이터센터의 평균 PUE가 향후 10년 내 빠르게 개선되어 2030년에는 1.2 수준, 2030년대 중반 이후에는 1.08 수준으로 떨어지는 것으로 가정하고(그림 3-23) 전력

소비 변화를 측정했다. PUE 1.08은 더 이상 개선의 여지가 크지 않는 수준으로, 2040년 이후로는 PUE 개선세가 정체 수준으로 둔화되어 2060년에는 평균 PUE가 1.06로 떨어지는 것으로 가정했다. 이러한 PUE 목표는 신규 데이터센터만의 PUE가 아닌, 기존 DC까지 포함한 전체 데이터센터의 평균 값으로 사실상 매우 도전적인 목표이며, 따라서 이후 언급되는 절감량은 최대 잠재량으로 보아야 한다.


[그림 3-23] PUE 정책 목표 설정



규모별로는 소형 데이터센터의 PUE 개선 여지가 가장 크며, 대형 하이퍼스케일의 경우는 현재도 PUE가 상당히 낮아 개선의 여지가 크지 않다. 규모별 평균 PUE를 낮추기 위해서는 기존에 운영하고 있는 데이터센터의 PUE 개선이 매우 중요하다. 본 연구에서는 2023~2040년 기간 중 기존 데이터센터의 PUE가 빠르게 신규 데이터센터의 PUE 수준으로 빠르게 개선된다고 가정했다.

다음의 [그림 3-24]는 이러한 PUE 개선 목표에 따른 절감 잠재량을 기준 전망과 시나리오 전망하에서 추정한 결과를 나타낸다. 2040년 이후 PUE 개선세는 정체 수준으로 둔화하지만, 전력 소비 절감 잠재량은 데이터센터 수의 증가와 함께 지속해서 증가한다. 이는 PUE 개선이 빠를수록 누적 절감량은 커진다는 의미로, PUE 규제가 빠를수록 에너지효율 측면에서는 정책 효과가 크다는 것을 시사한다.


[그림 3-24] PUE 개선 절감 잠재량



절감량을 절감 전 전력 수요량에 대한 비율(즉, 절감률)로 나타내면, BAU 전망에서는 2030년 12.1%에서 2040년 17.7%로 상승 후 18% 내외를 유지하고, AI 가속 시나리오 전망에서는 2030년 11.8%에서 2040년 16.4%로 상승 후 17% 내외를 유지하는 것으로 나타난다. 2040년까지 절감률이 큰 폭으로 상승한 이유는 기존 데이터센터의 PUE가 대부분 2040년까지 신규 데이터센터 수준으로 개선된다고 가정했기 때문이다. 주목할 점은 BAU에서의 절감률이 AI 가속 시나리오에서의 절감률보다 높다는 점이다. 이는 PUE 개선에 따른 절감 잠재량이 전기 소비 증가에 따라 비례적으로 증가하지 않는다는 의미로, AI 가속화로 전기 소비가 예상보다 빠르게 증가할 경우 PUE 개선 만으로는 절감에 한계가 있다는 것을 의미한다.

[그림 3-25]는 절감률을 데이터센터 규모별로 나타낸 것이다. BAU와 AI 가속 시나리오 모두에서 데이터센터의 규모가 작을수록 절감률이 높은 것을 알 수 있다. 이는 대규모 데이터센터보다는 소형 데이터센터에서 절감의 여지가 크다는 것으로, PUE 규제 정책 수립 시 규모가 작은 데이터센터의 PUE 개선에 집중해야 한다는 것을 시사한다. 또한, 초기에 절감률을 크게 상승시키기 위해서는 기존 데이터센터의 PUE 개선이 핵심이며 이에 따라 신형 데이터센터의 PUE 기준뿐만 아니라, 기존 데이터센터의 PUE 개선에 힘써야 한다. 요컨대, PUE 개선은 빠를수록 전체 정책 효과가 누적적으로 커지므로, 최대한 빨리, 대형보다는 소형 데이터센터를 중심으로, 신규보다는 기존 데이터센터를 중심으로 정책 결정이 이뤄져야 할 것이다.

[그림 3-25] 데이터센터 규모별 절감률(%)



〈표 3-11〉 절감 잠재량(TWh) 및 절감률(%)

기준 전망	2030	2040	2050	2060
총	1.7 (12.1%)	5.6 (17.7%)	9.0 (18.1%)	11.6 (17.8%)
소형	0.5 (21.6%)	1.5 (27.1%)	2.7 (25.2%)	3.9 (23.4%)
중형	0.6 (12.9%)	2.1 (18.7%)	3.3 (18.8%)	4.1 (18.2%)
대형	0.6 (8.7%)	2.0 (13.4%)	3.0 (14.0%)	3.6 (13.8%)
가속 시나리오	2030	2040	2050	2060
총	2.5 (11.8%)	9.8 (16.4%)	17.0 (16.7%)	22.2 (16.5%)
소형	0.7 (20.7%)	2.7 (24.1%)	5.2 (22.7%)	7.6 (21.4%)
중형	0.9 (12.6%)	3.5 (17.2%)	6.0 (17.3%)	7.6 (16.8%)
대형	1.0 (8.8%)	3.6 (12.7%)	5.8 (13.2%)	7.0 (13.0%)

3. 데이터센터 증가에 따른 국내 에너지 소비 시사점

3.1. 국가 전력 통계 및 전기 소비 추세

3.1.1. 국가 전력 통계

국내 DC 증가가 국가 총 전력 소비에 미치는 영향을 논의하기 앞서, 전기 소비량의 정의를 명확히 할 필요가 있다. 에너지경제연구원에서는 에너지법에 따라 국가 전체의 에너지 소비를 집계한 에너지밸런스를 국가에너지통계종합정보시스템

(KESIS)에 공표하고 있다. 에너지밸런스는 크게 간이 밸런스와 확장 밸런스로 나뉜다. 간이 밸런스는 월간으로 약 3개월의 시차를 두고 공개되며, 확장 밸런스는 연간으로 약 2.5년의 시차를 두고 발표된다.

〈표 3-12〉 부문별 전력 소비(간이 밸런스 vs. 확장 밸런스)

확장 밸런스(TWh)	1990	2000	2010	2020	2023*
총 전력	103.2	257.9	445.6	530.5	573.5
산업	67.9	150.6	233.8	284.3	304.0
수송	1.0	2.0	2.2	3.3	4.9
건물	34.3	105.3	209.7	242.9	264.6
가정	17.7	37.1	61.6	76.0	82.4
상업·공공	16.5	68.2	148.1	166.9	182.2
간이 밸런스(TWh)	1990	2000	2010	2020	2024
총 전력	93.0	235.7	425.5	496.9	536.6
산업	57.8	128.5	214.5	254.7	264.0
수송	1.0	2.0	2.2	3.3	5.5
건물	34.1	105.2	208.8	238.8	267.1
가정	17.7	37.1	61.2	74.1	84.4
상업·공공	16.4	68.1	147.6	164.8	182.7

주: 간이 밸런스와 확장 밸런스상 전기 소비의 차이는 주로 자가발전에 기인함. 간이 밸런스에서 전기 소비는 한국전력의 판매량이며, 확장 밸런스에서의 전기 소비는 한전의 판매량에 자가 발전량이 추가됨. 확장 밸런스는 기초 자료 수집 기간상 2023년 소비량이 가장 최신 수치임.

자료: 국가에너지통계종합정보시스템(KESIS)

〈표 3-12〉로부터 확장과 간이 밸런스상의 부문별 전기 소비량을 확인할 수 있다. 현재 기준 간이 밸런스는 2024년 수치가 최신이나, 확장 밸런스는 2023년 수치가 최신 수치이다. 표에서 알 수 있듯이 확장 밸런스상의 총 전기 소비량이 간이 밸런스 대비 크다. 이러한 차이의 주 원인은 자가발전의 분류 때문이다. 간이 밸런스의 전기 소비는 한국전력(한전)의 전력 판매량이며 여기에는 자가발전량은 포함되어 있지 않다. 반면, 확장 밸런스의 전기 소비에는 한전의 판매량뿐만 아니라 자

가발전량도 포함되어 있다. 이에 따라 자가발전이 없는 수송 부문의 경우 간이와 확장 밸런스의 값이 동일하며, 자가발전량이 많은 산업 부문에서는 간이와 확장 밸런스 사이에 차이가 존재한다. 건물(가정+상업·공공) 부문은 자가발전량이 작아 간이와 확장의 차이도 미미하다.

대부분의 전기 소비량 분석 및 연구에는 한전의 전력 판매량을 기초로 한 간이 밸런스 수치가 이용되며, 본 보고서에서도 전기 소비는 별도의 명시가 없는 한 간이 밸런스 기준이다. 간이 밸런스에서 자가발전은 발전량 대신 발전을 위해 투입된 에너지가 소비 주체의 최종 소비로 집계된다. 이에 따라 자가발전이 증가하면 간이 밸런스상의 전기 소비(즉, 한전으로부터의 수전량)는 상대적으로 감소한다. 대표적인 예가 최근 기계류에서의 전기 소비이다. 기계류는 반도체가 포함된 업종으로 국내에서 가장 전기 소비가 많은 업종이다. 기계류에서의 전기 소비는 우리나라의 반도체 산업 성장과 함께 빠르게 증가해 왔는데, SK하이닉스가 이천(2023.4)과 청주(2024.6)에 LNG 열병합 상용자가발전소를 가동하기 시작하며 전기 소비가 정제하고 있다. 반면, 기계류에서의 천연가스 소비는 급증하고 있다.


3.1.2. 국내 전력 소비 추세

다음으로는 국내 전력 소비 추세를 살펴볼 필요가 있다. 국내 전력 소비는 구조적 요인 등으로 2010년대 들어 증가세가 과거 대비 크게 둔화했다⁷¹. 김철현·박광수(2015)의 연구에 의하면 농사용을 제외한 모든 계약종별 및 총 전력 소비는 2010~2011년경에 공통적으로 증가 추세가 둔화했다. 추세 둔화의 원인으로는 여러가지 요인들이 지목되었는데, 그 중 구조적 요인으로는 경제 및 인구 구조 변화, 근무일수 감소, 상용자가발전 증가 등이 지목되었다. 특히, 중국의 경제 패러다임 변화에 따른 대중국 수출의 감소에 따른 국내 수출 구조 변화와 이에 따른 철강, 석유화학업을 중심으로 한 전력다소비업종의⁷² 산업구조 변화를 경제구조 변화의 요인 중 하나로 들고 있다.

⁷¹ 이러한 사실은 확장 밸런스 기준 전기 소비에도 동일하게 적용된다.

⁷² 2024년 기준 총 전력에서의 업종 비중은 기계류(16.7%), 석유화학(10.1%), 철강(4.0%) 순이며, 산업용에서의 비중은 각각 34.0%, 20.5%, 8.2%이다.

[그림 3-26] 국내 전기 소비 추이 및 기간별 연평균 증가율



자료: 국가에너지통계종합정보시스템(KESIS), 국가에너지수급통계(간이 에너지밸런스)

최근에는 철강과 석유화학의 구조적 불황이 더욱 심해져 산업용 전기 소비의 정체로 이어지고 있다. 또한, 앞서 언급한 기계류 등에서의 상용자가발전 증가도 산업용 전기 소비 정체의 주 요인으로 작용하고 있다. [그림 3-26]에서는 주요 부문별 전력 소비 추세와 2011년 이전과 이후의 부문별 연평균 증가율을 확인할 수 있다. 산업용 전기 소비는 1990~2011년에 연평균 6.9%로 증가해오다, 2011~2024년에는 연평균 1.0%로 증가세가 둔화했다. 데이터센터가 속한 상업·공공용 전기 소비도 동기간 연평균 11.1%에서 1.6%로 증가세가 큰 폭으로 둔화했다. 2010년대 들어 모든 용도의 전기 소비 증가세가 큰 폭으로 둔화했으나, 상대적으로 건물(가정+상업·공공) 부문이 양호하게 증가하며 전체 전력 소비 증가를 견인해 오고 있다. 이에 따라 상업·공공용과 산업용의 소비 격차도 지속해서 좁혀지고 있다. 2024년 기준 상업·공공용 전기 소비는 산업용 대비 81.3TWh 적다.

3.2. 국내 전력 소비에의 시사점

AI 시대 데이터센터의 빠른 증가로 산업용과 상업·공공용의 소비 격차는 더욱 빠르게 좁혀질 것으로 보인다. 하지만 그림에도 불구하고 DC의 증가 때문에 2040년 이전에 상업·공공용이 산업용을 추월하기는 쉽지 않을 것으로 예상된다. 2011~2024년의 연평균 증가율이 지속된다는 가정하에 산업용과 상업·공공용의 전력 소비량 격차는 <표 3-13>과 같이 2060년에도 50TWh 이상으로 추정된다. 이를

앞 절의 DC 전망 결과와 비교하면 상업·공공용이 산업용을 추월하는 시기는 기준 전망에서는 2050년 이후, 가속 시나리오에서는 2040년 이후가 될 것으로 보인다. 게다가 이 추정은 DC 전기 소비가 한전으로부터 전량 수전된다는 가정하에 도출된 것이다. 실제로는 DC 전기 소비의 상당 부분은 자가발전으로 충당될 것이다. 자가 발전은 간이 밸런스의 전기 소비에 포함되지 않으므로, 상업·공공용이 산업용을 추월하는 시기는 더욱 늦춰질 가능성이 크다.

〈표 3-13〉 산업용과 상업·공공용 전력 소비 차이 추정

소비량 차이 (TWh)	2024	2030	2040	2050	2060
산업용 - 상업·공공용	81.3	79.1	73.5	65.1	53.1


주: 산업용과 상업·공공용 전기 소비가 2011~2024년 연평균 증가율(각각 1.0%, 1.6%)을 유지한다는 가정하에 도출

이러한 결과가 시사하는 바는 DC 증가로 인한 전력 소비 증가가 적어도 단기적으로는 크게 우려할 만한 수준은 아니라는 점이다. 국내 전력 소비는 2011년경에 증가 추세가 크게 둔화했다. DC의 증가로 전력 소비 증가세가 2010년 이전 수준으로 복귀하지는 않을 것이며, 단기간에 산업용 전기 소비를 추월할 만큼 전기 소비가 증가하지 않을 것이다. 이러한 결과는 국내 DC의 전력 소비 폭증에 따른 국가 전력 공급망 우려와는 괴리가 있다. 2023년 기준 DC 전력은 국가 총 전력 소비의 약 0.9%이며, 2038년에는 전기본 기준과 목표 수요상으로 각각 4.1%, 4.8%를 차지한다. 단, 장기적으로는 본 연구에서의 기준 전망과 가속 시나리오 전망에서 2060년 소비량이 2040년 소비량의 2배 이상임을 감안하면, 2060년에는 DC 전력 수요의 비중이 기준 전망에서는 10%, 가속 시나리오에서는 20% 수준에 달할 수 있음을 시사한다.

한편, 냉방용 전력 소비에 관해서는 단기적으로도 DC 증가에 따른 전력 수급 안정에 주의를 기울여야 할 것이다. 최근 가정용 전기 소비가 타용도에 비해 상대적으로 빠르게 증가한 이유는 이상 폭염 등으로 냉방용 전력 소비가 크게 증가했기 때문이다. 가정용 전기 소비에서 냉방용이 차지하는 비중은 2010년대 중반 10% 미만에서 빠르게 상승해 2024년에는 24%를 초과했다(에너지경제연구원, 2025, p53). 2023년 기준 국내 데이터센터 전체의 냉방용 전기 소비는 0.8TWh로 추정

된다. 이는 전체 DC 전기 소비의 약 17.0%에 달하는 수치이다. DC의 냉방용 비중은 PUE 개선에 따라 낮아질 것으로 보이거나(2060년 기준 13.4%), 냉방용 전력 소비량은 기준 전망 기간 2023년 대비 2.4배(2030년), 5.2배(2040년), 8.0배(2050년), 10.2배(2060년)로 급격하게 증가할 것으로 예상된다.

[그림 3-27] 국내 데이터센터 냉방용 전기 소비 및 비중



DC 냉방용 전기 소비량 추정은 앞 장에서의 PUE와 냉방용 전기 소비 비중의 관계식을 이용했다. 식에서 Non-IT 전기 소비에서의 냉방용 비중으로는 제2장의 <표 2-4> 글로벌 데이터센터 유형별 용도별 전기 소비 비중을 각각 소형, 중형, 대형에 적용했다. PUE는 기준 전망의 수치를 적용했으며, 이 경우 2023년 국내 데이터센터 총 전기 소비에서 냉방용 비중은 소형(31.6%), 중형(18.1%), 대형(11.2%)로 추정된다. DC 전기 소비 기준 전망(<표 3-8>)과 비교하면, 전체 전기 소비 비중은 DC의 규모가 커질수록 상승하는 것과는 달리, 냉방용의 비중은 DC 규모와는 반비례 관계임을 알 수 있다. 즉, 전체 전력 소비량은 대형 DC에서 가장 많으나, 냉방용 전력 소비는 소형 DC가 대형 DC 보다 많다. 이는 “PUE 개선에 따른 절감 잠재량 분석” 부분에서의 시사점을 재확인시켜 준다. 냉방용 전력 소비 절약을 위해서는 개선의 여지가 상대적으로 큰 소형 DC에 집중해야 한다. 또한, 오토(Auto) DR과 같은 실시간 수요반응 제도를 데이터센터에 성공적으로 적용하려면 특히 소형 DC의 건물에너지 관리시스템 설치에 신경을 써야함을 시사한다.

한편, 최근 국내 전력 소비의 특징 중 하나는 2024년에 사상 처음으로 건물용

(가정+상업·공공) 소비가 산업용을 추월했다는 것이다. 이러한 현상은 일시적이 아니라 앞으로도 지속될 것으로 예상된다. 이는 구조적 요인에 따른 산업용 전기 소비 둔화, 가정 냉방용 부하 증가와 더불어 데이터센터 증가와 AI 관련 전자 기기 보급 확장도 영향을 미칠 것으로 보이기 때문이다.

다음으로는 국내 데이터센터의 전력 공급 방안에 대해 살펴본다.

3.3. 국내 데이터센터의 전력 공급 방안

앞에서 살펴봤듯이 데이터센터의 전력 수요는 계속 증가할 전망이다. 그렇다면 이렇게 증가가 예상되는 데이터센터의 전력 수요를 어떻게 충족할 수 있을까? 데이터센터의 전력 공급은 24/7(하루 24시간, 7일 내내) 안정적으로 이뤄져야 한다. 앞 장에서 이러한 안정성과 신뢰성에 따른 티어(Tier) 분류를 살펴본 바 있다. 우리나라에는 데이터센터의 자가발전 건설을 장려하기 위해 전력계통영향 평가 시 자기 전력 소비량의 40% 이상에 해당하는 자가발전 설비를 건설하면 가점을 주는 제도(전력계통영향평가 법령)가 있다. 하지만, 국내 데이터센터의 과반수 이상이 서비스 수요처인 수도권에 밀집되는 현상을 고려할 때 아직까지는 큰 영향을 끼치고 있지는 않는 것으로 판단된다. 게다가 데이터센터의 안정적인 전력 공급 목적 등으로 한전으로부터의 수전이 앞으로도 국내 데이터센터 전력공급의 상당 부분을 차지할 것으로 보인다.

데이터센터 전력 공급 방안으로 석탄 발전, 천연가스 발전, SMR, 재생에너지 발전, 연료 전지, 지열 발전, 수력 발전 등이 거론된다. 이 중에서 우리나라 자연 환경에 맞지 않는 지열과 수력 발전을 제외하고 나머지 발전원의 내외부 환경별로 긍정적인 측면과 부정적인 측면을 살펴본다. 아래에서는 먼저 발전원별 DC의 전력 공급원으로서의 일반적인 특징을 SWOT(Strengths, Weaknesses, Opportunities, Threats) 분석을 통해 살펴본 후, 국내 전력계통 및 온실가스 배출 측면을 종합적으로 고려하여 국내 DC의 현실적인 전력 공급원에 대해 알아본다.

3.3.1. 발전원별 장단점

(1) 석탄 발전

석탄 발전은 국내에서 오랫동안 기저발전원으로 사용되어 왔으나, 최근에는 온실가스 배출 감축 정책과 수도권 송전선로 부족에 따른 제약으로 발전량이 빠르게 감소해 오고 있다. 특히, 2022년부터는 수도권 송전선로 부족에 따른 발전 제한으로 동해안의 석탄 발전소가 가동을 중단하기도 했다. 이런 측면에서 석탄 발전은 활용 가능한 여유 용량이 많다는 것이 강점이지만, 탄소배출 문제로 국내 데이터센터의 전력 공급원으로서 활용하기는 어렵다. 탄소포집과 저장(CCS) 기술의 발전 시 향후 저탄소 대안이 될 수 있는 가능성은 있으나, 이 역시 탄소 저장 공간이 부족한 우리나라에서는 매력적인 대안이 되기 어렵다.

〈표 3-14〉 석탄 발전 방식 전력공급의 SWOT 분석

	긍정적인 측면	부정적인 측면
내부환경	[강점] ● 확립된 기술로서 안정적인 전력 공급이 가능함 ● 활용 가능한 기존 설비가 많음 ● 발전 단가가 상대적으로 저렴함	[약점] ● 다른 화석연료 대비 열량당 온실가스와 오염물질 배출이 많음
외부환경	[기회] ● 송전선로 제약으로 가동 중단된 동해안 발전소 활용 ● 탄소포집과 저장(CCS) 기술의 발전으로 저탄소 발전 가능함	[위협] ● 재생에너지 확대에 따른 경쟁력 저하 가능성이 큼 ● 환경 규제 강화로 인한 운영 비용이 증가 중 ● 사회적 수용성이 낮음

출처: 저자 정리

(2) 가스 발전

천연가스 발전은 석탄 화력 발전 대비 열량당 적은 온실가스를 배출한다. 그리고 첨두부하를 담당하는 발전 특성상 유연한 출력 조절이 가능하다는 점이 강점이다. 앞장에서 설명했듯이 데이터센터의 전력 부하 특성상 급격한 부하 상승에 대

응해 전력 공급량을 빠르게 늘릴 수 있는 응동력이⁷³ 매우 중요하다. 이러한 연유로 데이터센터에는 응동력이 가장 높은 배터리 설치가 필수적이다. 배터리를 제외하면 가장 빠른 응동력을 가진 발전원이 가스 발전이다. 가스 발전은 수십 초~수분 이내로 출력을 빠르게 조정할 수 있으며, 이는 석탄, 원자력, 재생에너지(풍력, 태양광)에 비해 월등히 빠르다. 예를 들어, 천연 가스 복합화력 발전은 출력 증가 속도(ramp rate)가 최대 부하의 5~100%(25~50MW)/분 수준이지만, 석탄 화력 발전은 0.5~8%(2~40MW)/분 수준이고⁷⁴, 원자력 발전은 석탄 발전 보다도 응동력이 낮다. 풍력·태양광 등 재생에너지는 출력변화가 자연에 의존하므로 인위적인 출력 조절은 어려우며, 저장장치(배터리)와 조합 시 초단기 응답이 가능하나, 시스템적 제약이 많다.

〈표 3-15〉 가스 발전 방식 전력공급의 SWOT 분석

	긍정적인 측면	부정적인 측면
내부환경	[강점] ● 석탄 대비 상대적으로 열량당 온실가스 배출량이 적음 ● 빠른 응동력	[약점] ● 경제성 확보를 위해 근접지에 터미널, 파이프라인 등 인프라 필요
외부환경	[기회] ● 석탄이나 원자력 대비 주민 수용성이 높아 수요지 인근에 위치 용이 ● 설비 증설을 통해 친환경 연료(수소, 바이오가스) 투입이 가능함	[위협] ● 장기적으로 탄소배출 규제 대상임. 좌초자산화 가능성이 있음 ● 재생에너지 확대에 따른 경쟁력 저하 가능성이 큼 ● 연료비의 변동성이 큼

출처: 저자 정리

그러나 고압의 가스 저장과 이송에 비용이 많이 들기 때문에 경제성 확보를 위해서는 발전소 입지가 LNG터미널 부근에 위치해야 하는 약점이 있다. 다만, 장기적으로 수소나 바이오가스를 가스 화력 발전에 투입할 수 있는 기술이 개발되고 있는 점은 기회라 할 수 있다. 반면에 화력발전이기 때문에 온실가스 배출이 발생할 수밖에 없어서 탄소 비용이 증가할 가능성이 있고, 국제 천연가스의 변동성이

⁷³ 전력 수요 변화나 계통 상황 변화에 따라 발전 설비가 얼마나 신속하게 전력 출력을 조정할 수 있는지 나타내는 능력

⁷⁴ Gonzalez-Salazar et al. (2018)

큰 점은 위협으로 작용한다. 그럼에도 주요국에서 가스 발전은 데이터센터의 전력 수요 증가를 충족하기 위한 가장 현실적인 대안으로 주목받고 있다. 예를 들어, 최근 미국에서 데이터센터의 전력 공급을 위해 천연가스 화력 발전소 건설 수요가 증가하고 있다. 루이지애나주의 엔터지 루이지애나는 Meta에 전력을 신규 공급하기 위해 2GW 이상의 추가 가스 발전소 건설을 계획하고 있다(EPRI, 2024).

(3) 원전 및 SMR

원전은 방사선 오염에 관한 우려 때문에 사회적 거부감이 크다. 그러나 전 세계적으로는 데이터센터 확대를 앞두고 안정적인 전력 공급을 위해서 원자력 발전의 활용도 재검토를 하는 추세이다. 2024년 9월 미국에서는 과거 대규모 폭발사고를 일으켜 폐쇄가 됐었던 쓰리마일 아일랜드의 원자력 발전소를 재가동하고 20년간 PPA로 전력을 공급하는 계약을 마이크로소프트와 Constellation Energy가 체결했다(IEA, 2025a). 대형 기술기업들은 SMR을 적극 고려 중인데 전 세계적으로 데이터센터 부문 공급을 위해 최대 25GW의 SMR 용량 구축 계획이 진행중에 있고, 10년 후에 실현될 가능성이 있다.

소형모듈원자로(SMR, Small Modular Reactor)는 출력 300MW 이하의 원자로로, 공장에서 부품을 모듈형으로 제작해 현장에서 조립할 수 있도록 설계된 차세대 원자력 기술이다. SMR은 기존 원전 대비 안정성이 높은 것으로 평가된다. 또한, 원전의 특성상 탄소 배출은 거의 없고, 소형 모듈이기 때문에 설치를 위한 입지 제약이 적다는 점이 강점이다. 기존의 대형 원전은 대량의 냉각수를 필요로 하기 때문에 입지에 제약이 컸다. 우리나라는 2022년 혁신형 SMR(i-SMR) 기술 개발 사업을 시작했으며, 정부는 제11차 전력수급기본계획에서 2028년까지 개발을 완료하고 2035년까지 상용화한다는 목표를 제시하고 있다. 또한, 2035~2036년 상용화 실증 1기(0.7GW)를 발전설비 계획에 반영하고 있다. 한편, 대구시와 한국수력원자력은 업무협약(2024.6)을 통해 군위 첨단산업단지 내 680 MW (170MW × 4기) 규모의 i-SMR 사업화를 추진하고 있다. SMR은 수출 상품으로의 가치도 큰데, 최근 글로벌 SMR 시장이 태동하고 있어서 SMR 기술의 개발과 활용은 이러한 시장에서의 기회를 내포한다.

이렇듯 SMR은 안정적인 전력 공급과 높은 신뢰성, 무탄소 전원, 모듈러 확장과 유연한 배치, 그리드 독립성과 이에 따른 송전 비용 절감 등의 장점이 있지만 아직 상용화 단계는 아닌 기술로서 단점 또한 많다. 주요 단점으로는 긴 건설 기간과 상용화 지연, 막대한 초기 투자 비용, 주민 수용성 문제 등이 있다. 이론적으로 SMR은 건설 기간이 대형 원전의 6~8년 대비 짧은 3~4년으로 알려져 있으나, 해외 실제 사례를 살펴보면 예상보다 긴 12~13년이 소요되고 있는 것으로 나타난다 (Schlissel & Wamsted, 2024). 동 보고서에 따르면 실제 건설 비용도 초기 추정치 대비 3~6배까지 증가한 것으로 나타난다. SMR은 대형 원전에서의 규모의 경제 효과가 없어 경제성도 전통적인 원전 대비 떨어질 수밖에 없다. 또한, 원자력 발전 시설에 대한 주민 수용성 문제와 관련한 제도의 미비도 데이터센터를 위한 SMR 설치의 큰 장애 요인이다. 이렇듯, 국내 DC 전력 공급 옵션으로의 SMR은 단기적으로는 불확실성과 한계가 많아 데이터센터의 주력 전력 공급원으로 부상하기까지는 오랜 시간이 걸릴 것으로 예상된다.

〈표 3-16〉 SMR발전 방식 전력공급의 SWOT 분석

	긍정적인 측면	부정적인 측면
내부환경	[강점] ● 기존 원전 대비 안전성이 높음 ● 탄소 배출이 없음 ● 기존 원전 대비 설치 입지 제약이 적음	[약점] ● 상용화 이전 단계로 기술 검증이 필요함 ● 초기 투자 비용이 높음 ● 기존 원전 대비 규모의 경제 효과가 작음
외부환경	[기회] ● 글로벌 SMR 시장이 태동 중으로 수출 산업화 가능성이 있음	[위협] ● 원자력에 대한 부정적 인식으로 주민 수용성 문제 ● 신기술로서 규제 체계가 미비함

출처: 저자 정리

(4) 재생에너지

데이터센터의 전력 공급원으로서 태양광, 풍력 등의 재생에너지는 간헐성(intermittency)과 불확실성(uncertainty)으로 인해 데이터센터의 전력 공급을 전담하기는 힘들다. 이러한 간헐성 탓에, 기존 전력망(grid)과의 복합 운영이 필수

적이다. 이 과정에서 전력망 연계, 송전, 예비전력 관리 등 기술적·비용적 복잡성이 크게 증가한다. 또한, 대규모 데이터센터에 전력을 공급하려면 태양광 패널 설치 등을 위한 막대한 부지 면적이 필요하다.

전세계적으로 재생에너지 발전의 DC 전력 공급은 주로 보조 전력원으로서 PPA를 통해 이뤄진다. 현재까지 전세계적으로 약 120GW 규모의 재생에너지 전력이 PPA를 통해 기업들에 조달되었는데, 이 중 데이터센터를 운영하는 기업들이 이 물량의 30% 이상을 차지하는 것으로 추정된다(IEA, 2025b). 2024년에는 전세계 데이터센터 전력 수요 약 415TWh 중 20%가 재생에너지 PPA로 충당되었고, 현재 60GW의 PPA 관련 용량이 개발 중이다. 재생에너지 발전을 데이터센터에 직접 공급하여 활용하는 두 번째 방법은 BESS(Battery Energy Storage System, 배터리 에너지저장 시스템)이다. 하지만, BESS는 일반적으로 1~4시간 정도의 짧은 지속 시간이 큰 한계여서 기존 전력망을 통한 전력 공급이 필수적이다. 결국, 재생에너지의 데이터센터의 전력 공급은 기존 전통적인 발전원에 PPA 또는 재생에너지+BESS가 결합된 혼합형이 될 수밖에 없다.

〈표 3-17〉 재생에너지 발전 방식 전력공급의 SWOT 분석

	긍정적인 측면	부정적인 측면
내부환경	[강점] ● 온실가스 배출이 없어서 친환경적임 ● 장기적으로 운영 시 발전 단가가 매우 낮음	[약점] ● 간헐성과 불확실성 문제로 기존 전력망 및 ESS와의 연계 필요 ● 초기 투자 비용 높음 ● 대규모 부지가 필요
외부환경	[기회] ● 지속적인 투자와 기술 발전으로 효율 증가 중 ● 에너지 저장 시스템(ESS) 기술이 함께 발전 중	[위협] ● 사회적 수용성이 상대적으로 높음에도 건설을 위한 적절한 부지 확보가 어려움

출처: 저자 정리

(5) 연료전지

연료전지 발전은 수소와 산소의 화학반응을 이용해 전기를 생산한다. 물의 전기분해 원리를 역으로 활용하여 화학 에너지를 전기로 변환한다. 청정 수소를 사

용한다면, 이산화탄소의 배출 없이 수소와 산소가 결합한 물만 배출하는 장점이 있다. 그런데, 우리나라에서 현재 사용하는 대부분의 연료전지는 천연가스를 투입하여 이를 수소로 개질하여 사용하는 방식으로 이산화탄소가 배출된다. 청정 수소가 아닌 천연가스나 다른 화석연료를 개질한 수소를 사용하는 경우 탄소포집과 저장(CCS)이 없다면 온실가스 저감 효과가 적다고 할 수 있다.

〈표 3-18〉 연료전지 발전 방식 전력공급의 SWOT 분석

	긍정적인 측면	부정적인 측면
내부환경	[강점] ● 다른 발전원 대비 상대적으로 효율이 높고 출력이 안정적임 ● 청정 수소 사용시 온실가스 배출이 없고, 수소 종류에 따라 온실가스 저감에 기여 가능함	[약점] ● 초기 설치 비용이 높음 ● 기술 성숙도가 낮음 ● 수소 충전 인프라 부족
외부환경	[기회] ● 수요지 인근에 설치 용이 ● 기술 발전에 따른 비용 절감 가능성이 있음	[위협] ● 수소 관련 법안 미흡 ● 연료(수소, LNG) 가격의 변동성이 높음

출처: 저자 정리

연료전지는 재생에너지와 같은 간헐성 문제없이 24시간 발전이 가능하고 상대적으로 설치 유연성이 높다. 설치면적이 작은 편으로 전력 수요가 많은 수요지 인근에 설치가 가능하다는 장점도 있다. 반면, 단점으로는 아직 성숙되지 않은 기술로서 높은 초기 설치비용, 수소 충전 인프라 부족, 관련 제도 및 규정 미흡, 기술적 한계 등이 지목된다. 특히, 데이터센터용 연료전지는 전 세계적으로 초기 투자비용이 높아 중소규모의 DC에서는 도입이 쉽지 않다. 또한 국내 수소 공급은 주로 석유화학 단지의 부생수소에 의존하고 있어 DC용 연료전지 충전 인프라가 부족하며, 위에서 언급한 대로 그린·블루 수소와 같은 청정수소의 비중도 매우 낮아 ESG와 배치된다. 한국의 수소 관련 법안은 수소사업 전반을 포괄적으로 다루지 못하고, 수소·암모니아의 용도 변경 관련 규정이 미흡하거나 부재한 상황이다. 데이터센터의 특성상 높은 전력 밀도에 대한 기술적 도전도 존재한다. 정부는 수소 경제 로드맵에 따라 2040년까지 연료전지 발전 용량 15GW 목표를 설정하고 있

으나, 현재의 다양한 한계 요인들에 대한 체계적인 해결책 마련이 필요한 상황이다. 또한 수소를 만드는데 사용하는 천연가스 가격의 변동성도 리스크 요인이다.

3.3.2. 건설 기간, 전력계통, 온실가스 배출 측면

데이터센터의 전력 공급원으로서 고려해야 할 또 다른 중요한 요소들은 건설 기간, 출력 조절 가능 여부, LCOE⁷⁵ 등이다. <표 3-19>는 발전원별 비교를 보여준다. 통상적으로 데이터센터의 건설에 2년 정도가 소요되는데, 건설 기간 측면에서 1~2년의 단기간 내에 건설할 수 있는 발전원은 가스와 태양광 발전, 폐지 원전의 재가동이다. 출력 조절 가능 측면에서는 태양광이나 풍력과 같은 재생에너지는 앞서 언급한 대로 DC의 직접 전력 공급원으로는 불가능하다.

<표 3-19> 전력 공급원별 건설 기간, LCOE, 출력조절 가능성

전력원	건설 기간	출력조절 가능여부	세계 평균 LCOE(USD/MWh)
유틸리티 태양광	1~4년	불가능(간헐적)	60
육상 풍력	2~5년	불가능(간헐적)	50
해상 풍력	3~7년	불가능(간헐적)	110
수력	5~15년	불가능(간헐적)/양수발전은 가능	80
지열	3~8년	가능	80
(신규)원자력	5~15년	가능	90
(재가동) 원자력	2~5년	가능	60
석탄 화력	3~6년	가능	80
가스 복합(CCGT)	2~4년	가능	90
가스 터빈	1~3년	가능	220
전력망을 통한 공급	3~7년	가능	미국: 350, 중국: 600 동남아시아: 610, 유럽: 240, 세계: 460

주: 건설 기간은 일반적인 프로젝트의 평균 소요 시간을 의미한다. (신규)원자력은 소형 모듈형 원자로(SMR)를 포함하고, (재가동)은 폐설비의 재가동이다. 전력망을 통한 공급의 LCOE는 연결 전력망 건설에 필요한 비용이다. 기타 가정은 IEA의 2024년 장기 에너지 수요 전망보고서인 World Energy Outlook의 가정을 사용했다.


출처: IEA(2025b), p. 79, Table 2.3

⁷⁵ 균등화 발전단가(Levelized Cost of Electricity, LCOE)는 서로 다른 발전 기술의 경제성을 비교하기 위해 발전소의 전체 수명 기간 동안 발생하는 모든 비용을 현재 가치로 환산해 총 발전량으로 나눈 평균 비용이다(비용/전력 1kWh).

마지막으로 국내 DC의 전력 공급원 분석을 위해서는 전력계통 및 온실가스 배출 측면을 고려해야 할 것이다. 최근 국내 전력계통의 가장 큰 이슈 중 하나는 송전선로 부족에 따른 송전제약이다. 우리나라의 주 전력 생산 지역은 비 수도권인 반면, 주 소비지는 수도권이다. 지역별로 동해안 지역에는 원자력과 석탄 발전이 주로 집중되어 있고, 호남 지역에는 태양광 발전이 집중되어 있다. 원자력, 석탄, 재생에너지 발전이 대부분 비 수도권에 위치하는 것에 반해, 가스 발전은 상대적으로 수요지 인근에 입지가 가능해 수도권에도 다수 존재한다.

비 수도권에서 생산된 전력은 송전망을 통해 수도권으로 송전되는데, 송전망 건설은 주민 수용성 문제 등으로 제때 건설되지 못하였다. 현재의 송전망 수준에서는 송전할 수 있는 전력량이 정해져 있는데, 2022년부터 최대 송전 가능 용량에 도달하여 발전 제약이 발생하고 있다. 송전망 부족으로 2022년부터 연간 신재생기타+원자력+석탄 발전량은 427~429TWh 수준에서 정체하고 있다([그림 3-28] 참조). 수요지 인근에 위치해 상대적으로 송전망 부족의 영향을 덜 받는 가스 발전을 제외한 나머지 발전원의 발전 총량이 최대치에 도달한 것이다. 이러한 발전 제약에 가장 직접적으로 영향을 받은 발전원은 석탄 발전이다.

[그림 3-28] 원자력+신재생기타, 석탄 발전량 및 석탄 발전 설비 이용률



주: 연간 발전 설비 이용률은 월간 이용률의 평균 값. 월간 발전 설비 이용률은 월말 발전설비 용량과 발전량을 이용해 저자 계산함

자료: 한국전력공사, 전력통계월보

우리나라의 전력 시장은 CBP(Cost Based Pool) 기반으로, 변동비(주로 연료비)가 가장 싼 발전원이 우선적으로 급전되는 구조이다. 재생에너지 발전은 변동비가 사실상 제로에 가깝고, 그 뒤를 이어 원자력, 석탄, 가스 순으로 변동비가 높다. 국내 신재생 발전은 태양광을 중심으로 빠르게 증가해 오고 있으며, 원자력 발전도 신규 원전 진입과 함께 2022년 이후에도 빠르게 증가해 오고 있다. 송전선로 부족으로 신재생 기타, 원자력, 석탄 발전량의 합이 연간 약 430TWh 수준에서 고정된 상황에서, 이러한 신재생과 원자력 발전의 빠른 증가는 석탄 발전의 제한으로 이어졌다.


특히, 동해안에 위치한 석탄 발전소가 직접적으로 영향을 받았는데, 2024년 5월에는 동해안의 석탄 발전소 대부분(8기)이 발전을 중단하기도 했으며, 2025년 1월 신규 진입했던 삼척 블루파워2호기는 발전계약으로 상업운전에 나서자마자 운영 중단하기도⁷⁶ 했다. 이에 따라, 2021년 60% 수준이었던 석탄 발전 설비 이용률은 2024년에 47% 수준까지 하락했다. 송전선로 부족에 따른 발전 제한은 사실 석탄 발전에만 국한된 것은 아니다. 2025년 들어 봄철(3~6월) 경부하기에 원자력과 태양광 발전이 갑발(출력제어)되는 사례가 증가하고 있으며, 태양광 발전 설비 증가세도 송전선로 부족에 따른 송전망 연결 어려움 등으로 과거 대비 증가세가 둔화되었다.

앞서 국내 DC 현황에서 살펴본 대로 국내 DC는 수도권에 집중되어 있는데, 이러한 송전선로 부족에 따른 발전 제한은 정부가 DC의 지방 분산을 추진하는 여러 이유 중의 하나이다. 명확히 해야 할 점은 DC 확장을 위한 발전 설비가 부족한 것은 아니라는 점이다. 수도권 지역은 송전선로 부족으로 현재로서는 전력 공급을 늘리기가 어려운 반면, 비 수도권 지역은 발전량이 남아 돌고 있다. 이러한 수도권 송전선로 부족에 따른 발전 제약은 송전선로가 완공되면 크게 완화될 것이다. 한전의 송변전설비계획(한국전력공사, 2025)에 따르면 동해안-수도권 송전선로는 2026~2027년, 서해안 송전선로는 2031년 이후 준공을 목표로 하고 있다. 요컨대 다른 이유들은 차치하고 현재 국내 전력계통 상황만을 고려하면, DC의 입지는 적어도 단기적으로는 비수도권이 현실적이다.

⁷⁶ 강원도민일보(2025.1.14.)

온실가스 측면까지 고려하면 중장기적으로는 DC의 전력 공급원은 무탄소 전원이 되어야 할 것이다. [그림 3-29]는 제11차 전기본 수요와 설비계획 정보를 이용하여 지역별로 계산된 2038년 기준 잉여 무탄소 용량을 보여준다⁷⁷. 그림에서 확인할 수 있듯이, 태양광 자원이 풍부한 호남 지역의 잉여 용량이 47.1GW로 가장 컸고, 다음으로 원자력 자원이 풍부한 영남의 잉여 용량이 19.7GW로 컸다. 반면에 수도권과 충청 지역은 무탄소 전원 자원이 부족하고 수요가 커서 마이너스 잉여 용량을 보이고 있다. 이는 국내 데이터센터의 전력을 무탄소 전원으로 공급하기 위해서는 호남과 영남지역이 대안이라는 점을 시사한다.

[그림 3-29] 2038년 지역별 잉여 무탄소 용량



주: 제11차 전기본을 바탕으로 산정.

⁷⁷ 계산 방법과 적용한 가정은 다음과 같다. 우선 수요는 전기본의 목표 피크수요에 한전통계월보의 지역별 수요 비율을 적용하여 배분하였다. 원자력은 전기본의 목표 용량에 현재의 지역별 원자력 용량 비중을 적용하여 배분하였다. 태양광은 전기본 목표 용량에 에너지공단의 지역별 발전 실적 비중을 적용하여 배분하였다. 육상풍력은 전기본 목표 용량에 역시 에너지공단의 지역별 발전 실적 비중을 적용하여 배분하였다. 해상풍력은 11차 전기본 목표 용량에 2023년 11월까지 발전사업허가를 받은 27.1GW 물량의 지역 비중을 적용하여 배분하였다. 그리고 향후 풍력은 해상풍력 중심으로 보급 되는 것으로 가정하였다.

3.3.3. 종합

지금까지의 논의를 종합하면, 국내 데이터센터의 입지 우선 지역은 호남과 동해안(강원+영남) 지역이다. 태양광과 풍력이 풍부한 호남 지역은 재생+BESS에 기존 전통적인 발전원이 결합된 형태가 여러 기준에서 유리하다. 중장기적으로는 여수 석유화학 단지의 부생수소를 이용한 연료전지도 추가 옵션으로 고려할 수 있다. 영남 지역은 재생+BESS뿐만 아니라 단기적으로 원자력 발전소 이용이 가능하다는 이점이 있다. 중장기적으로는 설계수명이 다한 원자력 발전소의 계속운전과 SMR이 주요 대안이 될 수 있으며, 울산 석유화학 단지를 활용한 연료전지도 생각해볼 수 있다. 강원 지역은 단기적으로는 송전선로 제한으로 가동 중지된 석탄 발전소를 활용하는 옵션이 있지만, 온실가스 배출 문제는 큰 제약이다. 중장기적으로 강원은 영남 지역과 마찬가지로 원전 계속운전과 SMR에 이점이 있을 것으로 보인다. 특히, 기존 대형 원전이나 폐 석탄 발전소 부지를 활용한다면 SMR의 주민 수용성 문제를 피할 수도 있다. 이상의 내용을 요약하면, 국내 데이터센터의 향후 입지는 단기적으로 호남과 영남을 중심으로 재생+BESS가 가장 현실적인 데이터센터 건설 시나리오이다.

지금까지 여러 가지 조건하에서 현실적인 국내 데이터센터의 입지와 에너지 공급원에 대해 살펴보았다. 앞에서 수 차례 언급한 대로 영호남의 재생+BESS 옵션 단독으로는 데이터센터의 전기 공급을 담당할 수 없다. 여기에 추가적으로 전통적인 발전원이 결합되어야 한다. 전통적인 발전원의 출처는 두 가지로 나뉜다. 첫째는 한전의 전력망에 의한 전력 공급이고 둘째는 데이터센터의 자가발전이다. 다음 절에서는 후자에 대한 내용을 국가 전체의 에너지 소비 측면에서 좀더 자세히 다룬다.

3.4. 국가 전체 에너지 소비에의 시사점

다음 장의 국내 데이터센터 정책 부분에서 다루겠지만, 국내 데이터센터의 신규 건설에는 자가발전 설치가 중요한 요소이다. 앞서의 “울산 AIDC 실증 분석”과 “국내 전기 소비 추세” 부분에서도 설명했지만, 국내 상용자가발전은 최근 몇 년간 LNG 열병합발전소를 중심으로 빠르게 증가하였으며, 향후 데이터센터의 자

가발전 역시 LNG 열병합발전소를 중심으로 증가할 것으로 보인다. 이는 빠른 응답력, 짧은 건설 기간, 주민 수용성, 석탄 대비 적은 환경 비용 등으로 데이터센터의 자가 발전원으로서 가장 강점이 있기 때문이다.


데이터센터의 자가발전소가 LNG 열병합발전소를 중심으로 추진된다면, 이는 한전의 전기 판매량과 LNG 민간 직수입에 큰 영향을 미칠 수 있어 이에 대한 정부의 대책 마련이 필요하다. 특히, 데이터센터가 산업단지에 위치할 경우 그 영향력은 더욱 확대할 수 있다. 이는 데이터센터의 LNG 열병합 자가발전소에서 생산되는 전기를 인근 수요지에 판매할 경우, DC 전기 소비보다 훨씬 더 많은 전기가 생산되기 때문이다. 제2장에서 설명했듯이 데이터센터의 전력 수요에 대한 불확실성은 매우 높다. DC 운영자 입장에서는 자가발전한 전력을 판매하여 수익을 높여려는 유인이 존재한다. 만약 초기 전망만큼 데이터센터의 전력 수요가 크지 않다면, 자가발전을 통해 DC가 자체 소비하는 전력보다 인근의 수요지에 판매하는 전력이 더 많을 수도 있다. 이러한 이유로 DC 자가발전소의 발전량은 데이터센터의 전산 처리량 보다 훨씬 더 빠르게 증가할 수 있다. DC 인근의 전기 소비자가 한국전력이나 한국난방공사 대비싼 가격에 전력이나 열을 구매할 수 있다면, 이러한 연쇄효과로 DC의 자가발전량은 AI와는 무관하게 예상보다 큰 폭으로 증가할 가능성이 크다.

앞서 언급한 대로 데이터센터와는 별개로 우리나라는 이미 LNG 상용자가발전의 증가로 산업용 전기 소비(한전 판매량)가 정체되고⁷⁸ LNG 직수입 물량이 증가하고 있다. [그림 3-30]에 나타난 바와 같이, 산업용 LNG 직수입은 LNG 상용자가발전소의 증가에 힘입어 최근 급증하고 있다. 2024년 기준으로 전체 산업용 가스(도시+천연)에서 천연가스가 차지하는 비중은 37.6%인데, 향후 데이터센터의 자가발전량이 인근 산업체에 판매되는 양까지 더해진다면 이러한 상승세는 지속될 것으로 보인다. 앞서 울산 AIDC 추정에서 언급한 바와 같이, DC의 LNG 자가발전의 효과는 국가 에너지수급통계상 일차적으로 상업·공공 부문의 천연가스 급증으로 이어질 것이다. 현재 국가 수급통계상 상업·공공 부문의 천연가스 소비량은 없

⁷⁸ 산업용 전기 소비 저조의 가장 큰 원인은 경기 불황 등에 따른 생산 정체이다.

으나, 향후 DC의 증가와 함께 상업·공공 부문도 LNG 직수입이 빠르게 증가할 가능성이 크다.⁷⁹

[그림 3-30] 산업용 도시가스 및 LNG 민간 직수입



자료: 국가에너지통계종합정보시스템(KESIS), 국가에너지수급통계(간이 에너지밸런스)

자가발전을 하는 사업체는 전력 시장 환경 변화에 따라 자가발전량과 한전으로부터의 수전량을 자유롭게 조정할 수 있기 때문에, 이러한 상용자가발전 증가는 한전의 판매량인 전력 소비 변동성 확대로 이어질 가능성이 크다. 예를 들어, 2021년 10~12월 천연가스 가격이 전년 동월 대비 300~456% 급등하자, 천연가스 상용자가발전과 한전 수전을 병행하는 철강업에서는 천연가스 직수입을 11.4~24.3% 줄이고 한전 수전량을 11.4~12.0% 늘린 바 있다⁸⁰. 데이터센터의 증가와 함께 앞으로는 상업용(일반용) 전기 소비 역시 이러한 변동성에 노출될 것으로 보인다.

또한, 국내 민간 LNG 직수입의 증가는 비용 절감과 시장 경쟁 활성화와 같은 긍정적 측면도 있으나, 공급 안정성 및 시장 형평성에 대한 문제를 초래할 수 있다. 민간기업은 LNG 비축 의무가 제한적으로 적용되기⁸¹ 때문에, 국제 천연가스 가격

⁷⁹ LNG 민간 직수입은 도시가스사업법에 따라 특정 용도(발전용, 산업용, 열병합용, 열전용 설비용)의 자가소비에 한해 직수입할 수 있다. 국가 에너지수급통계 측면에서는 이와는 별개로 데이터센터용은 에너지의 소비가 이뤄지는 상업용 또는 공공용으로 분류된다.

⁸⁰ 에너지경제연구원(2025) p.55

⁸¹ 도시가스사업법 시행규칙에 따라 자가소비 계획량의 30일분에 해당하는 양을 저장할 수 있는 저장시설을 갖추고 산업통상자원부의 인허가를 받아야 하며 원칙적으로 제3자 판매(리셀링)가 금지된다. 단, 자가발전으로 생산한 전기를 판매하는 것은 가능하다.

이 급등하면 직수입을 중단하는 체리피킹(Cherry picking) 등이 발생할 수 있고, 이는 가스 수요 변동성 확대와 국가 에너지 수급 불안 등의 문제로 이어질 수 있다. 이에 따라 정부는 현재의 직수입 제도를 안정적으로 정착시키기 위한 노력을 지속하고 있다. 특히, 정부나 가스공사는 발전용, 산업용, 연료전지용 천연가스 직수입 전망에 중점을 두고 있다. 하지만, 본 연구의 결과는 향후 DC 증가로 상업용 천연가스 직수입이 크게 증가할 가능성이 있음을 보여준다. 이는 현재 정부가 예상하는 것 보다 LNG 민간 직수입 증가가 더욱 가속될 수 있다는 것을 의미한다. 이러한 점을 고려할 때 정부는 직수입 제도 개선 및 보완과 천연가스 공급 안정성 강화 방안을 서둘러 마련해야 할 것으로 보인다.

이상으로 글로벌 DC 에너지 소비 관련 연구들과 국내 에너지 소비에의 영향에 대해 살펴보았다. 다음 장에서는 DC 에너지 소비에 관련한 정책에 대해 알아본다.

제4장

데이터센터 관련 정책 및 제안

지금까지 살펴본 대로 데이터센터의 전기 소비는 다른 업종과는 차별화되는 특수성을 가진다. 데이터센터는 단위면적당 전력 소비(전력 밀도)가 크며, 하루 24시간, 1년 365일 연속적으로 운영된다. 특히, AIDC의 경우 훈련과 추론의 부하는 상당 부문 GPU 최대 전력 근처에서 발생하며 변동성이 크다. 게다가 AI 연산량은 추론의 발생 빈도 및 시간, 추론 유형을 포함한 많은 요인들에 의존하므로, 계획된 생산량을 통해 예측할 수 있는 제조업의 전기 수요 대비 예측의 불확실성이 매우 높다. 이러한 DC 부하의 특수성으로, 국가 전력 수급 안정을 위해서는 적극적인 정책 개입이 필요하다.

이번 장에서는 이러한 요구에 대응해 해외 주요국들은 어떤 정책적 노력을 하고 있는지 구체적으로 살펴보고, 이를 바탕으로 단계적으로 국내 실정에 맞는 정책 고려사항들을 정리한다.

1. 에너지 소비 관련 글로벌 DC 정책

인공지능 시대의 도래로 국제적으로 많은 AI 관련 정책들이 수립되고 있다. 이러한 정책들은 보안, 윤리, 보급 및 인프라 확장 등의 분야로 확산되고 있다. 본 절

에서는 데이터센터의 에너지 소비와 관련된 내용을 중심으로 주요국의 정책들을 정리한다. 데이터센터에 관한 정책들은 아직까지는 주요국을 중심으로 수립되고 있다. 이러한 정책의 상당수는 최근에 채택되었으며, 대부분 2020년 이후 시행되고 있다. <표 4-1>에는 정책 카테고리별로 이를 채택한 국가가 정리되어 있다. 본 절에서는 이들 국가들을 위주로 데이터센터 관련 정책들을 알아본다.

<표 4-1> 데이터센터 정책 카테고리별 채택 국가

정책 카테고리	채택 국가
정부 허가 제도	중국, 싱가포르
최소 에너지 성능(효율) 기준 및 의무	중국, 프랑스, 독일, 일본, 네덜란드
클라우드 우선, 데이터 및 데이터센터 통합 정책	캐나다, 프랑스, 싱가포르, UK
공공 부문 조달 정책	호주, EU, 독일, 네덜란드, 미국(캘리포니아)
인센티브 제도	EU, 프랑스, 영국
자발적 계약	EU

자료: IEA 4E EDNA(2024), p.1

1.1. 유럽연합(EU)

유럽연합은 에너지효율 관리지침(EED, Energy Efficiency Directive 2023/1791⁸²)을 통해 데이터센터 부문에 대한 포괄적인 공통 규제 체제를 구축했다. 지침의 최신 개정은 2023년 9월에 이뤄졌는데, 이에 따라 EU 개별국은 2년 내 지침에 설정된 요소들을 자국의 국내법에 포함시켜야 한다. 개정된 EED의 핵심 내용은 IT 전력 수요 500kW⁸³ 이상 데이터센터의 운영자에게 연간 에너지 성능 데이터의 공개 보고를 의무화한 것이다. 또한, 총 전기 소비량이 1MW를 초과하는 데이터센터는 기술적 또는 경제적으로 실현 불가능한 경우를 제외하고 폐열을 난방이나 기타 에너지 회수 용도로 활용해야 한다.

⁸² Directive 2023/1791

⁸³ 이를 연간 전력 소비량으로 환산하면 약 4.4GWh이다.

EU 위원회는 2024년 3월 EED를 보완하는 데이터센터에 관한 위임 규정(Delegated Regulation)을⁸⁴ 채택하고 2024년 6월부터 시행했다. 위임 규정에는 데이터센터 운영자가 구체적으로 어떤 정보와 성과지표를 보고해야 하는지, 그리고 이를 측정하는 방법론이 명시되었다. 이 규정에 따라 데이터센터 운영자는 2025년부터 매년 5월 15일까지 데이터센터의 정보 및 주요성능지표(KPI, Key Performance Index)를 유럽 데이터베이스(European database)에⁸⁵ 보고해야 한다.⁸⁶ 모든 보고 정보는 직전 연도의 정보를 기준으로 하며, 보고된 내용은 회원국 및 EU 수준에서 집계된 형태로⁸⁷ 공개된다.

보고해야 하는 항목은 카테고리별로 데이터 센터 관련 정보, 에너지 및 지속가능성 지표, ICT 용량 지표, 데이터 트래픽 지표로 나뉜다. 이 중 에너지 및 지속가능성 지표에는 설치된 정보 기술 전력 수요 (PDIT), 데이터 센터 총 면적 (SDC), 데이터 센터 컴퓨터실 면적 (SCR), 총 에너지 소비량 (EDC), 정보 기술 장비의 총 에너지 소비량 (EIT), 전력망 기능 제공 여부, 평균 배터리 용량 (CBtG), 총 물 입력량 (WIN), 총 음용수 입력량 (WIN-POT), 폐열 재사용량 (EREUSE), 평균 폐열 온도 (TWH), 정보 기술 장비 흡기 평균 설정 온도 (TIN), 냉매 유형, 냉방도일 (CDD), 총 재생에너지 소비량 (ERES-TOT), 출처별 재생에너지 소비량 (원산지 보증(GO, Guarantees of Origin), 전력구매계약(PPA), 현장생성(on-site renewables)) 등이 포함된다. 보고된 정보와 주요 성능 지표를 기반으로 유럽 데이터베이스는 데이터센터의 지속가능성 지표(PUE, WUE, ERF, REF)를 계산하여 공개하게 된다. EU 국가들 중에서는 독일이 가장 먼저 EED를 국내법으로 구현했다.

⁸⁴ European Commission. Delegated Act -ANNEXES to the establishment of a common Union rating scheme for data centres.

⁸⁵ EED 제12조에 따라 데이터 센터의 지속가능성을 평가하기 위한 공동 연합 제도를 수립하는 첫 번째 단계의 일환으로 EU집행위원회는 데이터베이스를 구축해야 한다.

⁸⁶ 보고는 해당 회원국에 국가 보고 체계가 있는 경우는 해당 체계를 통해, 그렇지 않는 경우는 DC 운영자가 직접 데이터베이스에 보고해야 한다.

⁸⁷ 개별 데이터센터의 보고 정보는 기밀로 유지된다.

〈표 4-2〉 EU 규정에 따라 보고해야 하는 핵심 성능 지표

핵심 성능 지표(KPI)	항목	단위	세부 내용
에너지 및 지속가능성 지표	설치된 IT 전력수요	kWh	설치된 전력수요 또는 정격 IT 부하 사용, 기중평균 사용
	데이터센터 총 바닥 면적	m2	전체 구조물 또는 데이터센터 관련 부분 면적
	데이터센터 컴퓨터실 바닥 면적	m2	데이터 처리, 저장, 통신장비가 있는 공간 면적. 구조물 그룹의 경우 합계
	총 에너지 소비량	kWh	전기, 연료 등 데이터센터 기능에 사용된 모든 에너지 포함. 백업 발전기 소비량 분리 측정
	IT 장비의 총 에너지 소비량	kWh	UPS 또는 PDU 등 측정점 명시
	전기 그리드 기능 제공 여부	-	피크 수요 이동 또는 주파수 응답 등 지원 기능 제공 여부
	그리드에 제공된 배터리 평균 용량	kWh	
	총 물 사용량	m3	냉각 등 데이터센터 기능에 사용된 모든 물 포함
	총 식수 사용량	m3	데이터센터 기능에 사용된 모든 식수원 포함
	폐열 재사용량	kWh	데이터센터 경계 외부에서 사용되어 외부에너지 수요를 대체하는 열
	평균 폐열 온도	℃	IT 장비 냉각 유체의 평균 온도
	평균 IT 장비 흡입 공기 설정 온도	℃	컴퓨터 실내 냉각 시스템의 설정 평균 온도
	사용된 냉매 유형	-	냉각 장비에 사용된 냉매의 일반 또는 산업 명칭
	냉방도일	도일	데이터센터 위치의 전년도 냉방도일(기준 온도 21℃)
	총 재생에너지 소비량	kWh	GOO+ PPA+현장 재생에너지
ICT 용량지표	서버 ICT 용량	-	SERT 활성 상태 성능 또는 동등 값의 합계. 새로 설치된 서버에 대해 최소한 보고
	저장장비 ICT 용량	Pb	모든 SSD 및 HDD 장치의 raw 용량 합계. 새로 설치된 장비에 대해 최소한 보고
데이터 트래픽 지표	유입 트래픽 대역 폭	Gb/s	유입 트래픽의 총 프로비저닝된 대역 폭 평균
	유출 트래픽 대역 폭	Gb/s	유출 트래픽의 총 프로비저닝된 대역 폭 평균
	유입데이터 트래픽 양	Eb	보고 연도 동안의 총 유입 데이터 양
	유출데이터 트래픽 양	Eb	보고 연도 동안의 총 유출 데이터 양

자료: Directive 2023/1791를 바탕으로 저자 정리

〈표 4-3〉 EU 규정에 따라 보고해야 하는 데이터센터 정보

카테고리	항목	세부 내용
일반 정보	데이터센터 이름	데이터센터를 식별하는 이름
	소유자 및 운영자 정보	소유자 및 운영자의 이름 및 연락처 세부 정보
	위치	데이터센터 위치의 지방자치단체코드(LAU 코드)
	데이터센터 유형	주요 운영방식에 따른 유형(자사형, 코로케이션, 코호스팅), 단일 구조물 또는 구조물 그룹 여부 포함, 코로케이션/코호스팅 혼합 제공 시 여부
	운영 개시 연월	정보 기술 서비스 제공을 시작한 연도 및 월
운영 정보	전기 인프라 이중화 수준	고압/저압(라인업)/랙 수준에서의 이중화 수준
	냉각 인프라 이중화 수준	실내/랙 수준에서의 이중화 수준

자료: Directive 2023/1791를 바탕으로 저자 정리

1.2. 독일

독일은 에너지효율법(EnEfG, Energieeffizienzgesetz)을 2023년 11월에 제정 및 시행하며 EED를 국내법에 반영했다. EnEfG에서는 정부 및 공공기관, 민간 기업에 대해 에너지 및 환경 관리 시스템 구축 의무를 부과한다. 특히, 법은 데이터센터를 대상으로 PUE, 재사용 에너지 비율, 재생에너지 활용 비율, 에너지 및 환경 관리 시스템 등을 규정하고 있다.

먼저 PUE 의무 기준에 대해서는 2026년 7월 1일 이전에 운영을 시작한 기존 및 신규 데이터센터는 2027년 7월 1일 이후로는 연평균 PUE 1.5 이하, 2030년 7월 이후에는 영구적으로 1.3 이하를 달성해야 한다. 2026년 7월 1일 이후 운영을 시작하는 신규 데이터 센터는 가동 시작 후 2년 이내에 PUE 1.2 이하를 영구적으로 달성해야 한다.

EnEfG은 지난 3년간 연평균 에너지 소비량이 2.5 GWh를 초과한 모든 사업체에 대해서 기술적으로 가능한 범위 내에서 폐열 발생을 최소화하고, 기술적으로 불가피하게 발생한 폐열은 최대한 회수 및 활용해야 함을 명시하고 있다. 특히, 데이터센터의 경우 운영 과정에서 발생하는 폐열과 같은 에너지를 다시 포집하여 사용하는 재사용 에너지 비율을 규정하고 있다. 2026년 7월 이후 운영을 시작하는 DC에 대하여 최소 10%의 재사용 에너지 비율을 달성해야 한다. 이 비중은 DC의

운영 시점에 따라 점차 상승하는데, 2027년 7월 이후 운영되는 DC는 최소 15%, 2028년 7월 이후 운영되는 DC는 20% 이상이어야 한다. 단, 데이터센터가 지방 자치 단체 또는 열 네트워크 운영자와 폐열 사용에 대한 계약(협약)을 체결하는 경우에는 재사용 의무 비율 적용에서 제외된다. 이러한 계약에는 10년 이내에 폐열 재사용 요구 사항을 충족할 수 있는 하나 이상의 열 네트워크 구축이나 구체적인 허가 방안이 포함되어야 한다. 만약, 열 공급 인프라를 갖춘 DC 운영자의 재사용 에너지 이용에 대한 제안을 열 네트워크 운영자가 6개월 이내에 수락하지 않는 경우, 열 네트워크 운영자는 DC 운영자에게 열 네트워크 용량(열 수요량, 유휴 수용력, 기술적경제적 한계 등)에 대해 알려줄 의무가 있다. 이는 DC의 폐열 공급 제안에 대한 열 네트워크 운영자의 수용 불가능 이유를 투명하게 공개하여, 경쟁적이고 효율적인 열 공급 구조를 촉진하려는 목적이다.

독일 에너지효율법은 EED에서 규정하지 않는 데이터센터의 재생에너지 비중도 규정하고 있다. 데이터센터 운영자는 2024년 1일부터 총 전력 소비의 50%를, 2027년 1월부터는 100%를 재생에너지로 생산된 전력을 사용해야 한다. 여기서 재생에너지 전력 소비란 회계상(bilanzziel)의 의미로, 운영자는 재생에너지 비중을 충족하기 위해 원산지 보증(GO), PPA 등을 이용할 수 있다.

마지막으로 데이터센터 운영자는 2025년 7월 1일까지 에너지 또는 환경 관리 시스템을 구축해야 하고, 2026년부터는 시스템을 외부 전문 기관을 통해 검증 또는 인증할⁸⁸ 의무가 있다. 이 시스템에는 데이터센터 주요 구성 요소의 전기 성능 및 에너지 소비에 대한 지속적인 측정과 에너지효율 개선을 위한 조치가 포함되어야 한다. 단, 지난 3년 동안의 연간 평균 총 최종에너지 소비량이 7.5GWh를 초과하지 않으면서, 발생하는 재사용 에너지의 최소 50%가 열 네트워크를 통해 흡수되는 데이터센터나 2027년 7월 1일 이전에 해체 예정인 데이터센터는 에너지 또는 환경관리 시스템 구축 의무에서 면제된다.

위에서 언급한 대부분 규정의 대상은 비중복 정격 연결 용량이⁸⁹ 300kW 이상

⁸⁸ 검증 또는 인증 대상 데이터센터는 운영자(일반, 공공 기관, 정보 기술 운영자 등)에 따라 다르다.

⁸⁹ 전력 공급 설비의 중복(2N, N+1 등) 구성을 고려하지 않고, 단일 전원 공급망을 통해 IT 장비에 공급 가능한 최대 전력 용량을 의미한다.

인 데이터센터이지만, 정보 보고 의무는 200kW 이상인 DC에 대해 단계적으로⁹⁰ 적용된다. 데이터센터 운영자는 매년 3월 31일까지 전년도 운영에 대한 정보를 연방 에너지효율청(BAFA)에 보고해야 하며 이를 통해 최종적으로 유럽 데이터베이스로 정보가 전달된다. 보고해야 하는 정보는 EED에서 규정한 DC에 대한 일반정보와 운영 데이터를 포함한다.

〈표 4-4〉 독일, 보고 의무 데이터센터 정보

구분	항목	상세 내용
데이터센터 일반 정보	명칭	데이터센터의 명칭
	소유자/운영자 성명	데이터센터 소유자 및 운영자의 성명/명칭
	규모 등급	IT 연결 용량 기준 규모 (< 500Kw, < 1MW, < 5MW, < 10MW, < 50MW, < 100MW, >= 100MW)
	우편번호	데이터센터가 위치한 지역의 우편번호
	총 건물 면적	데이터센터의 전체 건물 면적
	정격 연결 용량	IT 정격 연결 용량 및 데이터센터의 비중복 정격 연결 용량
전년도 운영 관련 일반 데이터	전력 소비량	자가 발전 포함 총 전력 소비, 총 전력 구매, 계통으로 되팔거나 되돌린 전력량
	재생에너지 비율	총 전력 소비량 대비 재생에너지 비율 (DIN EN 50600-4-3 기준)
	방출된 폐열	공기, 물, 토지로 방출된 측정 또는 추정 가능한 폐열량 및 평균 온도
	공급된 폐열	열 소비자에게 공급된 폐열량(kWh/년) 및 평균 온도(°C)
	저장/처리된 데이터량	데이터센터에 저장 및 처리된 데이터의 양
	PUE	데이터센터 전체의 PUE(DIN EN 50600-4-2 기준)
	재사용 에너지 비율(RES)	재사용된 에너지의 비율(DIN EN 50600-4-6 기준)
	냉각시스템 효율	냉각 시스템 효율(DIN EN 50600-4-7 기준)
	WUE	물 사용 효율성 지표(DIN EN 50600-9 기준)

자료: EnEfG를 바탕으로 저자 정리

⁹⁰ 200~500 kW의 DC는 2025.7까지 최초 보고, 500 kW 이상 DC는 2024.5.15까지 최초 보고

1.3. 프랑스

프랑스도 2025년 4월 30일 공포된 DDADUE 법(LOI n° 2025-391)을 통해 EU의 에너지효율 관리지침을 국내법에 담고 있다. 이 법은 경제, 재정, 환경, 에너지, 운송, 보건 및 인적 이동 등 다양한 분야의 내용을 담고 있는데, 제25조에 데이터센터 관련 내용이 규정되어 있다. DDADUE에서 데이터센터 관련 주요 조항은 에너지 성과 향상을 위한 전용 프레임워크 구축, 에너지 성능 정보 공개 의무, 폐열 활용 의무 및 불이행 시 제재, 경제성 분석 의무 등을 포함하고 있다.

법에 따르면 군사용 등의 국익에 민감한 데이터센터를 제외한 500kW 이상의 데이터센터는 행정, 환경 및 에너지 관련 데이터를 유럽 데이터베이스에 제출하고 일반에 공개해야 한다. 이 조항은 2025년 5월 3일부터 발효되었으나 구체적인 적용 방식은 향후 행정명령을 통해 추가될 것으로 보인다. 폐열에 관해서는 설치 용량이 1MW 이상인 데이터센터는 폐열을 효율적으로 활용해야 하고, 신설 또는 대규모 프로젝트 변경 시 데이터센터의 운영자는 사전에 열 및 냉방 공급의 에너지 효율 개선에 대한 경제적 타당성(비용-편익) 분석을 실시해야 한다고 규정한다. DDADUE 법은 이러한 의무사항을 준수하지 않을 경우 최대 1년의 기간 동안 시정명령을 내릴 수 있고, 시정명령을 따르지 않을 경우 데이터센터당 최대 5만 유로의 벌금이 부과될 수 있다. 이러한 조항들은 2025년 10월부터 발효되고 구체적인 적용 방식 등은 관련 행정명령 등을 통해 향후 추가될 예정이다.

독일과 프랑스에 이어 EU 주요 국가들도 EU의 에너지효율 관리지침을 국내법에 반영하려고 노력하고 있다. 예를 들어 네덜란드는 설치 용량 500 kW 이상인 데이터센터에 대해 정보를 보고하도록 규정하였다. 하지만 현재까지 독일과 프랑스를 제외한 대부분의 EU 국가에서 구체적인 법안들은 나와있지 않은 상태이다.

1.4. 미국

미국에서 현재까지 데이터센터의 에너지효율을 민간 영역까지 규제하거나 PUE 등의 효율지표를 보고하도록 하는 주(States)는 없다. 캘리포니아의 경우 2014년 10월의 행정명령(Department of General Services, 2014.10.10.)에 따라 1,000평방피트를 초과하는 주립 데이터센터 및 서버실의 에너지효율 달성을 요

구하며, 매년 PUE를 측정하여 보고하고, PUE가 1.5를 초과할 경우 최소 매년 10%씩 감축해야 한다고 명시하고 있다. 뉴욕주의 경우에는 데이터센터에 대한 보고 의무 내용이 담긴 상원안(S6394A)과 하원 동반안(A9086A)이 현재 계류 중에 있다(NY State Assembly Bill 2025-A9086A and 2025-S6394A).

1.4.1. 인증제도

이처럼 데이터센터만을 위한 보고 및 효율 규제는 부족한 반면, 기존의 건물 에너지효율 인증 제도가 데이터센터에 맞게 조정되어 적용·확산되고 있다. 미국에서는 에너지효율 인증/라벨 제도로 대표적인 에너지스타(Energy Star)⁹¹가 있다. 미국 환경보호국(EPA)에서 1992년부터 시작한 이 프로그램은 제품, 주택, 건물 등에서 EPA가 정한 효율 기준을 충족한 경우 파란색 Energy Star 로고가 붙는다. 미국에서는 이 인증/라벨 제도를 데이터센터에 특화된 PUE 효율 기준을 바탕으로 데이터센터에도 적용하고 있다. 에너지스타의 점수는 1~100점으로 해당 점수는 백분위수를 의미한다. 즉 75점이면 전체 중 상위 25%에 속함을 의미한다. 그리고 75점 이상을 받아야만 에너지스타 인증/라벨을 부여받는다. 그런데 인증을 위한 기준 설정에 있어 데이터센터별 PUE값을 단순히 순서대로 나열하여 구분하지 않고, 데이터센터별 PUE값에 영향을 미칠 다양한 변수들을 고려하여 추정된 PUE값 대비 상대적으로 얼마나 높고 낮은지를 비교하여 산정한다.

추정(Predicted) PUE값을 회귀분석하기 위해서 독립 변수로 건물 면적, 데이터센터 면적, Tier 수준, 랙 수, UPS 활용률, 연간 IT 에너지, 건물 유형(독립, 다른 건물에 포함된 형태), 데이터 센터 유형(호스팅, 하이브리드, 인터넷, 전통, 통신 포함), 난방도일, 냉방도일이 검토되었는데, 최종적으로 계수에 대한 유의성이 높은 연간 IT 에너지 소비량만 독립 변수로 확정되었다. 그리하여 추정 PUE 값은 다음 식을 통해서 계산된다.

⁹¹ ENERGY STAR(2014.11.)

$$\begin{aligned} \text{Predicted PUE} = & -0.9506 * \{ \text{연간IT 에너지(TBtu)} \\ & - \text{회귀 방정식 데이터의 평균 연간IT 에너지}(0.2091 \text{ TBtu}) \} \\ & + 1.924 \end{aligned}$$

이를 바탕으로 실제 PUE와 추정된 PUE의 비율을 통해 에너지효율 비율을 계산하고 해당 비율의 누적 백분위 표를 통해 점수가 계산된다. 백분위 표에서 상위 25%에 해당되려면 EER값이 0.8648 보다 낮아야 한다.

$$\text{EnergyEfficiency Ratio} = \frac{\text{ActualPUE}}{\text{PredictedPUE}}$$

이러한 계산 방식은 단순히 특정 PUE 보다 낮아야 한다는 획일적인 기준보다 각 데이터센터별 IT 에너지 소비량을 고려한 상대값으로 인증을 한다는 점에서 조금 더 합리적인 방법이라고 판단된다.

다른 인증제도로는 미국그린빌딩위원회(USGBC)가 운영하는 LEED(Leadership in Energy and Environmental Design)가 있다. 해당 인증제도는 사전 필수 요건들을 모두 충족한 뒤에 각 기준별로 받은 점수를 합산하여 인증 등급을 받는다. 인증을 위한 심사는 GBCI(Green Business Certification Inc.)에서 진행한다. 각 인증 등급은 총 점수 110점을 기준으로 Certified(40-49점), Silver(50-59점), Gold(60-79점), Platinum (80점 이상)으로 나뉜다. LEED는 건물의 단계별로 인증 시스템을 구분한다. 디자인 및 건설 단계(BD+C), 인테리어 디자인 및 건설 단계(ID+C), 건물 운영 및 유지관리 단계(O+M)이다. 또한, 다양한 건물 종류별로 심사가 이루어지는데, 그 중 데이터센터도 별도로 분리하여 심사를 진행하고 있다(U.S. Green Building Council. LEED rating system). 데이터 센터로 인증 심사를 받기 위해서는 해당 건물의 60% 이상이 데이터센터 용도로 할당되어 있어야 한다. <표 부록-2>는 LEED의 BD+C 기준 점수 크레딧 항목과 해당 점수를 나타낸 것이다. 데이터센터를 포함한 대부분의 건물 유형에서 아래와 같은 점수 분류 체계에 맞게 심사가 이루어진다. 그러나 항목 내 점수 평가 방식에서는 각 건물의 특성을 고려한 심사가 이루어지는데, 특히 데이터센터만의 에너지 다소비 특성을 고려하여 별

도의 기준들이 마련되어 있다.⁹² 해당 인증제도는 국제적으로도 인정받고 있는 제도로 우리나라에도 많은 건물에서 LEED 인증을 획득하였으며, 데이터센터의 경우에도 네이버 데이터센터 등에서 인증을 받은 사례가 있다(네이버 보도자료, 2024.6.4.).

1.4.2. 인프라 확장 정책

한편, 미국은 트럼프 2기 행정부에 들어서면서 AI 분야에서 세계적인 지배력을 확보하고 유지하기 위해 많은 전략 계획을 쏟아내고 있다. 그 중 첫 번째 대표적인 사례가 스타게이트 프로젝트(Stargate Project)이다. 스타게이트 프로젝트는 트럼프 행정부의 AI 인프라 프로젝트로 향후 4년간 5천억 달러의 투자가 계획되고 있다. 해당 투자에는 소프트뱅크, OpenAI, 오라클, MGX, Arm, Microsoft, NVIDIA 등이 대거 참여한다(OpenAI, 2025.1.21.). 2025년 9월 기준 5곳의 AI 데이터센터 장소를 공개하였는데, 이는 전체 5천억 달러 투자 및 10GW 용량 목표 중에서 4천억 달러 투자 및 7GW 규모 용량을 차지하는 것이다(OpenAI, 2025.9.23.).

연결 선상에서 트럼프 행정부는 미국의 AI 행동 계획(America's AI Action Plan) 및 이와 관련한 행정명령을 2025년 7월 23일에 발표하였다.⁹³ 데이터센터에 대한 트럼프 행정부의 기본 방침은 환경 규제는 대폭 축소하고 인프라 확장에 집중한다는 것이다. 데이터센터 관련 건설이 일반적으로 환경에 중대한 영향을 미치지 않는다고 하여 국가환경정책법(NEPA)의 심사 절차를 면제받을 수 있는 범주 제외(Categorical Exclusions)에 속하도록 하였다. 또한, Fixing America's Surface Transportation Act(2015)에서 41편에 해당되는 연방정부의 대규모 인프라 프로젝트 허가 절차 개선에 대한 법안인 FAST-41에 적용 범위를 모든 데이터센터와 그와 관련된 에너지 프로젝트까지 범위를 넓혀 인허가 절차에 소요되는 시간을 단축하도록 하였다. 수질오염방지법(Clean Water Act) 제404조에서 데이터센터 건설 허가를 받을 때 개별 사업별로 심사를 하지 않고 반복·유사 유형

⁹² 관련된 자세한 사항은 USGBC(2023) 참고 바람.

⁹³ 해당 계획은 크게 AI 혁신 가속화, 미국 AI 인프라 구축, 국제 AI 외교 및 안보 선도로 3개의 축(Pillar)으로 구성되어 있다. 이 중 두 번째 축은 AI 혁신을 위한 데이터센터 및 에너지 인프라 구축에 초점이 맞춰져 있다(The White House, 2025.7.).

의 건설을 묶어 전국 단위의 일반 허가(Nationwide permit)로 처리할 수 있을지를 검토하도록 했다. 여기에 대기정화법(Clean Air Act), 수질정화법(Clean Water Act), 포괄적 환경보호법 등 관련 법률에 따른 규제를 간소화하여 환경 허가 절차를 신속하게 처리할 수 있도록 하였다. 행동 계획의 두 번째 축(Pillar) 내 규제 완화와 관련해서는 같은 날인 7월 23일에 행정명령을 통해서도 즉시 실행되도록 하였다.⁹⁴

미국은 주(State) 차원에서도 데이터센터 건설 및 투자에 대한 판매세(sale tax), 사용세(use tax) 등의 세제 혜택을 경쟁적으로 시행하고 있다(Illinois DCEO, 2025). <표 부록-3>에서는 미국 주별로 데이터센터 주자에 대한 세금 면제 혜택이 정리되어 있다. 각 주에서 데이터센터 유치를 위해 경쟁적으로 혜택을 제공하는 것은 관련 일자리뿐만 아니라 디지털 인프라 형성 등 다양한 이점이 있기 때문이라 판단된다.

그러나 무분별한 데이터센터의 도입이 전력망에 미칠 악영향에 대한 우려도 존재한다. 조지아주의 경우에는 데이터센터의 도입이 전력망에 미칠 영향을 검토하기 위해 2년간(2024년 7월 1일~2026년 6월 30일) 판매세 면제 혜택을 중단하는 내용을 골자로 하는 법안(HB1192)이 제안되었다. 동 법안은 하원과 상원을 통과했으나, 5월 7일 조지아주 주지사가 불과 2년 전(2022년)에 면제 혜택을 3년 더 연장하였고, 이를 바탕으로 이미 진행 중인 프로젝트에 미칠 영향을 고려하여 거부권을 행사하여 시행되지 않았다. 이는 주정부에서도 데이터센터의 무분별한 도입으로 인한 전력망 안정성에 대한 우려를 나타내는 동시에 각 주별로 데이터센터 유치를 위한 경쟁이 치열함을 보여주는 중요한 예라고 할 수 있다.(Georgia Recorder, 2024.5.8.)

1.5. 중국

중국은 2023년 4월 정부의 데이터센터 장비 및 서비스 조달 요건을 정의하는 “녹색 데이터센터” 표준을 발표했다⁹⁵. 이는 정부 자금을 이용해 데이터센터에 필

⁹⁴ The White House(2025.7.23.)

⁹⁵ 财政部 生态环境部 工业和信息化部(2023.4.10.)

요한 장비와 서비스를 구매할 때 준수해야 하는 표준을 정의한 것이다. 기본 요구 사항은 신에너지, 액체 냉각, 분산형 전원 공급 장치, 모듈형 컴퓨터 실 등의 고효율 옵션들을 우선 시 해야 함을 규정하고 있다. 또한, 정부 자금이 투입된 데이터센터의 PUE는 2025년부터는 1.3 미만이어야 하며, IT 장비의 연간 전력 소비당 물 소비량은 2.5L/kWh 미만이어야 한다. 그리고 데이터센터 총 에너지에서 재생 에너지가 차지하는 비중은 지속 증가해 2027년에는 50%, 2032년에는 100%를 달성해야 함을 요구하고 있다.

나아가 중국은 지속 가능한 디지털 인프라 발전을 위해 2024년 7월 데이터센터의 녹색 발전을 위한 행동계획을⁹⁶ 발표하고, 데이터센터의 합리적인 지역 배치, 에너지효율 향상, 재생에너지 이용 확대 목표를 공표했다. 계획에 따르면 "동수서산(东数西算, Eastern Data and Western Computing)"⁹⁷ 프로젝트를 강화하고, 신규 대형 및 초대형 데이터센터는 국가 허브(거점) 노드에 우선적으로 배치되어야 함을 정하고 있다. 또한, 실시간 요구사항이 높지 않는 컴퓨팅 시설이 서부 허브 노드로 이전되도록 지원하고, 대규모 풍력 및 태양광 기지와 국가 허브 노드 건설을 연계하는 것을 고려하고 있다.

데이터센터의 에너지효율 향상 측면에서는 PUE 기준, 기존 시설 개조, 에너지 절약 기술 및 장비 보급에 대해 명시하고 있다. 이에 따르면, 전국 평균 PUE는 2025년까지 1.5 미만, 신규 및 증설되는 대형 데이터센터의 PUE는 1.25 이내, 국가 허브 노드 데이터센터 프로젝트⁹⁸의 PUE는 1.2보다 높아서는 안 된다. 또한, 노후화된 소형 및 분산된 데이터센터는 통합 및 개조하여 불필요한 장비를 줄이고 최적화를 추진한다. 그리고 고효율 냉방 및 방열 기술을 추진하고, 신기술을 적용하여 전원 장비의 부하율과 컴퓨팅 장비의 이용률을 높이고 고효율 장비의 보급을 추진한다.

⁹⁶ 国家发展改革委 工业和信息化部 国家能源局 国家数据局(2024.7.3.)

⁹⁷ 경제·산업이 집중된 동부 지역의 데이터 처리 수요를 서늘한 기후, 재생에너지 및 부동산 등의 풍부한 자원, 낮은 전기요금의 서부 지역 컴퓨팅 인프라로 처리하고자 하는 프로젝트로, 8개의 주요 데이터센터 거점(허브) 및 10개의 클러스터의 구축을 추진하고 있다.

⁹⁸ 2022년에 출범한 이 프로젝트는 동수서산 계획의 핵심 인프라 사업으로, 2025년까지 전국에 8개의 국가 컴퓨팅 허브 노드와 10개의 대형 데이터센터 클러스터를 구축하는 것을 골자로 한다.

재생에너지 이용 확대에 관해서는 전국 데이터센터의 평균 재생에너지 이용률을 매년 10%씩 높이는 것을 목표로 하고 있다. 국가 허브 노드의 신규 데이터센터는 녹색 전력 비중이 2025년 말까지 80%를 초과해야 한다고 규정하고 있다. 데이터센터의 녹색 전력 및 녹색 증서 거래 참여를 장려하며, 데이터센터의 재생에너지 구매 정책을 추진한다. 그리고 신규 및 증설 데이터센터의 재생에너지 이용 목표 및 계획을 데이터센터 심사의 중요 내용으로 포함시킨다. 또한, 분산형 재생에너지+에너지 저장장치와 같은 프로젝트 건설을 지원한다.

이 밖에 국가발전개혁위원회, 국가데이터국, 공업정보화국이 공동으로 “국가 데이터 인프라 구축을 위한 가이드라인”⁹⁹을 발표(2024년 12월)하고, 2029년까지 5개년 3단계 건설 목표를 제시했다. 또한 2026년까지 데이터 인프라 기술 노선 시범실험을 진행, 2028년까지 데이터 인프라를 구축, 2029년까지 국가 데이터 인프라의 주체 구조를 완성할 계획을 세우고 있다. 이와 관련 지침에는 데이터의 유통 및 활용, 컴퓨팅 파워 기반, 네트워크 지원, 안보 및 방어·보호 등에 관한 방향을 제시하고 있다.

[그림 4-1] 중국 8대 국가 데이터센터 허브(거점)



자료: 한국무역협회 베이징지부(2022), p.6 그림 재인용

⁹⁹ 国家发展改革委 国家数据局 工业和信息化部(2024.12.31.)

1.6. 일본

일본은 에너지 합리화법(省エネルギー法)에 따라 연간 에너지 사용량이 1,500kl(원유환산)¹⁰⁰을 초과하는 특정 사업자는 에너지 사용량, 설비별·사무소별 에너지 소비 내역, 온실가스 배출량 자료 등을 담은 정기 보고서를 매년 제출하도록 규정하고 있다. 정보 미제출 또는 허위 보고 시 제재 사항이 존재한다. 또한, 해마다 에너지원단위 1% 개선을 목표로 사업자는 매년 에너지 사용의 합리화·효율화 및 절감 목표와 그 실행 방안을 3~5년 단위로 수립하여 중장기 사업 계획서를 제출하여야 한다. 계획서의 목표 미달성 시 계획 수정 명령 및 벌금 등의 행정 제재가 이뤄진다. 이러한 법에 따라 연간 에너지 사용량 조건을 충족하는 DC 사업자도 에너지 사용량 정기 보고, 에너지원단위 개선, 중장기 계획서 제출 등의 의무가 있다.

일본은 에너지절약법에 따라 특정 사업자에 대한 벤치마크(BM) 제도도 시행하고 있다. 벤치마크 제도는 사업자의 에너지 절감 현황을 업종 공통의 벤치마크 지표를 활용해 평가한 후, 각 사업자가 목표 달성을 위해 에너지 절감 노력을 추진하는 제도이다. 2023년 4월 개정된 에너지절약법에 따라 일정 규모를¹⁰¹ 초과하는 DC 운영 사업자도 벤치마크 제도의 대상이 되었다. 이에 따라 매년 PUE를 산업통상자원부 장관에게 보고하고, 2030년 PUE 1.4 이하 목표 달성을 위해 노력해야 한다. 목표를 달성한 기업은 우수 기업으로 정부 웹사이트에 게시되고 에너지 효율 보조금 지원을 받을 수 있다.

2025년 들어 일본 정부는 강화된 에너지효율 조치를 추진하고 있다. 자원에너지청의 ‘공장 등 판단 기준 워킹그룹(WG)’에서 DC 사업에 대해 추가적인 제도 설계를 논의하고 있으며, 2025년 5월 14일 WG에서 상세한 제도안이¹⁰² 제시되었다. 새로운 제도 안에서는 DC가 충족해야 할 에너지효율 기준을 설정하고, DC관련 추가 중장기 계획 및 정기 실적 제출 의무 도입 등이 논의되고 있다.

신 제도에서의 에너지효율 기준 설정에 관해서는 2029년 이후 신설되는 일정 규모 이상의 DC는 가동 후 2년부터 PUE 1.3 이하가 되도록 운영해야 한다. 만약

¹⁰⁰ 1,500kl(원유환산)은 약 15GWh에 해당한다.

¹⁰¹ 서버 면적 300㎡ 이상 또는 연간 에너지사용량이 1,500kl(원유환산)을 초과하는 DC

¹⁰² 経済産業省(경제산업성)(2025.7.1.)

기준에 미달할 경우 개선(합리화) 계획을 제출해야 하고, 미제출 시에는 개선 명령이 내려진다. 개선 명령을 무시할 경우 100만 엔 이하의 벌금이 부과된다. 단, 코로케이션 등과 같은 형태의 임차형 DC는 이용률(가동률)이 고객에 의해 좌우되고, 이에 따른 낮은 이용률이 PUE 기준 미달로 이어질 수 있으므로 이에 대한 별도 규정을 두고 있다. 즉, PUE가 1.3을 초과해도 설계 시 PUE가 1.28 이하이며, 미달 사유가 설비 가동률이 낮은 데 기인하는 것으로 확인될 경우 합리화 계획 작성 및 제출을 면제한다. 한편, 기존 BM 제도에서는 임차형 DC는 적용 대상이 아니었으나, 이제는 임차형 DC까지 모두 포함되게 된다. 다만 임차형 DC는 DC 전체가 아닌 전용 부분에 대해서만 PUE를 계산한다.

신제도에서는 2026년 이후 기존 중장기 계획서 제출 시 정부가 정하는 3가지 지표(① 신설 DC의 PUE 목표 값, ② 2030년 사업자 평균 PUE 목표 값, ③ 에너지원단위 중장기 개선율 목표 값)를 포함하는 추가 계획서를 제출해야 한다. 신설 DC의 PUE 및 에너지 소비 원단위 중장기 개선율 목표는 자율적으로 웹사이트 등을 통해 공개해야 한다. 또한, 매년 정기 보고서 제출 시 DC별 에너지 사용 현황 등을 담은 ‘DC업 정기 보고서’를 제출해야 한다. 2025년 이후 신설 DC는 보고서의 일부 항목을 웹사이트 등을 통해 대중에 공개해야 한다. 보고서에 포함해야 하는 정보와 공개 여부는 다음의 표와 같다.

한편, 일본은 우리나라와 유사하게 DC의 지방 분산화를 추진하고 있다. 일본의 DC는 대부분 도쿄권에 집중되어 있어 일본 정부는 지방 분산화를 위해 지방 거점 DC 구축에 대한 정부 보조금 및 세제 혜택을 제공하고 있다. 특히, 농촌 지역의 DC 투자를 장려하기 위해 보조금과 더불어 토지 개발 비용의 50%를 지원하고, 전력 및 통신 인프라에 대한 재정 지원도 제공하고 있다.¹⁰³

¹⁰³ DeepAware AI. Japan data center regulation.

〈표 4-5〉 일본 ‘DC업 정기 보고서’ 보고 항목

항목	공개 여부	보고·공개 수준	항목	공개 여부	보고·공개 수준
1. 명칭			7. DC 최대 수전 전력량(kW)	×	
1.1 데이터센터 명칭	○	DC별	8. 전기 사용량(kWh)		
1.2 병설하는 데이터센터 명칭	×	DC별	8.1 IT기기의 전기 사용량	×	DC별/사업 형태별 합계/사업자별 합계
2. DC 소유자·운영자			8.2 부대설비의 전기 사용량	×	DC별/사업 형태별 합계/사업자별 합계
2.1 DC 소유자	×		8.3 총 전기 사용량	×	DC별/사업 형태별 합계/사업자별 합계
2.2 DC 운영자	○		9. PUE	○	DC별/사업 형태별 합계/사업자별 합계
3. DC 소재지	×		10. 설계 시 PUE (2024년 이전에 신설된 DC는 임의 보고)	×	
4. DC 가동시작 연도	○		11. 에너지원단위 지표 (사업자 자체설정)	○	
5. DC의 용도·사업형태			12. 에너지원단위 5개년도 추이	×	
5.1 사업형태	○		13. 에너지원단위 5개년 연평균 변화	○	
5.2 주요 용도	○		14. 가동률	×	
6. DC 계약 전력량(kW)	×		15. 기타 기재사항	×	

자료: 経済産業省(경제산업성). (2025.5.14.). p23.

1.7. 싱가포르

싱가포르는 1.4GW 이상의 데이터센터를 보유해 1인당 데이터센터 용량이 아시아의 주요 도시(베이징, 홍콩, 서울, 시드니, 도쿄) 중 가장 높다. 급격한 DC의 성장에 싱가포르 정부는 신규 DC 건설을 2019~2022년에 일시적으로 중단(모라토리엄)시켰다. 모라토리엄 해제 후 경제개발청(EDB)과 정보통신미디어개발청(IMDA)은 데이터센터 신청(CFA, Call for Application) 제도를 시범(pilot) 실시하여, 정부의 지속가능성 기준에 따른 신규 DC를 모집했다¹⁰⁴. 정부의 세 가지 평가 기준은 동급 최고 수준의 자원 효율성 및 탈탄소화 달성, 국제 연결성과 지역 허브로의

¹⁰⁴ INFOCOMM MEDIA DEVELOPMENT AUTHORITY(2022.7.20.)


기준 강화, 광범위한 국가 경제 목표 달성에 대한 기여도이다. 시범 CFA 제도는 2023년 7월에 마감되어 최종적으로 4개 업체가 총 80MW 용량을 배정받았다.

싱가포르는 데이터센터 인증 제도도 운영하고 있다. 건축건설청(BCA)과 정보통신미디어개발청(IMDA)은 2012년에 그린 마크 데이터센터 인증(GMDC, Green Mark for Data Centres)을 발표했으며, 2019년 한 차례 업데이트한 후 현재는 2024년 베타 버전까지 공개하였다. GMDC는 데이터센터를 6개 섹션의¹⁰⁵ 여러 가지 항목으로 평가하고 이를 기준으로 세 가지 등급(플래티넘, 골드플러스, 골드)으로 구분한다. GMDC는 신규 건설되는 DC에게는 의무 사항이고, 기존 DC의 경우는 선택 사항이다. 인증을 받기 위한 필수 요건들 중 PUE와 냉각 시스템의 효율성이 특히 중요하다.

GMDC의 PUE와 냉각 효율 기준이 다른 나라와 차별화되는 점은 IT 부하별로 이들을 평가한다는 점이다. PUE의 경우 신규 DC는 25% IT 부하 시, 골드플러스(Goldplus) 등급은 1.46, 플래티넘 등급은 1.39를 달성해야 한다. 기존 DC는 지난 12개월간의 PUE 성능 데이터를 제출해야 한다. 냉각 시스템 효율성은 총 냉각 효율(TSE, Total Cooling System Efficiency) 또는 공랭 효율(Air-side efficiency)로 측정되는데, 공랭 효율은 지역 냉방(District Cooling) 시스템을 통해 냉방을 구매한 DC에만 적용된다. 신규 DC의 경우 특정 IT 부하에서 정해진 최소 TSE 값을 충족해야 한다. 이 밖에 냉각 시스템 운전 효율에 대한 영구적 측정 및 검증을 위한 장치를 설치해야 하며, 실시간 PUE를 제공하고 PUE 계산과 관련된 모든 에너지는 측정 및 추이 분석이 필수 요건으로 규정되어 있다.

¹⁰⁵ 평가 항목은 6가지(에너지효율성(Energy Efficiency), 탄소(Carbon), 회복탄력성(Resilience), 건강 및 웰빙(Health and Wellbeing), 지능(Intelligence), 유지보수(Maintenance)) 섹션으로 구성되는데, 이 중 가장 점수 비중이 큰 섹션은 에너지효율성이다. 자료: BCA & IMDA(2024)

[그림 4-2] 싱가포르 그린 마크 인증(GMDC)의 최소 PUE 기준



자료: BCA & IMDA(2024), p.3 Chart 1

싱가포르는 지속가능한 데이터센터의 성장을 위해 앞에서의 DC 신청 제도와 인증 제도를 포괄하는 그린 데이터센터 로드맵(Green Data Center Roadmap)을¹⁰⁶ 2024년 5월 발표했다. 로드맵의 핵심 목표는 에너지효율과 그린 에너지 사용을 가속화하는 것이다. 에너지효율 측면에서는 향후 10년 내 모든 DC가 100% IT 부하에서 PUE 1.3 이하를 달성하도록 목표를 설정하고, 2025년까지 컴퓨팅/IT 장비 에너지효율 및 액체 냉각 표준을 도입하여 이러한 기술의 채택을 촉진할 계획이다. 정부는 DC 운영사들의 에너지효율 개선 노력과 비효율적인 소규모 DC를 규합해 보다 효율적인 대형 DC로의 전환 노력을 지원한다. DC 운영사들은 배출 감축량에 따라 보조금을 지원하는 배출량 감축 자원 효율성 보조금(Resource Efficiency Grant for Emissions)과 측정 및 검증 가능한 탄소 감축 효과가 있는 프로젝트에 대해 세금 면제를 해주는 배출량 감축 추가 공제(Investment Allowance for Emissions Reduction) 등의 지원제도를 활용할 수 있다. 또한, DC 부문을 위한 신규 에너지효율 보조금을 활용하여 기업들이 에너지 효율적인 컴퓨팅/IT 장비로 교체할 수 있도록 지원한다.

¹⁰⁶ INFOCOMM MEDIA DEVELOPMENT AUTHORITY, Green Data Centre (DC) Roadmap.

DC의 전력 공급을 위한 그린 에너지로는 바이오 에너지, 탄소포집 기능이 있는 연료전지, 저탄소 수소 및 암모니아, 수직 건물 통합형/건물 부착형 태양광 등이 인정된다. 이러한 그린 에너지 활용 촉진을 위해서 DC 운영업체와 그린 에너지 공급업체 간의 파트너십을 장려한다.

로드맵에서는 물 효율성도 중요하게 다루고 있다. 싱가포르 정부는 2021년 기준 싱가포르 DC의 WUE 중간 값인 $2.2\text{m}^3/\text{MWh}$ 를 향후 10년 내에 $2.0\text{m}^3/\text{MWh}$ 이하로 줄이는 것을 목표로 제시한다. 이를 위해 공공시설관리청(PUB, Public Utilities Board)은 물 효율 관리의 모범 사례에 대한 지침을 제시하고, 물 효율 기금(Water Efficiency Fund)¹⁰⁷에 따른 물 효율성 이니셔티브의 실행을 촉진한다. 연간 물 소비량이 6만 m^3 이상인 DC는 PUB의 의무 물 효율 관리 사례를 따라야 하는데, 여기에는 개별 수도 계량기 설치와 물 효율성 계획 제출 등이 포함된다.

이상에서 글로벌 주요국의 DC 에너지 소비 관련 정책을 살펴보았으며, 지금부터는 국내 정책 현황을 살펴본다. 국내에서는 아직 DC에 특화된 정책은 없는 상태이다.

2. 국내 데이터센터 관련 정책 현황

2.1. DC 에너지 소비 관련 정책

국내에서 DC 사업 시 건축 측면, 에너지 측면, 사이버 보안 측면, 설비 점검 측면 등에서 여러 법이 적용된다. 이러한 법들은 정보통신 시설을 포함한 모든 사업에 적용되는 법으로, DC를 특정하여 규정하고 있지는 않다. 이 중 에너지 측면에서 DC와 관련이 있는 법은 크게 4가지(에너지이용합리화법, 전기사업법, 분산에너지 활성화 특별법, 녹색건축물 조성 지원법) 정도를 꼽을 수 있다.

¹⁰⁷ PUB가 물 수요의 효율적이고 혁신적인 관리를 위해 2007년에 출범

2.1.1. 에너지이용합리화법

에너지이용합리화법에 따르면 일정 규모 이상의 에너지를 사용하는 사업을 실시하거나 시설을 설치하려는 자는 에너지사용계획을 수립해 산업통상자원부 장관에게 제출하여야 한다. 에너지사용계획에는 사업의 실시와 시설의 설치로 에너지수급과 온실가스 배출에 미칠 영향 분석, 소요 에너지 공급계획, 에너지의 합리적 사용과 그 평가에 대한 계획이 포함되어야 한다. 에너지사용계획 제출 대상은 시행령을 통해 사업별(면적 기준), 시설별(에너지 사용량 기준)로 규정되어 있다. 데이터센터는 공공사업의 경우 연간 2,500toe 이상의 연료 및 열, 또는 연간 10GWh 이상의 전력을 사용하는 시설이 대상이다. 민간사업의 경우 공공의 두 배(각각 5천 toe, 20GWh) 기준이 적용된다. 에너지사용계획은 한국에너지공단이 ‘에너지사용계획 협의’ 제도를¹⁰⁸ 통해 에너지 수급 영향, 에너지효율, 신재생에너지 적용, 온실가스 감축 등을 종합적으로 평가 및 검토한다. 검토 결과 필요시 공공사업주관자에게는 계획의 수정·보완을 요청할 수 있고, 민간사업 주관자에게는 계획의 조정·보완을 권고할 수 있다. 결과 조치는 권고 사항으로 협의 미이행이나 자료 제출 거부 시 과태료가 부과된다.

2.1.2. 전기사업법

정부는 전기사업법 시행령 개정(2023.3.21)을 통해 전기를 대량으로 사용하려는 자로 인하여 전력계통의 신뢰도 및 전기품질을 유지하기 어려운 경우 전기 공급을 거부할 수 있도록 했다. 이에 따라 5MW 이상 DC는 전기 사용량에 따라 사용 예정일 1~4년 전에 한전에게 전력 수전 예정 통지를 해야 하고, 해당 부지가 위치한 지역에 전력 여유분이 없는 경우 한전이 전기 공급을 거부할 수 있다.

¹⁰⁸ 한국에너지공단. 에너지 사용계획 협의

2.1.3. 분산에너지법

(1) 분산에너지 설치

2024년 6월 14일에 시행된 분산에너지 활성화 특별법(분산에너지법)도 DC와 관련이 크다. 분산에너지법의 제13~15조는 분산에너지 설치 의무를 명시하고 있는데, 연간 20만 MWh(200GWh) 이상의 에너지 사용이 예상되는 건축물을 신축 또는 대수선하는 건축물의 소유자, 사업면적이 100만 m² 이상인 신규 택지·도시 개발 사업자 등은 분산에너지를 의무적으로 설치해야 한다. 이와 관련하여 산업통상자원부는 2024년 6월 3일 “분산에너지 설비 설치 계획서 제출 및 설치확인 등에 관한 규정”을 행정예고하고¹⁰⁹ 12월 3일에 고시했다.¹¹⁰ 이에 따르면 분산에너지 의무 설치자는 지역별과 연도별 의무 비율을 반영하여 분산에너지를 구축해야 한다. 지역별 의무 비율은 수도권(서울, 경기, 인천)은 100%, 비수도권은 0%가 적용된다. 연도별 의무 비율은 2026년 2%, 이후 단계적으로 증가해 2040년 이후에는 20%까지 상승한다. 이에 따라 의무 설치자의 분산에너지 의무 설치량(MW)은 아래와 같이 계산된다.

$$\frac{[\text{연간 에너지 사용량(MWh)} \times \text{지역별 의무 비율} \times \text{연도별 의무 비율}] - \text{직접 전력 거래량}}{\text{연간이용률(\%)} \times 8760(h)}$$

식에서 연간 에너지 사용량은 사업의 실시 또는 시설의 설치로 인해 예상되는 에너지 사용량이며, [연간 에너지 사용량 × 지역별 의무 비율 × 연도별 의무 비율]은 의무 분산에너지 사용량(MWh)이다. 직접 전력 거래량은 전력시장을 거치지 않고 직접 공급받는 전력량으로, 의무설치자가 전기를 공급받는 배전망과 연계된 발전설비로 한정된다. 연간 이용률은 분산에너지 발전 설비의 이용률이다. 식에 따라 비수도권 지역의 건축물은 지역 비율이 0%이므로 분산에너지 설치 의무가 없으며, 수도권 지역은 직접 전력 거래 계약을 통해 전력을 공급받는 경우 의무 분산에너지 설비 설치 규모가 작아진다.

¹⁰⁹ 산업통상자원부(2024.6.3.)

¹¹⁰ 산업통상자원부(2024.12.3.)

(2) 전력계통 영향 평가

〈표 4-6〉 전력계통 영향 평가 항목 및 배점

평가 항목			배점
기술적 평가항목 (60점)	전력공급 여유	계통 여유도	15
		과부하 증가율	10
	전력공급 여유 확보 난이도		20
	적정 전압 유지 가능 여부		가능/불가
	전력공급 영향 최소화 방안	자가 발전 운전 계획	10
		전력 사용 효율화 계획	5
	(가점) 부지 제공을 통한 공급 여유 확보 기여 여부		(+)5
	(감점) 적정 전압 신청 여부		(-)15
비기술적 평가항목 (20점)	사업 안정성		5
	지방재정기여도		5
	산업 활성화 효과	부가가치 유발 효과	5
		직접 고용 효과	5
	(가점) 해당 지역 지원사업		5
	(가점2) 특별법 지원사업 대상 여부		5
정책적 평가항목 (20점)	전력자립도		10
	전력정책 부합도		10
	(가·감점) 전력수요 분산화 효과		(-)15~(+15)
총점 ¹⁾			100

주1): 적정전압 유지가 가능하고 총점이 70점 이상인 평가서는 전력정책심의회 심의대상으로 상정 가능.

자료: 산업통상자원부(2024.11.11.), p.16 [별표 1] 평가항목별 배점

한편, 분산에너지법 제23~32조는 전력계통 영향 평가에 대해 규정하고 있다. 이에 따르면 계약전력 10MW 이상의 전력사용시설을 운용하려는 사업자는 희망 사업에 대한 승인·인가·허가 또는 지정을 신청하기 전에 산업통상자원부 장관에게 전력계통영향 평가서를 제출해야 한다. 분산에너지 의무 설치 규정과는 달리 대상 지역은 전국이다. 평가 총점이 70점 이상 되어야 전력 수전이 가능한데, 평가 항

목 및 배점은 <표 4-6>과 같다. 평가 항목에서 DC 운영자에게 특히 중요한 항목은 전력공급 영향 최소화 방안이다. 이 중 자가발전 운전 계획은 자가발전 용량이 계약전력의 40% 이상이면 만점(10점)이고 그 이하이면 수준에 따라 점수가 차감된다. 자가 발전에서 비상 발전기는 제외된다. 전력 사용 효율화 계획은 확장형 에너지 관리시스템(xEMS)과 에너지저장장치(ESS) 모두 설치 계획이 있을 경우 만점(5점)이다.

이상의 분산에너지법이 국내 DC 입지에 시사하는 바는 연간 총 에너지 사용량이 200GWh 이상의 대규모 DC는 수도권에 건설되기 어려워지며, 계약 전력 10 MW (연간 전기 소비량 약 88GWh¹¹¹) 이상의 DC는 백업 비상 발전기 외 자가 발전을 사실상 설치하여야 한다는 것이다. 반면, 연간 전력 소비량이 약 88GWh 이하의 DC는 상대적으로 건설에 제한이 적다는 것을 의미한다.

2.1.4. 녹색건축물 조성 지원법

국토교통부는 제3차 녹색건물 기본계획(2024.12)을 통해 기존의 ‘건축물 에너지효율등급제’를 ‘제로에너지건축물(ZEB) 인증제’로 통합 운영하기로 했으며, 이를 위해 개정된 녹색건축물 조성 지원법이 2025년 1월 1일부터 시행하고 있다. ZEB 인증은 에너지 자립률 또는 연간 단위면적(㎡)당 소비되는 에너지와 건축물 에너지 관리시스템 설치여부를 기준으로 최하 5등급에서 최상 + 등급으로 나뉜다. 법에 따라 연면적 1천 ㎡ 이상인 17개(방송통신 포함) 용도의 공공건축물은 신축 시 최소 ZEB 인증 4등급을 취득해야 한다. 민간건축물은 ZEB 인증을 취득할 의무는 없으나, 연면적 1천 ㎡ 이상의 건물 신축 시 건축 인허가 관련 설계 기준들에 최소 ZEB 인증 5등급 항목이 반영된다. 한편, ZEB 평가 항목 중 건축물에너지 관리시스템(BEMS)에는 데이터 수집 및 표시(대상건물에서 생산·저장·사용하는 에너지원별 데이터 수집 및 표시), 데이터 조회(일간, 주간, 월간, 연간 및 특정 기간별 데이터 조회), 에너지 소비 현황 분석(에너지원단위와 에너지 용도별 에너지 소비 현황 및 증감 분석) 등이 필수적으로 표시되어야 한다(제로에너지건축물).

¹¹¹ 10 MW × 24시간 × 365일 = 87.6 GWh

〈표 4-7〉 제로에너지건축물(ZEB) 인증 등급

ZEB 등급	구분	제 1 호	제 2 호		제 3 호
	등급산정기준	에너지 자립률(%)	주거용	비주거용	건축물에너지 관리시스템
			연간 단위면적당 1차 에너지소요량 (kWh/m ² *년)	연간 단위면적당 1차 에너지소요량 (kWh/m ² *년)	
+등급		120이상	~10 미만	~70 미만	설치여부 확인
1등급		100이상	10 미만	~ 30 미만	
2등급		80이상	30 미만	10 미만	
3등급		60이상	50 미만	50 미만	
4등급		40이상	70 미만	90 미만	
5등급		20이상	90 미만	130 미만	

출처: 제로에너지건축물

이상의 데이터센터 관련 국내 법을 정리하면 〈표 4-8〉과 같다. 요컨대, 국내 관련 법들은 대부분 신축 시 일회성으로 발생하고, 정기적 모니터링 및 보고 시스템은 존재하지 않는다. 규제 대상도 민간보다는 공공 DC, 수도권 위주이며, 대상 요건도 글로벌 기준에 비추어 상당히 포괄적이다. 이러한 규제들은 DC뿐만 아니라 에너지 다소비 건물에 공통적으로 적용되는 법들로 PUE 등과 같은 규제는 아직 없다.

〈표 4-8〉 국내 데이터센터 에너지 관련 법

법	의무 사항	대 상 DC	비고
에너지이용합리화법	에너지사용 계획 제출	공공(연간 10 GWh 이상) 민간(연간 20 GWh 이상)	결과 조치는 권고 사항
전기사업법	한전에 전력수전예정 통지	5 MW 이상	한전이 전기공급을 거부할 수 있는 근거
분산에너지법	분산에너지 설치	연간 200 GWh 이상의 수도권 DC	
	전력계통 영향 평가 70점 이상	계약전력 10 MW 이상	자가발전기 설치 없이는 70점 달성이 쉽지 않음
녹색건축물조성지원법	공공은 ZEB 최소 4등급 인증 민간은 설계기준에 최소 ZEB 5 등급 기준 반영	1천㎡ 이상의 신축 DC	

출처: 저자 정리

2.2. 국내 데이터센터 정책 방향 및 인증제도

우리나라의 데이터센터에 대한 정책 방향은 수도권에 집중되어 있는 DC의 지역분산을 유도하는 것이다(산업통상자원부, 2023.3.9.). 이를 위해 앞서 살펴본 법들을 통해 수도권 지역에는 신규 DC의 입지를 제한하는 동시에 DC의 지역분산 유도 방안을 제시하고 있다. 지역분산 유도 방안으로는 투자 유치 제도를 통한 규제 특례 및 지방에 신·증설하는 기업에 보조금 지원, 입지 유망 지역내 발전소와 DC 간 직접 PPA 활성화, 비수도권 입지 고객 대상 전력시설부담금 할인 등의 인센티브 제공 등이 제시되고 있다. 관련해서 한국전력은 기본공급약관 시행세칙을 개정(2024.10.24)해 데이터센터 공급 특례를 정했다. 이에 따르면 공급여유지역(행정구역상 비수도권)에서 22.9kV 이상의 전압으로 전력을 단독으로 공급받는 자사용 및 임대사업용 DC는 시설부담금¹¹²의 50%를 할인받을 수 있다. 또한 154kV 전력을 공급받는 대형 DC의 경우 전력계통 신뢰도 검토 결과에 문제가 없을 경우 예비전력¹¹³ 요금을 면제받는다. 이러한 특례는 2023년 6월 1일부터 2026년 5월 31일까지 전기 사용 신·증설을 신청하는 비수도권(서울, 인천, 경기 외) DC가 대상이며, 공공기관이 운영하는 DC는 제외된다.

지금까지 국내 DC에 적용되는 에너지 관련 법과 정책을 살펴보았는데, 우리나라는 해외와 같은 데이터센터의 PUE 등에 대한 법적 구속력이 있는 공식적인 효율 규제는 없다. 대신, 민간 자율 인증 제도로 한국데이터센터연합회(KDCC)가 운영하는 그린데이터센터 인증제가 2012년부터 시행되고 있다.¹¹⁴ 그린데이터센터 인증제는 지능정보화기본법 제40조에 의거하여 500㎡ 이상의 DC를 대상으로, PUE(80점)과 그린활동 지표(20점)를 이용해 평가한다. 인증 등급은 Bronze(60~70점), Silver(70~80점), Gold(80~90점), Platinum(90점 이상)의 총 4단

¹¹² 고객이 새로 전기를 사용하거나 계약전력을 증가시키는 경우, 공급방식·공급전압 등을 변경하거나 기존의 한전의 공급 설비를 보강·이용·철거하는 경우에 발생하는 배전선로 공사비 중 고객이 부담하는 금액임(자료: 기본공급약관(한국전력 공사, 2024)). 업계에 따르면 국내 DC 건설 시 평균적으로 3 km의 지중 배전선로 설치에 약 45억원의 공사 비용이 발생하는데, 이 공사 비용은 전액 시설부담금으로 청구되고 있음(연합뉴스, 2023.6.2.).

¹¹³ 상용공급설비의 보수, 사고 등으로 전력이 공급되지 않을 때 상용전력을 대체하여 공급하기 위한 비상용 전력(자료: 기본공급약관). 안정적 전력 공급을 위해 주 전력선 외 추가로 예비 전력선을 연결하는데, 한전은 전기 요금 중 기본요금의 2~6%까지를 예비전력 요금으로 따로 받음. 업계에서는 예비전력 요금 면제만으로 월 1천만원 이상의 전기요금 절감 효과가 있을 것으로 예상함(연합뉴스, 2023.6.2.).

¹¹⁴ 그린데이터센터인증

제로 구성된다. 인증 혜택으로는 K-텍소노미 녹색금융 활용 이자율 혜택, 온실가스 배출권 추가 할당 조정 계수 면제 등이 주어진다.

3. 국내 데이터센터 관련 정책 제안

이상에서 살펴본 바와 같이, 해외 주요국들은 DC의 에너지 규제를 적극적으로 실시하고 있으나 우리나라는 아직 DC에 특정된 정책은 매우 부족하다. 제3장에서 분석한 바와 같이, 장기적으로 국내 DC의 전력 소비는 국가 총 전력의 10% 이상을 점유할 수 있다. 특히, PUE 개선을 통한 상당한 전력 소비 절감 잠재력도 확인한 바 있다. 누적 효율 개선 효과 극대화를 위해서는 우리나라도 해외 주요국 수준의 구체적인 DC 에너지 소비 관련 정책을 서둘러 마련해야 한다.

국내 데이터센터의 에너지 소비 정책 관련 가장 시급한 과제는 DC에 대한 정확한 현황 파악 및 에너지 소비 정보 수집이다. 이를 위해 먼저 데이터센터의 분류 기준을 명확히 재정립해야 하며, 데이터센터의 정보 보고 체계를 마련해야 한다. 수집된 정보를 바탕으로 정부는 지속가능한 그린 데이터센터를 위한 지원과 관련 규제를 준비해야 한다.

3.1. 분류 기준 및 체계 마련

기능정보화 기본법과 정보통신망법에서 규정하고 있는 DC는 전산실 바닥 면적이 500㎡ 이상이다. 하지만 앞장의 주요 현황 부분에서 살펴보았듯이, 2022년 이전의 DC 수는 이러한 기준이 정확히 적용되지 않아 데이터의 일관성에 문제가 있었다. 한국데이터센터연합회(KDCC)에서조차 전산실 바닥 면적 기준을 비교적 정확하게 적용한 것은 최근(2022년 자료부터)일만큼, 국내 DC 분류 기준은 상당히 느슨하게 적용되어 왔다.

먼저 기존의 전산실 면적 기준을 해외 사례처럼 IT 용량 기준 또는 연간 전력 소비량 기준으로 변경하는 방식을 고려할 필요가 있다. 전산실 바닥 면적 500㎡는 150평 규모의 아파트 크기로 작지 않은 규모이다. 게다가 AI 반도체의 집약도가 지속 상승하면서 앞으로는 면적이 작은 DC도 정보 처리와 에너지 소비 측면에서 기존의 대형 DC를 능가할 수 있다. 또한, AI 시대가 정착되면 옛지 DC와 같은 소

규모 DC가 확대될 것으로 보이는데, 이러한 전망에 비추어도 현재의 면적 기준 정의는 한계가 있다. DC의 용량 및 전력 소비량 기준은 EU의 보고 및 규제 대상인 연간 약 4.4GWh 등과 같은 해외 사례를 참고하여 정부와 민간이 논의를 통해 정할 필요가 있다.


또한, 데이터센터의 용도 구분도 명확히 재정리할 필요가 있다. 국내 데이터센터는 건축법상 방송통신시설로 분류된다. 하지만 2019년 이전에는 건축법상 데이터센터의 용도에 대한 규정이 없어, 일부 DC는 교육연구시설로 등록되었을 것으로 보인다. 교육연구시설은 한전의 계약종별상 교육용으로 분류된다. 또한, 국내 DC는 공장 내에 설치된 경우도 많아, 이 경우 산업용 전력으로 분류되었을 가능성도 있다. 이러한 불명확한 기준은 국가 에너지통계 문제로도 이어진다. 국가 에너지수급통계에서 한전의 산업용 전기 판매량은 산업 부문의 에너지 소비로 분류되며, 일반용이나 교육용은 상업용 또는 공공용으로 분류되어 건물용(가정용+상업용+공공용)에 포함된다. 데이터센터의 에너지 소비는 건물용으로 분류되어야 하나, 앞서 제3장의 실증 분석에서 이용된 국토교통부의 건물에너지 전수 조사 자료에도 일부 DC의 주소와 매칭되는 자료는 찾을 수 없었다. 이는 국내 DC의 상당수가 건물용이 아닌 다른 부문으로 집계되었을 가능성을 나타낸다. 한편, 미국의 경우 2018년 EIA가 상업용 건물 에너지 사용량 조사에 데이터센터를 별도의 건물 유형으로 추가하는 시범 사업을 진행하였으나, 현재로서는 이러한 방식으로도 DC의 에너지 소비를 집계하는 것은 불가능에 가깝다고 보고하고 있다(IEA 4E EDNA, 2023). 이러한 상황은 데이터센터를 건물 유형으로 분류하여 에너지 소비량을 집계하는 것이 쉽지 않음을 시사한다. 결국 데이터센터의 에너지 소비 정보는 DC 운영자가 직접 집계하여 보고하는 것이 가장 현실적인 방법이라고 판단된다. 단, 한전, 가스공사, 석유공사 등 에너지 공공 기관이 DC에 판매하는 에너지는 별도의 분류를 통해 집계하여야 할 것이다.

본 연구에서는 한전이 데이터센터에 공급한 전기는 별도로 분류하여 집계하는 방식을 고려할 것을 제안한다. 전력 소비 관리, 관련 정책 수립, 합리적인 전기 요금 부과 등을 위해 DC 전기 소비를 별도로 집계할 필요가 있다. 이와 유사한 사례가 전기차 충전용 전력이다. 전기차 시대가 도래하며 정부는 전기차 충전용 전력을 따로 집계할 수 있는 법적 근거를 마련했으며, 이에 따라 한전도 이를 따로 집

제하고 있다. 데이터센터가 확장되는 시기에 데이터센터용 전력 소비를 별도로 집계하는 법률적 근거 마련이 필요하다.

또한, DC 전력 소비의 효율성, 유연성, 수요 대응 기능 장려, 불확실성에 따른 좌초자산 위험 방지¹¹⁵ 등을 위한 데이터센터용 전기 요금제를 별도로 규정하는 것도 고려할 필요가 있다. 한전의 기본공급약관과 전력시장운영규칙에 따르면 방송통신시설인 DC는 계약종별상 일반용 요금이 적용된다. 데이터센터의 전기 요금을 별도로 규정하는 해외 사례는 아직까지 많지 않지만, 각국 정부와 전력 당국은 DC를 위한 별도의 전기 요금 체계 도입을 고민 중이다. DC에 대한 별도의 전기 요금 체계가 필요한 이유는 앞서 언급한 높은 전력 밀도, 연속 운영, 대규모 단일 부하 및 변동성, 수요 예측의 불확실성 등과 같은 특수성 때문이다. 이러한 특성은 계통 안정성에 큰 부담을 줄 수 있으며, 수요 예측 불확실성에 따른 DC 사업자의 조기 철수 가능성 등으로 좌초자산에 대한 위험도 발생할 수 있다. 우리나라는 민생 안정을 위해 오랜 기간 주택용과 일반용 전기 요금 인상을 제한해 왔는데, 이러한 목적에서 민간 DC에 적용되는 일반용 전기 요금이 적절한지에 대한 논의도 필요하다.

[그림 4-3] 계약종별 전기 요금 추이



자료: 한국전력공사, 전력통계월보

¹¹⁵ 미국 오하이오 주는 이러한 불확실성에 대비해 DCT(Data Center Tariff)를 도입함

3.2. 정보 수집 및 보고 체계 마련

무엇보다 정부가 국내 DC의 에너지 소비 현황을 정확히 파악하는 것이 가장 시급한 과제이다. 앞서 언급했듯이, 국내 DC의 에너지 소비량에 대한 정보는 DC의 분류상의 느슨한 면적기준, 불확실한 용도별 분류, 한전의 DC 전기 소비량 별도 미집계 등으로 매우 미흡하다. 에너지 소비 실적에 대한 정보 부족으로 전기본에서도 미래의 DC 전력 수요를 전력 사용 예정통지를 보수적으로 반영하여 전망했다. 하지만, 전력 사용 예정통지는 실수요가 아닌 부동산 개발 목적 등으로 DC 전력 사용을 대표하기에는 불확실성이 매우 큰 변수이다. 정확한 DC의 에너지 소비 현황을 파악하는 것은 DC 관련 에너지 정책 수립에 필수적이다.

한편, 전기의 경우 한전은 공공 저압용을 중심으로 전 고객 스마트 계량기(AMI, Advanced Metering Infrastructure) 설치를 완료하며 원격 검침 시스템을 구축했다(산업통상자원부, 지능형전력망 시행계획). 그런데, DC의 에너지 소비는 IT용, 냉각용, 자가발전용 등으로 소비를 용도별로 세분화하는 것이 중요하며, 자가발전 설비는 AMI 설치 대상도 아니다. 결국, DC의 에너지 소비 정보는 DC 운영자가 직접 계측하여야 할 것이다. 정부가 민간 DC 사업자들과 협의를 통해 정한 데이터센터 관련 정보를 정기적으로 보고하고 확인하는 시스템을 구축할 필요가 있다. 또한, DC 운영자와 정부의 협의를 통해 공개 가능하다고 판단되는 정보는 투명하고 지속가능한 DC 운영을 위해 해외사례를 통해 볼 수 있듯이 대중에 공개하는 것이 바람직하다.

데이터센터의 에너지 관리 및 에너지 소비 정보 수집을 위해서는 건축물에너지 관리시스템(BEMS) 설치 의무 확대도 필요하다. 현재 녹색건축물 조성 지원법에서는 1천 ㎡ 이상 신축 공공 DC에 대해서만 설계 기준에 BEMS 설치를 의무화하고 있다. 적용 기준을 현실적으로 바꾸고, 대상도 신축 공공 DC뿐만 아니라 특정 조건을 충족하는 민간 및 공공 DC까지 확장하는 것을 고려해야 한다. ZEB 인증에 규정된 BEMS의 필수 요건(데이터 수집 및 표시, 조회, 에너지 현황 분석)도 DC에 관해서는 국제 기준에 맞게 세분화하고 확장해야 한다.

데이터센터별로 계측 및 보고해야 할 정보는 주요국의 사례처럼 일반 정보와 에너지 관련 정보로 구성될 것이다. 에너지 소비 관련 정보는 PUE, WUE, 재생에너

지 비율 등과 같은 에너지성과 지표를 계산할 수 있는 수준으로 세분화되어야 한다. 특히, DC의 배터리, 백업 발전기 및 자가발전기의 에너지와 관련해서는 총 발전량, 에너지원별 발전 투입 에너지, 자가소비량 뿐만 아니라, 인근 지역으로의 업종별 전력 판매량도 포함해야 할 것이다. 열병합 자가발전의 경우 열 정보도 포함하는 것이 중요하다. 열병합 자가 발전기를 통해 생산된 전기/열의 일부가 다른 사업체로 판매되었다면, 판매량을 업종별로 구분하여 집계해야 한다. 이는 국가 에너지통계의 일관성 및 정확도 제고에 매우 중요한 요소이다. DC가 운영하는 자가 발전기를 통해 생산된 전기/열을 인근의 여러 업종에 판매했는데 이에 대한 정보를 제공하지 않는다면, 다른 업종의 에너지 소비는 과소평가되고 DC의 에너지 소비는 과대평가되기 때문이다. 사실 이 문제는 DC에만 국한된 문제는 아니다. 현재도 주요 산업단지의 상용자가발전에 투입된 에너지는 업종별 전기 및 열 판매량 정보가 없어, 이를 업종별 에너지로 정확히 나누지 못하고 산업단지의 대표 업종에 판매된 것으로 간주해 국가 에너지 통계를 작성한다. 향후 DC의 증가와 함께 자가발전소도 증가할 것으로 보이는데, 이러한 자가발전 통계 집계의 문제를 해결하지 못하면 국가 전체 통계의 왜곡으로 이어질 가능성이 크다.

3.3. 에너지효율 개선 정책 마련

앞 절에서 정리한 대로 현재 우리나라는 데이터센터에 특화된 에너지 관련 정책이 미흡한 상태이다. 기존 에너지이용합리화법에 따른 에너지사용 계획 제출의 무 기준은 국제 수준에 비추어 너무 낮고, 에너지사용 계획에 포함되어야 하는 내용도 데이터센터의 특성을 제대로 반영하지 못한다. 게다가 계획 반영 결과 조치도 권고 사항에 불과하다. 분산에너지법의 규제를 받는 DC는 연간 전기 소비량이 약 88GWh(계약 전력 10MW)를 초과하는 DC이다. 하지만 제3장의 [그림 3-4]에서 보았듯이, 이러한 조건을 만족하는 기존 국내 DC는 소수이다¹¹⁶. EU의 에너지효율 관리지침상 정보 보고 및 규제 대상인 연간 약 4.4GWh나, 일본의 에너지합리화법의 규제 대상인 연간 15GWh에 비해서 국내 기준은 매우 포괄적이다.

¹¹⁶ 제3장의 분석에 이용된 자료의 특성상 연간 전력 소비량은 과대 추정되었을 가능성이 크며, 분석에 이용된 샘플 DC들도 국내 전체 DC 중 주요 DC들로 구성되었음을 고려하면 연간 88GWh의 기준을 만족하는 DC 비중은 작을 것으로 판단된다.

데이터센터의 에너지효율 개선을 위해서는 데이터센터의 에너지 성과지표를 바탕으로 에너지효율 규제 방안을 마련할 필요가 있다. 에너지 성과지표에는 PUE 뿐만 아니라 재생에너지 이용률, 폐열 활용률 등이 포함되어야 할 것이다. 이러한 지표를 바탕으로 기존 DC 및 신규 DC가 달성해야 할 에너지효율 수준과 지속적인 에너지효율 개선 목표가 제시되어야 하며, 이에 대한 가이드라인 또는 지침이 마련되어 한다. 특히, 이러한 성과지표는 DC의 규모 및 유형 등을 고려해 차등 적용되어야 할 것이다. 예를 들어, PUE 관련해서는 일본이나 싱가포르와 같이 DC의 유형이나 IT 부하율을 반영하는 옵션을 고려할 필요가 있다.

데이터센터의 폐열에 관해서도 독일과 프랑스의 사례를 참조해 버려지는 폐열을 최소화하는데 노력해야 한다. 이와 관련해서 오세신(2019)은 미활용 열에너지 인증서 발급, 집단에너지 사업자가 폐열 구매 거부 시 제한된 범위 내에서 인근 외부 사용자에게 난방용 폐열 공급 허용, 열요금 체계에 폐열 활용에 따른 인센티브 반영, 신도시 계획 단계에 DC의 폐열과 지역난방의 연계 사업 논의 필요성 등을 제안한 바 있다. 최근 제6차 집단에너지 공급 기본계획(산업통상자원부 신산업부 산에너지과, 2025.2.)에서는 미활용열 활용 증진과 청정 열원 열에너지 인증제도(RHC, Renewable Heating Certificate) 신규 도입 계획을 명시했다. 이러한 정부의 노력에 더해 집단에너지 사업자와 협력해 폐열을 활용하는 DC에는 인센티브를 주고, 일정 수준 이상의 폐열을 배출하는 DC에 관해서는 효율적 폐열 활용 방안 제시를 규정하는 것도 적극적으로 고려할 필요가 있다.

데이터센터 인증도 에너지효율 개선에 중요한 역할을 할 수 있다. 현재 우리나라 ‘그린 데이터센터 인증’은 민간 인증으로서 참여 유인이 크지 않고 구속력도 없다. 주요국의 사례처럼 정부 주도의 인증제도 고려할 필요가 있다. 좋은 사례가 미국의 에너지스타(Energy Star)이다. 앞에서 설명한 대로 에너지스타에서는 점수 계산에 단순 PUE가 아닌 해당 DC만의 고유한 상황들을 고려해 평균적으로 달성 가능한 PUE 대비 실제 PUE가 얼마나 작은 지를 평가한다. 국내 DC의 인증에 있어서도 합리적인 평가를 위해 DC 특성에 따른 평균적인 PUE 수준 추정 연구가 필요하다. 또한, 이러한 인증제를 통해 높은 수준의 에너지효율을 달성한 DC에게는 정부 차원에서 인센티브를 제공하는 방식 등을 고려할 필요가 있다.

3.4. 에너지 성과 달성 지원

국내 데이터센터가 에너지효율 성과를 달성하도록 지원하기 위해서는 먼저 데이터센터 설계 및 운영 모범 사례 마련을 고려해야 한다. 대표적인 해외사례로 미국의 “효율적인 DC 설계 모범 사례 가이드”가 있다. 이 가이드에서는 에너지효율적인 DC 설계를 위한 IT 시스템 및 환경 조건, 공기 관리, 냉각 및 전기시스템, 폐열 회수와 같은 항목을 다루며, PUE를 포함한 복수의 에너지성과 지표를 이용해 DC의 에너지 성능을 평가하고 벤치마킹하는 방법을 설명한다. 우리나라는 한국정보통신기술협회¹¹⁷에서 데이터센터 운영, 그린 데이터센터 구축 등에 관한 지침을 제공하고 있다. 이러한 지침은 국제적 표준에 기반한 지침들인데, 이를 기초로 분산에너지법 등 국내 현행 법과 지역별 계통 특성 등을 고려한 국내 상황에 부합하는 최적 모범 사례를 제시하는 것이 필요하다.

또한, AI 모델의 훈련과 추론에서의 에너지 소비 특성이 다르므로, 정부는 AI 모델 개발사에게 훈련과 추론 과정의 에너지 소비량에 대한 정보를 제공하도록 유도해야 한다. 정부는 이러한 정보를 바탕으로 서로 다른 AI 모델 간 에너지 소비를 비교하고 평가할 수 있는 지표를 개발해야 할 것이다. 미국 등에서도 훈련과 추론의 에너지 소비 평가 표준 마련의 필요성이 제기되고 있는데, 소버린(Sovereign) AI를¹¹⁸ 지향하고 있는 우리나라도 별도의 독자적인 표준을 마련해야 한다. 이러한 평가 표준 개발을 통해 AI 서비스 관련 탄소 배출량 산정이 가능하며 지속가능한 그린 데이터센터의 운영을 지원할 수 있을 것이다.

3.5. 적극적인 전력망 참여 지원

전세계적으로 데이터센터를 전력의 수동적 구매자에서 적극적인 전력망 참여자로 전환하기 위해 노력하고 있다. 기술적으로는 하이퍼스케일 DC 등을 유연성 자원으로 활용하는데 문제가 없으나 실제로 이러한 활용이 이루어지지 못하고 있다. 데이터센터가 전력망 참여자 기능을 수행하도록 하려면 DC의 비상발전기

¹¹⁷ 한국정보통신기술협회. 정보통신표준화위원회.

¹¹⁸ 외국의 기술이나 빅테크 생태계에 의존하지 않고, 자국의 데이터, 인프라, 알고리즘, 인재를 기반으로 각국이 자체적으로 개발, 운영, 통제할 수 있는 인공지능 시스템

나 자가발전기가 비상 상황에서 전력 공급자의 역할을 할 수 있도록 허용하는 연구와 제도 마련이 필요하다. 이러한 제도는 특히 PPA 및 DR과 연결된다.

본 연구에서는 국내 데이터센터의 PPA 활성화와 DR 참여를 위한 연구와 제도 확장을 제안한다. 현재 국내 PPA를 통해 공급 가능한 전력원은 비중앙급전 발전기, 주로 소규모 재생에너지(태양광, 풍력, 수력, 바이오, 연료전지 등)에 한정되어 있다. 정부는 2023년 ‘데이터센터 수도권 집중 완화 방안’ 발표를 통해, 대규모 수력발전소(중앙급전자원)와 인근 DC 간의 PPA 계약 허용을 추진하고, 출력제어로 인한 잉여전력(재생+비재생)을 PPA로 공급할 수 있도록 하는 방안을 검토하기로 했다. 이와 관련해 최근에는 SK하이닉스, 네이버, 삼성전자 등이¹¹⁹ 대규모 수력발전소와 직접PPA 계약을 체결한 바 있다. 또한, 정부는 2024년 2월 전기사업법 개정을 통해 송전계약 PPA를 시행하고 있다. 이는 송전망 부족으로 발전한 전력을 전력시장에 공급하지 못하는 지역에서, 발전사업자가 인근 전력 수요처와 직접 전력 공급 계약을 체결할 수 있도록 허용하는 제도이지만, 아직 세부사항에 대한 고시가 제정되지 않아 실질적인 운영은 어려운 상황이다. 데이터센터뿐만 아니라 안정적인 전력공급을 위해서라도 세부 고시 제정을 서둘러야 할 것으로 판단한다. 한편, 현재 분산에너지특구 내 500MW 이하 열병합발전은 PPA가 가능하다. 중단기적으로 하이퍼스케일 중심의 DC 확장을 고려하면, 이러한 500MW 이하 기준 완화에 대해서도 고민이 필요해 보인다.

데이터센터는 무정전전원장치(UPS), 백업발전기, 배터리를 보유하고 있어 수요 반응(DR) 참여를 통해 계통 안정에도 기여할 수 있다. 관련해서 미 캘리포니아 에너지부(CEC)는 스마트 배전 시스템에서 DC의 에너지효율을 높이는 기술에 대한 연구 보고서(CEC, 2024)를 발간하고, 관련 기술들을 IEEE 표준에 등록했다. 이 보고서는 서버, 랙/DC, DC 클러스터의 세 가지 수준에서 각각 에너지효율 향상을 위한 기술을 제시하고 이러한 세 가지 기술 결합 시 DC의 총 에너지 비용을 약 48% 절감시킬 수 있음을 보이고 있다. 특히, 랙/DC 수준에서 제시된 서버 간 최적 부하 분배 기술과, DC 클러스터 수준에서 제시된 데이터센터의 전력 시장 주파수 조절 시장 참여 프레임워크는 DC의 수요반응 시장 활성화에 중요한 역할을 할 수 있다.

¹¹⁹ 기후에너지데이터뱅크(2024.12.27.), 연합뉴스(2025.5.30.), 한국수자원공사(2023.11.28.)

전자는 DR 자원의 효율적인 운영 조정에 적용될 수 있으며, 후자는 분산 시스템의 신뢰성 개선에 도움이 된다. 국내 DC의 유연성 자원으로서의 역할을 위해서는 먼저 소형 DC를 포함한 모든 DC의 스마트 배전 시스템 확보에 노력해야 하고, IEEE 표준에 등록된 이러한 기술들을 적극적으로 검토할 필요가 있다.

Ghatikar et al.(2010)은 데이터센터가 개방형 자동 DR(Open Automated Demand Response)의 훌륭한 후보임을 주장하고 있다. 개방형 자동 DR은 전력회사와 수요자 간에 실시간으로 표준화된 신호를 주고받아, 수요관리 사업자나 전력회사가 전력 감축 요청(DR)을 발령하면 참여 고객의 에너지 관리시스템(EMS)이나 스마트홈 플랫폼이 자동적으로 전력 사용을 감축하는 제도이다. 이는 신뢰성 DR이나 경제성 DR이 하루 전 시장에서 거래되는 것과는 달리 실시간 시장에서 거래되는 차이가 있다. 우리나라에서도 이와 비슷한 오토 DR을 검토 중이다. 오토 DR은 국민 DR 등의 기존 수요반응 제도에 IoT, AI, 스마트가전 등 첨단 ICT 기술을 접목해 전력거래소에서 감축 요청이 발령되면 가정이나 상업 시설의 EMS, 스마트가전, 조명 및 냉난방기기 등이 자동으로 전력 사용을 감축하도록 설계된 제도이다. 이러한 오토 DR에 데이터센터를 포함시키기 위한 정책 검토도 필요하다.

또한, DC의 DR 역할 확대를 위해 VPP에 데이터센터의 비상발전기나 자가발전기를 참여시키는 방안도 고려할 필요가 있다. 비상발전기를 VPP에 포함시킨 해외 사례는 유럽과 북미 지역에서 흔하게 찾아볼 수 있다. 국내에서도 KT 내부의 비상발전기가 주간예고 수요조정제도와 지능형 DR 프로그램을 기반으로 시장에 참여한 사례가 있다(이상준, 2014). 데이터센터의 발전기들은 IoT 기술과 결합해 실시간 모니터링 및 원격 제어가 가능해 AI 기반 최적화를 통해 전력망 안정에 기여할 수 있을 것이다.

3.6. 균형있고 안정적인 분산

AI의 훈련과 추론이 반드시 동일한 DC에서 이뤄져야 하는 것은 아니다. 제2장에서 다뤘듯이, 훈련의 전력 소비는 추론에 비해 평균 부하가 높으며, 일단 시작하면 몇 개월까지 지속될 수도 있고 중간에 중단하기 힘들다. 이런 점에서 훈련의 전력 수요 관리는 추론 대비 유연성이 작다. 그러나 DC의 지리적 입지 측면에서는

훈련용 DC가 추론 중심 DC보다 유연성이 더 높다. 추론은 상대적으로 저지연성이 중요하다. 특히, 금융거래, 자율주행 등 극도로 낮은 지연이 요구되는 분야에서는 1밀리초(1ms) 미만의 지연이 중요하다¹²⁰. 반면, 훈련은 추론과는 달리 저지연성이 중요하지 않으며, 이에 따라 훈련용 DC는 수요지(인구 밀집 지역) 인근에 위치할 필요가 없다. 이는 훈련용 DC는 송전제약 여부 및 지역별 전력계통 부하 등을 고려해 적절히 배치될 수 있음을 의미한다.

본 연구에서는 DC의 지방 분산에 관해 대해 정부가 훈련형과 추론형의 이분법적으로 접근하길 권고한다. 특히, 송전제약 및 전력계통 부하 완화에 도움이 되는 지역에 정부 주도의 AI 훈련용 DC 운영을 고려할 필요가 있다. 현재 강원도의 데이터센터 비중이 가장 낮는데, 수도권과의 거리 및 향후 원전 계속운전 등을 고려하면 강원 지역의 훈련용 AIDC 배치도 고려할 만하다. 이러한 정부주도 AIDC는 국내 개발중인 AI 모델의 테스트베드(test bed)로서의 역할도 수행 가능하다. 이를 통해 국내 AI 훈련 및 추론 알고리즘 개발과 에너지효율 평가를 위한 공동연구와 협력의 시너지 창출이 가능할 것이다. 또한, 이러한 테스트베드의 운영을 통해 앞에서 언급한 AI 모델의 훈련과 추론의 에너지 소비를 평가하는 표준 마련에 필요한 정보를 획득하는 것도 중요하다.

¹²⁰ 일반적으로 광케이블 1km당 약 5마이크로초(5μs)의 지연이 발생하며, 수요지와 100km 떨어진 DC의 왕복 지연은 약 1밀리초(1ms)에 달한다. 우리나라는 국토 면적이 좁아 저지연성 문제는 크지 않을 것으로 판단된다.

제5장

결론

본 장에서는 지금까지의 내용을 장 별로 요약한 후 맺음말로 연구를 마무리한다.

1. 주요 결과 요약

1.1. 제 2 장: 데이터센터의 에너지 소비와 불확실성

제2장에서는 DC에 대한 글로벌 선행 연구들을 종합해 정리했다. 데이터센터는 IT와 비IT 시스템으로 나눌 수 있다. IT 시스템은 서버, 스토리지, 네트워크로 구성되며, 이 중 서버에서의 에너지 소비가 대부분을 차지한다. 비IT 시스템의 주 구성 요소는 전력 시스템(무정전 전원 공급 장치, 배터리, 백업 발전기 등)과 냉각 시스템으로 구성된다. 비IT 시스템의 에너지 소비 대부분은 냉각 부문에서 발생한다. 글로벌 평균 IT와 비IT의 에너지 소비 비율은 약 7:3 정도로 추정된다.

DC의 유형은 여러 기준에 따라 나눌 수 있는데, DC의 규모가 커질수록 에너지 소비가 증가할 뿐만 아니라 규모의 경제 효과로 에너지효율도 상승한다. 일반적으로 DC의 규모가 상승할수록 서버와 IT 부문의 에너지 소비 비중은 커지며, 반대로 냉각과 비IT 부문의 비중은 작아진다. 최근 몇 년간 데이터센터는 대규모 하이

퍼스케일 DC를 중심으로 증가해 왔는데, AI 데이터센터(AIDC)의 확대 등으로 향후에도 단기적으로는 이러한 추세가 유지될 것으로 보인다.

연구에 따르면 데이터센터의 일간 시간별 부하 패턴은 근무 시간에 부하가 상승하는 DC와 하루 24시간 내내 일정한 부하를 가진 DC로 나뉜다. 전자는 사무실 등의 부대 시설에 따른 영향으로 보이며, 이 경우 기온에 따라 부하가 상대적으로 크게 변한다. AIDC와 기존 DC의 전력 패턴은 전력 소비량과 변동 폭에서 크게 차이가 난다. AIDC는 에너지 소비가 많은 GPU 등의 AI 가속기를 사용하기 때문에 절대적 에너지 소비량이 기존 DC보다 크며, AI 연산의 부하 특성상 변동 폭도 상대적으로 매우 클 수 있다.

글로벌 DC의 에너지 소비 추정 및 전망에 관한 연구는 다수 존재한다. 이러한 연구들은 기초 자료의 수준과 접근 방법에 따라 추정 결과에 상당한 차이가 존재한다. 예를 들어 2022년 글로벌 DC의 전기 소비량 추정치는 연구에 따라 200~1,300TWh로 편차가 매우 크다. 상대적으로 정확하다고 여겨지는 IEA의 연구에서 추정한 2023년 글로벌 DC의 전기 소비는 약 361TWh이며 이는 글로벌 총 전력 소비의 약 1.5%에 달하는 수치이다. IEA의 시나리오 분석에서 2030년 글로벌 DC의 전력 수요 전망치의 최소와 최대치의 차는 2배 이상의 차이가 난다. 이러한 전망의 불확실성은 미국, EU의 DC 전력 수요 증가 연구에서도 동일하게 나타난다. 인공지능으로 DC의 에너지 소비가 증가할 것이라는 것에는 대부분 동의하나, 이로 인해 에너지 소비가 얼마나 증가할지를 전망하는 것은 매우 어렵고 불확실성이 매우 크다. 이는 AI 연산의 에너지 소비가 수많은 요인들에 의해 영향을 받기 때문이다.

AI 연산은 학습(훈련)과 추론으로 나뉜다. 학습은 대규모 데이터셋을 이용한 엄청난 양의 연산이 요구되는 과정으로 에너지 소비가 매우 크다. 반면, 추론은 사용자의 요청에 따라 연산이 이뤄지므로 학습 대비 단위 연산당 에너지 소비는 훨씬 적다. 하지만, 학습이 일회성인데 비해 추론은 반복적으로 수행되므로, 결국 전체적인 관점에서는 추론의 에너지 소비가 학습 대비 훨씬 많을 수 있다. 학습과 추론은 부하의 특성에도 차이가 난다. 학습 시 전력 소비는 AI 칩의 최대 전력에 근접하지만, 추론 시에는 상대적으로 최대 전력의 60~80% 수준에 그친다. 또한 훈련은 특정 이벤트가 종료되면 그 즉시 부하가 거의 제로로 떨어지지만, 추론은 상대적으

로 안정적으로 유지된다. 이러한 특성은 단일 모델의 결과이며, 실제 DC 수준에서는 수십 개의 모델이 운영되므로 다수의 모델에 특정 이벤트가 동시에 발생하지 않는다면 이러한 변동성은 상당 부분 스무딩(smoothing)된다. 그럼에도 불구하고, 이러한 AI 연산의 부하 특성으로 기존 DC 대비 AIDC의 변동성은 훨씬 크다.

훈련의 에너지 소비에 영향을 미치는 요인에는 대표적으로 모델의 파라미터 수, 데이터셋 사이즈, 훈련 시간 등이 있다. 딥 러닝 시대(2010년 이후)에 들어와서 이러한 요소들의 증가 속도는 과거보다 매우 빨라졌다. 하지만, 동기간 훈련의 에너지 소비는 이러한 요소들의 증가세에 비해 완만하게 증가했다. 이는 최적 배치 크기 조정, 유틸 전력 절감, AI 알고리즘, AI 칩의 에너지원단위 개선 등에 따른 에너지효율 개선 때문이다. 이러한 효율 개선 요인들은 훈련뿐만 아니라 추론의 에너지 소비에도 동일하게 적용된다. 최신 연구에 따르면, 에너지효율 개선으로 추론의 전기 소비 증가세는 학습 대비 훨씬 완만한 것으로 조사되고 있다. 한편, 추론의 에너지 소비 전망은 AI 이용이 얼마나 증가할 것인가에 달려 있어 불확실성이 매우 큰데, 이에 더해 추론 작업의 유형별 에너지 소비 차이도 불확실성을 더욱 키우는 요소이다. 연구에 따르면 텍스트 기반보다는 이미지 기반 추론 작업에 드는 전기 소비가 훨씬 크다. 이미지 생성은 텍스트 생성의 약 62배에 달하는 전기가 소비되는 것으로 조사되고 있다. 향후 추론에서 이러한 이미지 생성 작업이 차지하는 비중이 얼마나 될지 예측하는 것은 매우 어렵다.

데이터센터의 에너지효율을 정확하게 측정할 수 있는 단일 지표는 없다. 데이터센터의 에너지 성과를 평가하기 위한 수많은 지표들이 존재하고 개발되고 있는데, 이 중 가장 일반적으로 널리 쓰이는 대표적인 지표는 PUE(전력효율지수)이다. PUE는 보다 정확히 말하면 DC의 인프라 효율을 측정하는 지표이나, 계산의 편의성 등으로 DC의 에너지 성과 평가에 가장 널리 쓰이고 있다. 주요 연구에 따르면 글로벌 DC의 평균 PUE는 2010년대 중반까지 빠르게 개선되다 이후 개선세가 크게 둔화되었다. 2024년 기준 글로벌 평균 PUE는 1.4~1.5 수준으로 추정되고 있다. PUE는 냉방용 전력 수요와 밀접하게 관련되는데, 본 연구에서는 글로벌 평균 PUE를 이용해 2024년 글로벌 DC의 평균 냉방용 전력 소비 비중을 19~24% 수준으로 추정했다.

데이터센터의 효율에 영향을 미치는 요인들은 앞서 언급한 훈련과 추론 관련한 요인들 외에도 여러 가지가 있다. IT 장비 측면에서는 하드웨어 혁신과 장비 이용률에 따라 에너지 소비가 영향을 받는다. 데이터센터의 인프라 측면에서는 PUE에 영향을 미치는 요소, 특히 냉각 기술이 에너지 소비에 영향을 미친다. 데이터센터의 설계, 운영, 관리 측면의 요소들로는 전력 관리 설계, 티어 등급, 폐열 재활용 및 재생에너지 활용, 에너지 관리시스템, AI를 이용한 워크로드 및 자원 관리 최적화 등이 있다. 이러한 DC의 에너지효율을 높이기 위한 많은 방법들이 개발 및 연구되어 적용되고 있으며, EU를 비롯한 주요국들도 DC에 대한 에너지효율 규제를 적극적으로 하고 있다. 현재 실시되고 있는 주요국의 에너지효율 규제의 영향을 측정한 몇몇 연구들에 따르면 DC 에너지 소비 절감에 가장 효과가 큰 정책은 PUE 규제로 조사되고 있다.

데이터센터 에너지 소비 전망의 불확실성을 높이는 요인으로서는 AI 연산 증가 요인과 에너지효율 향상 요인 외에 구조적 요인들도 있다. 대표적으로 양자 컴퓨터의 도입이나, 옛지 DC의 확산, 온디바이스 중심의 AI 확산이 이뤄진다면, AI 시대가 도래해도 데이터센터의 에너지 소비는 예상보다 빠르게 증가하지 않을 수도 있다.

1.2. 제 3 장: 국내 DC 전력 소비 전망 및 에너지 소비 영향

DC에 대한 공개 정보가 매우 제한적인 상황에서, 국내 데이터센터의 에너지 소비에 대한 연구는 없다. 제3장에서는 에너지총조사, 녹색건축포털, 한전, KDCC 등 복수의 자료원에서 국내 데이터센터 관련 에너지 소비량 정보를 최대한 수집해 실증 분석을 시도했다. 실증 분석에 앞서, 국내 데이터센터의 현황에 대해 조사했다. 국내 법에서 지원이나 규제의 대상이 되는 국내 데이터센터는 전산실 바닥면적 500㎡ 이상이며, 수전용량이나 전산 설비 용량 기준은 제시되지 않고 있다. 용도별로는 국내 데이터센터는 방송통신시설로 분류된다. 국내 데이터센터의 수는 2020년까지 지속 증가하다 정체하고 있는 것으로 나타나는데, 이는 데이터센터의 면적 기준이 정확하게 적용되지 못해 발생한 통계상의 오류인 것으로 추측된다. 한국데이터센터 연합회에 따르면 2024년 기준 국내 데이터센터의 수는 165개소이며, 전체 데이터센터의 민간과 공공 비중은 56:44 이다. 주요 제공 서비스

는 코로케이션을 위주로 운영되고 있으며, 바닥면적 2,000㎡ 이상의 데이터센터가 50% 이상을 차지한다. 국내 데이터센터는 2024년 기준 60.4%가 수도권에 위치하고 있는 것으로 조사되고 있다.

다음으로 실증 분석 부분은 세 부분으로 나누어 이뤄졌다. 첫 번째 부분에서는 국토부 녹색건축포털의 국내 건물에너지 정보 전수 조사 자료를 이용해 국내 데이터센터의 월간 전력 소비 패턴을 분석했다. 데이터센터의 전기 소비량 자료는 다양한 출처들부터 수집한 국내 데이터센터의 주소를 국토부 자료의 건물 주소와 매칭하여 추출했다. 분석을 위한 총 25개의 DC에 대한 월간 에너지 소비 자료를 얻을 수 있었다. 샘플 DC는 국내 주요 DC들을 중심으로 구성되었다. 가장 최신 연도를 기준으로 연간 전기 소비량이 100GWh를 초과하는 DC는 3개였으며, 50~100GWh 수준이 5개, 나머지는 50GWh 미만의 DC였다. 분석에 이용된 DC가 주요 데이터센터임을 고려하면, 분석에 포함되지 않는 대부분의 DC는 연간 전력 소비량 50GWh 미만에 속할 것으로 추측된다. 분석 결과 대부분의 샘플에서 여름철에 전력 소비가 증가하는 계절성이 나타났다. 계절성의 정도를 클러스터 분석과 STL 분석을 통해 절대적 소비 변동 폭 측면과 분산 측면으로 나누어 살펴보았다. 계절에 따른 소비 변동 폭은 일부 대규모 DC를 제외하고는 크지 않은 것으로 나타났다. 연간 100GWh 이상의 대형 DC의 경우, 여름철에 전기 소비가 최대 0.7GWh가량 상승하는 것으로 추정되었다. 반면, 분산 측면에서는 상당수의 DC에 있어 전력 소비 변동의 원인이 계절성에 기인하는 것으로 분석되었다. 일부 DC에 있어서는 연중 전력 소비 변동의 70% 이상이 계절성 때문으로 나타났다. 이상의 결과는 국내 데이터센터의 DR 자원 활용 가능성을 보여준다.

계절성 분석에 이용된 샘플에 AIDC는 포함되지 않았다. 국내 AIDC는 최근 들어 건설되기 시작했기 때문이다. 대표적인 예가 울산 AIDC이다. 두 번째 실증 분석 부분에서는 울산 AIDC의 에너지 소비량을 추정했다. 울산 AIDC가 완공되었을 때의 에너지 소비량 추정은 여러 출처에서 보도된 AI 칩 수(약 6만 장)를 기초로 이뤄졌다. 구체적으로 어떤 종류의 AI 칩이 얼마나 설치될지 알 수 없고, 이용률과 PUE에 대한 정보도 없기 때문에, 대표적인 AI 칩의 공개된 최대 전력 정보, GPU 이용률, PUE에 대한 범위를 설정해 울산 AIDC 에너지 소비의 최대치와 최소치를 추정했다. 추정 결과 울산 AIDC의 연간 전력 소비량은 약 33~718GWh

로 추정되었으며, 가장 현실적인 가정하에서는 연간 약 213GWh를 소비할 것으로 추정되었다. 특히, AIDC에서 소비하는 전력은 대부분 LNG 열병합 상용자가 발전으로 충당될 것으로 보이는데, 이 경우 울산의 상업용 천연가스 직수입 물량은 현실적 가정하에서 연간 약 3만 톤, High 시나리오에서는 최대 약 11만 톤가량 증가할 수 있는 것으로 추정되었다. 이 추정치는 AI 반도체 6만 장이라는 가정하에 도출된 수치로서, 향후 국내 칩 보급 수에 따른 AIDC의 에너지 소비 전망에 대한 대략적인 가늠자 역할을 할 수 있을 것으로 여겨진다.

실증분석의 마지막은 우리나라 전체 DC 전기 소비 전망이다. 이를 위해 국내 데이터센터를 규모별로 대형, 중형, 소형으로 나누고 각각에 대해 데이터센터 개소, 수전용량, 수전용량 이용률, PUE를 전제했다. 각각의 변수들은 제2장의 글로벌 데이터센터에 관한 기존 문헌에서의 정보들과 KDCC, 한전 등에서의 이용 가능한 국내 정보들을 종합하고 2023년 전기 소비량이 제11차 전기본에서의 DC 추정치(5TWh)를 만족하도록 조정 및 전제되었다. 전망은 2060년까지의 기간에 대해 기준 전망과 고성장(AI 가속) 시나리오에 대해 실시했다. AI 가속 시나리오는 단순히 국내 데이터센터의 총 개수가 기준 전망 대비 2배 더 많이 증가하는 경우로 설정했다. 제2장에서 살펴보았듯이 데이터센터 에너지 소비 증가 요인과 감소(둔화) 요인을 모두 고려하여 시나리오를 설정하기에는 불확실성이 너무 크기 때문이다. 단, DC 수와 수전용량의 증가세 비율은 유지된다고 가정했다.

기준 전망에서 국내 DC의 총 전기 수요는 전망 기간(2023~2060년) 연평균 7.2% 증가해 2060년에는 65TWh에 도달하고, 가속 시나리오에서는 연평균 9.3% 증가해 235TWh 수준에 도달할 것으로 전망되었다. 전망 초기에는 대규모 클라우드 및 코로케이션 DC를 중심으로 에너지 소비가 증가하고, AI 시대가 어느 정도 정착되기 시작하는 후기에는 소규모 DC를 중심으로 에너지 소비가 증가하는 것으로 나타났다. 이에 따라 기간별 에너지 소비 증가세도 초반에는 상대적으로 빠르게 증가하고 점차 증가세가 하향 안정화될 것으로 전망되었다.

〈표 5-1〉 국내 DC 전력 소비 전망 및 절감 잠재량

전력 수요(TWh)	2023	2030	2040	2050	2060
기준 전망	5.0	13.8	31.6	49.9	65.4
가속 시나리오	5.0	20.9	59.8	101.4	134.8
PUE 개선 절감 잠재량(TWh)	2023	2030	2040	2050	2060
기준 전망	-	1.7	5.6	9.0	11.6
가속 시나리오	-	2.5	9.8	17.0	22.2

한편, 글로벌 주요국들은 DC의 에너지효율 정책을 실시하고 있다. 몇몇 연구에서는 이러한 정책의 효과를 분석하고 있는데, 효과는 주로 PUE 개선에 기인한 것으로 나타난다. 우리나라는 아직까지 DC 관련 구체적인 효율 정책이 없다. 본 연구에서는 국내도 주요국 수준의 DC 효율 정책이 실시된다는 가정하에 PUE 개선에 따른 DC 전력 소비 절감량을 추정해 보았다. 구체적으로 현재 1.6 수준인 국내 평균 PUE가 2030년경에는 1.2 수준, 2030년 중반 이후로는 1.1 이하로 하락하는 것을 목표로 설정했다. 이는 신규 DC와 기존 DC를 모두 포함한 평균 PUE로서 도전적인 목표라고 할 수 있다. 이러한 PUE 목표 달성 시 2060년 기준 기준 전망과 AI 가속 시나리오에서의 DC의 전력 소비량은 각각 17.8%(12TWh), 16.5%(22TWh) 절감될 것으로 추정되었다. PUE 개선 효과는 DC의 규모가 작을수록 큰 것으로 나타나, PUE 개선 정책 수립 시 소형 DC가 중요함을 시사한다. 또한, 누적 효과로 PUE 개선 정책이 빠를수록 전체 절감 효과가 큰 것으로 나타났는데, 초기 PUE 개선 폭을 빠르게 확대하기 위해서는 기존 DC의 PUE 개선이 중요하다는 것을 알 수 있다. 마지막으로, AI 가속 시나리오에서의 PUE 개선에 따른 전력 소비 절감률이 기준 전망 대비 작은 것으로 나타났는데, 이는 AI 가속화로 전기 소비가 예상보다 빠르게 증가할 경우 PUE 개선 정책 외에 추가적인 DC 효율 개선 정책이 필요함을 의미한다.

이상의 국내 DC 전력 소비 전망이 국가 에너지 소비에 미치는 영향은 어느 정도일까? 결론적으로 DC 소비가 국내 전력 소비 증가 추세에 미치는 영향은 중단

기적으로는 그렇게 크지 않을 것으로 보인다. 먼저 국내 전력 소비는 2011년경 이후 과거 대비 증가 추세가 크게 둔화했다. 여기에는 복합적인 이유가 있는데, 가장 중요한 구조적 이유 중 하나는 산업 및 수출 구조 변화에 따른 산업용 전력 소비의 둔화 때문이다. 특히, 3대 전력 다소비업종(기계류, 석유화학, 철강)에서의 전기 소비 둔화세가 최근 들어 더욱 심화되고 있는데, 이러한 추세가 향후에 극적으로 바뀌기는 힘들다. 앞에서 추정한 국내 DC의 전기 소비 전망치는 이미 크게 둔화된 국가 전체 전기 소비 증가세를 바꾸기에는 미미한 수준이다. 다만, 국내 부문별 전력 소비 구조에는 주요한 영향을 미칠 것으로 보인다. 2024년 기준 국내 부문별 전력 소비 비중은 산업(49.2%), 상업·공공(34.0%), 가정(15.7%), 수송(1.1%) 수준인데, DC의 전기 소비 증가로 산업용과 상업·공공용의 소비 격차는 지속해서 축소될 것으로 보인다. 다른 요인들이 동일하다면, 2040년 이후에는 DC 증가로 상업·공공용이 산업용 전기 소비량을 초과할 것으로 보인다. 특히, 2024년에 건물용(가정+상업·공공) 전기 소비가 산업용을 사상 처음으로 초과했는데, 향후 DC 증가가 주요 원인 중 하나로 작용할 것이며, 이러한 현상이 지속될 것으로 보인다. DC 증가로 전력 공급 안정성에서 우려되는 부분은 여름 냉방용 전력이다. 2023년 기준 국내 DC 전체 전기 소비에서 냉방용 부하는 약 17%(0.8TWh)에 달하는 것으로 추정되었다. DC 냉방용 전력 수요는 2060년(기준 전망)에는 10배 이상 증가하여 향후 여름철 전력 수급 안정에 상당한 영향을 미칠 것으로 예상된다.

제3장에서는 국내 데이터센터의 현실적인 입지와 전력 공급원에 대해서도 분석했다. 데이터센터가 요구하는 빠른 응답력, 짧은 발전소 건설 기간, 온실가스 배출, 송전망 제약 등을 고려했을 때, 국내 데이터센터의 입지는 수도권과 충청권을 제외한 나머지 지역이 될 것으로 보인다. 호남과 영남지역의 데이터센터 전력 공급원으로는 태양광/풍력+에너지저장장치+전통적인 전력 공급원이 결합된 형태가 가장 유리할 것으로 판단된다. 중장기적으로는 영남과 강원 중심의 원자력 발전소 계속운전이 데이터센터 전력 공급의 가장 현실적인 선택지가 될 것으로 보인다. 한편, SMR과 연료전지는 기술적, 제도적, 경제적 불확실성 등으로 데이터센터의 주 전력 공급 방안으로 부상하기까지는 시간이 걸릴 것으로 판단된다.

앞서 DC 증가에 따른 국내 총 전력(즉, 한전의 판매량)에의 영향에 대해 논의했

는데, DC의 전력 공급 방안을 고려하면 신경을 써야 할 것은 전력뿐만 아니라 천연가스 수급이다. 특히, 자가발전용으로 민간의 천연가스 직수입이 최근 빠르게 증가해 왔는데, 향후 DC 증가는 이러한 천연가스 민간 직수입 증가를 더욱 가속시킬 것으로 보인다. 본 연구는 DC의 LNG 상용자가발전에 투입되는 천연가스 소비량은 DC에 소비되는 자가발전뿐만 아니라, DC 인근의 자가발전 구매자에 따른 연쇄 효과로 훨씬 큰 폭으로 증가할 가능성에 주목한다. 이 경우 앞서의 울산 AIDC 건설에 따른 천연가스 직수입 물량은 상업용(DC 소비)뿐만 아니라, 산업용(인근 구매자 소비)에서도 증가할 수 있으며, 물량도 기존 추정치보다 더 큰 폭으로 증가할 수 있다. 이러한 자가발전용 천연가스 민간 직수입의 증가는 국가 에너지 수급 불안의 원인으로 작용할 수 있다. 자가발전 업체는 국제 에너지 가격 변동에 따라 자가발전량과 한전으로부터의 전력 수전량을 자유롭게 조정할 수 있기 때문에, 이에 따른 한전의 전력 판매량과 국내 천연가스 수급 변동성 확대에 주의해야 한다.

1.3. 제 4 장: 주요국 DC 관련 정책 현황 및 국내 정책 제언

제4장에서는 먼저 데이터센터의 에너지 소비에 대한 주요국의 정책들을 정리했다. 이러한 정책들은 대부분 최근에 수립되어 2020년 이후 시행되고 있다. 가장 체계적이고 구체적인 정책을 설정한 지역은 EU이다. EU 에너지효율 관리지침에는 데이터센터가 보고해야 하는 정보들과 보고 체계에 대해 규정되어 있다. 이러한 정보에는 IT 용량 및 전력 수요, 물 및 폐열 사용량, 재생에너지 소비량, 데이터 트래픽 지표 등이 포함된다. 이러한 지침에 따라 독일과 프랑스 같은 국가들은 관련 내용들을 국내법에 포함시키고, 데이터센터의 에너지효율을 포괄적으로 규제하고 있다. 중국은 국가 주도하에 DC의 합리적인 지역 배치, 에너지효율 향상, 재생에너지 이용 확대를 목표로 인터넷 네트워크 요구가 높은 업무는 동부의 DC에, 네트워크 요구가 낮은 업무는 서부의 DC에 집중하는 “동수서산” 프로젝트를 추진하고 있다. 일본에서는 2025년에 들어 데이터센터에 대해 강화된 에너지효율 규제를 추진하고 있다. 신규 제도에서는 EU와 유사하게 정부가 정한 DC의 에너지 성과 관련 지표를 보고 및 공개해야 한다. 싱가포르에서는 정부가 정한 기준에 따라 신규 DC 건설을 규제하고 있다. 또한, 정부 주도의 데이터센터 인증제 등

을 포함한 그린 데이터센터 로드맵을 통해 데이터센터의 에너지효율과 그린 에너지 사용을 규제하고 있다. 한편, 미국은 DC 에너지 정보에 대한 보고 체계는 없다. 다만 캘리포니아의 경우 PUE 규제와 개선 규정이 있으며, 뉴욕 주의 경우 보고의무 규정 마련을 추진하고 있다. 미국은 “에너지스타”와 같은 정부 주도의 인증제도를 운영하고 있다. 트럼프 2기에 들어서면서 DC의 환경 규제는 크게 축소하고, AI 인프라 구축 및 확장에 집중하고 있다.

규제의 범위와 내용이 조금씩 다르지만, 글로벌 주요국들은 데이터센터의 에너지효율과 재생에너지 사용에 대한 내용을 구체적으로 포함하고 있다. 예컨대, PUE 같은 대표적 에너지 성과지표가 모든 나라에서 DC의 에너지효율 규제 수단으로 명시되어 있다. 반면, 우리나라는 방송통신 시설이라는 카테고리하에서 데이터센터를 간접적으로 규제하고 있다. 에너지 측면에서 크게 4가지 법이 데이터센터에 적용되는데, 주로 대규모 DC가 대상이며 내용도 자가발전기 설치나 지역분산에 집중된다. DC의 에너지효율 측면에서 법적으로 구속력 있는 규제는 사실상 부재하다.

〈표 5-2〉 주요국 데이터센터 PUE 규제

국가	PUE
독일	2026.7 이전 운영 DC: 2027.7월 이후로는 PUE 1.5 이하, 2030.7 이후로는 영구적으로 1.3 이하 달성 2026.7 이후 운영 DC: 가동 후 2년 이내에 PUE 1.2 이하 영구적 달성
캘리포니아(미국)	PUE 1.5 초과 시 매년 10%씩 감축
중국	정부자금 투입 DC: 2025년 이후 PUE 1.3 이하 2025년까지 PUE 목표: 전국 평균 1.5 이하, 신규/증설 DC는 1.25 이하, 국가 허브 노드 DC는 1.2 이하
일본	2029년 이후 일정 규모 이상 신설 DC: 가동 2년 후부터 PUE 1.3 이하 단, 임차형 DC는 별도 규정
싱가포르	향후 10년내 모든 DC: 100% IT 부하에서 PUE 1.3 이하

주: 제4장 내용을 바탕으로 저자 정리

국내도 PUE 같은 성과지표를 활용해 DC의 에너지효율 정책을 실시하기 위해서는 먼저 데이터센터의 에너지 소비에 대한 정확한 정보를 획득하는 것이 급선무

다. 이를 위해서는 먼저 데이터센터의 분류 기준을 명확히 해야 한다. 현재의 전산 실 상면 면적 기준을 보다 합리적인 IT 용량이나 에너지 소비량 기준으로 변경할 필요가 있다. 또한 용도 구분도 명확히 해야 한다. 데이터센터의 에너지 소비는 사용 목적상 건물용으로 분류되어야 하나, 산업용, 교육용 등 여러 용도로 집계되고 있는 것으로 보인다. 이러한 불명확한 용도 구분으로 한전에서도 데이터센터의 전기 소비량을 정확히 파악하지 못하고 있다. 본 연구에서는 한전이 데이터센터를 별도의 용도로 분류해 집계할 것을 제안하였다. 명확한 용도 구분은 데이터센터의 전력 소비량 집계뿐만 아니라, 향후 데이터센터의 효율성, 유연성, 수요 대응(DR) 기능 장려 등을 위한 합리적인 DC 전용 요금제 설정을 위한 첫 단계이다.

〈표 5-3〉 주요국 정보 보고 대상 데이터센터

국가	정보 보고 규정 및 대상
EU	에너지효율 관리 지침에 따라 IT 전력 수요 500 kW 이상 DC 정보 보고 의무
독일	에너지효율법에 따라 비중복 정격용량 200 kW 이상 DC 정보 보고 의무
프랑스	EU 지침 준수: IT 전력 수요 500 kW 이상 DC 정보 보고 의무
일본	에너지 합리화법에 따른 에너지 사용량 매년 보고: 연간 1,500 kl(원유환산) 초과 DC 벤치마크 제도에 따른 매년 PUE 보고 의무: 연간 1,500 kl 초과 DC
싱가포르	GMDC 인증제(신규 DC는 의무적, 기존 DC는 선택적)에 따라 최근 12개월 PUE 보고

주: 제4장 내용을 바탕으로 저자 정리

데이터센터의 에너지 소비 정보는 단순히 DC별 총 전력 소비만으로는 불충분하다. 앞서 PUE는 IT 부문에서의 전력 소비도 알아야 계산이 가능하다. 게다가 데이터센터 전기의 상당 부분은 자가발전으로 충당된다. 한전이 집계할 수 있는 부분은 오로지 한전이 데이터센터에 판매한 전력뿐이다. 결국, 데이터센터의 상세한 에너지 소비는 DC 운영자가 직접 계측해야 한다. 또한, 이러한 계측의 정확도 및 에너지 소비 관리를 위해서는 DC 운영자가 정부에 보고하는 체계를 갖춰야 한다. 이러한 보고 체계와 관련해서는 EU 등 주요국의 사례를 참고할 수 있다. 보고해야 할 정보는 DC 사업자와 정부가 협의하여 결정하고, 필요하다고 판단되는 정보는 주요국처럼 대중에게 공개하도록 해야 할 것이다. 보고 정보는 주요 에너지 성과

지표를 계산할 수 있는 수준으로 세분화되어야 한다. 국가 통계의 정합성 및 정확도 제고 측면에서 데이터센터의 업종별 전력 및 열 판매량도 보고 정보에 포함할 필요가 있다. 데이터센터 에너지 정보의 투명성 및 수집을 위해 건축물에너지 관리 시스템 설치 의무를 확대하는 것도 고려해야 한다.

정부는 DC 운영자가 보고한 정보를 바탕으로 에너지 성과 지표를 계산하여 모니터링하고 효율 개선에 대한 정책을 마련해야 한다. 이러한 정책에는 주요국의 사례처럼 PUE, 재생에너지 이용률, 폐열 활용률 등 복수의 성과 지표에 대한 신규 및 기존 DC의 목표 제시가 포함될 수 있다. 정부 주도의 데이터센터 인증제도 이러한 정책 중 하나로 고려할 수 있다. 데이터센터의 에너지효율 달성 지원을 위해서는 정부가 국내 상황에 맞는 DC 설계 및 운영 모범사례를 제시하는 것도 고려할 필요가 있다. 특히, AI 모델의 훈련(교육)과 추론 과정에서의 에너지 소비를 비교 평가할 수 있는 표준을 마련한다면 보다 정확하고 합리적인 에너지효율 모니터링 및 지원이 가능할 것으로 보인다.

또한, 정부는 전력의 수동적 구매자가 아닌 적극적인 전력망 참여자로서의 데이터센터의 역할 전환을 지원해야 한다. 이를 위해 데이터센터의 배터리, 백업 발전기, 자가발전기가 비상 상황에서 PPA와 DR에 적극적으로 참여할 수 있도록 하는 연구와 제도 마련이 필요하다. 현재의 소규모 재생에너지 중심의 PPA를 적극 확대하고 송전제약 PPA의 실질적인 시행을 위해 노력해야 한다. 현재 분산에너지 특구 내 PPA 가능 열병합발전의 용량 기준 제한 완화도 생각해볼 수 있다. 데이터센터의 DR 참여 확대를 위해서는 먼저 소형 DC를 포함한 스마트 배전 시스템 확보에 노력하고, IEEE 표준에 등록된 서버 간 최적 부하 분배 알고리즘이나 데이터센터의 주파수 조절 시장 참여 프레임워크를 적극 검토할 필요가 있다. 또한, 현재 검토 중에 있는 오토 DR과 VPP에 데이터센터를 참여시키는 방안도 고려할 필요가 있다.

마지막으로 데이터센터의 지방 분산과 관련해서, 단순히 지리적 분산이 아닌 훈련형과 추론형 AIDC의 이분법적 접근도 고려할 필요가 있다. 예를 들어 지리적으로 유연성이 더 큰 훈련 전용 DC를 송전 제약이나 계통 부하를 고려해 분산시킬 수 있을 것이다. 만약, 정부 주도의 훈련 중심 AIDC가 이러한 이분법적 접근으로 건설된다면, 국내 개발중인 AI 모델의 테스트 베드(test bed)로의 역할도 가능할

것이다. 정부 주도 AI 테스트베드의 운영은 AI 모델 개발뿐만 아니라 에너지효율 평가 기준 마련에도 큰 역할을 할 것으로 보인다.

[그림 5-1] 카테고리별 주요 정책 제안

DC 분류 기준·체계 재정립	• 면적 기준의 IT 용량(GW)·연간 소비량(GWh) 기준 전환 • DC용도 구분 일관화 • 한전의 DC 공급 전력 통합 집계 및 DC 전용 요금제 고려
정보 수집·보고 체계	• DC 운영자 측정 및 정기 보고 체계 마련 • 보고 정보 선정과 공개가능 지표의 대중 공개 • BEMS 설치 의무화 확대
효율 규제·지침	• PUE 등 성과지표를 바탕으로 효율 개선 지침 및 효율 규제 기준 마련 • 기존 및 신규 DC가 달성해야 할 효율 수준과 효율 개선 목표 제시 • 정부 주도 DC 인증제와 인센티브 확대
성과 달성 지원	• 국내 상황에 맞는 DC 설계 및 운영 모범사례 제시 • AI 훈련/추론 에너지 소비 비교 및 평가 표준 개발
전력망 참여 확대	• DC의 PPA 이용 범위 확대 • 스마트 배전·IEEE 표준 기술 도입 통한 DR 확대 • 오토DR 확대, DC의 발전기의 VPP 참여
균형적 분산	• 훈련형 vs 추론형 DC 이원화 • 송전제약·계통부하 완화 지역에 정부주도 훈련형 DC 배치 • 테스트베드를 운영을 통한 AI 모델의 에너지 소비 표준 마련의 정보 획득

2. 맺음말

이상으로 각 장의 주요 연구 결과를 정리했다. 정보의 홍수 속에 가능한 많은 정보를 체계적으로 정리, 분석하여 정책 시사점을 제안하고자 노력했으나, 연구의 한계도 존재한다. 제3장의 국내 데이터센터의 월간 전력 소비 자료 분석은 원 자료의 한계상 데이터센터만의 전력 소비는 아니며, 계절성에 영향을 미치는 데이터센터별 특징에 대한 분석도 자료 부족으로 수행되지 못했다. 국내 DC 총 전력 수

요 추정 및 전망도 많은 가정에 기초했다. 전망을 위한 변수의 전제를 위해 이용 가능한 국내외 자료들을 최대한 참조했으나, 이 역시 자료의 한계로 연구자의 주관적 판단을 완전히 배제하기는 힘들었다. 국내 정책 부분에서는 여러 단계에서 복수의 안건들을 제안했지만, 안건별로 상세한 타당성 분석이나 구체적인 실행 방법을 제시하기 보다는 큰 틀에서 정책 연구 주제를 제안하는데 그쳤다. 이러한 연구의 한계들은 모두 향후 연구 과제로 남긴다.

마지막으로 국내 데이터센터 증가에 대한 추가적인 제언은 다음과 같다. 첫째, 데이터센터는 ‘전기 먹는 하마’라는 부정적인 인식이 널리 퍼져 있는데, 데이터센터의 에너지 소비 증가를 우려의 시선으로만 볼 필요는 없다. AI로 인해 엄청난 생산성 향상이 이뤄지고, 국가 전체의 경제 사회적 비용은 오히려 감소할 가능성이 크기 때문이다.

둘째, 데이터센터의 대규모 확장이 AI 강국이라는 목표의 필수 조건은 아니다. 최근 초대형 AIDC를 유치할 위해 지방자치단체들이 경쟁하고 있다. DC 사업자들은 AI 강국을 위해 대규모로 건설해야 할 DC를 위한 전기가 부족하다고 주장하기도 한다. 많은 수의 데이터센터 건설이 AI 강국의 지름길이라면, 전 세계 AI 최강국 중 하나는 DC 전기가 국가 총 전력의 18%를 차지하는 아일랜드일 것이다. DC는 결국 수요지에 위치한다. ChatGPT 서버가 전세계 DC에 분포되어 있듯이, 세계적인 AI 모델을 개발하기 위해 반드시 국내에 DC가 많아야 하는 것은 아니다. AI 강국은 DC 확장보다는 우수한 AI 모델에 대한 연구와 개발로 달성될 수 있으며, 다양한 산업 분야에 특화된 모델들을 위주로 개발이 이뤄진다면 거대 범용 모델 대비 DC 수요는 작을 수 있다.

셋째, DC 에너지 소비 전망의 양방향 불확실성에 모두 대비해야 한다. 제2장의 내용을 한 단어로 정리하면 “불확실성”이다. AI 시대를 생각할 때 에너지 소비의 ‘상방’ 불확실성에 치우치는 경향이 크나, ‘하방’ 불확실성에도 대비해야 한다. 예를 들어, 국내 AIDC의 전기 소비를 예상할 때, 대부분 AI 수요가 폭증하는 경우만을 우려하지만, 현실은 AI 수요가 예상보다 적을 경우도 발생할 수 있다. 현재 우리나라는 지자체의 DC 유치 경쟁과 정부의 지방 분산화 정책이 맞물려, 시설부담금 할인, 예비전력 요금 면제를 비롯해 여러 지원책들이 실행 및 제안되고 있다. 이러한 지원책들은 현재 한시적으로 실행되고 있기는 하나, 장기적으로는 신중히

고려되어야 한다. 예상보다 적은 AI 수요에 등에 따른 투자 실패는 결국 사회 경제적 국민 부담으로 돌아올 수 있다.

넷째, 정책 담당자는 미디어의 글로벌 DC 전기 소비 증가에 대한 잘못되거나 극단적인 정보에 휘둘리지 말아야 한다. 예를 들어, “기존 구글 검색당 전기 소비 0.3Wh vs. ChatGPT 2.9Wh”와 같은 과거의 추정치에 기반한 10배 전기 폭증 시나리오, 데이터센터 냉방용 전기 소비 비중 40~50% 등과 같은 정확하지 않은 정보들로 AI 시대 데이터센터 증가로 국내 전력 소비가 폭발할 것이라는 오해가 양산되고 있다. 제2장과 제3장에서 보았듯이, 최신 정보를 반영한 ChatGPT의 검색당 전기 소비는 0.3Wh에 불과하며, DC 냉방용 부하 비중의 글로벌 평균은 19~24%, 우리나라는 17% 수준이다. 또한, 국내 총 DC 전력 전망에서 살펴보았듯이, 국내 DC 증가가 적어도 중단기적으로 국가 전력 수요 폭증과 이에 따른 전력 공급 부족으로 이어질 가능성은 낮다.

마지막으로, 그럼에도 불구하고 장기적인 관점에서 제4장에서 제안한 DC 관련 정책들을 보완해야 한다. 제3장에서 언급했듯이, 2060년에는 국내 DC의 전력 수요 비중이 10~20%에 달할 수도 있다. 미래학자 로이 아마라(Roy Amara)의 명언처럼 인류는 단기적으로는 기술의 영향력을 과대 평가하고, 장기적으로는 과소 평가하는 경향이 있다. 데이터센터의 전기 소비 증가에 관해서도 아마라의 법칙이 적용된다고 생각한다. 단기적으로 DC의 에너지 소비를 과대 평가해서는 안되지만, 동시에 장기적으로 DC의 에너지 소비를 과소 평가해서도 안될 것이다.

참고문헌

〈국내 문헌〉

- 국토교통부. (2024.12.). 제3차 녹색건축물 기본계획.
- 김철현 & 박광수. (2015). 국내 전력 소비 패턴의 구조적 변화 및 변화요인 분석.
https://www.keei.re.kr/pdfOpen.es?bid=0001&list_no=81735&seq=1
- 네이버. (2022). TCFD REPORT. Towards 2040 Carbon Negative. https://campaign-cdn.pstatic.net/0/campaign/2022/10/environment/pdf/NAVER_2022_TCFD_KOR.pdf
- 산업통상자원부. (2023.3.9.). 데이터센터 수도권 집중 완화 방안.
- 산업통상자원부. (2024). 2024년도 지능형전력망 시행계획.
- 산업통상자원부. (2024.6.3.). 「분산에너지 설비 설치계획 제출 및 절차 등에 관한 규정」 제정(안) 행정예고. 산업통상자원부 공고 제2024-445호.
<https://motie.go.kr/kor/article/ATCLa6723dc7b/341/view>
- 산업통상자원부. (2024.11.11.). 「전력계통영향평가 제도 운영에 관한 규정」 제정(안) 재행정예고. 산업통상자원부 공고 제2024-779호.
<https://motie.go.kr/kor/article/ATCLa6723dc7b/376/view>
- 산업통상자원부. (2024.12.3.). 「분산에너지 설비 설치계획 제출 및 절차 등에 관한 규정」 제정·고시 산업통상자원부 고시 제2024-187호
<https://motie.go.kr/kor/article/ATCL0c554f816/64713/view#>
- 산업통상자원부. (2025.3.13.). 제11차 전력수급기본계획(2024~2038).
- 산업통상자원부 신산업분산에너지과. (2025.2.). 제6차 집단에너지 공급 기본계획.
- 에너지경제연구원. (2025). KEEI 단기 에너지수요전망 2025 상반기호.
https://kesis.keei.re.kr/pdfOpen.es?bid=0020&list_no=2429&seq=1

- 오세신. (2019). 데이터센터 폐열의 지역냉난방 활용 사례와 정책적 시사점. 수시연구보고서. 에너지경제연구원.
https://www.keei.re.kr/pdfOpen.es?bid=0001&list_no=81973&seq=1
- 이상준. (2014). 비상용 자가발전기를 이용한 전력수요관리 방안연구. 수시연구보고서 에너지경제연구원.
https://www.keei.re.kr/pdfOpen.es?bid=0001&list_no=81645&seq=1
- 한국무역협회 베이징지부. (2022). 중국 디지털경제 인프라사업 동수서산(东数西算) 추진 동향. 차이나 마켓 리포트 2022.4.29.
- 한국수자원공사. (2023.11.28.). 한국수자원공사-네이버(주) 재생에너지 직접전력거래계약(PPA) 체결.
https://www.kwater.or.kr/news/repoView.do?seq=134082&brdId=KO26&orderByField=&orderByDirection=&s_mid=36
- 한국전력공사. (2025). 제11차 전력수급기본계획 관련 장기 송변전설비계획(2024~2038).
- 한국전력공사 보도자료. (2025.3.11). 한전, 「2025년도 자체감사 책임자 회의」 서 ‘데이터센터 전기공급실태 특별감사’ 성과 발표.
- KDCC(Korea Data Center Council). (2024). KOREA DATA CENTER MARKET Report 2024~2027.
- KDCC(Korea Data Center Council). (2025). KOREA DATA CENTER MARKET Report 2025-2028.
- Savills Korea. (2024). 한국 데이터센터 시장 2024 1H. <https://pdf.savills.asia/asia-pacific-research/korea-research/korea-spotlight/1h2024-korea-data-center-market-final-rev.pdf>

〈외국 문헌〉

- BCA & IMDA. (2024). GMDC: 2024 BCA-IMDA Green Mark for Data Centres.
https://www1.bca.gov.sg/docs/default-source/docs-corp-buildsg/sustainability/20241008_gmdc2024_ver1.pdf?sfvrsn=407a219c_0
- Benhari, A., Denneulin, Y., Desprez, F., Dufossé, F., & Trystram, D.(2024). Green HPC: An analysis of the domain based on Top500.
<http://arxiv.org/abs/2403.17466>

- Castro, D. (2024). Rethinking Concerns About AI's Energy Use.
<https://www2.datainnovation.org/2024-ai-energy-use.pdf>
- CEC(California Energy Commission). (2024). Enabling Energy Efficient Data Center in Smart Power Distribution Systems.
- Chauhan, S. (2024). The Growing Energy Demand of Data Centers: Impacts of AI and Cloud Computing. *International Journal for Multidisciplinary Research*, 6(4). <https://www.ijfmr.com/papers/2024/4/26591.pdf>
- Chui, M., Hazan, E., Roberts, R., Singla, A., Smaje, K., Sukharevsky, A., Yee, L., & Zimmel, R. (2023). The economic potential of generative AI The next productivity frontier
<https://www.mckinsey.com/~media/mckinsey/business%20functions/mckinsey%20digital/our%20insights/the%20economic%20potential%20of%20generative%20ai%20the%20next%20productivity%20frontier/the-economic-potential-of-generative-ai-the-next-productivity-frontier.pdf>
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3-73.
<https://www.wessa.net/download/stl.pdf>
- Coherent Market Insights. (2025). On Device Intelligence Market Share and Size, 2025-2032. <https://www.coherentmarketinsights.com/industry-reports/on-device-intelligence-market>
- Davenport, C., Lee, B., Corbett, B., Ritchie, J., Jaiya, J., Venugopal, V., Cash, N., Halferty, O., Singer, B., Mackay, J., Miller, J., Delaney, M., Mehta, N., Modak, A., Hari, T., & Revich, J. (2024.4.28.). AI, data centers and the coming US power demand surge. Goldman Sachs Global Investment Research.
<https://www.goldmansachs.com/pdfs/insights/pages/generational-growth-ai-data-centers-and-the-coming-us-power-surge/report.pdf>
- Delestrac, P., Bhattacharjee, D., Yang, S., Moolchandani, D., Catthoor, F., Torres, L., Novo, D., & Multi, al. (2024). Multi-level Analysis of GPU Utilization in ML Training Workloads. *Automation and Test in Europe Conference*. <https://hal.umontpellier.fr/hal-04523554>

- Dell'Acqua, F., Saran, R., Mcfowland III, E., Krayner, L., Mollick, E., Candelon, F., Lifshitz-Assaf, H., Lakhani, K. R., & Kellogg, K. C. (2023). Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality. <https://ssrn.com/abstract=4573321>
- Department of General Seviles. (2014.10.10.). ENERGY EFFICIENCY IN DATA CENTERS AND SERVER ROOMS. Management Memo. https://www.dgs.ca.gov/-/media/Divisions/AD/OTAS/Memos/Memos/2010-2019/MM14_09.pdf
- De Roucy-Rochegonde, L., & Buffard, A. (2025). AI, Data Centers and Energy Demand: Reassessing and Exploring the Trends. Ifri. <https://www.ifri.org/en/papers/ai-data-centers-and-energy-demand-reassessing-and-exploring-trends-0>
- Desislavov, R., Martínez-Plumed, F., & Hernández-Orallo, J. (2023). Trends in AI inference energy consumption: Beyond the performance-vs-parameter laws of deep learning. *Sustainable Computing: Informatics and Systems*, Vol. 38. <https://doi.org/10.1016/j.suscom.2023.100857>
- de Vries, A. (2023). The growing energy footprint of artificial intelligence. In *Joule* (Vol. 7, Issue 10, pp. 2191-2194). Cell Press. <https://doi.org/10.1016/j.joule.2023.09.004>
- de Vries-Gao, A. (2025). Artificial intelligence: Supply chain constraints and energy implications. *Joule*, 9(6), 101961. <https://doi.org/10.1016/J.JOULE.2025.101961>
- Donnellan, D., Analyst, R., Lawrence, A. Bizo, D., Judge, P., O'Brien, J., David, J., Smolaks, M., Williams-George, J., & Weinschenk, R. (2024). Uptime Institute Global Data Center Survey 2024. In Research Analyst Max Smolaks. <https://datacenter.uptimeinstitute.com/rs/711-RIA-145/images/2024.GlobalDataCenterSurvey.Report.pdf>
- ENERGY STAR. (2014.11.). ENERGY STAR Score for Data Centers in the United States Technical Reference OVERVIEW. <https://www.energystar.gov/sites/default/files/tools/Data%20Centers.pdf>

- EPRI. (2024). Powering Intelligence_Analyzing Artificial Intelligence and Data Center Energy Consumption.
<https://www.epri.com/research/products/3002028905>
- Fieni, G., Rouvoy, R., & Seinturier, L. (2025). xPUE: Extending Power Usage Effectiveness Metrics for Cloud Infrastructures.
<https://doi.org/10.1109/TSUSC.2025.3549687>
- Gao, Y., He, Y., Li, X., Zhao, B., Lin, H., Liang, Y., Zhong, J., Zhang, H., Wang, J., Zeng, Y., Gui, K., Tong, J., & Yang, M. (2024). An Empirical Study on Low GPU Utilization of Deep Learning Jobs. In 2024 IEEE/ACM 46th International Conference on Software Engineering (ICSE '24). Lisbon, Portugal (Vol. 1). <https://doi.org/10.1145/3597503.3639232>
- Ghatikar, G., Piette, M. A., Fujita, S., Mckane, A., Dudley, J. H., & Radspieler, A. (2010). Demand Response and Open Automated Demand Response Opportunities for Data Centers. Berkeley Lab
<https://eta.lbl.gov/publications/demand-response-and-open-automated>
- Gonzalez-Salazar, M. A., Kirsten, T., & Prchlik, L. (2018). Review of the operational flexibility and emissions of gas- and coal-fired power plants in a future with growing renewables. In Renewable and Sustainable Energy Reviews (Vol. 82, pp. 1497-1513). Elsevier Ltd.
<https://doi.org/10.1016/j.rser.2017.05.278>
- Grand View Research. (2025). On-device AI Market Size And Share, Industry Report, 2030. <https://www.grandviewresearch.com/industry-analysis/on-device-ai-market-report>
- Greenpeace. (2021). China 5G and Data Center Carbon Emissions Outlook 2035. <https://www.greenpeace.org/static/planet4-eastasia-stateless/2021/05/a5886d59-china-5g-and-data-center-carbon-emissions-outlook-2035-english.pdf>
- Heatubun, D., Dragan, I., Bolchi, M., Lopes Bautista, P., Hinterholzer, S., Hintemann, R., Marx, N., & Furda, P. (2025). Assessment of the energy performance and sustainability of data centres in the EU.
- Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., de Las Casas, D., Hendricks, L. A., Welbl, J., Clark, A., Hennigan, T., Noland, E., Millican, K., van den Driessche, G., Damoc, B., Guy, A.,

- Osindero, S., Simonyan, K., Elsen, E., ... Sifre, L. (2022). Training Compute-Optimal Large Language Models. *Advances in Neural Information Processing Systems*, 35. <https://arxiv.org/pdf/2203.15556>
- IDC. (2024). AI-driven growth in datacenter energy consumption. <https://my.idc.com/getdoc.jsp?containerId=prUS52611224>
- IDC. (2025). South Korea Datacenter Operations and Colocation Services Market Trends, 2025. <https://my.idc.com/getdoc.jsp?containerId=AP53247925&pageType=PRINTERFRIENDLY>
- IEA. (2008). Combined Heat and Power. <https://www.iea.org/reports/combined-heat-and-power>
- IEA. (2024). Electricity 2024. Paris. <https://www.iea.org/reports/electricity-2024>
- IEA. (2025a). Electricity 2025. Paris. <https://www.iea.org/reports/electricity-2025>
- IEA. (2025b). Energy and AI. Paris. <https://www.iea.org/reports/energy-and-ai>
- IEA 4E EDNA. (2022). Energy Efficiency Metrics for Data Centres. <https://www.iea-4e.org/wp-content/uploads/2022/10/EDNA-Studies-Metrics-for-data-centre-efficiency-Final.pdf>
- IEA 4E EDNA. (2023). Policies for Data Centre Energy Efficiency: Scope, Trends and Availability of Data. <https://www.iea-4e.org/wp-content/uploads/publications/2023/02/DC-Workstream-activity-1-publication-version.pdf>
- IEA 4E EDNA. (2024). Policy development on energy efficiency of data centres. <https://www.iea-4e.org/wp-content/uploads/2024/02/Policy-development-on-energy-efficiency-of-data-centres-draft-final-report-v1.05.pdf>
- IEA-ETSAP. (2010). Combined Heat and Power. https://iea-etsap.org/E-TechDS/PDF/E04-CHP-GS-gct_ADfinal.pdf

- Illinois DCEO. (2025). Data Center Investment Program 2024 Annual Report.
<https://dceo.illinois.gov/content/dam/soi/en/web/dceo/aboutdceo/reportsrequiredbystatute/2024-data-centers-annual-report-submission.pdf>
- Intel. (2025). Intel® Gaudi® 3 AI Accelerator white paper
<https://www.intel.com/content/www/us/en/content-details/817486/intel-gaudi-3-ai-accelerator-white-paper.html>
- ISO/IEC 30134-2. (2016). Information technology — Data centres — Key performance indicators — Part 2: Power usage effectiveness (PUE). In International Organization for Standardization.
<https://www.iso.org/standard/63451.html>
- ISO/IEC 30134-3. (2016). Information Technology—Data Centres—Key Performance Indicators—Part 3: Renewable Energy Factor (REF).
<https://www.iso.org/standard/66127.html>
- ISO/IEC 30134-4. (2017). Information technology—Data centres—Key performance indicators—Part 4: IT Equipment Energy Efficiency for servers (ITEEsv). <https://www.iso.org/standard/66191.html>
- ISO/IEC 30134-5. (2017). Information technology—Data centres—Key performance indicators—Part 5: IT Equipment Utilization for servers (ITEUsv). <https://www.iso.org/standard/66934.html>
- ISO/IEC 30134-6. (2021). Information technology—Data centres key performance indicators—Part 6: Energy Reuse Factor (ERF).
<https://www.iso.org/standard/71717.html>
- ISO/IEC 30134-7. (2023). Information technology—Data centres key performance indicators—Part 7: Cooling efficiency ratio (CER).
<https://www.iso.org/standard/80493.html>
- ISO/IEC 30134-8. (2022). Information technology—Data centres key performance indicators—Part 8: Carbon usage effectiveness (CUE).
<https://www.iso.org/standard/77691.html>
- ISO/IEC 30134-9. (2022). Information technology—Data centres key performance indicators—Part 9: Water usage effectiveness (WUE).
<https://www.iso.org/standard/77692.html>

- Joi, P. (2025.2.). Using AI from lab to jab: how did artificial intelligence help us develop and deliver COVID-19 vaccines? Gavi The Vaccine Alliance. <https://www.gavi.org/vaccineswork/using-ai-lab-jab-how-did-artificial-intelligence-help-us-develop-and-deliver-covid>
- Kamiya, G., & Bertoldi, P. (2024). Energy Consumption in Data Centres and Broadband Communication Networks in the EU. <https://doi.org/10.2760/706491>
- Kamiya, G. & Coroama, V. C. (2025). Data Centre Energy Use: Critical Review of Models and Results. EDNA - IEA 4E TCP. <https://www.iea-4e.org/wp-content/uploads/2025/05/Data-Centre-Energy-Use-Critical-Review-of-Models-and-Results.pdf>
- Kaplan, J., McCandlish, S., Henighan OpenAI, T., Brown OpenAI, T. B., Chess OpenAI, B., Child OpenAI, R., Gray OpenAI, S., Radford OpenAI, A., Wu OpenAI, J., & Amodei OpenAI, D. (2020). Scaling Laws for Neural Language Models. <https://arxiv.org/pdf/2001.08361>
- Lam, R., Sanchez-Gonzalez, A., Willson, M., Wirsberger, P., Fortunato, M., Alet, F., Ravuri, S., Ewalds, T., Eaton-Rosen, Z., Hu, W., Merose, A., Hoyer, S., Holland, G., Vinyals, O., Stott, J., Pritzel, A., Mohamed, S., & Battaglia, P. (2023). Learning skillful medium-range global weather forecasting. *Science*, 382(6677), 1416-1422. <https://doi.org/10.1126/SCIENCE.ADI2336>
- Latif, I., Newkirk, A. C., Carbone, M. R., Munir, A., Lin, Y., Koomey, J., Yu, X., & Dong, Z. (2024). Empirical Measurements of AI Training Power Demand on a GPU-Accelerated Node. <https://doi.org/10.1109/ACCESS.2025.3554728>
- Libon Council Research. (2024). Sustainable Computing for a Sustainable Planet. https://lisboncouncil.net/wp-content/uploads/2024/04/LISBON_COUNCIL_Research_Sustainable_Computing_For_A_Sustainable_Planet.pdf
- Liu, R., & Zeng, W. (2025). Automatic detection of structural defects in tunnel lining via network pruning and knowledge distillation in YOLO. *Structural Health Monitoring*. <https://doi.org/10.1177/14759217241289066>

- Li, Y., & Li, Y. (2025). AI Load Dynamics-A Power Electronics Perspective.
<http://arxiv.org/abs/2502.01647>
- Luccioni, A. S., Jernite, Y., & Strubell, E. (2024). Power Hungry Processing: Watts Driving the Cost of AI Deployment? 2024 ACM Conference on Fairness, Accountability, and Transparency, FAccT 2024, 85-99.
<https://doi.org/10.1145/3630106.3658542>
- Luccioni, A. S., Viguier, S., & Ligozat, A.-L. (2022). Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model.
<http://arxiv.org/abs/2211.02001>
- Masanet, E., Lei, N., & Koomey, J. (2024). To better understand AI's growing energy use, analysts need a data revolution. *Joule*, 8(9), 2427-2436.
<https://doi.org/10.1016/J.JOULE.2024.07.018>
- Masanet, E., Shehabi, A., Lei, N., Smith, S., & Koomey, J. (2020). Recalibrating global data center energy-use estimates. *Science*, 367(6481), 984-986.
<https://doi.org/10.1007/s12053-019-09809-8>
- Maslej, M., Fattorini, L., Perrault, R., Gil, Y., Parli, V., Kariuki, N., Capstick, E., Reuel, A., Brynjolfsson, E., Etchemendy, J., Ligett, K., Lyons, T., Manyika, J., Niebles, J. C., Shoham, Y., Wald, Y., Walsh, T., Hamrah, A., Santarlasci, L., ... Oak, S. (2025). The AI Index 2025 Annual Report.
https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf
- Mavromatis, I., Katsaros, K., & Khan, A. (2024). Computing Within Limits: An Empirical Study of Energy Consumption in ML Training and Inference.
<http://arxiv.org/abs/2406.14328>
- McKinsey & Company. (2024.10.29.). AI power: Expanding data center capacity to meet growing demand.
<https://www.mckinsey.com/industries/technology-media-and-telecommunications/our-insights/ai-power-expanding-data-center-capacity-to-meet-growing-demand>
- Mitsubishi Electric. (2024). Mitsubishi Electric, HACARUS to Expand AI Visual-inspection Business.
<https://www.mitsubishielectric.com/en/pr/2024/pdf/0122.pdf>

- Mordor Intelligence Research & Advisory. (2025). Global Data Center Generator Market (2025-2030). <https://www.mordorintelligence.com/industry-reports/data-center-generator-market>
- Mosca, M., & Piani, M. (2024). QUANTUM THREAT TIMELINE REPORT 2024. <https://globalriskinstitute.org/publication/2024-quantum-threat-timeline-report/>
- Moura, P., Nuttall, C., Harrison, B., Jehle, C., & de Almeida, A. (2016). Energy savings potential of uninterruptible power supplies in European Union. *Energy Efficiency*, 9, 993~1013. <https://doi.org/10.1007/s12053-015-9406-7>
- Narasingu, S. P. (2025). AI-POWERED SOLUTIONS FOR ENHANCING ENERGY EFFICIENCY AND RESOURCE MANAGEMENT IN MODERN DATA CENTERS. *INTERNATIONAL JOURNAL OF COMPUTER ENGINEERING AND TECHNOLOGY*, 16(1), 1065-1078. https://doi.org/10.34218/IJCET_16_01_083
- Nguyen, M.-T., Nguyen, D.-H., Sabahi, S., Le, H., Yang, J., & Hotta, H. (2023). When Giant Language Brains Just Aren't Enough! Domain Pizzazz with Knowledge Sparkle Dust. <https://arxiv.org/pdf/2305.07230>
- Nøland, J. K., Hjelmeland, M., & Korpås, M. (2024). Will Energy-Hungry AI Create a Baseload Power Demand Boom? <https://doi.org/10.36227/techrxiv.171710280.07098775/v1>
- NVIDIA Technical Blog. (2024.8.4). How to Prune and Distill Llama-3.1 8B to an NVIDIA Llama-3.1-Minitron 4B Model. <https://developer.nvidia.com/blog/how-to-prune-and-distill-llama-3-1-8b-to-an-nvidia-llama-3-1-minitron-4b-model/>
- OECD. (2024). Explanatory memorandum on the updated OECD definition of an AI system. OECD Artificial Intelligence Papers, No. 8. https://www.oecd.org/content/dam/oecd/en/publications/reports/2024/03/explanatory-memorandum-on-the-updated-oecd-definition-of-an-ai-system_3c815e51/623da898-en.pdf
- OECD. (2025). Introducing the OECD AI Capability Indicators. OECD Publishing. <https://doi.org/10.1787/be745f04-en>

- Patel, P., Goiri, Í., Choukse, E., Warriier, B., Bianchini, R., Zhang, C., & Mahalingam, N. (2024). Characterizing Power Management Opportunities for LLMs in the Cloud. *International Conference on Architectural Support for Programming Languages and Operating Systems - ASPLOS*, 3, 207-222. <https://doi.org/10.1145/3620666.3651329>
- Patterson, M. K., Poole, S. W., Hsu, C.-H., Maxwell, D., Tschudi, W., Coles, H., Martinez, D. J., & Bates, N. (2013). TUE, a new energy-efficiency metric applied at ORNL's Jaguar. https://datacenters.lbl.gov/sites/default/files/isc13_tuepaper.pdf
- Pilz, K. F., Rahman, R., Sanders, J., Frymire, L., & Heim, L. (2025.4.30). The computational performance of leading AI supercomputers has doubled every nine months. *Epoch AI*. <https://epoch.ai/data-insights/ai-supercomputers-performance-trend>
- Rajput, S., & Sharma, T. (2024). Benchmarking Emerging Deep Learning Quantization Methods for Energy Efficiency. *2024 IEEE 21st International Conference on Software Architecture Companion (ICSA-C)*, 238-242. <https://ieeexplore.ieee.org/document/10628367>
- Schlissel, D. & Wamsted, D. (2024). SMRs: Still Too Expensive, Too Slow and Too Risky. https://ieefa.org/sites/default/files/2024-05/SMRs%20Still%20Too%20Expensive%20Too%20Slow%20Too%20Risky_May%202024.pdf
- Scripps Research. (2025). AI pinpoints new anti-aging drug candidates. *Scripps Research News*. <https://www.scripps.edu/news-and-events/press-room/2025/20250529-petrascheck-ai-anti-aging.html>
- Sevilla, J. & Roldán, E. (2024). Training Compute of Frontier AI Models Grows by 4-5x per Year. *Epoch AI*. <https://epoch.ai/blog/training-compute-of-frontier-ai-models-grows-by-4-5x-per-year>
- Shehabi, A., Smith, S. J., Hubbard, A., Newkirk, A., Lei, N., Abu Bakar Siddik, M., Holecek, B., Koomey, J., Masanet, E., & Sartor, D. (2024). *2024 United States Data Center Energy Usage Report*. <https://escholarship.org/uc/item/32d6m0d1>

- Shehabi, A., Smith, S. J., Masanet, E., & Koomey, J. (2018). Data center growth in the United States: Decoupling the demand for services from electricity use. *Environmental Research Letters*, 13(12). <https://doi.org/10.1088/1748-9326/aaec9c>
- Siderius, H.-P., Triana, A. D., & Brocklehurst, F. (2024). Policy measures for energy efficiency of data centres. *Eceee Summer Study 2024*. <https://www.researchgate.net/publication/381670475>
- Song, Y., Zhang, Y., Sun, Y., & Shi, W. (2009). Utility analysis for Internet-oriented server consolidation in VM-based data centers . 2009 IEEE International Conference on Cluster Computing and Workshops (CLUSTER) , 1-10. <https://doi.org/10.1109/CLUSTER.2009.5289190>
- The WHITE HOUSE. (2025.7.) Americas-AI-Action-Plan. <https://www.whitehouse.gov/wp-content/uploads/2025/07/Americas-AI-Action-Plan.pdf>
- Tran, N. P., Jaumard, B., & Delgado, O. (2025). Energy-Aware LLMs: A step towards sustainable AI for downstream applications. <http://arxiv.org/abs/2503.17783>
- Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- Vora, V. A. (2025). Serverless computing and container synergy in network architectures. *World Journal of Advanced Research and Reviews*, 26(1), 3429-3438. <https://doi.org/10.30574/wjarr.2025.26.1.1472>
- Walsh, K. (2024). Data centres and energy. *Houses of the Oireachtas* https://data.oireachtas.ie/ie/oireachtas/libraryResearch/2024/2024-07-23_spotlight-data-centres-and-energy_en.pdf
- Wang, Z., Chu, Z., Doan, T. V., Ni, S., Yang, M., & Zhang, W. (2024). History, Development, and Principles of Large Language Models-An Introductory Survey. *AI and Ethics*, 5(3), 1955-1971. <https://doi.org/10.1007/s43681-024-00583-7>

- Widmann, T., Merkle, F., Nocker, M., & Schöttle, P. (2023). Pruning for Power: Optimizing Energy Efficiency in IoT with Neural Network Pruning. *Communications in Computer and Information Science*, 1826 CCIS, 251-263. https://link.springer.com/chapter/10.1007/978-3-031-34204-2_22
- Wu, A., & Brocklehurst, F. (2025). Total Energy Model 4.0-Data Centres. <https://www.iea-4e.org/wp-content/uploads/2025/05/TEM-4-Report-Draft-v0-15-FINAL.pdf>
- Wu, C.-J., Raghavendra, R., Gupta, U., Acun, B., Ardalani, N., Maeng, K., Chang, G., Behram, F. A., Huang, J., Bai, C., Gschwind, M., Gupta, A., Ott, M., Melnikov, A., Candido, S., Brooks, D., Chauhan, G., Lee, B., Lee, H.-H. S., ... Hazelwood, K. (2022). Sustainable ai: Environmental implications, challenges and opportunities. *Proceedings of Machine Learning and Systems*, volume 4, 795-813. https://proceedings.mlsys.org/paper_files/paper/2022/hash/462211f67c7d858f663355eff93b745e-Abstract.html
- 国家发展改革委 工业和信息化部 国家能源局 国家数据局. (2024.7.3.) 数据中心绿色低碳发展专项行动计划. 发改环资[2024]970号 https://www.ndrc.gov.cn/xwdt/tzgg/202407/t20240723_1391895.html
- 国家发展改革委 国家数据局 工业和信息化部. (2024.12.31.). 国家数据基础设施建设指引的通知. 发改数据[2024]1853号 https://www.gov.cn/zhengce/zhengceku/202501/content_6996487.htm
- 經濟部産業省(경제산업성). (2025.5.14.). 令和7年度 第2回工場等判断基準WG 省エネ法に関する措置について https://www.meti.go.jp/shingikai/enecho/shoene_shinene/sho_energy/kajo_handan/pdf/2025_002_03.pdf
- 經濟部産業省(경제산업성). (2025.7.1.). 2025年度第2回 総合資源エネルギー調査会 省エネルギー・新エネルギー分科会 省エネルギー小委員会 工場等判断基準ワーキンググループ.

〈웹사이트〉

(국내)

강원도민일보. (2025.1.14). 전력 공급망 부족에 삼척 블루파워 상업운전 중단. 검색일: 2025.9.15.

<https://www.kado.net/news/articleView.html?idxno=1288318&ref=ai-ethics.kr>

공공데이터포털(국토교통부 건축HUB 건물에너지정보 서비스) 검색일: 2025.6.10.

<https://www.data.go.kr/data/15135963/openapi.do>

국가에너지통계종합정보시스템(KESIS). 검색일: 2025.8.25. <https://kesis.keei.re.kr/>

그린데이터센터인증. 검색일: 2025.9.3.

<https://kdcc.or.kr/green/pageview.do?url=green01&keyvalue=green>

기후에너지데이터뱅크. (2024.12.27.). 수자원공사, SK하이닉스에 RE100용 수력 전기 공급. 검색일: 2025.9.9.

<https://edata.ekn.kr/article/view/ekn202412310001>

냉난방공조 신재생 녹색건축 전문저널. (2022.6.12.). 산업 디지털화 기반...데이터센터 현재와 미래. 검색일: 2025.7.12.

<https://www.kharn.kr/mobile/article.html?no=19486>

네이버 보도자료. (2024.6.4.). 검색일: 2025.9.27.

<https://www.navercorp.com/media/pressReleasesDetail?seq=31837>

녹색건축포털 그린투게더. 검색일: 2025.6.15.

https://www.greentogether.go.kr/main.do;jsessionid=ZHWROe1Fg6mZZVtjMspRmXWa87kd8J1DTAk2YKFAazCqcHKovmU4qt27TuRnNnTd.nbemisp1_servlet_engineGbp

삼성SDS 클라우드 용어집. 클라우드 서비스(Cloud Service)란? 검색일: 2025.5.21.

<https://www.samsungsds.com/kr/cloud-glossary/cloud-service.html>

연합뉴스. (2023.6.2.). 非수도권에 데이터센터 건설하면 전기 끌어오는 비용 “반값.”

검색일: 2025.9.25.

<https://www.yna.co.kr/view/AKR20230601163300003?input=1195m>

연합뉴스. (2025.5.30.). 수자원공사, SK하이닉스에 남강댐 수력발전 친환경 에너지 공급.

검색일: 2025.9.25. <https://www.yna.co.kr/view/AKR20250530136100063>

울산저널. (2025.7.19.). 7조 데이터센터 유치... “울산에 풍부한 산업 데이터를 연료로 AI 고속도로 달릴 스타트업 키워야”. 검색일: 2025.9.15.

<https://m.usjournal.kr/news/newsview.php?ncode=1065615693820194>

제로에너지건축물. 검색일: 2025.9.4.

https://min24.energy.or.kr/nzeb/BC/BC03/BC03_05_002.do

한국에너지공단. 에너지 사용계획 협의. 검색일: 2025.9.4.

<https://www.energy.or.kr/front/conts/105002001010000.do>

한국전력공사. (2024.3.21.). 데이터센터 전기공급 현황. 공공데이터포털. 검색일: 2025.8.8. <https://www.data.go.kr/data/15127315/fileData.do>

한국전력공사. 기본공급약관. 검색일: 2025.8.8.

<https://online.kepco.co.kr/TEM022D00>

한국전력공사. 전력통계월보. 검색일: 2025.8.8.

<https://www.kepco.co.kr/home/customer/library/electricity-statistics/monthly-stats/boardList.do>

한국정보통신기술협회. 정보통신표준화위원회. 검색일: 2025.9.17.

<https://committee.tta.or.kr/index.jsp>

(국외)

Amazon. (2022.10.18.). reMARS revisited: Amazon’s supply chain optimization.

Amazon Science. 검색일: 2025.8.8. <https://www.amazon.science/latest-news/remars-revisited-amazons-supply-chain-optimization>

Biron, L. (2023.11.29.). Google DeepMind Adds Nearly 400,000 New Compounds to Berkeley Lab’s Materials Project – Berkeley Lab News Center. Berkeley Lab.

검색일: 2025.8.8. <https://newscenter.lbl.gov/2023/11/29/google-deepmind-new-compounds-materials-project/>

Carbon Brief. (2025.4.6.). Explainer: How China is managing the rising energy demand from data centres. 검색일: 2025.6.4.

<https://www.carbonbrief.org/explainer-how-china-is-managing-the-rising-energy-demand-from-data-centres/>

CompuDynamics. (2024.6.25.). The “Liquidification” of Data Center Cooling.

검색일: 2025.9.25. <https://compu-dynamics.com/blog/design/the-liquidification-of-data-center-cooling/>

- Coursera. (2025.6.9.). Transformers vs. Convolutional Neural Networks: What's the Difference? 검색일: 2025.8.8.
<https://www.coursera.org/articles/transformers-vs-convolutional-neural-networks>
- DeepAware AI. Japan data center regulation. 검색일: 2025.8.25.
<https://www.deepawareai.com/knowledge-base/japan-data-center-regulation>
- Dgtl Infra. (2023.12.15.). Modular Data Centers: Prefabricated Containers and Modules. 검색일: 2025.8.8. <https://dgtlinfra.com/modular-data-centers/>
- Epoch AI. Data on AI Models. 검색일: 2025.5.28. <https://epoch.ai/data/notable-ai-models#explore-the-data>
- Epoch AI. Data on AI Models. 검색일: 2025.5.28.
https://epoch.ai/data/generated/ai_models.zip
- European Commission. Delegated Act -ANNEXES to the establishment of a common Union rating scheme for data centres. 검색일: 2025.9.15.
https://ec.europa.eu/info/law/better-regulation/have-your-say/initiatives/13818-Data-centres-in-Europe-reporting-scheme_en
- Gartenberg, C. (2024.7.16.). How we built AlphaFold 3 to predict the structure and interaction of all of life's molecules. Google Keyword. 검색일: 2025.8.8. <https://blog.google/technology/ai/how-we-built-alphafold-3/>
- Georgia Recorder. (2024.5.8.). Governor vetoes pausing data center tax breaks, homestead exemption bump and higher ed assistance. 검색일: 2025.9.28.
<https://georgiarecorder.com/2024/05/08/governor-vetoes-tax-breaks-for-data-centers-homestead-exemption-increase-and-higher-ed-assistance/>
- Goldman Sachs. (2024.5.14.). AI is poised to drive 160% increase in data center power demand. 검색일: 2025.7.11.
<https://www.goldmansachs.com/insights/articles/AI-poised-to-drive-160-increase-in-power-demand>
- Google Cloud. Introduction to Cloud TPU. 검색일: 2025.8.19.
<https://cloud.google.com/tpu/docs/intro-to-tpu>

- Google Official Blog. (2009.1.11.). Powering a Google search. 검색일: 2025.7.5.
<https://googleblog.blogspot.com/2009/01/powering-google-search.html>
- IEA. Global data centre energy demand by data centre type. 검색일: 2025.6.2.
<https://www.iea.org/data-and-statistics/charts/global-data-centre-energy-demand-by-data-centre-type>
- INFOCOMM MEDIA DEVELOPMENT AUTHORITY. Green Data Centre (DC) Roadmap. 검색일: 2025.8.25. <https://www.imda.gov.sg/how-we-can-help/green-dc-roadmap>
- INFOCOMM MEDIA DEVELOPMENT AUTHORITY. (2022.7.20.). Launch of pilot Data Centre - Call for Application ("DC-CFA") to support the sustainable growth of DCs. 검색일: 2025.8.25.
<https://www.imda.gov.sg/resources/press-releases-factsheets-and-speeches/press-releases/2022/launch-of-pilot-data-centre---call-for-application-to-support-sustainable-growth-of-dcs>
- KT Cloud. (2025.6.2.). KT Cloud, 전국 최초 민·관 협력 “경북 AI 클라우드 데이터센터” 준공. AI·데이터 산업 생태계 활성화 기대. 검색일: 2025.6.25.
<https://tech.ktcloud.com/entry/2025-06-ktcloud-ai-cloud-datacenter-%EB%8D%B0%EC%9D%B4%ED%84%B0%EC%84%BC%ED%84%B0-%EC%A4%80%EA%B3%B5>
- Kunkel, C. (2025.1.29.). Data Centers Drive Buildout of Gas Power Plants and Pipelines in the Southeast. IEEFA. 검색일: 2025.7.17.
<https://ieefa.org/articles/data-centers-drive-buildout-gas-power-plants-and-pipelines-southeast>
- Lee, V., Seshadri, P., O’Niell, C., Choudhary, A., Holstege, B., & Deutscher, S. A. (2025.1.20.). Breaking barriers to data center growth. Boston Consulting Group. 검색일: 2025.7.17.
<https://www.bcg.com/publications/2025/breaking-barriers-data-center-growth>
- LOI n° 2025-391. 검색일: 2025.5.29.
<https://www.legifrance.gouv.fr/jorf/id/JORFTEXT000051538879>
- Lyons-Cunha, J. (2025). AI Energy Consumption: Is It a Problem? Built In. 검색일: 2025.11.4.
<https://builtin.com/artificial-intelligence/ai-energy-consumption>

- Merchant, A., & Cubuk, E. D. (2023.11.29.). Millions of new materials discovered with deep learning. 검색일: 2025.8.8.
<https://deepmind.google/discover/blog/millions-of-new-materials-discovered-with-deep-learning/>
- Moesker, N. (2024.10.4.). Context Length in LLMs: What Is It and Why It Is Important? DataNorth Blob. 검색일 2025.8.8.
<https://datanorth.ai/blog/context-length>
- Mozilla. (2024.2.6.). Mozilla Report: How Common Crawl's Data Infrastructure Shaped the Battle Royale over Generative AI. Mozilla Report, Mozilla Foundation. 검색일: 2025.7.25.
<https://www.mozillafoundation.org/en/blog/Mozilla-Report-How-Common-Crawl-Data-Infrastructure-Shaped-the-Battle-Royale-over-Generative-AI/>
- NAVER CLOUD PLATFORM. 검색일: 2025.6.26.
<https://www.ncloud.com/intro/dataCenter>
- Nolibois, Q. (2025.6.11.). NVIDIA Builds World's First Industrial AI Cloud to Advance European Manufacturing. NVIDIA Newsroom. 검색일: 2025.9.25.
<https://nvidianews.nvidia.com/news/nvidia-builds-worlds-first-industrial-ai-cloud-to-advance-european-manufacturing>
- NVIDIA. Data Centers Built for Advanced AI Reasoning. 검색일: 2025. 8.19.
<https://www.nvidia.com/en-us/data-center/>
- NVIDIA. Lab-in-the-Loop AI for Life Science. 검색일: 2025. 8.19.
<https://www.nvidia.com/en-us/use-cases/lab-in-the-loop-ai-for-life-science/>
- NY State Assembly Bill 2025-A9086A. 검색일: 2025.9.25.
<https://www.nysenate.gov/legislation/bills/2025/A9086/amendment/A>
- NY State Senate Bill 2025-S6394A. 검색일: 2025.9.25.
<https://www.nysenate.gov/legislation/bills/2025/S6394/amendment/A>
- Ontiveros, J. E., Patel, D. and Pandey A. (2025.6.25). AI Training Load Fluctuations at Gigawatt-scale – Risk of Power Grid Blackout? SemiAnalysis. 검색일: 2025. 9. 10.,
<https://semianalysis.com/2025/06/25/ai-training-load-fluctuations-at->

- gigawatt-scale-risk-of-power-grid-blackout/#the-nightmare-scenario-pt-2-cas
- OpenAI. (2025.1.21.). Announcing The Stargate Project 검색일: 2025.9.28.
<https://openai.com/index/announcing-the-stargate-project/>
- OpenAI. (2025.9.23.). OpenAI, Oracle, and SoftBank expand Stargate with five new AI data center sites 검색일: 2025.9.28.
<https://openai.com/index/five-new-stargate-sites/>
- Pfizer. (2024). mRNA Artificial Intelligence in Vaccine Development. 검색일: 2025.9.25.
https://www.pfizer.com/news/articles/how_a_novel_incubation_sandbox_helped_speed_up_data_analysis_in_pfizer_s_covid_19_vaccine_trial
- Quantum Zeitgeist. (2025.2.27.). Deepmind AI Cuts Google Data Center Cooling Bill By 40%, Revolutionizing Energy Efficiency, 검색일: 2025.6.17.
<https://quantumzeitgeist.com/deepmind-ai-cuts-google-data-center-cooling-bill-by-40-revolutionizing-energy-efficiency/>
- SemiAnalysis. (2023.2.9.). The Inference Cost Of Search Disruption – Large Language Model Cost Analysis. 검색일: 2025.7.25.
<https://semianalysis.com/2023/02/09/the-inference-cost-of-search-disruption/>
- SemiAnalysis. (2025.6.25.). AI Training Load Fluctuations at Gigawatt-scale – Risk of Power Grid Blackout? 검색일: 2025.7.25.
<https://semianalysis.com/2025/06/25/ai-training-load-fluctuations-at-gigawatt-scale-risk-of-power-grid-blackout/#the-nightmare-scenario-pt-2-cas>
- SemiAnalysis. Datacenter Industry Model. 검색일: 2025.7.3.
<https://semianalysis.com/datacenter-industry-model/>
- Syracus University School of Information Studies. Types of AI: Explore Key Categories and Uses. 검색일: 2025.9.24.
<https://ischool.syracuse.edu/types-of-ai/>
- The Korea Herald. (2025.6.1.). S. Korea is global No. 2 in paid ChatGPT users, OpenAI says. But does that mean anything? 검색일: 2025.9.24.
<https://www.koreaherald.com/article/10500190>

The WHITE HOUSE. (2025.7.23.). Accelerating Federal Permitting of Data Center Infrastructure – The White House. 검색일: 2025.9.28.
<https://www.whitehouse.gov/presidential-actions/2025/07/accelerating-federal-permitting-of-data-center-infrastructure/>

U.S. Green Building Council. LEED rating system. 검색일: 2025.9.27.
<https://www.usgbc.org/leed>

U.S. Green Building Council. LEED scorecard. 검색일: 2025.9.27.
<https://www.usgbc.org/leed-tools/scorecard>

Uptime Institute. Tier Classification System. 검색일: 2025.5.21.
<https://uptimeinstitute.com/tiers>

Wikipedia. GPT-3. 검색일: 2025.10.27. <https://en.wikipedia.org/wiki/GPT-3>

You, J. (2025.2.7.). How much energy does ChatGPT use. Epoch AI.
 검색일: 2025.10.27. <https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use>

财政部 生态环境部 工业和信息化部. (2023.4.10.).
 绿色数据中心政府采购需求标准(试行) 的通知. 검색일: 2025.10.25.
https://www.ccg.gov.cn/zcfg/mof/202304/t20230410_19680193.htm

韩雪 (2024.5.20.) 数据中心的低碳运营有效缓解AI巨大能耗需求. 검색일: 2025.10.25.
<https://www.drc.gov.cn/DocView.aspx?chnid=379&leafid=1338&docid=2907711>

〈법령〉

건축법 시행령[시행 2025. 10. 1.] [대통령령 제35811호, 2025. 10. 1., 타법개정]
 [별표 1] 용도별 건축물의 종류(제3조의5 관련). 검색일: 2025.5.30.
[https://law.go.kr/%EB%B2%95%EB%A0%B9%EB%B3%84%ED%91%9C%EC%84%9C%EC%8B%9D/\(%EA%B1%B4%EC%B6%95%EB%B2%95%EC%8B%9C%ED%96%89%EB%A0%B9,%EB%B3%84%ED%91%9C1\)](https://law.go.kr/%EB%B2%95%EB%A0%B9%EB%B3%84%ED%91%9C%EC%84%9C%EC%8B%9D/(%EA%B1%B4%EC%B6%95%EB%B2%95%EC%8B%9C%ED%96%89%EB%A0%B9,%EB%B3%84%ED%91%9C1))

방송통신발전 기본법 시행령([시행 2025. 4. 23.] [대통령령 제35470호, 2025. 4. 22., 일부개정]). 검색일: 2025.6.30.
<https://www.law.go.kr/LSW/lsSc.do?section=&menuId=1&subMenuId=15&tabMenuId=81&eventGubun=060101&query=%EC%A0%84%EA%B8%B0%ED%86%B5%EC%8B%A0%EC%82%AC%EC%97%85%EB%B2%95#J23:0>

정보통신망 이용촉진 및 정보보호 등에 관한 법률([시행 2025. 6. 4.] [법률 제20534호, 2024. 12. 3., 일부개정]). 검색일: 2025.6.30.

<https://www.law.go.kr/LSW/lsInfoP.do?lsiSeq=266671#0000>

정보통신망 이용촉진 및 정보보호 등에 관한 법률 시행령([시행 2025. 5. 20.] [대통령령 제35533호, 2025. 5. 20., 일부개정]) 검색일:2025.6.30.

<https://www.law.go.kr/%EB%B2%95%EB%A0%B9/%EC%A0%95%EB%B3%B4%ED%86%B5%EC%8B%A0%EB%A7%9D%EC%9D%B4%EC%9A%A9%EC%B4%89%EC%A7%84%EB%B0%8F%EC%A0%95%EB%B3%B4%EB%B3%B4%ED%98%B8%EB%93%B1%EC%97%90%EA%B4%80%ED%95%9C%EB%B2%95%EB%A5%A0%EC%8B%9C%ED%96%89%EB%A0%B9>

지능정보화기본법 [시행 2025. 3. 27.] [법률 제20410호, 2024. 3. 26., 일부개정]

검색일: 2025.6.30.

<https://www.law.go.kr/LSW/lsInfoP.do?lsId=000028&ancYnChk=0#0000>

Directive 2023/1791. 검색일: 2025.5.29.

[https://eur-lex.europa.eu/legal-](https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=OJ%3AJOL_2023_231_R_0001&qid=1695186598766)

[content/EN/TXT/?uri=OJ%3AJOL_2023_231_R_0001&qid=1695186598766](https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=OJ%3AJOL_2023_231_R_0001&qid=1695186598766)

EnEfG. 검색일: 2025.5.30.

<https://www.gesetze-im-internet.de/enefg/>

부록

〈표 부록-1〉 주요 AI 모델 전력 소비 및 특성 비교

Model Name	연도	훈련 (일수)	전력 소비 (MWh)	모델 설명
T5	2019	~20	85.7	텍스트 입력을 텍스트 출력으로 변환하도록 훈련된 다목적 모델로서 번역 및 요약과 같은 작업에 적합
Meena	2019	~30	232	대화를 나누고 문맥의 맥락을 더 자연스럽게 이해하도록 설계된 Google에서 개발한 챗봇 모델
Evolved Transformer	2019	~7	7.5	작업 성능 향상을 위해 신경망 구조 탐색을 사용하여 설계된 머신 러닝 모델
Switch Transformer	2020	~27	179	트랜스포머 모델의 변형으로, 활성화 값을 하위 집합으로 동적으로 라우팅함으로써 매개변수를 보다 효율적으로 다룸
GShard-600B	2020	~3	24.1	대규모 멀티태스킹 훈련에 최적화된 Google의 모델로, 방대한 양의 매개변수 처리를 지원함
ChatGPT-3	2021	~34	1,287	OpenAI의 최첨단 언어 모델로, 긴 문장에서도 일관되고 문맥에 맞는 문장을 생성함
BERT	2021	~6	2.8	좌우 방향(좌에서 우, 우에서 좌)으로 단어를 분석하여 문장 내 단어의 맥락을 이해하는 모델로, 감정 분석 및 기타 예측 작업에 널리 사용됨
Gopher	2022	~23	1,066	과학 및 인문학 등 특정 전문 주제에 대한 질문에 답하는 데 이용되는 대규모 언어 모델
BLOOM	2022	~117	433	빅사이언스 참여형 프로젝트에서 탄생한 다국어 오픈소스 모델로, 대규모 언어 모델 연구 작업의 발전을 지원하기 위해 고안됨
ChatGPT-4	2023	~100	62,318.8	ChatGPT 시리즈의 고급 버전으로, 보다 미묘하고 문맥을 인식하는 언어 생성을 위해 설계됨
OPT-175B	2023	~33	324	일관되고 문맥상 관련성 높은 문장을 생성하는 것으로 알려진 Meta의 최첨단 언어 모델

자료: EPRI(2024) p.30, Table B1.

〈표 부록-2〉 LEED BD+C 기준 크레딧 항목 및 점수

분류	크레딧 항목	점수
통합 설계 (Integrative Process)	통합 설계 프로세스	1
입지 및 교통 (Location and Transportation)	LEED 인접 개발지 위치	16
	민감지 보호	1
	우선 개발지·형평성 있는 개발	2
	주변 밀도 및 다양한 용도	5
	질 높은 대중교통 접근성	5
	자전거 시설	1
	주차 면적 축소	1
	전기차 지원	1
지속가능 부지 (Sustainable Sites)	공사 중 오염 방지	필수
	부지 평가	1
	서식지 보호 또는 복원	2
	오픈 스페이스	1
	비 관리	3
	열섬 효과 저감	2
	광공해 저감	1
물 효율 (Water Efficiency)	실외 수사용량 절감	필수
	실내 수사용량 절감	필수
	건물 단위 급수 계측	필수
	실외 수사용량 절감	2
	실내 수사용량 절감	6
	공정(프로세스) 용수 최적화	2
	수도 계측	1
에너지 및 대기 (Energy and Atmosphere)	기본 커미셔닝 및 검증	필수
	최소 에너지 성능	필수
	건물 단위 에너지 계측	필수
	기본 냉매 관리	필수

	강화 커미셔닝	6
	에너지 성능 최적화	18
	고성능 에너지 계측	1
	수요 대응(Demand Response)	2
	재생에너지 생산	5
	강화 냉매 관리	1
자재 및 자원 (Materials and Resources)	재활용물 보관·수거 체계	필수
	건물 생애주기 영향 저감	5
	환경제품선언(EPD)	2
	원자재 소싱(책임 조달)	2
	자재 성분(건강·투명성) 관리	2
	건설·철거 폐기물 관리	2
실내 환경질 (Indoor Environmental Quality)	최소 실내공기질 성능	필수
	간접흡연(ETS) 제어	필수
	강화 실내공기질 전략	2
	저방출 자재	3
	공사 단계 IAQ 관리 계획	1
	실내공기질 평가(시험/플러시아웃)	2
	열쾌적	1
	실내 조명(제어·품질)	2
	주광(Daylight)	3
	조망(Quality Views)	1
	음향 성능	1
혁신 (Innovation)	혁신(이노베이션)	5
	LEED 공인 전문가(LEED AP)	1
지역 우선 (Regional Priority)	지역 우선 크레딧(최대 4개)	4
총점		110

자료: U.S. Green Building Council, LEED Scorecard을 바탕으로 저자 작성

〈표 부록-3〉 미국 주별 데이터센터 투자 인센티브

주	인센티브	기간	요건
일리노이 (IL)	- 판매세 및 사용세 면제 (전기, 장비, 건축 자재 등) - 서비스 취약 지역에 한해, 건설 근로자 임금의 20% 세액 공제	-20년 (5년 단위 갱신 가능한 증명서 발급)	- 투자: 최소 2억 5천만 달러 - 고용: 20개 이상의 신규 정규직 (해당 카운티 평균 임금의 120% 이상 지급) - 기타: 친환경 건축 기준 충족, 프로젝트 노동 협약(PLA) 체결 필요
알라바마 (AL)	- 판매세, 사용세, 재산세 인센티브 (자재, 장비, 부동산 및 동산 적용) - 공동 입주(코로케이션) 허용 및 입주사 혜택 확대	-10년 ~ 30년 (투자 금액에 따라 변동)	- 투자: 2억 ~ 4억 달러 이상 - 고용: 20개 이상의 신규 일자리 (최저 연봉 4만 달러)
애리조나 (AZ)	- 거래 특권세(TPT) 및 사용세 인센티브 (장비, 소프트웨어, 물 절약 시스템 등)	-10년 (지속 가능한 재개발 프로젝트의 경우 최대 20년)	- 투자: 최소 2,500만 ~ 5,000만 달러 (카운티 인구에 따라 차등 적용)
아칸소 (AR)	- 판매세 및 사용세 인센티브 (데이터 센터 장비, 관련 서비스 및 전기) - 운영 개시 후 5년 이내 투자 요건 충족	-기간 제한 없음	- 투자: 최소 5억 달러- 보상: 운영 시작 후 2년간 주 내 직원에게 연간 총 100만 달러 이상 보상 지급
조지아 (GA)	- 컴퓨터 및 데이터 센터 장비에 대한 판매세·사용세 면제 - 공동 입주 허용 (단, 일자리 세액 공제 청구는 금지)	-10년 (장비 면제는 2028년, 데이터 센터 면제는 2031년 일몰)	- 투자: 최소 1억 ~ 2억 5천만 달러 (카운티 인구에 따라 차등 적용) - 고용: 20개 이상의 양질의 일자리
아이다호 (ID)	- IT 장비 및 관련 구매에 대한 판매세·사용세 면제 - 공동 입주 허용 (단, 혜택은 자격을 갖춘 사업체로 제한)	-기간 제한 없음	- 투자: 최소 2억 5천만 달러 - 고용: 30개 이상의 신규 일자리
인디애나 (IN)	- 총 소매세, 사용세 및 지방 재산세 면제 (전기, 소프트웨어, 물 절약 시스템 등) - 공동 입주 허용	-25년 (투자액 7억 5천만 달러 이상 시 50년으로 연장)	- 투자: 최소 2,500만 ~ 1억 5,000만 달러 (카운티 인구에 따라 차등 적용) - 고용: 특정 요건 없음
아이오와 (IA)	- 판매세 및 사용세 인센티브 (신규 시설 건설 관련 서버 장비 및 구매) - 재산세 혜택 제공	-기간 제한 없음	- 투자: 최소 2억 달러 - 고용: 30개 이상의 신규 일자리 - 기타: 공동 입주(코로케이션) 불허

켄터키 (KY)	- 컴퓨터 시스템 관련 판매세·사용세 면제 (PC, 서버, 소프트웨어, 저장 장치 등) - 공동 입주 불필요, 일자리 세액공제 사용 불가	-기간 제한 없음 (환급 방식)	- 투자: 최소 1억 달러 이상
플로리다 (FL)	- 판매세 및 사용세 면제 (건설 자재, 장비, 유형 개인 재산, 전기) - 공동 입주 허용 및 임차인에게 혜택 확대 적용	-기간 제한 없음	- 투자: 최소 1억 5천만 달러 이상 - 기타: 세무부 신청 및 증명서 발급 필요
미시간 (MI)	- 판매세·사용세 면제 (컴퓨터, 서버, 발전기, 환경 제어 장비 등) - 특정 "르네상스 구역" 내 재산세 면제	-기간 제한 없음	- 투자/고용: 특정 요건 없음 - 기타: 공동 입주 허용
메릴랜드 (MD)	- 판매세, 사용세, 재산세 인센티브 (컴퓨터 장비, 소프트웨어, 에너지 생산 장비 등) - 공동 입주 허용	-최대 10년 (대규모 투자 시 최대 20년까지 연장 가능)	- 투자: 최소 200만 ~ 500만 달러 (지역에 따라 차등 적용) - 고용: 5개 이상의 적격 일자리
미네소타 (MN)	- 판매세 및 사용세 인센티브 (전력, IT 장비, 소프트웨어) - 공동 입주 및 임차인의 환급 신청 허용	-최대 20년 (또는 2042년 6월 30일 중 먼저 도래하는 시점)	- 투자: 최소 3,000만 달러(신규) 또는 5,000만 달러(리모델링)
미시시피 (MS)	- 판매세, 사용세, 소득세, 프랜차이즈세 인센티브 (장비, 소프트웨어, 전기 등)	-기간 제한 없음	- 투자: 최소 2,000만 달러 - 고용: 20개 이상의 신규 정규직 (주 평균 임금의 125% 이상 지급)
미주리 (MO)	- 판매세 및 사용세 면제 (유틸리티, 기계, 장비, 건설 자재) - 공동 입주 허용	-10년 (기존 시설) 또는 15년 (신규 시설)	- 투자: 최소 500만 달러(기존) 또는 2,500만 달러(신규) - 고용: 5개(기존) 또는 10개(신규) 이상의 신규 일자리
네브래스카 (NE)	해당 없음	-해당 없음	- 기타: 2020년 12월 31일 이후 신규 신청이 중단됨
네바다 (NV)	- 판매세, 사용세, 재산세 인센티브 (장비, 소프트웨어, 전기 등) - 공동 입주 허용	-10년 또는 20년	- 투자: 10년 감면시 최소 2,500만 달러, 10~20년 감면시 최소 1억 달러 투자 - 고용: 10년 감면시 최소 10개, 10~20년 감면시 최소 50개 -그외: 공동입주 허용, 기업유치 세액공제 등 다른 인센티브 적용 제외

뉴욕 (NY)	- 판매세 및 사용세 면제 (데이터 센터 관련 기계, 장비, 서비스) - 공동 입주 제한 없음	- 기간 제한 없음	- 투자/고용: 특정 요건 없음
노스 캐롤라이나 (NC)	- 판매세 및 사용세 인센티브 (소프트웨어, 전력, 지원 장비) - 공동 입주 허용	- 기간 제한 없음	- 투자: 최소 7,500만 달러 이상
오하이오 (OH)	- 판매세 및 사용세 인센티브 (컴퓨터 데이터 센터 장비) - 공동 입주 허용	- 기간 제한 없음	- 투자: 3년간 최소 1억 달러 - 급여: 연간 총급여 최소 150만 달러 이상
노스다코타 (ND)	- 판매세 및 사용세 인센티브 (IT 장비 및 컴퓨터 소프트웨어) - 공동 입주 허용	- 기간 제한 없음	- 투자/고용: 특정 요건 없음
오클라호마 (OK)	- 판매세 및 사용세 면제 (컴퓨터 서비스 및 데이터 처리용 기계, 장비) - 공동 입주 허용	- 기간 제한 없음	- 투자/고용: 특정 요건 없음
오리건 (OR)	- 판매세 및 사용세 면제 (컴퓨터 서비스 및 데이터 처리용 기계, 장비)	- 무기한	- 투자/고용: 특정 요건 없음 - 기타: 매년 세무 위원회에 자격 충족 진술서 제출 필요
펜실베이니아 (PA)	- 판매세 및 사용세 면제 (컴퓨터 데이터 센터 장비)	- 자격 신청 연도 이후 25년	- 투자: 최소 7,500만 ~ 1억 달러 (카운티 인구에 따라 차등 적용) - 고용: 25 ~ 45개의 신규 일자리 (카운티 인구에 따라 차등 적용)
사우스 캐롤라이나 (SC)	- 판매세 및 사용세 인센티브 (컴퓨터, 장비, 하드웨어, 소프트웨어, 전기)	- 기간 제한 없음	- 투자: 최소 5,000만 ~ 7,500만 달러 - 고용: 25개 일자리 (주 또는 카운티 1인당 소득의 150% 이상 보상)
테네시 (TN)	- 판매세 및 사용세 면제 (컴퓨터, 소프트웨어, 주변 장치 등) - 전기 요금 감면 세율(1.5%) 적용	- 기간 제한 없음	- 투자: 최소 1억 달러 - 고용: 15개 이상의 일자리 (주 평균 임금의 150% 이상 지급)
텍사스 (TX)	- 판매세 및 사용세 면제 (장비, 소프트웨어, 전기)	10년 (투자액 2.5억 달러 미만) 또는 15년 (투자액 2.5억 달러 이상)	- 투자: 최소 2억 달러 - 고용: 20개 이상의 일자리 (카운티 평균 임금의 120% 이상 지급)
버지니아 (VA)	- 판매세 및 사용세 면제 (컴퓨터 장비 및 지원 소프트웨어)	기간 제한 없음	- 투자: 최소 1억 5천만 달러 (재정난 지역은 7천만 달러) - 고용: 50개 이상의 신규 일자리 (재정난 지역은 10개)

유타 (UT)	- 데이터 센터 장비에 대한 판매세 및 사용세 면제	기간 제한 없음	- 투자/고용: 특정 요건 없음
워싱턴 (WA)	- 판매세 및 사용세 면제 (농촌 및 도시 데이터 센터의 서버 장비 및 인프라)	농촌 지역은 2048년, 도시 지역은 2038년까지	- 투자 및 고용 요건은 농촌/도시 유형에 따라 상이함 - 기타: 유형별로 선착순 6개 인증서만 발급
웨스트 버지니아 (WV)	- 개인 재산세 및 판매세·사용세 면제 (소프트웨어, 서버, 건축 자재 등)	기간 제한 없음	- 투자/고용: 특정 요건 없음 - 기타: 세무국장에게 신청 및 인증 필요
와이오밍 (WY)	- 판매세 및 사용세 면제 (특정 장비, 소프트웨어, 무경전 전원 공급 장치 등)	기간 제한 없음	- 특정 투자 기준액 및 일자리 창출 인증 필요

자료: Illinois DCEO(2025) pp.5-15.

1. AI 기술 발전과 에너지 수요의 관계¹²¹

컴퓨터란 전자화된 정보를 반도체 회로를 사용하여 고속으로 처리하는 기계이다. 당연히 전기가 없으면 작동할 수 없고, 계산 속도와 용량이 커질수록 대량의 전기를 사용할 수밖에 없다. 반도체의 효율이 개선되면서 에너지 소비 효율도 개선이 되었지만, AI 기술의 등장으로 전산 시스템의 전기 소비는 효율 개선 속도를 크게 앞지르게 되었다. AI 시스템이 왜 기존 전산 시스템보다 더 많은 에너지를 필요로 할까?

AI 기술이 소비하는 막대한 에너지는 기술의 특정 구조와 연산 과정에서 필연적으로 발생한다. AI 모델, 특히 거대 언어 모델의 근간을 이루는 트랜스포머(Transformer) 아키텍처는 수십억에서 수조 개에 이르는 매개변수(parameter)를 기반으로 복잡한 행렬 연산을 수행하며, 이 과정에서 막대한 양의 전력이 소모된다. AI 모델의 성능을 높이기 위해 모델의 크기와 학습 데이터의 양을 기하급수적으로 늘리는 ‘스케일링 법칙(Scaling Laws)’이 지배적인 패러다임으로 자리 잡으면서, AI 연산에 필요한 전력 소비량 또한 폭발적으로 증가하고 있다. 여기서는 AI 기술의 어떤 전산학적 특성이 에너지 수요를 발생시키는지 설명한다.

1.1. AI 시스템의 에너지 수요


AI 모델의 에너지 소비는 근본적으로 반도체 칩 내부에서 이루어지는 수많은 전기적 스위칭(switching) 과정의 물리적 결과이다. AI 연산의 기본 단위는 부동소수점 연산(FLOP, Floating-Point Operation)이며, GPU(Graphics Processing Unit)나 TPU(Tensor Processing Unit)와 같은 AI 가속기는 이러한 연산을 병렬로 처리하는 데 특화되어 있다. 하나의 부동소수점 연산을 수행하기 위해서는 수많은 반도체가 켜지고 꺼지는 과정을 반복해야 하며, 이 과정에서 전력이 소모되고 열이 발생한다. 따라서 AI 모델의 에너지 수요를 이해하려면 해당 모델이 작업을 수행하기 위해 얼마나 많은 연산을, 어떤 구조로 처리하는지를 이해해야 한다.

¹²¹ 연세대학교 소프트웨어학부 임효상 교수에게 의뢰하여 작성하였다.

1.1.1. 트랜스포머(Transformer) 모델

현대 AI, 특히 거대언어모델(LLM)의 기반이 되는 트랜스포머 아키텍처는 그 구조상 막대한 양의 행렬 연산을 요구한다(Vaswani et al., 2017). [그림 부록-1]은 트랜스포머 모델의 아키텍처를 도식화한 것이다. 이 모델에서 에너지 소비가 발생하는 핵심적인 연산 과정은 다음과 같이 세 부분으로 나눌 수 있다.

[그림 부록-1]트랜스포머 모델의 아키텍처



자료: Vaswani et al.(2017), p3, Figure 1

가) 입력 임베딩 (Input Embedding) 및 위치 인코딩 (Positional Encoding)

AI 모델은 자연어를 직접 처리할 수 없으므로, 입력된 텍스트를 숫자 형태의 벡터(vector)로 변환하는 과정이 필요하다. 먼저 텍스트는 토큰(token)이라는 작은 단위(단어 또는 하위 단어)로 분리된다(토큰화). 이후 각 토큰은 고유한 숫자 ID에 매핑되고, 임베딩 행렬(Embedding Matrix)을 참조하여 고차원의 벡터로 변환된다. 예를 들어, GPT-3의 경우 50,257개의 토큰 어휘를 가지며 각 토큰은 12,288 차원의 벡터로 표현된다(Wang et al., 2024). 이 과정은 본질적으로 거대한 참조 테이블에서 해당 토큰의 벡터 값을 찾는 행렬 연산이다. 또한, 순차적 정보가 없는 트랜스포머의 특성을 보완하기 위해 각 토큰의 위치 정보를 담은 위치 인코딩 벡터가 더해진다. 이 단계는 전체 연산량에서 차지하는 비중이 크지는 않지만, 모든 자연어 처리의 필수적인 첫 단계이다.

나) 셀프 어텐션 (Self-Attention) 메커니즘

셀프 어텐션은 트랜스포머의 핵심이자 가장 많은 연산이 집중되는 부분이다. 셀프 어텐션은 문장 내의 각 토큰이 다른 모든 토큰과 얼마나 연관되어 있는지를 계산하여 문맥적 의미를 파악하는 메커니즘이다. 이 과정은 다음과 같은 행렬 연산을 통해 수행된다.

- ① 먼저, 각 입력 토큰 벡터로부터 쿼리(Query, Q), 키(Key, K), 밸류(Value, V)라는 세 개의 벡터를 생성한다. 이는 입력 벡터에 각각의 가중치 행렬(W_Q , W_K , W_V)을 곱하는 선형 변환(Linear Transformation) 과정이다.
- ② 다음으로, 특정 토큰의 쿼리 벡터(Q)를 다른 모든 토큰의 키 벡터(K)와 내적(dot product)하여 어텐션 스코어(Attention Score)를 계산한다. 이 스코어는 토큰 간의 연관성을 나타낸다.
- ③ 어텐션 스코어를 키 벡터 차원의 제곱근($\sqrt{d_k}$)으로 나누어 안정적인 그래디언트(gradient)를 확보하고(Scaling), 소프트맥스(Softmax) 함수를 적용하여 합이 1이 되는 어텐션 가중치(Attention Weight)를 계산한다.
- ④ 이 가중치를 각 토큰의 밸류 벡터(V)에 곱하여 가중합을 구함으로써, 문맥 정보가 풍부하게 반영된 최종 출력 벡터를 얻는다.

이 전체 과정을 수식으로 표현하면 다음과 같다.

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

여기서 핵심은 어텐션 스코어를 계산하는 QK^T 행렬 곱셈이다. 입력 시퀀스의 길이를 n , 각 토큰 벡터의 차원을 d 라고 할 때, Q 와 K 행렬의 크기는 각각 $n \times d$ 가 된다. 따라서 연산의 계산 복잡도(Computational Complexity)는 $O(n^2 \cdot d)$ 에 달한다. 즉, 입력 시퀀스의 길이가 길어질수록 필요한 연산량은 제곱에 비례하여 폭발적으로 증가하며, 이는 트랜스포머 모델의 에너지 소비를 지배하는 가장 중요한 요인이다.

다) 피드 포워드 네트워크 (Feed-Forward Network, FFN)

어텐션 메커니즘을 통과한 출력 벡터는 피드 포워드 네트워크(FFN)라는 또 다른 연산 집약적인 계층을 거친다. FFN은 일반적으로 두 개의 선형 변환(행렬 곱셈)과 그 사이에 비선형 활성화 함수(ReLU 등)가 포함된 구조로 이루어져 있다. 첫 번째 선형 변환은 입력 벡터의 차원을 확장(예: 4배)하고, 두 번째 선형 변환은 다시 원래의 차원으로 축소하는 역할을 한다. 이 과정은 모델이 더 복잡하고 추상적인 특징을 학습할 수 있도록 돕지만, 모델의 매개변수 대부분이 이 FFN에 집중되어 있어 셀프 어텐션과 함께 에너지 소비의 주요 원인이 된다.

〈표 부록-4〉는 트랜스포머 모델의 연산별 계산 복잡도와 에너지 소비 기여도를 정리한 것이다. 이러한 임베딩, 셀프 어텐션, FFN으로 구성된 블록(Block)이 GPT-3의 경우 96개나 수직으로 쌓여 있다(Wang et al., 2024). 입력 데이터는 이 96개의 블록을 순차적으로 통과하며 반복적으로 막대한 양의 행렬 연산을 거치게 되고, 이 과정에서 소비되는 누적 연산량이 곧 AI 모델의 막대한 에너지 수요로 귀결되는 것이다.

〈표 부록-4〉 트랜스포머 주요 연산별 계산 복잡도 및 에너지 소비 기여도

연산 구분	주요 연산	계산 복잡도 (시퀀스 길이 n , 차원 d)	에너지 소비 기여도
임베딩	행렬 참조 (Matrix Lookup)	$O(n \cdot d)$	낮음
셀프 어텐션	행렬 곱셈 (QK^T)	$O(n^2 \cdot d)$	매우 높음
피드 포워드 네트워크	행렬 곱셈 (2 x Linear Layers)	$O(n \cdot d^2)$	높음

자료: 저자 작성

이러한 트랜스포머 아키텍처의 연산 복잡도는 모델의 규모, 즉 입력 시퀀스 길이(n)와 임베딩 차원(d)이 커질수록 현실적인 에너지 문제로 직결된다. 현재 널리 사용되는 거대언어모델(LLM)들은 이 두 변수를 극단적으로 확장하고 있다.

입력 시퀀스 길이 (n , Context Length): 모델이 한 번에 처리할 수 있는 토큰의 최대 길이를 의미하는 컨텍스트 길이는 초기 GPT-3의 2,048 토큰에서 Llama 3의 8,000 토큰, Claude 3의 200,000 토큰, 그리고 Gemini 1.5 Pro의 100만 토큰에 이르기까지 폭발적으로 증가했다(Moesker, 2024.10.4.). 컨텍스트 길이가 길어지면 모델이 더 긴 문서나 대화를 이해하고 일관성 있는 답변을 생성할 수 있지만, 셀프 어텐션 연산량이 시퀀스 길이의 제곱에 비례($O(n^2)$)하여 증가하므로 에너지 소비 또한 기하급수적으로 늘어난다.

임베딩 차원 (d , Embedding Dimension): 각 토큰을 표현하는 벡터의 크기를 의미하는 임베딩 차원 역시 모델의 표현력을 높이기 위해 크게 설정된다. 예를 들어, GPT-3(175B) 모델은 12,288차원의 임베딩을 사용하며, Llama 3(8B)는 4,096차원을 사용한다(Wikipedia). 임베딩 차원이 커지면 피드 포워드 네트워크의 연산량이 임베딩 차원의 제곱에 가깝게 증가($O(d^2)$)하여 에너지 소비를 가중시킨다.

트랜스포머 모델 이외에도 다양한 모델들이 AI 서비스에서 사용되고 있다. 다른 주요 아키텍처들 역시 고유의 연산 특성과 에너지 소비 특성을 가진다.

1.1.2. 합성곱 신경망 (CNN, Convolutional Neural Networks)

주로 이미지 인식, 객체 탐지 등 컴퓨터 비전 분야에서 사용되는 CNN은 이미지의 지역적 특징(edge, texture)을 추출하는 데 특화되어 있다. CNN의 핵심 연산인 합성곱(convolution)은 전체 입력이 아닌 작은 필터(filter) 내에서만 연산이 이루어지므로, 전역적인 관계를 파악하는 트랜스포머의 셀프 어텐션에 비해 계산적으로 훨씬 효율적이다(Coursera, 2025.6.9.). 따라서 CNN은 일반적으로 더 적은 데이터로 학습이 가능하고 연산 비용이 낮아 실시간 영상 분석이나 모바일 기기에서의 비전 작업에 널리 활용된다.

1.1.3. 디퓨전 모델 (Diffusion Models)

Stable Diffusion과 같은 이미지 생성 모델에서 주로 사용되는 이 아키텍처는 무작위 노이즈(noise)로부터 시작하여 점진적으로 노이즈를 제거하는 과정을 반복함으로써 고품질 이미지를 생성한다. 이 반복적인 '디노이징(denoising)' 과정은 수십에서 수백 단계에 걸쳐 복잡한 연산을 수행해야 하므로, 단일 이미지를 생성하는 데에도 상당한 계산량이 요구된다. 한 연구에 따르면, 이미지 생성 모델로 이미지 한 장을 만드는 데 스마트폰을 완전히 충전하는 것과 맞먹는 에너지가 소모될 수 있다(Lyons-Cunha, 2025).

1.1.4. 과학 분야 특화 모델 (AlphaFold 등)

구글 딥마인드의 AlphaFold는 단백질 구조 예측 문제를 해결하기 위해 개발된 모델로, 트랜스포머의 핵심인 어텐션 메커니즘을 변형한 'Evoformer' 블록을 사용한다. 또한, AlphaFold 3는 구조 생성을 위해 디퓨전 모델을 통합하는 등 여러 아키텍처를 결합했다. 이러한 모델의 학습과 추론에는 막대한 계산이 필요하지만, 수년이 걸리던 단백질 구조 실험을 수 분 내로 단축함으로써 전체 과학 연구 과정의 에너지와 비용을 획기적으로 절감하는 효과를 가져온다(Gartenberg, 2024.7.16.).

결론적으로, 언어 모델의 트랜스포머, 이미지 생성의 디퓨전, 과학적 발견을 위한 특화 모델 등 분야를 막론하고, 이들 모델의 핵심 연산 과정은 본질적으로 막대

한 계산량을 수반한다. 이러한 수십억, 수조 번의 부동소수점 연산은 반도체 칩 내에서 물리적인 전기 신호의 형태로 처리되며, 이는 피할 수 없는 에너지 소비와 발열로 이어진다. 즉, AI가 보여주는 놀라운 성과의 이면에는 연산의 물리적 대가로서 막대한 에너지 소비가 필연적이다.

1.2. AI 매개변수와 학습 데이터 규모의 기하급수적 증가 원인


AI 모델의 에너지 수요를 폭증시킨 또 다른 핵심 동인은 ‘스케일링 법칙(Scaling Laws)’으로 알려진 경험적 발견이다. 스케일링 법칙이란 AI 모델의 성능(손실 값, loss)이 모델의 크기(매개변수 수), 학습 데이터의 양, 그리고 학습에 사용되는 컴퓨팅 자원의 양에 따라 예측 가능한 형태로 향상된다는 법칙이다(Kaplan et al., 2020). 즉, ‘더 큰 모델을 더 많은 데이터로 더 오래 학습시키면 성능이 좋아진다’는 단순한 명제가 경험적으로 입증되면서, AI 기술 개발 경쟁은 곧 ‘누가 더 큰 모델을 만들 수 있는가’의 경쟁으로 직결되었다.

매개변수는 인공신경망에서 입력 신호의 중요도를 조절하는 가중치(weight)와 뉴런의 활성화를 조절하는 편향(bias)을 통칭하는 것으로, 모델이 데이터로부터 학습하는 모든 지식이 이 매개변수에 저장된다. 매개변수의 수가 많다는 것은 모델이 더 복잡하고 미묘한 패턴을 학습할 수 있는 용량(capacity)이 크다는 것을 의미한다. 스케일링 법칙의 발견은 AI 연구자들에게 모델의 성능을 높이는 확실한 방법을 제시했고, 이는 지난 몇 년간 AI 모델 매개변수 수의 폭발적인 증가를 이끌었다(Nguyen et al., 2023).

- 2018년, BERT-Large: 3억 4천만 개의 매개변수를 가진 모델로, 자연어 이해(NLU) 분야에서 혁신을 일으켰다.
- 2019년, GPT-2: 15억 개의 매개변수를 가지며, 인간과 유사한 문장을 생성하는 능력으로 큰 주목을 받았다.
- 2020년, GPT-3: 1,750억 개의 매개변수로 이전 모델들을 압도하며, 별도의 미세 조정(fine-tuning) 없이도 다양한 작업을 수행하는 ‘인컨텍스트 학습(in-context learning)’ 능력을 보여주었다.

- 2021년, Megatron-Turing NLG: 마이크로소프트와 엔비디아가 공동 개발한 5,300억 개의 매개변수를 가진 모델로, 거대 모델 경쟁의 정점을 보여주었다.
- 2022년, PaLM: 구글이 발표한 5,400억 개의 매개변수를 가진 모델로, 추론 능력과 코드 이해 능력을 한 단계 끌어올렸다.
- 2024년, Llama 3.1: 메타가 공개한 4,050억 개 매개변수 모델로, 오픈소스 진영에서도 초거대 모델 개발이 활발함을 보여준다.

[그림 부록-2] 주요 거대언어모델의 매개변수 수 변화 추이



자료: Nguyen et al. (2023) p7, Figure 6

모델의 크기가 커짐에 따라, 효과적인 학습을 위해 필요한 데이터의 양 또한 기하급수적으로 증가했다. 모델이 가진 수많은 매개변수를 의미 있는 값으로 채우기 위해서는 방대한 양의 텍스트 데이터가 필수적이기 때문이다. 딥마인드(DeepMind)의 연구에 따르면, 최적의 성능을 위해서는 모델 매개변수 1개당 약 20개의 데이터 토큰이 필요하다는 ‘친칠라 스케일링 법칙(Chinchilla Scaling Laws)’이 제시되기도 했다(Hoffmann et al., 2022). 이는 1,750억 개 매개변수를 가진 GPT-3와 같은 모델을 최적으로 학습시키기 위해서는 약 3조 5천억 개의

토큰이 필요하다는 것을 의미한다.

이러한 방대한 데이터 수요를 충족시키기 위해 사용되는 것이 ‘커먼 크롤(Common Crawl, <https://commoncrawl.org/>)’과 같은 웹 크롤링 데이터셋이다. 커먼 크롤은 수십억 개의 웹 페이지를 정기적으로 수집하여 공개하는 비영리 프로젝트로, 그 데이터 규모는 수 페타바이트(PB)에 달한다. GPT-3 학습 데이터의 약 80% 이상이 이 커먼 크롤에서 비롯되었을 정도로, 현대 거대언어모델은 사실상 인터넷 전체를 학습 데이터로 삼고 있다(Mozilla, 2024.2.6.).

결론적으로, AI 성능 향상을 위한 가장 확실한 방법으로 ‘스케일링’이 채택되면서 모델의 매개변수와 학습 데이터의 규모는 상호작용하며 폭발적으로 증가했다. 이는 필연적으로 앞서 설명한 행렬 연산의 양과 복잡도를 기하급수적으로 증대시켰고, AI 기술의 에너지 수요를 폭발적으로 증가시킨 근본 원인이 되었다.

2. AI 전환의 현재와 미래¹²²

AI의 발전은 단순히 기존 산업의 효율을 높이는 응용 기술의 차원을 넘어, 인류의 지식 창출과 기술 개발 방식 자체를 근본적으로 바꾸는 ‘패러다임 전환’의 기폭제가 될 가능성이 있다. 여기서는 AI가 단순한 응용 도구가 아니라, 과학 발견과 기술 혁신의 속도 자체를 가속하는 ‘근본적인 도구(fundamental tool)’로 진화하고 있는 사례들을 찾아본다. 과학, 의료, 산업이라는 세 분야의 구체적인 사례를 통해 AI의 미래를 그려본다.

2.1. 과학 분야: 과학 연구 방법의 전환

AI는 과학자들이 사용하는 보조 도구를 넘어, 과학적 발견의 방법론 자체를 근본적으로 바꾸고 있다. AI를 연구 도구로 사용하면서 과학의 모든 분야가 고강도 연산 집약적 분야로 변화하고 있다. AI는 증기기관이나 전기와 같이 여러 산업에 걸쳐 파급 효과를 일으키는 ‘범용 기술(General-Purpose Technology, GPT)’의 특성을 명확히 보여준다. 범용 기술은 그 자체로도 중요하지만, 다른 분야의 기

¹²² 연세대학교 소프트웨어학부 임효상 교수에게 의뢰하여 작성하였다.

술 혁신을 촉발하고 전반적인 생산성을 향상시킨다는 점에서 큰 의미가 있다. 과학 연구 분야에서 AI 역할이 특히 두드러지는데, 과거에는 상상할 수 없는 수준으로 연구개발의 속도와 규모를 개선하고 있다. 2024년 노벨 물리학상과 화학상 수상이 모두 AI와 관련이 있다는 사실이 이를 극적으로 보여준다.

인공신경망과 딥러닝의 기초를 닦은 제프리 힌튼(Geoffrey Hinton)과 존 홉필드(John Hopfield)가 노벨 물리학상을 수상했는데, 이들은 통계 물리학의 개념을 활용하여 데이터로부터 패턴을 학습하는 방법을 제안하였고 이는 오늘날 ChatGPT와 같은 거대언어모델을 포함한 거의 모든 현대 AI 기술의 이론적 기반이 되었다. 일견 컴퓨터 과학자로 보이는 두 사람에게 물리학상을 수여한 것은, 이들이 제안한 AI의 근본 원리가 물리학에 뿌리를 두고 있고, AI 기술이 다시 물리학을 포함한 모든 기초 과학의 발전에 지대한 영향을 미치고 있음을 인정하였기 때문이다.

더욱 직접적인 사례는 노벨 화학상이다. 화학상은 단백질 구조 예측 AI 모델인 '알파폴드(AlphaFold)'를 개발한 구글 딥마인드의 데미스 하사비스(Demis Hassabis), 존 점퍼(John Jumper)와 계산 단백질 설계 분야를 개척한 데이비드 베이커(David Baker)에게 공동 수여되었다. 단백질의 3차원 구조를 아미노산 서열로부터 예측하는 것은 지난 50년간 생물학계의 가장 큰 난제 중 하나였다. 알파폴드는 딥러닝 기술을 이용해 이 문제를 놀라운 정확도로 해결함으로써, 사실상 AI 시스템이 과학적 '난제(grand challenge)'를 해결했음을 공식적으로 인정받은 최초의 사례가 되었다.

AI가 주도하는 과학 연구 방법의 전환은 생명과학을 넘어 물질과학, 기후과학 등 다양한 분야로 빠르게 확산되고 있다. 구글 딥마인드의 또 다른 AI 모델인 'GNoME(Graph Networks for Materials Exploration)'는 딥러닝을 이용해 기존에 알려지지 않았던 38만 개 이상의 새로운 안정적인 무기 결정 구조를 발견했다(Merchant & Cubuk, 2023.11.29.). 연구팀은 이 결과를 '800년 치의 지식'에 해당하는 성과로 평가했다. GNoME는 향후 반도체나 초전도체, 배터리 등에 활용될 수 있는 5만 2천 종의 신규 화합물도 발견하였다. AI의 이러한 가시적인 성과도 중요하지만, AI가 로봇 기술과 결합하면서 '자율 실험실(autonomous laboratory)'이라는 연구체계가 발전하고 있다는 점이 중요하다. 로렌스 버클리

국립연구소는 GNoME이 예측한 물질 중 41종을 로봇만을 사용하여 합성하는 데에 성공했다(Biron, 2023.11.29.). 이는 AI가 가설을 생성하고, 로봇이 이를 검증하는 과학 연구 체계가 현실화되고 있음을 의미한다.

기후 과학 분야에서도 AI는 복잡한 대기 시스템 모델을 구현하고 기상과 기후 변화를 예측하는 데 큰 기여를 하고 있다. 구글 딥마인드가 개발한 '그래프캐스트(GraphCast)'는 기존의 물리 기반 시뮬레이션 모델보다 훨씬 빠르고 정확하게 전 지구적 기상 패턴을 예측하는 능력을 보여주었으며(Lam et al., 2023), 이는 기후 변화 대응 및 재난 예방에 중요한 기여를 할 것으로 기대된다.

아래 표는 AI가 최근 과학 기술 분야의 혁신을 어떻게 주도하고 있는지를 요약한 것이다.

〈표 부록-5〉 AI 기반 주요 과학 기술 혁신 사례

분야	프로젝트/기술	주요 내용	기대 효과
생명과학	AlphaFold (Google DeepMind)	50년 난제인 단백질 3차원 구조를 딥러닝으로 예측 (2024년 노벨 화학상)	신약 개발, 질병 메커니즘 규명, 유전 공학 등 생명과학 연구 전반 가속화
물질과학	GNoME (Google DeepMind)	38만 종 이상의 새로운 안정적 결정 구조 발견, '800년 치의 지식'에 해당	차세대 반도체, 고효율 배터리, 초전도체 등 신소재 개발 시간 획기적 단축
물질과학	A-Lab (Berkeley Lab)	GNoME이 예측한 신물질들을 로봇이 자동으로 합성, 과학 연구의 자동화 실현	가설 수립부터 실험, 검증까지의 연구개발 주기 단축과 자동화
기후과학	GraphCast (Google DeepMind)	기존 슈퍼컴퓨터 모델보다 정확하게 중장기 기상 예측	기후 변화 모델 정밀도 향상, 이상 기후, 자연재해 조기 예보 시스템 개선

자료: 저자 작성

이러한 사례들은 이제 AI는 과학 방법론 자체를 변화시키고 있음을 보여준다. 전통적으로 과학 방법은 이론과 실험이라는 두 축에 의존하였다. 과학자는 이론으로부터 가설을 도출하고, 실험을 통해 이를 검증했다. 그러나 이제 AI는 '대규모 계산적 탐색(large-scale computational exploration)'이라는 새로운 축을 제안하고 있다. 알파폴드나 GNoME와 같은 생성형 AI 모델은 인간이 세운 가설을

검증하는 것을 넘어, 과학자가 고려하지 못했던 무한한 가능성을 시뮬레이션하여 새로운 발견을 도출해낸다. 미래의 과학자에게는 이론적 통찰과 실험적 기술뿐만 아니라, AI를 활용 역량이 필수적임을 의미한다. 이는 또한 모든 과학 연구가 필요로 하는 연산의 규모가 크게 증가할 것임을 시사한다.

2.2. 의료 분야: 인간 생명과 건강의 재정의

과학 연구 분야에서 AI 활용 성과는 곧바로 인 의료와 생명과학 분야에도 확산되고 있다. 코로나19 대유행 시기에, 의료 분야 혁신에서 AI 활용의 가능성이 크게 부각되었다. 코로나19 백신으로 처음 활용된 mRNA 백신은 개발 착수 후 1년이 채 되지 않아 긴급 사용 승인을 받았는데, 백신 개발에는 평균 10년 이상의 시간이 소요되는 것을 고려할 때 놀라운 일이었다. 그리고 그 배후에는 AI 기술이 있었다. 대표적으로 모더나(Moderna)는 클라우드 컴퓨팅(AWS) 환경에서 머신러닝 알고리즘을 활용하여, 코로나바이러스의 유전자 서열이 공개된 지 불과 이틀 만에 백신의 핵심 물질인 mRNA 서열 설계를 완료했다(Joi, 2025). AI의 역할은 설계 단계에만 국한되지 않았다. 화이자(Pfizer)는 임상시험 과정에서 발생하는 수천만 건의 데이터를 검수하고 오류를 찾아내는 과정에 AI를 도입하여, 데이터 분석에 소요되는 시간을 한 달 이상 단축했다고 밝혔다(Pfizer, 2024).

AI는 신약 개발 과정에 소요되는 시간도 획기적으로 감소시키고 있다. 통상적으로 신약 개발에는 평균 13~15년의 시간과 막대한 비용이 소요되며, 임상 1상을 통과한 후보 신약 중 최종 제품화 비율이 10% 미만에 불과할 정도로 신약 개발은 매우 어려운 과정이다. AI를 도입함으로써 신약 개발 과정을 혁신하고 있다. 알파폴드2가 단백질의 정적인 3차원 구조를 예측하였다면, 2024년 발표된 알파폴드3는 단백질과 DNA, RNA, 약물과 같은 작은 분자(ligand) 사이의 상호작용을 예측함으로써 신약 개발에 도움을 주고 있다. 이는 질병을 일으키는 단백질의 작용을 원자 수준에서 이해하고, 해당 단백질과 결합하여 질병 유발을 막을 수 있는 신약 후보 물질을 설계할 수 있게 만들어 준다.

이러한 기술을 바탕으로 제약 산업은 '랩 인 더 루프(lab-in-the-loop)'라는 새

로운 R&D 패러다임으로 전환하고 있다.¹²³ 이는 AI 모델이 신약 후보 물질의 구조와 효능을 예측하면, 실험실에서 이를 실제로 합성하고 테스트한다. 그리고 그 실험 결과를 다시 AI 모델에 학습시켜 모델의 예측 정확도를 더욱 높이는 선순환 구조를 의미한다. 이 방식은 막대한 비용과 시간이 드는 시행착오를 컴퓨터 시뮬레이션으로 대체함으로써 신약 개발의 성공률을 높이고 기간을 획기적으로 단축할 수 있다.

AI는 질병 치료의 패러다임을 '평균적인 환자'를 대상으로 하는 표준화된 치료에서 개개인의 유전적, 환경적 특성을 고려하는 '정밀 의료(precision medicine)' 또는 '개인 맞춤형 의료(personalized medicine)'로 전환시키는 핵심 기술이다. 인간의 유전체(genome), 단백질체(proteome), 대사체(metabolome) 등 방대한 '다중 오믹스(multi-omics)' 데이터와 전자의무기록(EHR), 생활 습관 데이터 등을 통합적으로 분석하는 것은 인간의 능력으로는 불가능하다. AI, 특히 딥러닝 모델은 이러한 고차원의 복잡한 데이터 속에서 질병의 발병 위험을 예측하고, 특정 약물에 대한 환자의 반응성을 예측하는 미세한 패턴을 찾아낼 수 있다. 예를 들어, AI는 환자의 유전 정보를 분석하여 특정 항암제가 효과적일지, 혹은 심각한 부작용을 유발할지를 사전에 예측함으로써(약물유전체학, pharmacogenomics), 환자에게 가장 효과적이고 안전한 치료법을 제시할 수 있다. 이는 더 이상 질병을 치료하는 것을 넘어, 질병의 발생 자체를 예측하고 예방하는 방향으로 의료의 무게 중심을 이동시키고 있다.

AI를 활용하여 '노화(aging)'라는 의학의 궁극적인 문제 해결에 도전하고 있다. 노화는 인체 내의 여러 시스템이 복합적으로 작용하며 발생하는 복잡한 과정이다. 따라서 단일 표적만을 목표로하는 전통적인 신약 개발 방식으로는 해결에 한계가 있다. AI는 이러한 복잡성에 대응이 가능하게 만들어준다. 스크립스 연구소(Scripps Research)와 바이오테크 기업 제로(Gero)의 공동 연구팀은 AI를 이용해 노화와 관련된 여러 생물학적 경로에 동시에 작용하는 '다중약리학적(polypharmacological)' 화합물을 식별하는 데 성공했다(Scripps Research, 2025). AI 모델은 기존 연구 결과와 약물 데이터베이스를 학습하여, 노화에 영향

¹²³ NVIDIA, Lab-in-the-Loop AI for Life Science.

을 주는 세 가지 다른 수용체(도파민, 세로토닌, 히스타민)에 동시에 작용할 수 있을 것으로 예상되는 약물 후보군을 찾아냈다. 이렇게 찾아낸 후보 물질들을 실험실에서 예쁜꼬마선충(*C. elegans*)에 투여한 결과, 70% 이상에서 수명 연장 효과가 있었다. 이는 AI가 인간의 노화라는 복잡한 현상의 이해를 돕고, 수명 연장을 위한 방법을 찾아내는 데 도움을 줄 수 있음을 시사한다.

이러한 변화들은 의료 분야의 경제 모델과 연산 수요 구조를 근본적으로 바꾸고 있다. 전통적인 의료가 질병 발생 후 통계적 확률에 기반해 치료하는 '사후 대응적' 모델이었다면, AI 기반의 정밀 의료는 개인의 생체 정보를 계산적으로 분석하여 질병을 예측하고 예방하는 '사전 예비적' 모델이다. 이 새로운 모델에서 모든 환자는 하나의 통계적 샘플이 아니라, 해결해야 할 고차원의 '계산 문제(computational problem)'가 된다. 이러한 'N=1' 맞춤형 공학 접근법을 전 세계 수십억 인구에게 확장하는 것은, 의료 분야의 전산 수요가 영구적이고 폭발적으로 증가하는 강력한 동력이 될 것이다.

또한, 의료 분야에서도 과학 연구와 마찬가지로 '데이터 생성의 선순환 구조'가 형성되고 있다. AI 모델이 신약 개발이나 질병 예측을 가속하면, 이는 더 많은 임상시험과 유전체 분석을 통해 더 방대하고 정밀한 생체 데이터를 생산해낸다. 그리고 이 데이터는 다시 AI 모델을 더욱 정교하게 훈련시키는 데 사용된다.

2.3. 산업 분야: 경쟁력의 근본적인 재편

AI가 촉발하는 근본적 변화는 인간 경제 활동의 물리적 기반을 이루는 산업 현장으로 확산되고 있다. AI는 더 이상 소프트웨어나 연구실의 도구가 아니라, 제조, 물류, 운송 등 물리적 경제의 운영 체계이자 핵심 경쟁력으로 자리 잡고 있다. 이러한 산업 분야의 정보화 수요는 과거에는 존재하지 않았던 막대한 규모의 새로운 연산 수요를 신규로 창출하고 있다.

AI는 '스마트 팩토리'를 구현하는데 사용된다. 공장 내의 모든 설비와 공정에 센서를 설치하고, 여기서 얻어지는 방대한 데이터를 AI를 사용하여 분석함으로써 생산성을 극대화하는 방법을 찾을 수 있다. '예측 유지보수(predictive maintenance)'가 대표적인 응용 사례이다. 보통 산업현장에서는 설비가 고장 난 후에 수리하거

나, 고장을 막기 위해 정해진 주기에 따라 부품을 교체한다. 그러나 AI는 각종 센서를 통해 얻어진 설비의 진동, 온도, 소음 등 데이터를 실시간으로 분석하여, 보수가 필요한 설비와 시점 정보를 제공할 수 있다. 예측 유지보수를 통해 갑작스러운 생산 중단을 방지할 수 있다.

품질 관리에서는 'AI 기반 비전 검사'가 유용하다. 컴퓨터 비전 시스템은 생산 과정의 제품을 초고속으로 스캔하여, 미세한 흠집, 이물질, 조립 불량 등을 바로 판별할 수 있다. 미쓰비시 전기와 같은 기업은 이 기술을 최종 조립 공정에 도입하여 품질 검사의 정확도와 속도를 획기적으로 향상시켰다(Mitsubishi Electric, 2024). '디지털 트윈(Digital Twin)'은 생산 공정을 디지털화한 AI 기반 시뮬레이션 모델이다. 디지털 트윈에서 새로운 생산 공정을 도입하거나 설비 배치를 변경하는 등의 다양한 시뮬레이션을 미리 해볼 수 있다. 이를 통해 문제점을 파악하고 최적의 설치 방안을 찾음으로써, 비용과 리스크를 줄일 수 있다. BMW와 GE는 디지털 트윈을 활용하여 공장 설계 및 운영 효율을 최적화하고 있다(Nolibois, 2025.6.11.).

글로벌 물류 시스템은 수많은 변수가 영향을 주고받는 복잡한 체계이다. AI는 물류 시스템의 복잡성을 파악하고, 이를 예측 가능하고 자율적으로 운영되는 지능형 네트워크로 변화시키고 있다. 이 분야의 선두주자인 아마존(Amazon)은 물류 시스템의 모든 단계에 AI를 적용하고 있다(Amazon, 2022.10.18.). 아마존의 AI 시스템은 과거 판매 데이터, 소셜 미디어 트렌드, 경제 지표, 날씨 예보 등 다양한 변수를 종합 분석하여 상품 수요를 예측한다. 그리고 수요 예측에 따라 재고를 최적화하고, 배송 단계에서는 실시간 교통 상황을 반영하여 최적의 배송 경로를 제공한다. AI 도입을 통해 아마존은 비용을 절감하고, 배송 시간은 물론 고객 만족도도 개선한 것으로 알려졌다. 최근에는 생성형 AI를 활용하여 구매 주문서 작성과 승인과 같은 업무까지 자동화하여 효율성을 높이고 있다.

물리적 세계에서 AI의 능력이 가장 집약적으로 구현되는 분야는 단연 자율주행이다. 자율주행차는 복잡하고 예측 불가능한 실제 도로 환경에서 주변 상황을 실시간으로 인지(perception)하고, 다른 차량과 보행자의 행동을 예측(prediction)하며, 가장 안전하고 효율적인 경로를 계획(planning)하여 차량을 제어해야 한다. 이러한 고도의 작업을 수행하기 위해 자율주행 시스템은 막대한 양의 연산을 필요

로 한다. 테슬라(Tesla)는 전 세계에 운행 중인 자사 차량들로부터 수십억 마일에 달하는 실제 주행 데이터를 수집하여 '완전자율주행(FSD)' 모델을 훈련시킨다. 웨이모(Waymo)는 데이터센터의 거대한 '교사 모델(Teacher Model)'이 방대한 시뮬레이션과 실제 주행 데이터를 학습한 후, 그 지식을 차량에 탑재되는 작고 효율적인 '학생 모델(Student Model)'에 증류(distill)하는 방식을 사용한다. 자율주행의 연산 수요는 모델 학습 단계에만 머무르지 않는다. 운행 중인 모든 자율주행차는 주변 환경을 인식하고 판단하기 위해 초당 수백만에서 수천만 번의 추론(inference) 연산을 끊임없이 수행해야 한다. 이는 자율주행차가 도로 위를 달리는 '데이터센터'나 다름없음을 의미한다. 미래에 수백만, 수천만 대의 자율주행차가 도로를 누비게 된다면, 이들이 생성하는 누적 추론 연산량은 현재 데이터센터의 총 연산량을 가뿐히 넘어설 것이다.

아래 표는 주요 산업 분야에서 AI 전환(AI Transformation, AX)의 첨단 사례를 보여준다.

〈표 부록-6〉 주요 산업별 AI 전환(AX) 현황 및 핵심 응용 사례

분야	핵심 응용 사례	대표 기업	기대 효과
제조	예측 유지보수, 비전 검사, 디지털 트윈	Siemens, GE, BMW	생산성 극대화, 품질 향상, 다운타임 최소화, 가상 환경에서의 공정 최적화
물류	수요 예측, 창고 자동화, 경로 최적화	Amazon, UPS	재고 비용 절감, 배송 효율성 증대, 공급망 가시성 및 회복탄력성 강화
자동차/운송	자율주행 (인지, 예측, 계획)	Waymo, Tesla	교통사고 감소, 운전 편의성 증대, 새로운 모빌리티 서비스(로보택시) 창출
에너지	스마트 그리드, 에너지 수요 예측	PepsiCo	에너지 효율 최적화, 신재생에너지 통합 관리, 전력망 안정성 향상

자료: 저자 작성

산업 분야의 변화는 AI연산에서 추론의 비중이 커질 수 있음을 시사한다. 스마트 팩토리의 로봇, 공급망 관리 시스템, 그리고 수백만 대의 자율주행차는 물리적 세계와 상호작용하기 위해 365일 24시간 끊임없이 추론 연산을 수행해야 하기 때문이다.

또한, AI는 산업 자본재의 성격마저 바꾸고 있다. 공장 설비나 자동차는 구매하는 순간부터 가치가 하락(감가상각)하는 자산재이다. 그러나 AI와 연동된 자산은 ‘학습하는 자산’으로 가치가 상승할 수 있다. 테슬라 자동차나 스마트 팩토리의 로봇이 그 사례이다. 이들은 무선 소프트웨어 업데이트(OTA, Over-the-Air)를 통해 새로운 기능을 얻고 성능이 향상될 수 있다. 전 세계에 판매된 수백만 대의 테슬라 자동차들은 데이터를 수집하고, 이를 중앙의 AI 모델로 전송한다. 중앙 AI는 이 데이터를 학습하고, 더 향상된 기능을 다시 테슬라 자동차들에 배포한다. 이처럼 물리적 자본재가 AI 학습 루프의 일부가 되면서, 산업의 핵심 경쟁력은 단순히 자본 설비의 성능이 아니라 AI모델과 수집 데이터 사이 환류의 규모와 질에 의해 결정될 수 있다. 이는 산업 현장에서 더 많은 데이터를 수집하도록 만드는 강력한 유인이 되며, 수집된 데이터를 처리하고 AI 모델을 학습시키는 데 필요한 연산 수요는 지속적으로 증가할 수밖에 없을 것이다.

— 김철현 ■ 現 에너지경제연구원 선임연구위원 —

〈주요저서 및 논문〉

에너지원단위를 이용한 국가에너지효율지표 개발 및 분석. 에너지경제연구원 기본연구. 2022.
극치이론을 활용한 최대전력 수요의 확률 분석. 에너지경제연구원 기본연구. 2019.
박광수 공저. 저소득층 자원을 위한 가정용 냉난방 에너지 소비행태 분석. 에너지경제연구원 기본연구. 2019.
박광수 공저. 주요 선진국의 에너지 소비 구조 변화 분석. 에너지경제연구원 기본연구. 2018.
강병욱 공저. 국내 에너지 소비 변화의 요인 분해 분석. 에너지경제연구원 기본연구. 2017.
박광수 공저. 국내 전력 소비 패턴의 구조적 변화 및 변화요인 분석. 에너지경제연구원 기본연구. 2015.

— 김성균 ■ 現 에너지경제연구원 연구위원 —

〈주요저서 및 논문〉

도로 부문 월간 수송용 유류의 저장수요 분석. 에너지경제연구원 기본연구. 2023.
이지웅 공저. 우리나라 적정 사회적 할인율 및 탄소의 사회적 비용 추정. 에너지경제연구원 기본연구. 2015.

기본연구보고서 2025-09

AI 시대 데이터센터 증가의 국내 에너지 소비 시사점

인 쇄 2025년 12월 29일

발 행 2025년 12월 31일

저 자 김 철 현 · 김 성 균

발행인 김 현 제

발행처 에너지경제연구원

주 소 44543 울산광역시 중구 종가로 405-11

연락처 (052)714-2114(대) FAX (052)714-2028

등 록 제 369-4030000251001992000001 호

인 쇄 디자인매일 (051)467-3337

©에너지경제연구원2025

ISBN 978-89-5504-983-1 93320

* 파본은 교환해 드립니다.

값 7,000원



44543 울산광역시 중구 중가로 405-11
TEL : 052-714-2114
www.keei.re.kr

